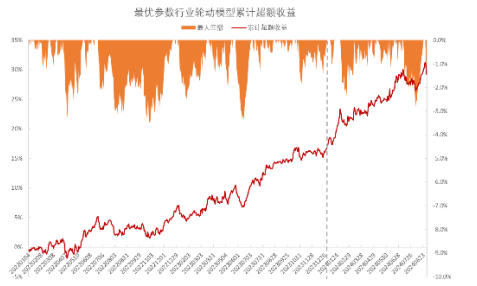
模式识别之状态匹配

——基于隐马尔可夫模型的行业轮动策略

金融工程 | 量化研究专题报告 | 2024.09.12

陈军华
金融工程首席分析师
SAC 执证编号：S0110524010002
chenjunhua@sczq.com.cn
电话：0755-23609495

行业轮动模型累计超额收益及回撤



资料来源：Wind 资讯、首创证券

核心观点

本文以 Leonard E. Baum 等人提出的隐马尔可夫模型（HMM）为理论基础，基于历史会重演的理论假设，在识别当前行业所处状态的基础上，通过计算当前行业所处状态序列与历史中该行业未来出现显著上涨或下跌时所有状态序列的平均相似度，以此预测当前行业未来的上涨概率，进而构建行业轮动策略。

- **隐马尔可夫模型：**隐马尔可夫模型由初始状态概率向量π、状态转移矩阵A和观测概率矩阵B决定。π和A决定状态序列，B决定观测序列。在隐马尔可夫模型中针对观测变量、隐藏状态以及两者之间的关系可以产生三个典型问题：概率计算问题、学习问题、预测问题。
- **样本内收益稳定：**2022 年费后超额收益超过 7%、2023 年费后超额收益超过 9%，最大回撤分别为 3.50%、3.40%。从胜率来看，2022 年胜率为 66.67%，而 2023 年胜率更是高达 91.67%，全年 12 个月份，只有一个月跑输 30 个中信一级行业平均收益；2022 年和 2023 年的超额收益年化波动均低于 6%，表现不错。
- **样本外收益持续：**从 2024 年前 8 个月的超额收益来看，费后累计超额收益为 10.75%，年化超额收益为 16.54%，显著高于样本内。样本外最大回撤仅为 2.8%，比样本内低接近 1%；同时样本外的月盈亏比为 1.91，该数据也显著优于样本内。
- **样本外 Top 行业实际收益排名靠前：**2024 年前 8 个月中有 5 个月的平均名次在前 15.5 名以内，其中 1 月以及 6 月的平均名次更是位于前 10 名。此外前 8 个月中第 1 名出现 4 次，前 3 名共计出现 8 次，前 5 名共计出现 13 次，前 10 名共计出现 20 次，前 15 名则共计出现 28 次，相对于总样本数量占比 58%，接近五分之三。
- **2024 年 9 月份 Top 行业：**基于隐马尔可夫算法行业轮动模型所选择的 Top 行业为**石油石化、煤炭、家电、非银行金融、通信以及综合金融**等六个行业。
- **风险提示：**报告中所涉及测算均基于历史数据，未来市场可能发生变化，历史会惊人相似，但并不会简单重复；由于金融市场数据不一定完全服从正态分布，可能影响隐马尔可夫模型的准确性，进而对当前行业所处状态做出误判，不利于模型对行业未来上涨概率进行预测，最终影响行业轮动模型效果。

目录

1 前言 1
2 时间序列建模方法概述 1
2.1 其他时间序列模型——GARCH 模型 1
2.2 隐马尔可夫模型原理 2
2.3 隐马尔可夫模型示例 3
3 基于隐马尔可夫模型行业轮动策略回测框架 5
3.1 样本区间选择 5
3.2 模型回测逻辑及框架 5
3.3 模型回测逻辑的几点思考 6
3.3.1 形态特征代理变量的选择 6
3.3.2 特征的标准化 7
3.3.3 上行、下行形态的划分 8
3.3.4 状态序列相似度计算采样窗口长度 8
3.3.5 状态序列相似度计算逻辑 8
4 基于隐马尔可夫算法行业轮动模型回测表现 9
4.1 样本内回测 9
4.1.1 模型参数选择 9
4.1.2 优选参数下样本内表现 13
4.2 样本外检验 15
5 总结和展望 19
5.1 本文总结 19
5.2 未来展望 19
6 风险提示 20

插图目录

图 1 收盘价概率分布图 6
图 2 收益率概率分布图 6
图 3 波动率概率分布图 7
图 4 波动率差分概率分布图 7
图 5 换手率概率分布图 7
图 6 换手率差分概率分布图 7
图 7 样本内最优参数下行业轮动模型累计超额收益 12
图 8 样本内分组超额收益 13
图 9 历史区间 3.5%涨跌阈值下样本内显著上涨、下跌平均样本数 14
图 10 行业轮动模型累计超额收益及最大回撤 16
图 11 样本外月度 IC 统计 16
图 12 样本外月度超额收益 16
图 13 样本外 Top 行业下月收益位于全行业平均名次 18
图 14 样本外 Top 行业下月收益位于全行业各名次出现次数 18
图 15 样本外 Top 行业月度换手率 18

表格目录

表 1 各个鱼缸两种颜色鱼的数量 3
表 2 样本内不同涨跌阈值、不同观察窗口长度下模型累计超额收益 9
表 3 样本内不同涨跌阈值、不同观察窗口长度下模型超额收益最大回撤 10
表 4 样本内不同涨跌阈值、不同观察窗口长度下模型超额收益年化波动率 10
表 5 样本内不同涨跌阈值、不同观察窗口长度下模型超额收益月度胜率 11
表 6 样本内不同涨跌阈值、不同观察窗口长度下模型超额收益月盈亏比 11
表 7 样本内不同涨跌阈值、不同观察窗口长度下模型超额收益信息比率 12
表 8 样本内月度超额收益 15
表 9 样本外超额收益统计 15
表 10 样本外月度优选行业及其下月收益排名 17

本文在中信一级行业指数量价数据的基础上，基于隐马尔可夫模型（HMM）识别当前行业所处的状态，进而通过对观察窗口与历史窗口状态匹配的方式预测行业未来的上涨概率，进而构建行业轮动策略。

1 前言

序列数据是指在某一种维度下，按先后顺序采集，数据采样点之间不能前后交换的数据序列。时间序列数据是一种经典的序列数据，例如：语音数据、金融数据等都是时间序列数据。而时间序列建模是会对序列中的每个元素进行建模和预测，并构建一个从输入/观测序列到输出/标记序列的映射过程。在自然语言处理中，序列建模通常用于语言生成、机器翻译、语音识别等领域。

趋势跟踪作为技术分析方法的一种延伸，其核心理念为：市场历史价格在一定程度上反映了所有已知信息，而这些已知信息往往会驱动股票价格沿着特定的方向持续运动，即形成所谓的“趋势”或“状态”。

由此可以想到，使用时间序列建模方法对信噪比较低的金融数据进行抽丝剥茧，识别价格变化的趋势或者当前价格所处的状态，可能会更好地剥离原始数据噪声，提高数据的信噪比，进而提升模型的预测能力。

本文比较不同金融领域时间序列建模方法的优劣，最终通过 Leonard E. Baum 等人提出的隐马尔可夫模型（HMM），识别行业指数当前所处的状态，基于历史会重演的理论假设，预测当前行业未来的上涨概率，最终构建行业轮动策略。

2 时间序列建模方法概述

股票价格时间序列和其他金融时间序列都具有相似的特点，例如：强波动性、非平稳性和潜在周期性等。统计学上有多种金融时间序列数据建模的方法。比较著名的有：随机游走理论（RW），差分自回归移动平均模型（ARIMA）和广义自回归条件异方差模型（GARCH）等。

本章简述常见的时间序列建模方法，并此类方法在应用上的不足之处。

2.1 其他时间序列模型——GARCH 模型

GARCH 模型作为 ARCH 模型的重要扩展，由学者 Bollerslev 在 1986 年提出。GARCH 模型的基本原理在于通过引入条件异方差来描述时间序列数据的波动性特征。它假设误差项的方差遵循自回归移动平均过程，从而能够预测未来的波动率。GARCH 模型通常由两部分组成：均值方程和方差方程。均值方程用于描述时间序列数据的线性关系，而方差方程则是 GARCH 模型的核心，用于描述时间序列数据的波动性。

对于序列 y_t，令 $\varepsilon_t = y_t - \mu_t$，其中 μ_t 是 y_t 的平均值。如果 ε_t 满足下述条件，则称 ε_t 服从 GARCH(p,q)模型：

$$\varepsilon_t = \sigma_t z_t$$

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^{p} \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^{q} \beta_j \sigma_{t-j}^2$$

其中 z_t 为零均值单位方差的独立同分布白噪声序列。同时考虑到模型的稳定性以及使得 σ_t 为正，模型假定：

$$\alpha_0 > 0$$

$$\alpha_i >= 0$$

$$\beta_j >= 0$$

$$0 < \sum_{i=1}^{p} \alpha_i + \sum_{j=1}^{q} \beta_j < 1$$

其中，σ_t^2 为 t 时刻的条件方差，ε_t 为 t 时刻的残差项，α_0 是常数项，α_i 和 β_j 是模型的参数。q 和 p 分别表示方差方程中自回归项和移动平均项的阶数。

GARCH 模型的不足

尽管 GARCH 模型可以较好处理随时间变化的条件方差，但是该模型对参数估计要求较高，对数据质量亦要求较高，模型复杂度较大。此外该模型也无法解释市场在于利好上行、利空下行这两种状态下波动的非对称性。

2.2 隐马尔可夫模型原理

20 世纪 60 年代后半期，Leonard E. Baum 和其他 GARCH(p,q)学者在一系列的统计学论文中提出隐马尔可夫模型。后续在 20 世纪 70 年代中期，该模型最初应用于语音识别领域。

隐马尔可夫过程是由一个隐藏的马尔可夫链随机生成不可观测的状态序列，再由各个状态生成一个观测值，进而产生观测值随机序列的过程。序列每一个位置可以看作是一个时刻。该模型由初始概率分布、状态转移概率分布以及观测概率分布确定。模型定义如下：

设 Q 是所有可能状态的集合，V 是所有可能观测的集合：

$$Q = \{q_1, q_2, \cdots\cdots, q_N\},$$

$$V = \{v_1, v_2, \cdots\cdots, v_M\},$$

其中 N 是可能的状态数，M 是可能的观测数。

设 S 是长度为 T 的状态序列，O 是对应的观测序列：

$$S = [s_1, s_2, \cdots\cdots, s_T]$$

$$O = [o_1, o_2, \cdots\cdots, o_T]$$

状态转移概率矩阵 A 为：

$$A = [a_{i,j}]_{N \times N}$$

其中 $a_{i,j} = P(s_{t+1} = q_j \mid s_t = q_i), i = 1, 2, \cdots, N;\ j = 1, 2, \cdots, N$，表示在时刻$t$处于状态 q_i 的条件下，在时刻$t+1$ 转移到状态 q_j 的概率。

观测概率矩阵 B 为：

$$B = [b_{j,k}]_{N \times M}$$

其中 $b_{j,k} = P(o_t = v_k \mid s_t = q_i), k = 1, 2, \cdots, M;\ j = 1, 2, \cdots, N$，表示在时刻 t 处于

状态 q_i 的条件下生成观测 v_k 的概率。

初始状态概率向量π为：

$$\pi = [\pi_i]$$

其中，$\pi_i = P(s_1 = q_i), i = 1, 2, \cdots, N$，表示时刻$t = 1$处于状态$q_i$的概率。

隐马尔可夫模型由初始状态概率向量π、状态转移矩阵A和观测概率矩阵B决定。π和A决定状态序列，B决定观测序列。因此隐马尔可夫模型λ可以用三元符号表示即：

$$\lambda = (A, B, \pi)$$

其中，A、B和π称为隐马尔可夫模型的三要素。在隐马尔可夫模型中针对观测变量、隐藏状态以及两者之间的关系可以产生三个典型问题：

（1）概率计算问题。给定模型$\lambda = (A, B, \pi)$和观测序列$O = [o_1, o_2, \cdots\cdots, o_T]$，计算在模型$\lambda$下观测序列$O$出现的概率$P(O|\lambda)$。

（2）学习问题。已知观测序列$O = [o_1, o_2, \cdots\cdots, o_T]$，估计$\lambda = (A, B, \pi)$参数，使得在该模型下的观测序列概率$P(O|\lambda)$最大。即用极大似然估计模型。

（3）预测问题，也称为解码问题。已知模型$\lambda = (A, B, \pi)$和观测序列$O = [o_1, o_2, \cdots\cdots, o_T]$，求对给定观测序列条件概率$P(S|\lambda)$最大的状态序列$S = [s_1, s_2, \cdots\cdots, s_T]$，即给定观测序列，求最有可能对应的状态序列。

2.3 隐马尔可夫模型示例

本节以一个形象的例子，详细描述如何将现实中的问题转换为标准的隐马尔可夫模型。

现有 4 个鱼缸（如表 1 所示），每个鱼缸里都装有红、黑两种颜色的鱼，各个鱼缸中两种颜色鱼的数量见表 1。按照下述规则选择 5 次鱼缸，每次都从选择的鱼缸中随机抽出 1 条鱼，记录颜色后将其放回。

表 1 各个鱼缸两种颜色鱼的数量

	鱼缸 1	鱼缸 2	鱼缸 3	鱼缸 4
红鱼数	2	5	3	8
黑鱼数	8	5	7	2

资料来源：首创证券

第 1 次：从 4 个鱼缸中随机选取 1 个鱼缸；

剩余 4 次的规则如下：

若上一次选择的是鱼缸 1，那这次以 50%的概率选择鱼缸 2、以 50%的概率选择鱼缸 4；

若上一次选择的是鱼缸 2，那这次以 10%的概率选择鱼缸 1、以 90%的概率选择鱼缸 3；

若上一次选择的是鱼缸 3，那这次以 30%的概率选择鱼缸 2、以 70%的概率选择鱼

缸 4；

若上一次选择的是鱼缸 4，那这次以 50%的概率依然选择鱼缸 4、以 50%的概率选择鱼缸 3；

经过上述 5 次操作，可以得到一个鱼的颜色序列：[红，红，黑，黑，红]。

在上述过程中，外部观察者只能观测到所抽取鱼的颜色序列，即为观测序列；无法得知鱼是从哪个鱼缸取出，观测不到鱼缸序列，即为状态序列。状态序列每个状态的取值仅取决于上一个时刻状态（见前文抽 5 次鱼规则的描述），与其他状态无关。

上述问题可以转换为如下隐马尔可夫模型：

选择的鱼缸对应隐藏状态，即状态集合为：Q={鱼缸 1，鱼缸 2，鱼缸 3，鱼缸 4}。状态集合表述的是“所有可能状态的集合”；状态序列表述的是“实际操作中产生的状态序列”。因状态序列无法观测，在定义中其表示为：$S=[s_1,s_2,\cdots\cdots,s_T]$。

所抽取鱼的颜色对应观测，即观测集合为：V={红，黑}。观测集合表述的是“所有可能观测的集合”；观测序列表述的是“实际操作中产生的观测序列”，在定义中其表示为：$O=[o_1,o_2,\cdots\cdots,o_T]$。上述示例中观测序列是：O=[红，红，黑，黑，红]。

由于共计抽取 5 次，状态序列和观测序列的长度 T=5。第一次抽样称之为时刻 1，后续以此类推，因第一次选择鱼缸时为随机抽取，初始状态概率分布为：

$$\pi = [0.25,0.25,0.25,0.25]$$

状态转移概率分布矩阵为：

$$A=\begin{bmatrix} 0.0 & 0.5 & 0.0 & 0.5 \\ 0.1 & 0.0 & 0.9 & 0.0 \\ 0.0 & 0.3 & 0.0 & 0.7 \\ 0.0 & 0.0 & 0.4 & 0.6 \end{bmatrix}$$

例如：$a_{2,3}=0.9$，表示：时刻 t 选择的鱼缸 2(q_2)时，时刻 t+1 选择鱼缸 3(q_3)的概率是 0.9。

观测概率分布矩阵为：

$$B=\begin{bmatrix} 0.2 & 0.8 \\ 0.5 & 0.5 \\ 0.3 & 0.7 \\ 0.8 & 0.2 \end{bmatrix}$$

例如：$b_{3,1}=0.3$，表示：时刻 t 处于鱼缸 3(q_3)状态时，选择红鱼(v_1)的概率是 0.3。

3 基于隐马尔可夫模型行业轮动策略回测框架

本章基于前文提到的隐马尔可夫模型，以中信一级行业指数为例，基于技术分析常见的历史会重演的理论假设，在识别当前行业所处状态的基础上，通过计算当前行业所处状态序列与历史中该行业未来出现显著上涨或下跌时所有状态序列的平均相似度，以此预测当前行业未来的上涨概率，进而构建行业轮动策略。

3.1 样本区间选择

本节以 30 个中信一级行业指数为例，选取 2018 年 1 月至 2024 年 8 月的量价数据为样本区间，分别在样本内回测、样本外检验基于隐马尔可夫模型状态匹配的行业轮动策略效果。

历史状态序列采样区间：2018 年 1 月初至计算当月，即固定起点的滚动时间窗口。

样本内区间：2022 年 1 月至 2023 年 12 月，共计 24 个月。

样本外区间：2024 年 1 月至 2024 年 8 月，共计 8 个月。

3.2 模型回测逻辑及框架

本节详细介绍基于隐马尔可夫模型状态匹配的行业轮动策略回测框架。模型回测的再平衡周期之所以设置为月度，主要是考虑到行业轮动模型其本质为资产配置策略，因此其持有周期不宜过短，年化换手率不宜过高。其详细步骤如下：

1、**对所有月份 i、行业 j 进行遍历**。

2、**定义训练模型特征矩阵：**基于当前行业 j 行情数据，选取该行业从 2018 年 1 月初至当前月份 i 上一个月（不包含当前月，即 i-1 月）量价数据，生成 M*5 特征矩阵用作训练数据。其中 M 为所训练数据的总天数，即 2018 年 1 月初到月份 i-1 月末所有交易日天数；5 列为所选择作为该行业当前特征的 5 个代理变量，分别为：日收益率、日换手率、日波动率、日波动率变化、日换手率变化。

3、**定义当前月特征矩阵：**利用同样方法，选取当前行业 j 月份 i 的行情数据，生成 N*5 特征矩阵，其中 N 为月份 i 所有交易日天数。

4、**生成状态序列：**基于步骤二得到的特征矩阵训练 HMM 模型，可得到训练样本所对应的状态序列；并将步骤三得到的当前月份 i 特征矩阵，输入训练所得到的 HMM 模型中，生成当前月份 i 每一个交易日的状态序列。

5、**历史样本分类：**从 2018 年 1 月初至当前月份 i 的上一个月，对当前行业 j 的状态序列，按照滚动 K 个交易日的方式滚动采样，计算每一段长度为 K 的子窗口（待比较窗口，下同）其未来一个月收益，并将所有子窗口（样本）按照其未来收益率的大小划分为显著上涨、显著下跌两类。

6、**计算相似度平均值：**计算当前行业 j 当前月份 i 最后 K 个交易日（观察窗口，下同）的状态序列分别与历史上该行业显著上涨、显著下跌子窗口状态序列的相似度平均值。

7、**定义行业未来上涨概率：**当前行业 j 未来上涨的概率为：

$$\frac{S_{Up}}{S_{Up}+S_{Dn}}$$

其中 S_{Dn} 为当前行业 j 观察窗口的状态序列与历史上所有显著下跌子窗口状态序列的相似度平均值；S_{Up} 为当前行业 j 观察窗口的状态序列与历史上所有显

著上涨子窗口状态序列的相似度平均值。

8、 **行业优选配置：**选择截面上当前月份 i 预测上涨概率较高的前五分之一行业（六个）等权配置，并计算 Top 行业相对于所有行业平均收益的超额收益。

9、 **样本内参数选择：**根据样本内 2022 年 1 月至 2023 年 12 月行业轮动模型的信息系数、累计超额收益、月度胜率、超额收益最大回撤等指标，选择样本内综合表现较好的参数作为模型的最终参数。

本行业轮动模型历史收益回测过程中假设成交价为月初第一天行业指数的开盘价，交易费用为双边 0.25%。

3.3 模型回测逻辑的几点思考

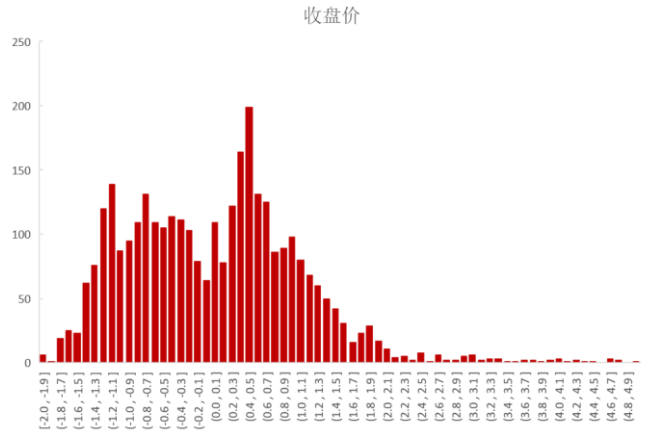
本节详细讨论行业轮动模型搭建过程中需要考虑的部分细节。

3.3.1 形态特征代理变量的选择

特征选择方面，本文在首创金工团队上一篇专题报告《模式识别之形态匹配——基于动态时间弯曲算法的行业轮动策略研究》中所用到特征（收盘价、日收益率、换手率、换手率变化）的基础上，增加 20 日波动率以及 20 日波动率差分两个特征。

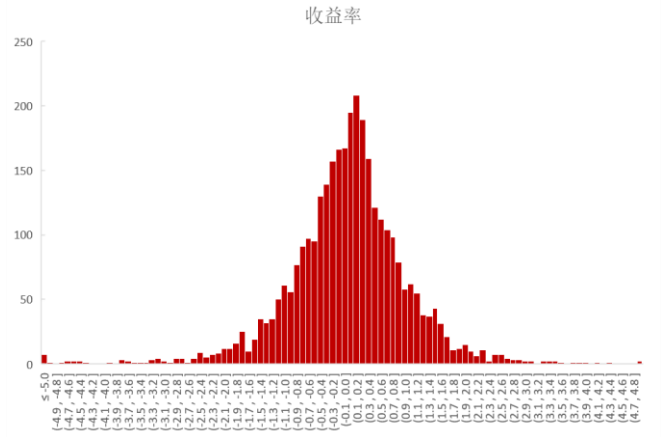
之所以有上述考虑，是因为本文认为不同的波动率水平反映了市场的不同状态。以下行市场为例，高波动率背景下的下跌和低波动率背景下的下跌，这两种状态对未来股价影响会有较大差异。

图 1 收盘价概率分布图



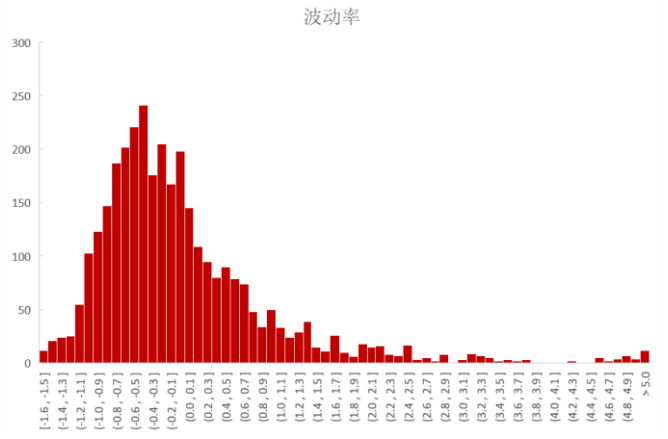
资料来源：万得资讯，首创证券

图 2 收益率概率分布图



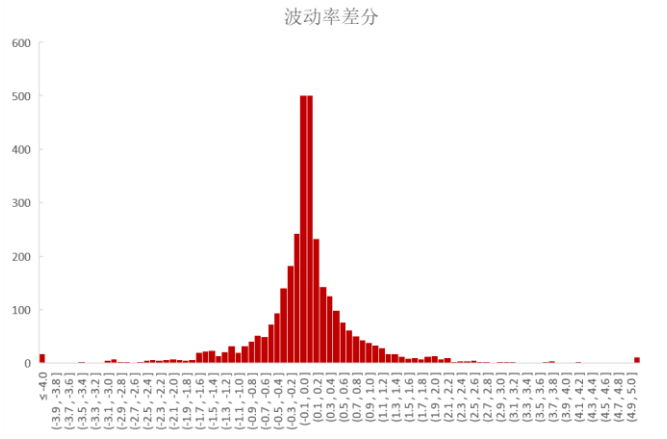
资料来源：万得资讯，首创证券

图 3 波动率概率分布图



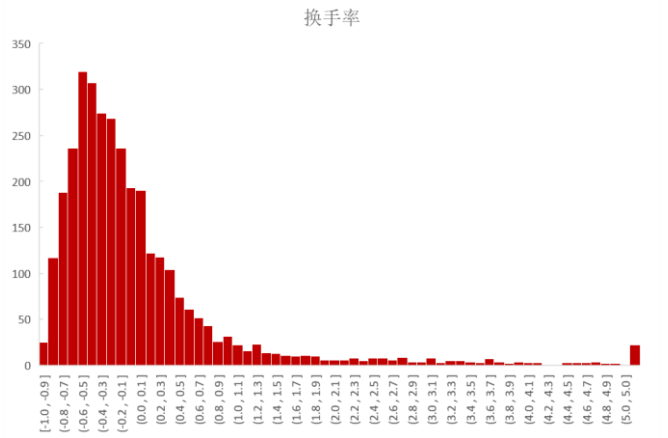
资料来源：万得资讯，首创证券

图 4 波动率差分概率分布图



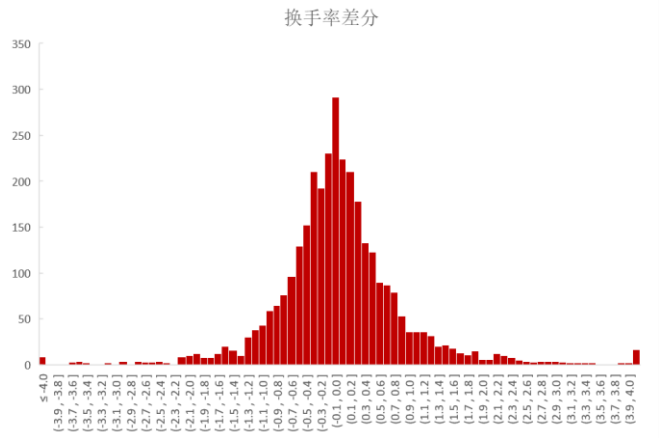
资料来源：万得资讯，首创证券

图 5 换手率概率分布图



资料来源：万得资讯，首创证券

图 6 换手率差分概率分布图



资料来源：万得资讯，首创证券

图 1 至图 6 展示前文提到的 6 个特征因子的概率分布图，从图 1 中可以看出收盘价的概率分布图中有两个波峰，属于混合正态分布。为了降低模型的复杂度，本策略剔除收盘价因子，最终选择组成特征矩阵的 5 个因子为：日收益率、20 日波动率、20 日波动率差分、日换手率以及日换手率差分。

3.3.2 特征的标准化

鉴于本文需要对多维特征训练隐马尔可夫模型，考虑到不同特征之间数量级有较大差异，因此各个特征纳入模型训练之前，需要先将其标准化，否则将会无形中放大数量级较大的特征的权重。本文选择的方法为常见的 Z-Score 标准化方法，其计算公式如下：

$$X' = \frac{X - Mean(X)}{Std(X)}$$

其中 $Mean(X)$ 为 X 的均值；$Std(X)$ 为 X 的标准差。

此外需要注意的是，隐马尔可夫模型解决的是时间序列建模问题，若对用于训练模型、预测状态的特征矩阵分别用其自身的均值和标准差做 Z-Score 标准化，则在时间序列上，每个特征因子标准化后的 Scale 前后不一致，可能直接导致预测的状态序列失真。

因此本文在对训练的特征矩阵、预测的特征矩阵做标准化时，均选择训练模型特征矩阵的均值和标准差对上述两个矩阵的数据做 Z-Score 标准化。

3.3.3 上行、下行形态的划分

本文通过计算当前行业观察窗口的状态序列分别与历史上该行业所有显著上涨、显著下跌子窗口状态序列相似度平均数的方式，预测当前行业未来的上涨概率，因此显著上涨、显著下跌的认定标准（阈值）将十分重要。

若该阈值选择过小，会引入该行业下月收益波动不显著的样本，无形中加入噪声，影响模型效果；若该阈值选择过大，则会剔除该行业过多有效样本，使得结果受个别样本影响较大，不具有统计特性。综合考虑上述因素，本文所选行业显著上涨、显著下跌的阈值为：{2.0%、2.5%、3.0%、3.5%、4.0%、4.5%、5%、5.5%、6%}。

3.3.4 状态序列相似度计算采样窗口长度

众所周知，离当前月最后一个交易日越近的状态序列，越能反映最近的交易特征，越能更好地对未来进行预测。

但如果状态序列观察窗口时间长度 K 较小，例如只选取当前月最后两天的状态序列作为观察窗口计算相似度，则容易出现与大多数待比较窗口状态相似度都为 0 的情况；如果长度 K 较大，例如选取当前月的全部交易日作为观察窗口计算相似度，则会过多地增加较早的信息，影响预测的准确性。综上考虑，本文选取{5，10，15，20}作为观察窗口时间长度 K 的取值范围。

3.3.5 状态序列相似度计算逻辑

由状态的定义可知状态序列为离散序列，而离散的序列无法通过相关系数或者欧式距离的方式计算相似度。常见的离散序列相似度计算方法为：若两个序列相同时刻的状态相同则记为 1，否则记为 0。

考虑到完全匹配的要求过高，即相同位置上状态相同情况较少，出现概率较低。本文适当放宽对相似度的匹配要求，若时间上相邻位置上的状态相同即视作模糊匹配，记为 0.5。本文对状态序列相似度的定义如下：

$$S_i=\begin{cases}1.0 & if \quad W_i^{Now}=W_i^{Past}\\ 0.5 & if \quad W_i^{Now}=W_{i-1}^{Past} \ \ or \ \ W_i^{Now}=W_{i+1}^{Past}\\ 0 & \text{otherwise}\end{cases}$$

其中 W_i^{Now} 为观察窗口状态序列中第 i 个交易日的状态，W_i^{Past} 为待比较窗口状态序列中第 i 个交易日的状态，S_i 表示两个状态序列第 i 个交易日的相似度。基于上述定义，两个状态序列整体的相似度为：

$$S=\sum_{i=1}^{K}S_i$$

4 基于隐马尔可夫算法行业轮动模型回测表现

本章基于前文提到的隐马尔可夫算法预测当前行业所处的状态，通过计算当前行业所属状态序列与历史中该行业未来出现所有显著上涨或显著下跌时所有状态序列的平均相似度，预测行业未来上涨概率，进而构建基于隐马尔可夫模型的行业轮动策略，同时评估样本外模型效果。

4.1 样本内回测

正如前文所提到的，历史形态选择区间为 2018 年 1 月初至计算当月。收益回测样本内区间为 2022 年 1 月至 2023 年 12 月，本节在上述区间内优选模型综合表现较好的参数作为模型最终参数。

4.1.1 模型参数选择

为避免过度优化，本模型只有两个待定参数：行业显著上涨、显著下跌阈值以及观察窗口长度。表 2 至表 7 展示不同涨跌阈值和观察窗口长度下，样本内行业轮动模型累计超额收益，最大回撤，年化波动率表现、月度胜率、月盈亏比、信息比率。这里提到的超额收益业绩比较基准为所有行业同期平均收益。从表 2 至表 7 中可以看出：

沿横轴的方向，随着窗口长度的增大，累计超额收益呈向下的趋势。这个结果侧面验证了前文的假定：如果选取的采样窗口较长，则会过多增加更早的信息，影响预测的准确性。

沿纵轴的方向，在观察窗口长度为 5 的情况下，随着涨跌阈值的增大，行业轮动模型的累计超额收益、月度胜率和信息比率都呈现先扬后抑的趋势。这方面也验证了本文前期假设：阈值过小，会引入不显著的样本，影响模型效果；而阈值过大，则会剔除过多有效样本，使得结果受个别样本影响较大；

表 2 样本内不同涨跌阈值、不同观察窗口长度下模型累计超额收益

	累计超额收益			
	5	10	15	20
2.0%	3.0%	-2.0%	1.4%	-4.0%
2.5%	3.4%	-0.8%	2.8%	-4.2%
3.0%	8.9%	2.3%	2.9%	-4.6%
3.5%	16.7%	2.9%	2.0%	-2.7%
4.0%	4.6%	5.7%	-0.8%	-0.8%
4.5%	4.4%	-0.9%	0.1%	-1.0%
5.0%	2.7%	-6.5%	-3.3%	-1.0%
5.5%	2.5%	-5.2%	-2.3%	1.1%
6.0%	1.5%	-6.0%	-7.5%	-2.5%

资料来源：万得资讯，首创证券

表 3 样本内不同涨跌阈值、不同观察窗口长度下模型超额收益最大回撤

	最大回撤			
	5	10	15	20
2.0%	-6.5%	-9.1%	-7.4%	-9.4%
2.5%	-5.4%	-7.9%	-6.4%	-10.1%
3.0%	-5.2%	-8.2%	-6.3%	-10.1%
3.5%	-3.5%	-6.1%	-5.5%	-7.2%
4.0%	-5.9%	-6.5%	-6.3%	-6.9%
4.5%	-5.8%	-7.3%	-6.1%	-6.4%
5.0%	-6.3%	-10.5%	-7.8%	-7.0%
5.5%	-4.4%	-10.7%	-6.7%	-7.0%
6.0%	-5.7%	-11.4%	-12.2%	-7.7%

资料来源：万得资讯，首创证券

表 4 样本内不同涨跌阈值、不同观察窗口长度下模型超额收益年化波动率

	年化波动			
	5	10	15	20
2.0%	5.5%	6.0%	6.4%	6.0%
2.5%	5.8%	6.1%	6.3%	6.3%
3.0%	5.8%	6.2%	6.3%	6.2%
3.5%	5.6%	6.2%	5.9%	6.2%
4.0%	5.7%	6.3%	6.3%	6.1%
4.5%	5.4%	5.8%	5.7%	6.1%
5.0%	5.2%	5.7%	5.7%	6.1%
5.5%	5.3%	5.8%	5.9%	6.0%
6.0%	5.8%	5.8%	5.9%	6.0%

资料来源：万得资讯，首创证券

表 5 样本内不同涨跌阈值、不同观察窗口长度下模型超额收益月度胜率

	月度胜率			
	5	10	15	20
2.0%	67%	50%	54%	54%
2.5%	71%	58%	63%	54%
3.0%	71%	63%	58%	58%
3.5%	79%	71%	58%	63%
4.0%	63%	67%	58%	67%
4.5%	58%	58%	50%	58%
5.0%	63%	46%	50%	67%
5.5%	54%	50%	58%	71%
6.0%	50%	50%	54%	58%

资料来源：万得资讯，首创证券

表 6 样本内不同涨跌阈值、不同观察窗口长度下模型超额收益月盈亏比

	月盈亏比			
	5	10	15	20
2.0%	0.68	0.86	0.95	0.67
2.5%	0.55	0.67	0.76	0.66
3.0%	0.87	0.73	0.89	0.53
3.5%	1.13	0.53	0.85	0.50
4.0%	0.82	0.83	0.69	0.49
4.5%	1.03	0.65	1.03	0.69
5.0%	0.75	0.69	0.78	0.48
5.5%	1.07	0.65	0.60	0.45
6.0%	1.15	0.56	0.47	0.62

资料来源：万得资讯，首创证券

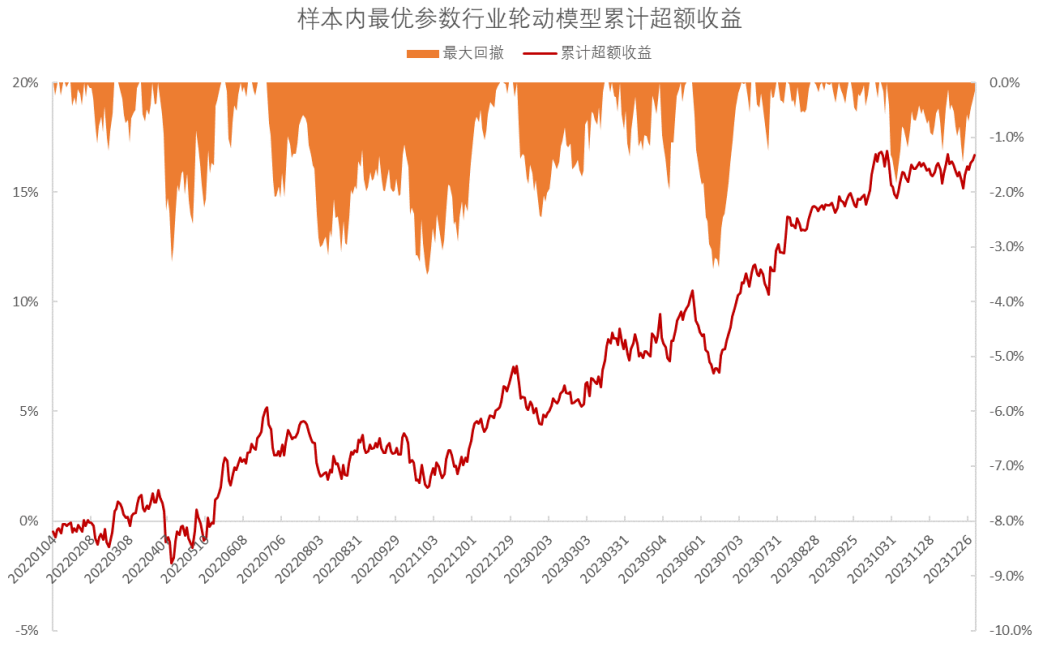
表 7 样本内不同涨跌阈值、不同观察窗口长度下模型超额收益信息比率

	信息比率			
	5	10	15	20
2.0%	0.29	-0.14	0.14	-0.31
2.5%	0.31	-0.04	0.25	-0.31
3.0%	0.76	0.21	0.26	-0.35
3.5%	1.40	0.27	0.20	-0.19
4.0%	0.42	0.48	-0.03	-0.03
4.5%	0.43	-0.05	0.04	-0.06
5.0%	0.28	-0.57	-0.26	-0.05
5.5%	0.26	-0.43	-0.17	0.12
6.0%	0.16	-0.51	-0.62	-0.18

资料来源：万得资讯，首创证券

就基于隐马尔可夫算法行业轮动模型的最优参数而言，3.5%涨跌阈值、观察窗口长度为 5 的情况下，样本内行业轮动模型表现不错，费后累计超额收益 16.7%，超额收益最大回撤为 3.50%，月度胜率高达 79%。月度胜率在实际投资工作中十分重要，能大大减轻来自业绩方面的压力，也有利于增强投资者对模型的信心。基于上述方面考虑，本文选择涨跌阈值参数为 3.5%、观察窗口长度参数为 5 作为样本内最优参数。

图 7 样本内最优参数下行业轮动模型累计超额收益



资料来源：万得资讯，首创证券

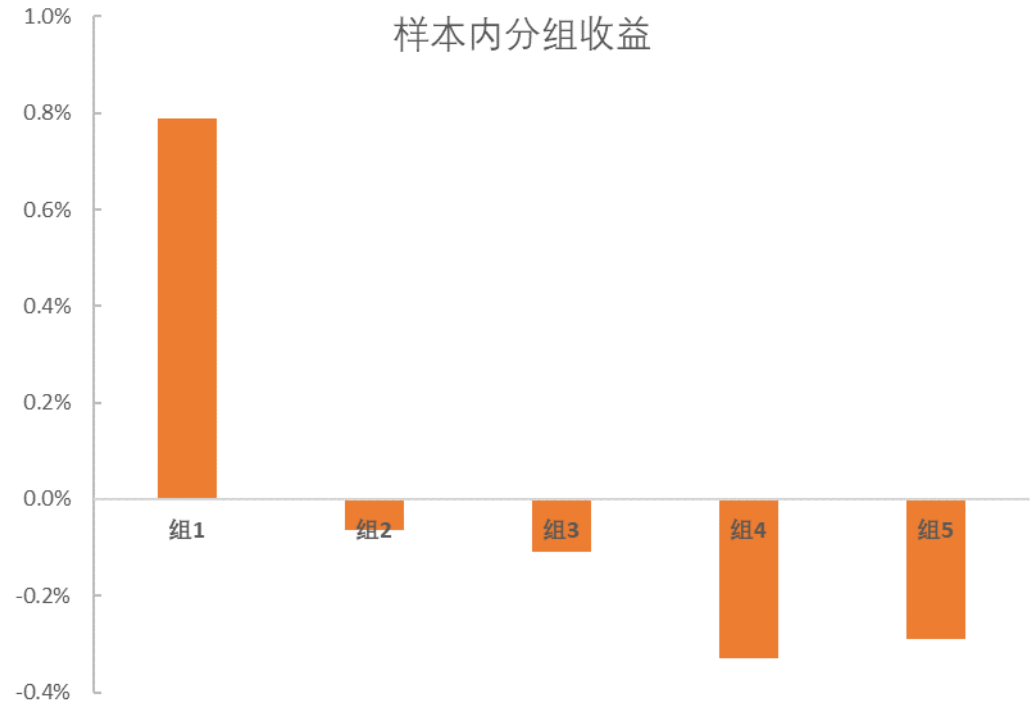
图 7 展示样本最优参数（涨跌阈值及观察窗口长度）下行业轮动模型累计超额收益表现，从图中红色曲线可以看出，3.5%涨跌阈值、观察窗口长度为 5 时模型累计超额收益稳步上行，且最大回撤较为可控。

4.1.2 优选参数下样本内表现

如图 8 所示，组 1 为预测收益较高的行业，组 5 为预测收益较低的行业。

从样本内的分组收益来看，整体上看前四组下月实际收益呈现比较显著的单调性，随着预测收益的下降，实际收益接近单调下行。尽管第 5 组收益略高于第 4 组，打破了单调性，但其收益依然显著低于前 3 组。整体上分组收益单调性较为完美。

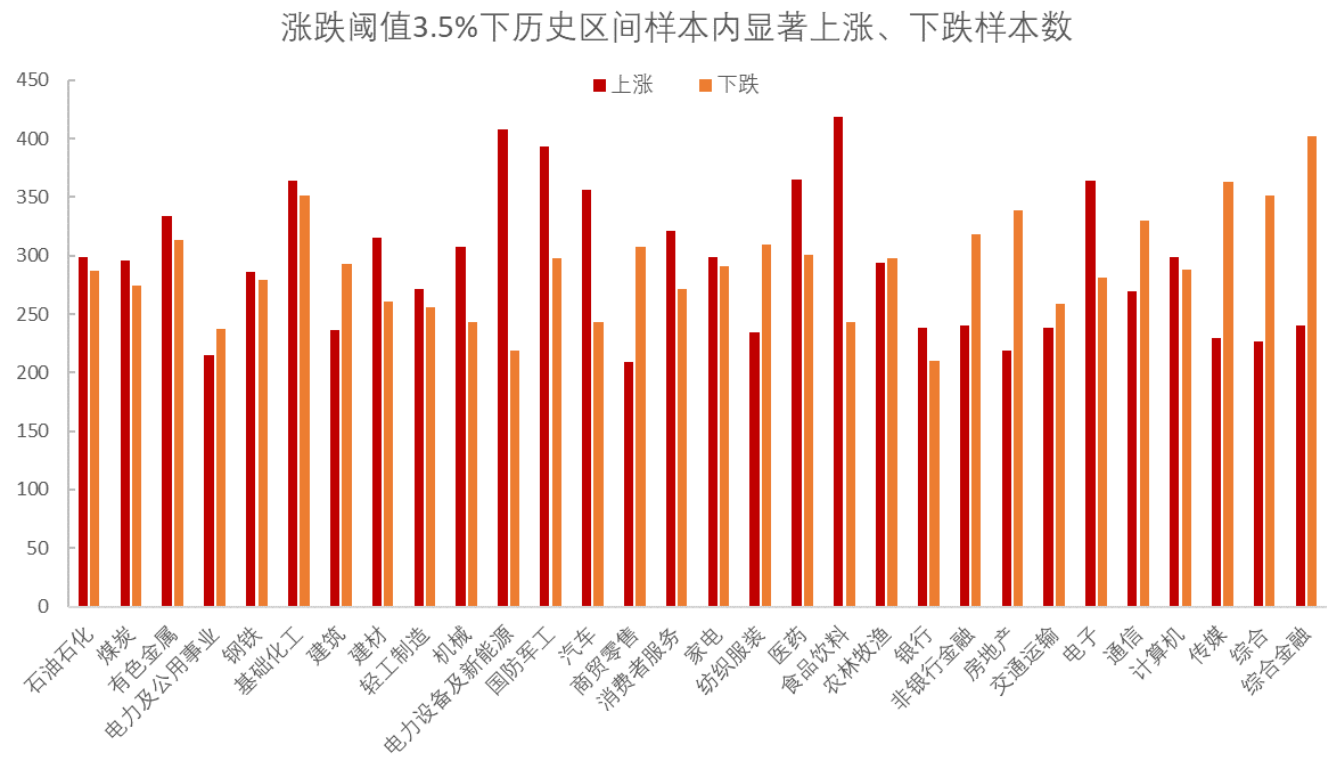
图 8 样本内分组超额收益



资料来源：万得资讯，首创证券

从样本内最优参数下历史区间显著上涨、下跌样本数来看（图 9），所有行业的有效样本数都在 200 以上。普遍来看，食品饮料、电子、电力设备及新能源、国防军工、医药以及汽车等行业，上涨行情的样本数显著多于下跌行情，其上涨行情的有效样本数均超过 250 个。

图 9 历史区间 3.5%涨跌阈值下样本内显著上涨、下跌平均样本数



资料来源：Wind 资讯、首创证券

从样本内行业轮动模型月度超额收益来看(见表 8),2022 年费后超额收益超过 7%、2023 年费后超额收益超过 9%，最大回撤分别为 3.50%、3.40%。从胜率来看，2022 年胜率为 66.67%，而 2023 年胜率更是高达 91.67%，全年 12 个月份，只有一个月跑输 30 个中信一级行业平均收益。

在月度盈亏比方面,2022 年超额收益的盈亏比为 1.76,而 2023 年只有一个月亏损,因此其盈亏比不具有统计性。就超额收益年化波动率而言，2022 年和 2023 年的超额收益年化波动率均低于 6%，表现不错。

表 8 样本内月度超额收益

	2022 年	2023 年
1 月	0.02%	-2.03%
2 月	0.87%	0.35%
3 月	-0.07%	2.88%
4 月	-0.64%	0.11%
5 月	2.27%	0.22%
6 月	0.52%	1.55%
7 月	0.54%	2.12%
8 月	0.13%	1.57%
9 月	-0.64%	0.22%
10 月	-1.39%	0.53%
11 月	2.03%	0.59%
12 月	3.26%	0.66%
累计超额	**7.02%**	**9.03%**
最大回撤	**-3.50%**	**-3.40%**
月度胜率	**66.67%**	**91.67%**
年化波动	**5.91%**	**5.33%**
月盈亏比	**1.76**	**0.48**

资料来源：万得资讯、首创证券

4.2 样本外检验

从样本外 2024 年前 8 个月的超额收益来看(见表 9),费后累计超额收益为 10.75%,年化超额收益为 16.54%，显著高于样本内 2022 年和 2023 年的累计超额收益。

此外虽然样本外的年化波动率略微高于样本内 2022 年和 2023 年的年化波动率，但是样本外最大回撤仅为 2.8%，比样本内低接近 1%；同时样本外的月盈亏比为 1.91，该数据也显著优于样本内。

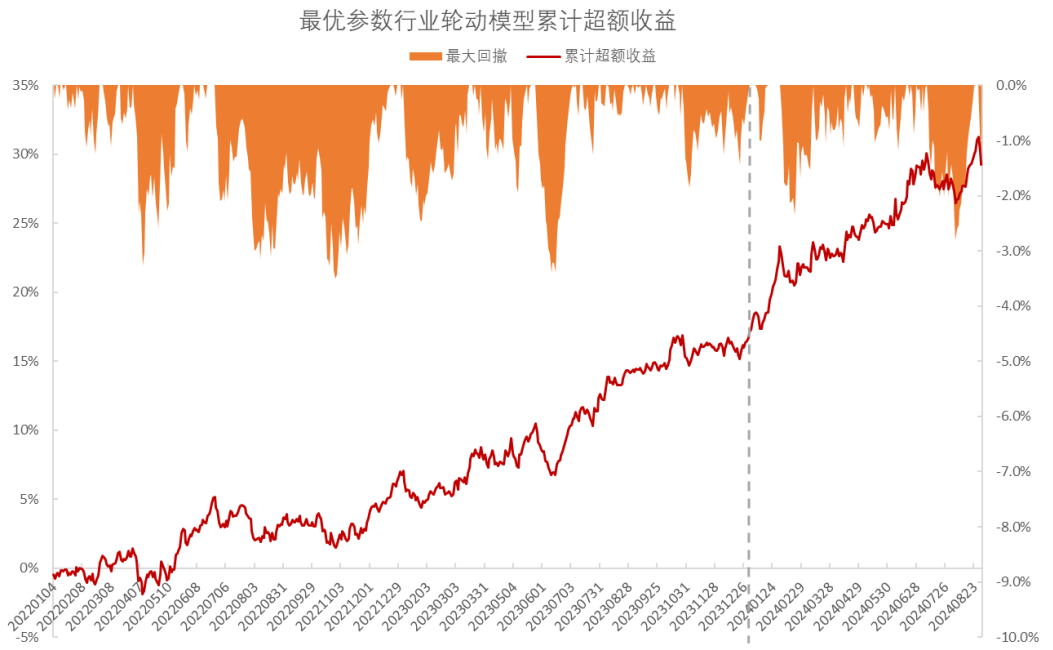
表 9 样本外超额收益统计

	累计超额	最大回撤	月度胜率	年化波动	月盈亏比
2024 年	10.75%	-2.80%	75.00%	6.77%	1.91

资料来源：万得资讯、首创证券

图 10 展示行业轮动模型的累计超额收益(红色曲线)及日频最大回撤(橙色阴影),其中灰色垂直虚线的左侧为样本内、右侧为样本外。从图中可以看出，本模型样本内、样本外的一致性较好,样本外延续了样本内稳定的超额收益,说明模型有较强的鲁棒性,其泛化能力不错。

图 10 行业轮动模型累计超额收益及最大回撤

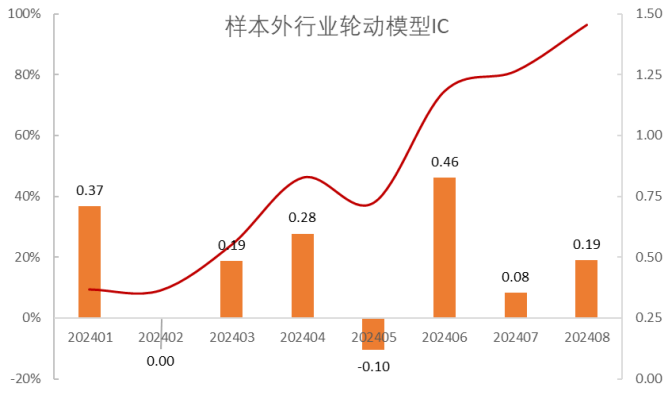


资料来源：万得资讯，首创证券

从样本外的月度 IC 来看（见图 11），2024 年前 8 个月中，只有 1 个月份月度 IC 小于 0。平均而言，前 8 个月的月均 IC 为 18.2%。

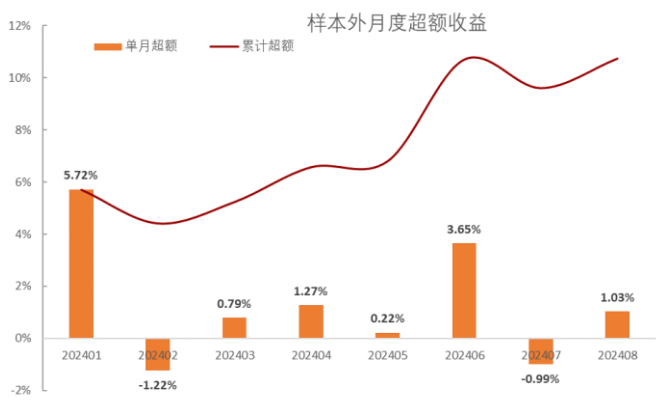
样本外月度超额收益方面（见图 12），2024 年前 8 个月中有 2 个月超额收益为负，分别为 2 月和 7 月，且其亏损幅度不大，收益均为-1%左右。此外在 6 个超额收益均为正的月份中，1 月和 6 月的超额收益超过 3%，其中 1 月份的超额收益更是高达 5.72%。最终样本外 2024 年前 8 个月累计超额收益为 10.75%。

图 11 样本外月度 IC 统计



资料来源：万得资讯，首创证券

图 12 样本外月度超额收益



资料来源：万得资讯，首创证券

从样本外月度所选行业来看（见表 10，橙色阴影表示当前行业被选中，数字表示该行业实际收益排名），前 8 个月 Top 行业主要分布在 17 个行业中，占全行业数量的比例为 57%。此外前 8 个月家电、电力设备及新能源等行业分别入选 6 次、5 次，石油石化、

非银行金融以及通信等行业入选 4 次。而 Top 行业下月收益排名方面，电力及公共事业、食品饮料、银行、非银行金融以及综合金融等行业其入选时下月实际收益位于全行业前 15 名的概率为 100%。

表 10 样本外月度优选行业及其下月收益排名

	202401	202402	202403	202404	202405	202406	202407	202408	202409
石油石化	3					5	28	2	
煤炭	1					9	30		
有色金属									
电力及公用事业				11					
钢铁									
基础化工		11	16					12	
建筑									
建材									
轻工制造									
机械		7		17	18				
电力设备及新能源		9	4	21	10	23			
国防军工									
汽车									
商贸零售		25	15		21				
消费者服务					25				
家电	4	12		1	19	12	21		
纺织服装									
医药									
食品饮料			14						
农林牧渔			11	22	3				
银行						4		6	
非银行金融	8			7			1	4	
房地产									
交通运输									
电子			19						
通信	20					1	23	22	
计算机									
传媒									
综合	19	30						25	
综合金融							3		

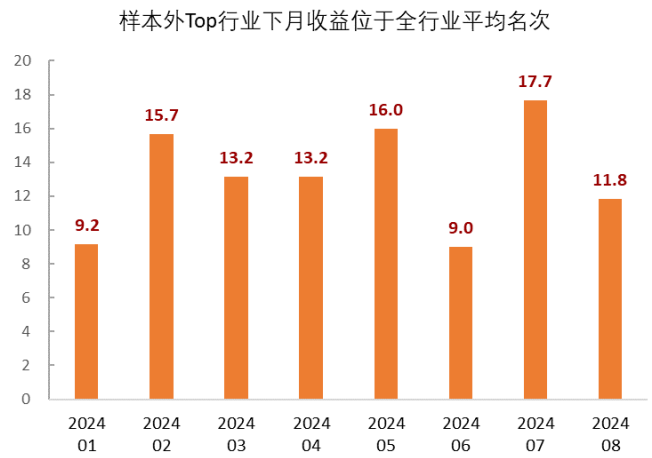
资料来源：万得资讯，首创证券

从样本外 Top 行业下月收益位于全行业的平均名次来看（见图 13），2024 年前 8 个月中有 5 个月的平均名次在前 15.5 名以内，其中 1 月以及 6 月的平均名次更是位于前 10 名。2 月、5 月以及 7 月的平均名次稍弱，但也仅略低于行业中位数，位于 15 至 18

名之间，平均值为 16.4 名。

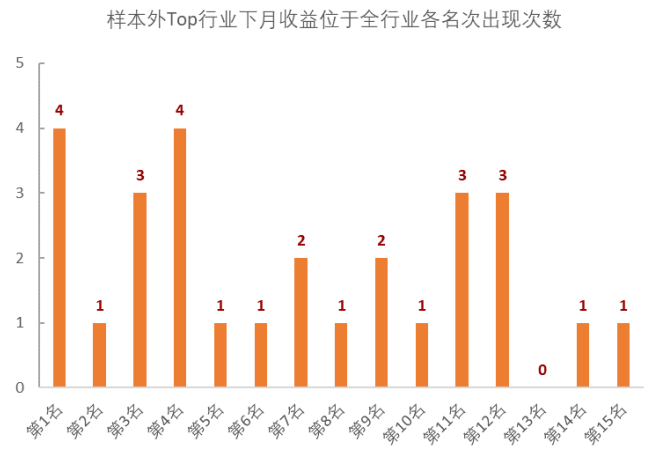
就 2024 年 9 月份而言（见表 10），基于隐马尔可夫算法行业轮动模型所选择的 Top 行业为石油石化、煤炭、家电、非银行金融、通信以及综合金融等六个行业。

图 13 样本外 Top 行业下月收益位于全行业平均名次



资料来源：万得资讯，首创证券

图 14 样本外 Top 行业下月收益位于全行业各名次出现次数

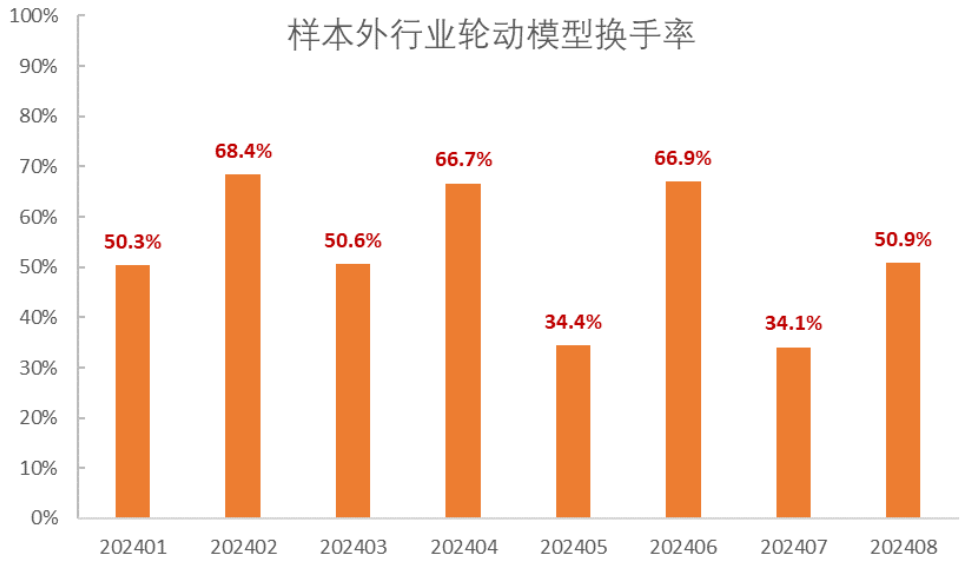


资料来源：万得资讯，首创证券

就样本外 Top 行业下月收益位于全行业不同名次出现的次数而言（每个月优选 6 个行业，前 8 个月共计 48 个样本，结果见图 14），第 1 名出现 4 次，前 3 名共计出现 8 次，前 5 名共计出现 13 次，前 10 名共计出现 20 次。而前 15 名则共计出现 28 次，相对于总样本数量占比 58%，接近五分之三。

从行业月度换手率来看，2024 年前 8 个月平均月度换手率为 53%（见图 15），即平均每个月换手 3 个行业，占持仓行业数量的一半。具体而言，2 月、4 月以及 6 月换手率较高，每月换手 4 个行业；而 5 月、7 月份换手率较低，仅有三分之一的行业换手。虽然本文构建隐马尔可夫模型时只用到量价相关的特征，但整体来看换手率大小适中，相对可控。

图 15 样本外 Top 行业月度换手率



资料来源：万得资讯，首创证券

5 总结和展望

5.1 本文总结

早期Leonard E. Baum等学者在一系列统计学文章中，提出隐马尔可夫模型(HMM)，后续该模型被广泛应用于自然语言处理以及语音识别领域，均取得不错效果。本文在中信行业指数量价数据的基础上，以该方法为理论基础识别和判断当前行业所处状态，并基于技术分析中常用的历史会重演理论假设，通过计算当前行业所属状态序列与历史中该行业未来出现所有显著上涨或显著下跌时所有状态序列的平均相似度，预测行业未来上涨概率，进而构建基于隐马尔可夫模型的行业轮动策略。

常见的时间序列模型不足——GARCH 模型：

该模型可以较好处理随时间变化的条件方差，但是对参数估计、数据质量要求较高，模型复杂度较大。此外该模型也无法解释在因利好上行、利空下行这两种状态下市场波动的非对称性。

基于隐马尔可夫算法行业轮动模型回测表现：

样本内：

2022 年费后超额收益超过 7%、2023 年费后超额收益超过 9%，最大回撤分别为 3.50%、3.40%。从胜率来看，2022 年胜率为 66.67%，而 2023 年胜率更是高达 91.67%，全年 12 个月份，只有一个月跑输 30 个中信一级行业平均收益；2022 年和 2023 年的超额收益年化波动均低于 6%，表现不错。

样本外：

从 2024 年前 8 个月的超额收益来看，费后累计超额收益为 10.75%，年化超额收益为 16.54%，显著高于样本内。样本外最大回撤仅为 2.8%，比样本内低接近 1%；同时样本外的月盈亏比为 1.91，该数据也显著优于样本内。

Top 行业下月收益排名方面，2024 年前 8 个月中有 5 个月的平均名次在前 15.5 名以内 。其中 1 月以及 6 月的平均名次更是位于前 10 名。2 月、5 月以及 7 月的平均名次稍弱，但也仅略低于行业中位数，位于 15 至 18 名之间，平均值为 16.4 名。

就 Top 行业下月收益位于全行业不同名次出现的次数而言，第 1 名出现 4 次，前 3 名共计出现 8 次，前 5 名共计出现 13 次，前 10 名共计出现 20 次。而前 15 名则共计出现 28 次，相对于总样本数量占比 58%，接近五分之三。

2024 年 9 月份 Top 行业：

就 2024 年 9 月份而言，基于隐马尔可夫算法行业轮动模型所选择的 Top 行业为石油石化、煤炭、家电、非银行金融、通信以及综合金融等六个行业。

5.2 未来展望

文中涉及的状态匹配有别于首创证券金工团队之前关于形态匹配的研究，隐马尔可夫模型可以将多维度特征构成的复杂形态抽丝剥茧，提取其离散的抽象状态，进而可以达到降低噪声的目的。

此外本文是对模式识别之状态匹配研究的初探，并将其应用于行业轮动模型中，取得不错的样本外效果。未来可以尝试将该模型应用于大类资产配置中，在识别各类资产所处状态的基础上，预测不同资产未来上涨概率，进而构建大类资产配置策略。

6 风险提示

报告中所涉及测算均基于历史数据，未来市场可能发生变化，历史会惊人相似，但并不会简单重复；由于金融市场数据不一定完全服从正态分布，可能影响隐马尔可夫模型的准确性，进而对当前行业所处状态做出误判，不利于模型对行业未来上涨概率进行预测，最终影响行业轮动模型效果。

分析师简介

陈军华，金融工程首席分析师，华中科技大学管理科学与工程专业硕士、信息管理与信息系统专业学士，10 年以上量化投资、研究工作经验，曾在招商证券研究发展中心、招商资管、中融基金等公司工作。

分析师声明

本报告清晰准确地反映了作者的研究观点，力求独立、客观和公正，结论不受任何第三方的授意或影响，作者将对报告的内容和观点负责。

免责声明

本报告由首创证券股份有限公司（已具备中国证监会批复的证券投资咨询业务资格）制作。本报告所在资料的来源及观点的出处皆被首创证券认为可靠，但首创证券不保证其准确性或完整性。该等信息、意见并未考虑到获取本报告人员的具体投资目的、财务状况以及特定需求，在任何时候均不构成对任何人的个人推荐。投资者应当对本报告中的信息和意见进行独立评估，并应同时考量各自的投资目的、财务状况和特定需求，必要时就法律、商业、财务、税收等方面咨询专业财务顾问的意见。对依据或者使用本报告所造成的一切后果，首创证券及/或其关联人员均不承担任何法律责任。投资者需自主作出投资决策并自行承担投资风险，任何形式的分享证券投资收益或者分担证券投资损失的书面或口头承诺均为无效。

本报告所载的信息、材料或分析工具仅提供给阁下作参考用，不是也不应被视为出售、购买或认购证券或其他金融工具的要约或要约邀请。该等信息、材料及预测无需通知即可随时更改。过往的表现亦不应作为日后表现的预示和担保。在不同时期，首创证券可能会发出与本报告所载意见、评估及预测不一致的研究报告。

首创证券的销售人员、交易人员以及其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。首创证券没有将此意见及建议向报告所有接收者进行更新的义务。首创证券的自营部门以及其他投资业务部门可能独立做出与本报告中的意见或建议不一致的投资决策。

在法律许可的情况下，首创证券可能会持有本报告中提及公司所发行的证券头寸并进行交易，也可能为这些公司提供或争取提供投资银行业务服务。因此，投资者应当考虑到首创证券及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突。投资者请勿将本报告视为投资或其他决定的唯一信赖依据。

本报告的版权仅为首创证券所有，未经书面许可任何机构和个人不得以任何形式转发、翻版、复制、刊登、发表或引用。

评级说明

1. **投资建议的比较标准**

   投资评级分为股票评级和行业评级

   以报告发布后的 6 个月内的市场表现为比较标准，报告发布日后的 6 个月内的公司股价（或行业指数）的涨跌幅相对同期的沪深 300 指数的涨跌幅为基准

2. **投资建议的评级标准**

   报告发布日后的 6 个月内的公司股价（或行业指数）的涨跌幅相对同期的沪深 300 指数的涨跌幅为基准

	评级	说明
股票投资评级	买入	相对沪深 300 指数涨幅 15%以上
	增持	相对沪深 300 指数涨幅 5%-15%之间
	中性	相对沪深 300 指数涨幅－5%-5%之间
	减持	相对沪深 300 指数跌幅 5%以上
行业投资评级	看好	行业超越整体市场表现
	中性	行业与整体市场表现基本持平
	看淡	行业弱于整体市场表现