基于条件随机场的周频择时策略

交易性择时策略研究之十三

报告摘要:

- **条件随机场模型及股市择时思路**

自 1988 年，西蒙斯成立了大奖章基金并在多次股灾中取得稳定的收益后，纯技术量化型的投资策略开始受到投资者的广泛关注，而机器学习正是这种技术量化型策略的中坚力量。目前使用较为成熟的模型之一是隐马尔可夫模型 HMM，其与条件随机场是一对“生成判别对”。相比起 HMM，条件随机场具有更加灵活等优点。事实上，条件随机场（Conditional Random Field，CRF）是描述给定一组输入随机变量条件下另一组输出变量的条件概率分布的模型。基于条件随机场，我们可以建立观测指标值和走势状态及走势状态与走势状态之间复杂的函数依赖关系，从而，当给定新的观测指标值时，我们可以给出新的走势状态值，实现涨跌模式识别的目标。

- **预测指标提取及模型参数选择**

预测指标提取及模型参数选择是应用机器学习算法时的两个关键问题，对条件随机场也不例外。关于预测指标的提取，我们实际上采取的是机器学习中常用的升维后降维的思想，我们从两个在以往的研究中发现的可能对中短期择时有预测作用的指标——涨跌幅和换手率出发，衍生出更多的特征指标以增加输入信息，接着对这些特征指标进行逐一测算，我们剔除了其中冗余无效的信息，最终筛选出一个较为稳健的预测指标组，其中包括涨跌幅、涨跌幅波动率和收盘价连涨连跌序列。关于模型参数的选择，我们的主要思路是控制数量和质量，控制质量指的是参数所确定的模型要能较好地描述我们的实际问题，而控制数量则指的是要避免参数过多所导致的参数估计不准和模型过拟合。在周频择时中，我们最终确定了以三结点的链式结构模型作为我们的模型框架。

- **指数择时测算**

最后，我们利用上述指标组构建的线性链条件随机场模型对 2014 年末到 2018 年初的市场走势进行了预测，测算的指数包括沪深 300 指数、深证成指、上证综指、上证 50 和中小板指。测算结果显示，我们的模型在样本外总体表现良好，具有较强的泛化能力和适用性。在不考虑交易费用时，沪深 300 年化收益率约为 14%；考虑双边千二交易成本后，年化收益率约为 12%。

- **风险提示**

本篇报告仅作为基于条件随机场择时的研究，进行投资方法与建模的相关讨论，不提供任何投资建议。

图 1、基于条件随机场的择时思路

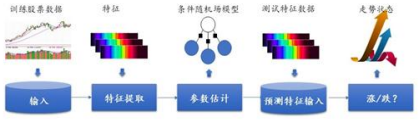


图 2、沪深 300 周频择时样本外表现



图 3、上证综指周频择时样本外表现



分析师: 张 超 S0260514070002
020-87578291
zhangchao@gf.com.cn

机器学习相关研究:

趋势策略的深度学习增强	2017-10-26
虚拟遗憾最小化应用于量化择时与交易	2017-07-06
深度学习之股指期货日内交易策略	2014-06-18
深度学习算法掘金 ALPHA 因子	2014-06-19

“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

目录索引

一、机器学习在投资领域的应用 4
二、条件随机场模型及股市择时思路 4
（一）条件随机场模型概述 4
（二）条件随机场的三个基本问题 7
三、预测指标提取及模型参数选择 9
（一）预测指标提取 10
（二）模型参数选择 13
四、指数择时测算 14
五、总结 20
风险提示 20

“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

图表索引

图 1：无向图示例 5
图 2：线性链条件随机场模型结构示例 6
图 3：基于条件随机场进行股市择时的思路框架图 9
图 4：单指标涨跌幅在深证成指多空择时净值曲线（样本内） 12
图 5：单指标涨跌幅波动率在沪深 300 多空择时净值曲线（样本内） 12
图 6：单指标收盘价连涨连跌序列在上证综指多空择时净值曲线（样本内） ... 13
图 7：完全图条件随机场模型结构示例 14
图 8：三结点链式条件随机场模型 15
图 9：链式结构在沪深 300 多空择时净值曲线（样本外） 15
图 10：链式结构在深证成指多空择时净值曲线（样本外） 16
图 11：链式结构在上证综指多空择时净值曲线（样本外） 17
图 12：链式结构在上证 50 多空择时净值曲线（样本外） 18
图 13：链式结构在中小板指多空择时净值曲线（样本外） 19

表 1：衍生预测特征 10
表 2：衍生预测指标多空择时的收益回撤比（样本内） 11
表 3：预测指标的相关系数矩阵（全样本） 11
表 4：组合指标策略预测准确率和收益回撤比（样本外） 14
表 5：链式结构在沪深 300 多空择时表现（样本外） 16
表 6：链式结构在深证成指多空择时表现（样本外） 16
表 7：链式结构在上证综指多空择时表现（样本外） 17
表 8：链式结构在上证 50 多空择时表现（样本外） 18
表 9：链式结构在中小板指多空择时表现（样本外） 19

“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

一、机器学习在投资领域的应用

自1988年，西蒙斯成立了大奖章基金并在多次股灾中取得稳定的收益后，纯技术量化型的投资策略开始受到投资者的广泛关注，而机器学习正是这种技术量化型策略的中坚力量。近三十年来，人工神经网络（Artificial Neural Network，ANN）、支持向量机（Support Vector Machine，SVM）、决策树（Decision Tree）、隐马尔科夫模型（Hidden Markov Model，HMM）等算法都在投资领域得到了成功的运用。但随着近几年来行为金融学的大火，不少研究者对使用数学模型对市场运作进行描述提出了质疑。诚然，利用数学模型来描述投资者行为和市场运作是一件异常困难的事情，但当我们发现存在传统金融理论所不能解释的“反常现象”时，我们却可以利用数学模型尝试建立起投资者非理性行为与市场表现之间的关系，因为很多模型就是为建立两个因素间的联系而服务的。例如，我们可以证明市场中存在“输者赢者效应”，但我们确实很难用数学模型去描述这种反常效应是如何在整个市场中运作的，但我们可以尝试利用模型去刻画过去的“输者赢者组合”收益与其后续收益的关系，而且刻画的这种关系当然是越准确越好。因此，机器学习中的数学模型本身是非常灵活的。

而提及机器学习在投资领域的应用，我们不得不提应用得较为成熟的HMM，HMM也是西蒙斯的主要应用工具之一。HMM可以较好地描述股价走势状态动态变化的过程，但由于其需要满足马尔科夫性假设，即状态转移概率不随时间变化，而具有一定的局限性。事实上，HMM与我们即将使用的条件随机场模型是一对“生成判别对（Generative-discriminative Pair）”，其中HMM属于生成式模型；条件随机场属于判别式模型。从“生成判别对”角度来看，条件随机场是对条件概率进行建模，从而不需要估计输入变量**x**的边际分布，从而使用最大似然估计参数时，判别式模型能给出更准确的参数估计；从灵活度来看，HMM描述的是一种链式依赖关系，且状态转移概率不随时间变化；而条件随机场不仅可以描述更加复杂的依赖关系，同时其状态间关系可以随时间变化。因此，接下来我们将尝试使用条件随机场对市场走势状态进行识别，探索其在投资领域的应用。

本报告我们将首先介绍条件随机场模型及其中的三个关键算法，并给出模型应用在股市择时中的思路框架。接着，我们将详细介绍预测特征提取和模型参数选择的方法，并给出一个较稳健的预测指标组合和模型结构。最后，我们将上述模型运用在市场走势状态预测中，并在沪深300、深证成指、上证综指、上证50和中小板指中测算其风险收益情况。

二、条件随机场模型及股市择时思路

（一）条件随机场模型概述

条件随机场（Conditional Random Field，CRF）是描述给定一组输入随机变量**x**条件下另一组输出变量**y**的条件概率分布的模型，其特点是假设输出随机变量构成马尔可夫随机场。因此，在介绍条件随机场前，我们需要对马尔科夫随机场做一个简单的回顾。

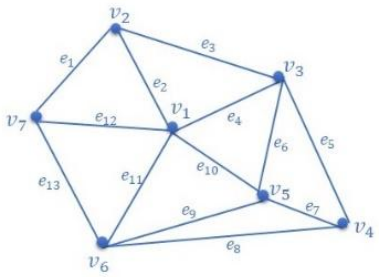
“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

马尔科夫随机场（Markov Random Field，MRF），又称概率无向图模型（Probabilistic Undirected Graphical Model），是一个可以由无向图表示的联合概率分布。图1给出了一个无向图示意图。设有联合概率分布P(Y)，由无向图$G=(V,E)$表示，其中$V=\{v\}$是结点构成的集合，$E=\{e\}$是连接结点的边构成的集合。在图G中，结点表示随机变量，边表示随机变量之间的依赖关系，满足马尔可夫随机场的联合概率分布可以进行因式分解，将原图分解为一些较小的团上函数的乘积，即：

$$p(\mathbf{y})=\frac{1}{Z}\prod_{A}\Psi_{A}(y_A)$$

其中，y_A是$\mathbf{y}$的子集；Z是规范化因子（Normalization Factor），$Z=\sum_{y}\prod_{A}\Psi_{A}(y_A)$，规范化因子保证$p(\mathbf{y})$构成一个概率分布；函数$\Psi_{A}(y_A)$是对应$y_A$的兼容函数(Compatibility Function)，也称势函数(Potential Function)，其将$\mathcal{V}^n$映射到$\mathcal{R}$。

图1：无向图示例



资料来源：广发证券发展研究中心

而条件随机场则是在马尔科夫随机场的基础上，进一步引入输入随机变量$\mathbf{x}$，条件随机场描述的就是给定$\mathbf{x}$的条件下，$\mathbf{y}$的马尔科夫随机场，即：

$$p(\mathbf{y}|\mathbf{x})=\frac{1}{Z}\prod_{A}\Psi_{A}(y_A,x_A)$$

其中，x_A是$\mathbf{x}$的一个子集；y_A是$\mathbf{y}$的一个子集；函数$\Psi_{A}(y_A,x_A)$是对应x_A和y_A的兼容函数；$Z=\sum_{x,y}\prod_{A}\Psi_{A}(y_A,x_A)$是规范化因子。记因子$F=\{\Psi_{A}\}$是所有兼容函数的集合。在实际应用中，兼容函数一般取指数族，即兼容函数具有以下形式：

$$\Psi_{A}(y_A,x_A)=\exp\{\sum_{k}\theta_{Ak}f_{Ak}(y_A,x_A)\}$$

其中，$f_{Ak}(y_A,x_A)$是对应x_A和y_A的实值特征函数，θ_{Ak}是对应实值参数。一般来说，特征函数一般选为以下形式：

$$f_{Ak}(y_A,x_A)=1_{\{y_A=\tilde{y}_A\}}q_{Ak}(x_A)$$

“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

其中，$1_{\{y_A=\tilde{y}_A\}}=\begin{cases}1, & y_A=\tilde{y}_A\\ 0, & 其他\end{cases}$，$q_{Ak}(x_A)$是$x_A$的实值函数。

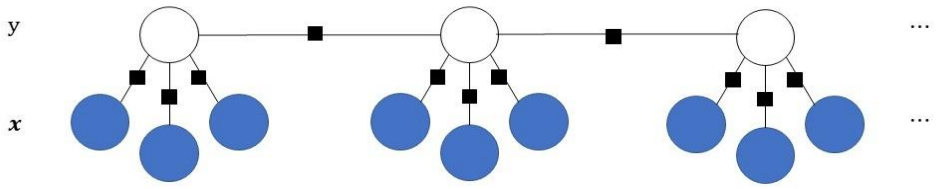
在一个实际问题中，$\mathbf{x}$表示可观察的相关属性，而$\mathbf{y}$表示输出的状态序列。例如对于一个词性标注的问题，$\mathbf{x}$可以指代单词开头是否大写等，$\mathbf{y}$表示单词词性序列。

条件随机场可以描述非常复杂的图模型结构，由于其灵活性，目前条件随机场已在文本处理、生物信息学和图像处理等领域取得广泛的应用。而最常用图模型结构有线性链结构、树状结构和完全图结构，为更方便理解，接下来我们的推导将基于线性链条件随机场，当然推导也可以非常方便地推广到更一般的情况中。线性链条件随机场即输出状态序列$\mathbf{y}$具有线性链式依赖关系，图1给出了一个线性链结构的示例，其中，连接结点的边上的黑色小方框表示兼容函数。一个具有T个结点的线性链条件随机场具有以下形式:

$$\mathrm{p}(\mathbf{y}|\mathbf{x})=\frac{1}{\mathrm{Z}(\mathbf{x})}\prod_{t=1}^{T}\exp\{\sum_{k=1}^{K}\theta_k f_k(y_t,y_{t-1},\boldsymbol{x}_t)\}$$

其中，$\mathrm{Z}(\mathbf{x})=\sum_{\boldsymbol{y}}\exp\{\sum_{k=1}^{K}\theta_k f_k(y_t,y_{t-1},\boldsymbol{x}_t)\}$。也即，图1所示的结构可以分解为相邻两两结点兼容函数的乘积，$\Psi_{\mathrm{t}}(\boldsymbol{y}_t,\boldsymbol{x}_t)=\Psi_{\mathrm{t}}(y_t,y_{t-1},\boldsymbol{x}_t)=\exp\{\sum_{k=1}^{K}\theta_k f_k(y_t,y_{t-1},\boldsymbol{x}_t)\}$，$\mathrm{t}=1,\cdots,\mathrm{T}$；且令$\mathrm{t}=1$时，$\Psi_{1}(\boldsymbol{y}_1,\boldsymbol{x}_1)=\Psi_{1}(y_1,y_0,\boldsymbol{x}_1)=\exp\{\sum_{k=1}^{K}\theta_k f_k(y_1,y_0,\boldsymbol{x}_1)\}=\exp\{\sum_{k=1}^{K}\theta_k f_k(y_1,\boldsymbol{x}_1)\}$。

图2：线性链条件随机场模型结构示例



资料来源：广发证券发展研究中心

记$\boldsymbol{\theta}=\{\theta_k\}_{k=1}^{K}$是模型的参数集合；$\mathbf{x}=\{\boldsymbol{x}_1,\cdots,\boldsymbol{x}_T\}$是一个$T\times m$维的矩阵，表示输入观测值构成的随机变量矩阵；$\mathbf{y}=\{\boldsymbol{y}_1,\cdots,\boldsymbol{y}_T\}$是一个$T\times 1$维的向量，表示输出状态值构成的随机向量；$S$是$\boldsymbol{y}$的状态集合。因此，为描述一个条件随机场，我们需要解决三个基本问题:

问题1（概率问题）: 给定模型参数$\boldsymbol{\theta}$、观测值$\mathbf{x}$和状态值$\mathbf{y}$，计算条件概率$\mathrm{p}(\mathbf{y}|\mathbf{x})$;

问题2（训练问题）: 给定训练数据$\{\boldsymbol{x}^{(i)},\boldsymbol{y}^{(i)}\}_{i=1}^{N}$的情况下，以最大化条件概率$\mathrm{p}(\mathbf{y}|\mathbf{x})$为目标，给出模型参数$\boldsymbol{\theta}$;

“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

问题3（预测问题）：给定模型参数**θ**和观测值**x**，计算最大化条件概率p(**y**|**x**)对应的状态值**y**。

（二）条件随机场的三个基本问题

1. 概率问题

给定模型参数**θ**、观测值**x**和状态值**y**，计算条件概率p(**y**|**x**)可以通过前向—后向算法（Forward-backward Algorithm）进行。

定义前向变量：

$$\alpha_t(j) \stackrel{\text{def}}{=} p(y_t = j, x_1, \cdots, x_t) = \sum_{y_1 \in S, \cdots, y_{t-1} \in S} \Psi_t(j, y_{t-1}, x_t) \prod_{t'=1}^{t-1} \Psi_{t'}\left(y_{t'}, y_{t'-1}, x_{t'}\right)$$

即$\alpha_t(j)$表示长度从1到t，且在t时状态值是j的状态序列的条件概率。

1）初始化：$\alpha_1(j) = \Psi_1(j, y_0, x_1)$;

2）递推计算：$\alpha_t(j) = \sum_{i \in S} \Psi_t(j, i, x_t)\, \alpha_{t-1}(i)$;

3）终止：$\mathrm{Z}(\mathbf{x}) = \sum_{j \in S} \alpha_T(j)$。

类似的，可以定义后向变量：

$$\beta_t(i) \stackrel{\text{def}}{=} p(y_t = i, x_{t+1}, \cdots, x_T) = \sum_{y_{t+1} \in S, \cdots, y_T \in S} \prod_{t'=t+1}^{T} \Psi_{t'}\left(y_{t'}, y_{t'-1}, x_{t'}\right)$$

即$\beta_t(i)$表示长度从$t+1$到T，且在t时状态值是i的状态序列的条件概率。

1） 初始化：$\beta_T(i) = 1$;

2） 递推计算：$\beta_t(i) = \sum_{j \in S} \Psi_{t+1}(j, i, x_{t+1})\, \beta_{t+1}(j)$;

3） 终止：$\mathrm{Z}(\mathbf{x}) = \beta_0(y_0) = \sum_{y_1} \Psi_1(y_1, y_0, x_1)\beta_1(y_1)$

利用前向后向变量，我们很容易得到：

$$\mathrm{p}(y_t, y_{t-1}|\mathbf{x}) = \Psi_t(y_t, y_{t-1}, x_t)\left(\sum_{y_1 \in S, \cdots, y_{t-2} \in S} \prod_{t'=1}^{t-1} \Psi_{t'}\left(y_{t'}, y_{t'-1}, x_{t'}\right)\right)$$

$$\left(\sum_{y_{t+1} \in S, \cdots, y_T \in S} \prod_{t'=t+1}^{T} \Psi_{t'}\left(y_{t'}, y_{t'-1}, x_{t'}\right)\right) / \mathrm{Z}(\mathbf{x})$$

$$= \alpha_{t-1}(y_{t-1})\, \Psi_t(y_t, y_{t-1}, x_t)\beta_t(y_t) / \mathrm{Z}(\mathbf{x})$$

“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

2. 训练问题

给定训练数据$\{\boldsymbol{x}^{(i)},\boldsymbol{y}^{(i)}\}_{i=1}^{N}$的情况下，为最大化条件概率$\mathrm{p}(\mathbf{y}|\mathbf{x})$，我们可以通过极大似然估计法给出模型参数$\boldsymbol{\theta}$。

我们考虑条件对数似然函数:

$$\mathrm{logL}(\theta)=\sum_{i=1}^{N}logp(\boldsymbol{y}^{(i)}|\boldsymbol{x}^{(i)})=\sum_{i=1}^{N}\sum_{t=1}^{T}\sum_{k=1}^{K}\theta_k f_k\left(y_t^{(i)},y_{t-1}^{(i)},x_t^{(i)}\right)-\sum_{i=1}^{N}log\,\mathrm{Z}(\boldsymbol{x}^{(i)})$$

对参数求导可得:

$$\frac{\partial \mathrm{L}(\theta)}{\partial\theta_k}$$

$$=\sum_{i=1}^{N}\sum_{t=1}^{T}f_k\left(y_t^{(i)},y_{t-1}^{(i)},x_t^{(i)}\right)$$

$$-\sum_{i=1}^{N}\sum_{y_1,\cdots,y_T}p(y_1,\cdots,y_T|\boldsymbol{x}^{(i)})\sum_{t=1}^{T}f_k\left(y_t^{(i)},y_{t-1}^{(i)},\boldsymbol{x}_t^{(i)}\right)$$

$$=\sum_{i=1}^{N}\sum_{t=1}^{T}f_k\left(y_t^{(i)},y_{t-1}^{(i)},x_t^{(i)}\right)-\sum_{i=1}^{N}\sum_{t=1}^{T}\sum_{y,y'}f_k\left(y,y',\boldsymbol{x}_t^{(i)}\right)p\left(y,y'\,\middle|\boldsymbol{x}^{(i)}\right)$$

其中，等式右边的第一部分是f_k在经验分布$\tilde{p}(y,x)=\frac{1}{N}\sum_{i=1}^{N}1_{\{y=y^{(i)}\}}1_{\{x=x^{(i)}\}}$下的期望，第二部分是$f_k$在模型分布$\mathrm{p}(\mathbf{y}|\mathbf{x};\boldsymbol{\theta})\tilde{p}(x)$下的期望，则当$\frac{\partial\ell(\theta)}{\partial\lambda_k}=0$时，有上述两部分期望相等。

一般来说，我们很难得到$\boldsymbol{\theta}$的解析解，但目前已有非常多成熟有效的算法来得到数值解。另外，由于$\mathrm{L}(\theta)$是凸函数，其局部极值也是其全局极值，这给我们的参数估计带来了极大的方便。这些数值解法例如，1)牛顿法（NewtonMethod），通过局部二阶导来近似梯度方向，其收敛速度较快，但由于其需要存储参数的海森矩阵（Hessian Matrix），当参数数量较大时需要较大的存储空间；2）拟牛顿法（quasi-Newton Method，Bertsekas,1999）如BFGS算法,类似于牛顿法，其用一阶偏导去近似海森矩阵，但同样没有解决参数量大时的存储问题。于是，常用LBFGS算法（limited-memory BFGS，Byrd，1994）来代替，LBFGS算法利用最近几步迭代的信息来构建海森矩阵的近似从而降低存储量；在接下来的实证研究中，我们采用的也是这种算法；3）共轭梯度法（Conjugate Gradient Method，Hestenes，1952），与BFGS算法类似的是，共轭梯度法也是只需利用一阶导数信息，但其不需要存储海森矩阵，它的每一个搜索方向是相互共轭的，且这些搜索方向仅仅是负梯度方向与上一次迭代的搜索方向的组合，因此，存储量少，计算方便。

3. 预测问题

给定模型参数$\boldsymbol{\theta}$和观测值$\mathbf{x}$，计算最大化条件概率$\mathrm{p}(\mathbf{y}|\mathbf{x})$对应的状态值$\mathbf{y}$，

“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

$y^* = argmax_y p(\boldsymbol{y}|\boldsymbol{x})$可以通过维特比算法（Viterbi Algorithm）进行。定义：

$$\delta_t(j) \stackrel{\text{def}}{=} \max_{y_1,\cdots,y_{t-1}} p(y_1,\cdots,y_{t-1},y_t = j|x_1,\cdots,x_t)$$

则

$$\delta_t(j) \stackrel{\text{def}}{=} \max_{j\epsilon S} \max_{y_1,\cdots,y_{t-2}} p(y_1,\cdots,y_{t-2},y_{t-1} = i,y_t = j|x_1,\cdots,x_t)$$

$$= \max_{j\epsilon S} \max_{y_1,\cdots,y_{t-2}} p(y_1,\cdots,y_{t-2},y_{t-1} = i|x_1,\cdots,x_t)\ \Psi_t(j,i,x_t)$$

$$= \max_{j\epsilon S} \delta_{t-1}(i)\ \Psi_t(j,i,x_t)$$

于是，

1) 初始化：$\delta_0(j) = 1$;

2) 递推计算：$\delta_t(j) = \max_{i\in S} \Psi_t(j,i,x_t)\delta_{t-1}(i)$

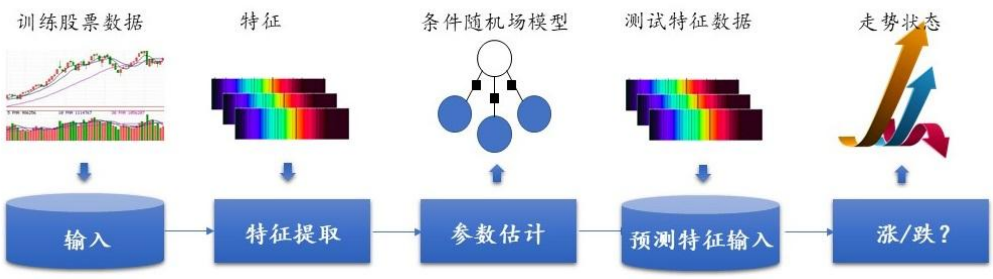
3) 终止：$y^* = \max_{j\in S} \delta_T(j)$。

至此，条件随机场的三个关键问题已经解决

三、预测指标提取及模型参数选择

基于以上理论背景，我们尝试将条件随机场应用到股市走势预测中。我们假定历史相似假设成立，即过去资料建立的趋势外推模型能适合未来，能代表未来趋势变化的情况，也即未来和过去的规律是一样，或者说，历史是相似甚至历史会重演的。于是，利用条件随机场进行股市预测的基本思路为，通过历史一段时间的观测指标值$\mathbf{x}$和走势状态值$\boldsymbol{y}$，我们可以训练出一个模型M，确定模型中的参数$\boldsymbol{\theta}$，从而确定观测指标值$\mathbf{x}$和走势状态值$\boldsymbol{y}$之间的依赖关系$p(\boldsymbol{y}|\boldsymbol{x})$；进而，当出现新的观测指标值$\mathbf{x}^*$时，我们可以将其输入训练好的模型M，得出最可能的走势状态y^*，其中$y^* = argmax_y p(\boldsymbol{y}|\boldsymbol{x})$。股市预测的基本思路可以用下图2概括：

图3：基于条件随机场进行股市择时的思路框架图



资料来源：广发证券发展研究中心

“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

因此，在给定模型框架的基础上，为达到一个较理想的预测效果，我们还需要1）给模型输入有效的训练样本，其中“有效”意味着观测指标与走势状态值应有一定的相关性；2）同时，调整模型固有结构参数，以建立一个更合理的观测值与状态值的依赖关系。

（一）预测指标提取

在所有预测模型中，所选取的输入特征是否能真正对因变量有解释作用对预测效果非常大的影响，甚至可以说，有效输入特征的提取比预测模型本身更加重要。在中短期择时中，价量关系往往是重要的，以往的研究发现涨跌幅和换手率对市场走势有一定的预测作用，因此我们基于以上两个基础指标进行衍生，并基于条件随机场模型逐一测算各个指标分别在沪深300指数、深证成指及上证综指样本内中的预测效果。其中，沪深300指数、深证成指和上证综指测算开始时间分别取2005年4月8日、2004年1月2日和2004年1月2日；结束时间均取为2018年1月17日；均以周频为单位；其中前二分之一设为样本内，用于训练，后二分之一设为样本外，用于检验模型效果。

表 1：衍生预测特征

预测指标	指标参数	计算公式
收盘价连涨连跌序列	$n_1 = 3$	$\mathrm{CP}_t = \begin{cases} 1, P_{t-\mathrm{i}} < P_{t-\mathrm{i}+1},\ i = 1,\cdots,n_1 \\ -1, P_{t-\mathrm{i}} > P_{t-\mathrm{i}+1},\ i = 1,\cdots,n_1 \\ 0, 其他 \end{cases}$
涨跌幅	-	$\mathrm{PCTCHG}_t = \frac{P_t - P_{t-1}}{P_{t-1}}$
涨跌幅差值符号序列	-	$\mathrm{PCTCHG_SIGN}_t = \begin{cases} 1, \mathrm{PCTCHG}_t > \mathrm{PCTCHG}_{t-1} \\ -1, \mathrm{PCTCHG}_t < \mathrm{PCTCHG}_{t-1} \\ 0, 其他 \end{cases}$
涨跌幅波动率	$n_2 = 3$	$\mathrm{PCTCHG_VIOLAT}_t = std(\mathrm{PCTCHG}_{t-n_2+1},\cdots,\mathrm{PCTCHG}_t)$
涨跌幅连涨连跌序列	$n_3 = 3$	$\mathrm{CPCTCHG}_t = \begin{cases} 1, PCTCHG_{t-\mathrm{i}} < PCTCHG_{t-\mathrm{i}+1},\ i = 1,\cdots,n_3 \\ -1, PCTCHG_{t-\mathrm{i}} > PCTCHG_{t-\mathrm{i}+1},\ i = 1,\cdots,n_3 \\ 0, 其他 \end{cases}$
换手率	-	TURN_t
平稳换手率	$n_4 = 5$	$\mathrm{TURN_MA}_t = \frac{\mathrm{TURN}_t}{mean(\mathrm{TURN}_{t-n_4+1},\cdots,\mathrm{TURN}_t)}$
换手率波动率	$n_5 = 3$	$\mathrm{TURN_VIOLAT}_t = std(\mathrm{TURN}_{t-n_5+1},\cdots,\mathrm{TURN}_t)$

“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

换手率连涨连跌序列	$n_6 = 3$	$\mathrm{CTURN}_t = \begin{cases} 1, TURN_{t-\mathrm{i}} < TURN_{t-\mathrm{i}+1},\ i = 1,\cdots,n_6 \\ -1, TURN_{t-\mathrm{i}} > TURN_{t-\mathrm{i}+1},\ i = 1,\cdots,n_6 \\ 0, 其他 \end{cases}$

数据来源：广发证券发展研究中心

表 2：衍生预测指标多空择时的收益回撤比（样本内）

预测指标	沪深 300	深证成指	上证综指
收盘价连涨连跌序列	6.7	11.4	13.8
涨跌幅	12.4	16.9	15.2
涨跌幅符号序列	4.0	3.1	0.7
涨跌幅波动率	38.6	3.4	8.8
涨跌幅连涨连跌序列	5.5	3.5	0.2
换手率	0.6	1.4	5.6
平稳换手率	0.7	1.2	2.9
换手率波动率	3.5	0.7	6.4
换手率连涨连跌序列	11.6	0.6	0.6

数据来源：广发证券发展研究中心，wind资讯

可以看到，上述10个预测指标中，涨跌幅在各指数测算中具有较为稳健的预测效果，这与移动平均线（MA）、指数平均线（EMA）和低延迟趋势线（LLT）跟踪市场趋势进行择时某种程度上是一样的，思路都是将当前股价信息与历史股价信息通过某种函数关系联系在一起，从而达到通过历史股价信息预测当前（未来）股价信息的目的，各种策略的不同之处就在于这种函数依赖关系是不一样的。除涨跌幅外，收盘价连涨连跌序列和涨跌幅波动率也有不俗的预测效果。以沪深300指数为例，各预测指标相关性矩阵如下表所示，其中涨跌幅连涨连跌序列与其他指标的的相关性通过点二列相关系数（Point-Biserial Correlation Coefficient）给出，即 $r_{pb} = \frac{\bar{Y}_1 - \bar{Y}_0}{S_Y}\sqrt{\frac{np_0p_1}{n-1}}$，其中 $S_Y = \sqrt{\frac{\sum_{k=1}^{n}(y_k - \bar{Y})^2}{n-1}}$；$\bar{Y}_1$、$\bar{Y}_0$和$\bar{Y}$分别是第1组、第0组和总体均值；$p_1$和$p_0$分别是样本落在第1组和第0组的概率。

表 3：预测指标的相关系数矩阵（全样本）

相关系数	涨跌幅	收盘价连涨连跌序列	涨跌幅波动率
涨跌幅	1.00	0.19	-0.47
收盘价连涨连跌序列	0.19	1.00	-0.12
涨跌幅波动率	-0.47	-0.12	1.00

数据来源：广发证券发展研究中心，wind资讯

综合单指标策略的测算结果和指标间的相关系数，我们考虑将前收盘价、涨跌

“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

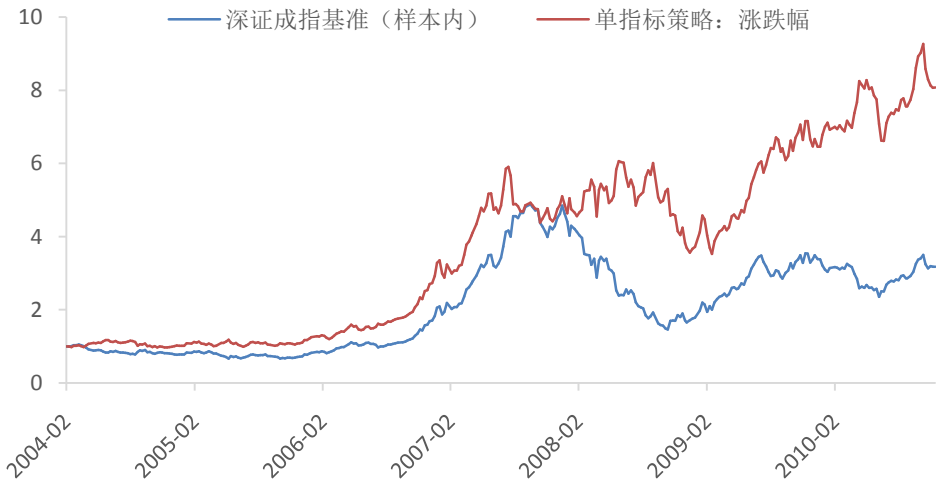
幅、涨跌幅波动率和收盘价连涨连跌序列作为输入观测值：

x_1：涨跌幅；

x_2：涨跌幅波动率；

x_3：收盘价连涨连跌序列。

图4：单指标涨跌幅在深证成指多空择时净值曲线（样本内）



数据来源：广发证券发展研究中心，wind资讯

图5：单指标涨跌幅波动率在沪深300多空择时净值曲线（样本内）



数据来源：广发证券发展研究中心，wind资讯

“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入http://www.hibor.com.cn

图6：单指标收盘价连涨连跌序列在上证综指多空择时净值曲线（样本内）



数据来源：广发证券发展研究中心，wind资讯

（二）模型参数选择

在条件随机场模型框架下，我们需要确定的结构参数有1）图的拓扑结构$G=\{V,E\}$；2）图的结点数nNodes；3）兼容函数$\Psi_A(y_A,x_A)$的形式。

图的拓扑结构。我们分别考虑两种常见的图模型结构，分别为线性链式结构和完全图结构。其中，线性链式结构模型如图2所示，完全图结构模型下图7所示，图中边之间的黑色小方框表示兼容函数。

图的结点数。对于一个有3个输入变量的链式结构图，如果图有3个结点则需要估计约50个参数；4个结点需要估计约80个参数。考虑到训练样本数量的限制，我们直接取$nNodes=3$。

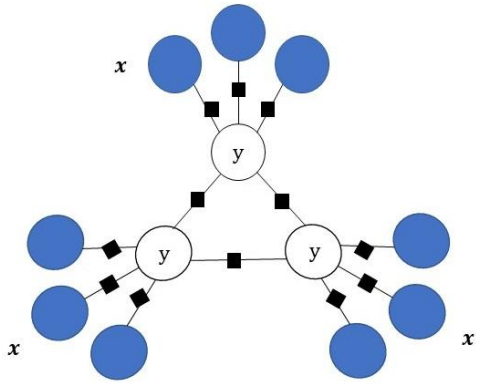
兼容函数的形式。我们考虑将图G分解为两两结点构成的团上的函数的乘积，即$\Psi_A(y_A,x_A)=\Psi_{ij}(y_i,y_j,x_i,x_j)$，即：

$$p(\mathbf{y}|\mathbf{x})=\frac{1}{Z(\mathbf{x})}\prod_A\Psi_A(y_A,x_A)=\frac{1}{Z(\mathbf{x})}\prod_{i,j}f_{ij}(y_i,y_j,\boldsymbol{x})\prod_i f_i(y_i,\boldsymbol{x})$$

其中，$f_{ij}(\cdot,\cdot,\boldsymbol{x})=\begin{pmatrix}e^{\boldsymbol{w}'_{i,j,11}x_{ij}} & e^{\boldsymbol{w}'_{i,j,12}x_{ij}}\\ e^{\boldsymbol{w}'_{i,j,21}x_{ij}} & e^{\boldsymbol{w}'_{i,j,22}x_{ij}}\end{pmatrix}$，称为边特征函数；$f_i(\cdot,\boldsymbol{x})=\left(e^{\boldsymbol{v}'_{i,1}x_i},e^{\boldsymbol{v}'_{i,2}x_i}\right)$，称为节点特征函数。

“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

图7：完全图条件随机场模型结构示例



资料来源：广发证券发展研究中心

四、指数择时测算

从表中指标间相关性矩阵可以看出，指标间的相关性较小，也即涨跌幅、涨跌幅波动率和收盘价连涨连跌序列是从不同的侧面给股市的未来走势提供信息的。因此，为增强预测的稳健性和提高择时的准确度，在单指标择时的基础上，我们进一步将选出的表现较好的单指标进行组合，考虑组合指标择时效果。构成该组合的指标包括：涨跌幅、涨跌幅波动率和收盘价连涨连跌序列。我们选取沪深300指数、深证成指、上证综指、上证50和中小板指对组合指标进行测算。其中，沪深300指数、深证成指、上证综指、上证50和中小板指测算开始时间分别取2005年4月8日、2004年1月2日、2004年1月2日、2004年1月30日和2006年12月29日；结束时间取为2018年1月17日；均以周频为单位；其中除中小板指外，其他指数取前二分之一为样本内，后二分之一为样本外；中小板指由于起始时间较晚，因此取前三分之二为样本内，后三分之一为样本外；样本内数据用于训练，样本外数据用于检验模型效果。下面，我们给出不同图结构下，组合指标策略在各指数上的测算结果：

表 4：组合指标策略预测准确率和收益回撤比（样本外）

		预测准确率	收益回撤比
链式结构	沪深 300	55.69%	4.5
	深证成指	54.52%	2.8
	上证综指	53.42%	6.3
	上证 50	50.26%	0.5
	中小板指	56.22%	2.1
完全图结构	沪深 300	51.04%	0.3
	深证成指	49.86%	-0.9
	上证综指	52.05%	0.5
	上证 50	47.88%	1.5

“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

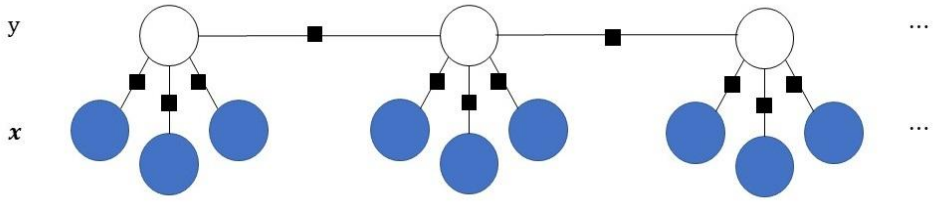
中小板指	58.71%	2.5

数据来源：广发证券发展研究中心，wind资讯

从上面的结果我们发现，图模型为链式结构时能有较稳定的预测效果。事实上，当图模型为完全图结构时，其样本内效果一般远好于对应的链式结构下样本内效果，但其样本外效果却往往远不如对应链式结构下的样本外效果，这一方面是因为完全图模型结构过于复杂，它能很好地拟合样本内的情况，但不能泛化推广到样本外，即容易出现过拟合情况；另一方面是因为完全图结构下，需要估计参数数量较多，在样本量相对不足的情况下，参数容易估计不准。因此，在周择时中，我们建议一般直接选取链式结构即可。

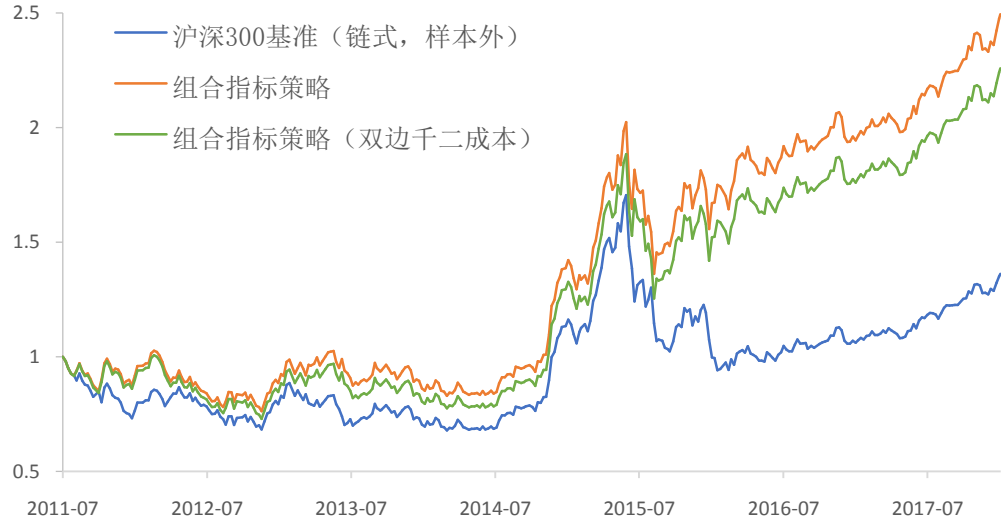
最终，我们确定以三结点的链式结构模型作为基本模型框架，并以涨跌幅、涨跌幅波动率和收盘价连涨连跌序列构成的指标组合作为模型的输入特征。该模型的示意图如下图8所示。接下来，我们给出该模型下各指数多空择时详细表现情况。

图8：三结点链式条件随机场模型



资料来源：广发证券发展研究中心

图9：链式结构在沪深300多空择时净值曲线（样本外）



数据来源：广发证券发展研究中心，wind资讯

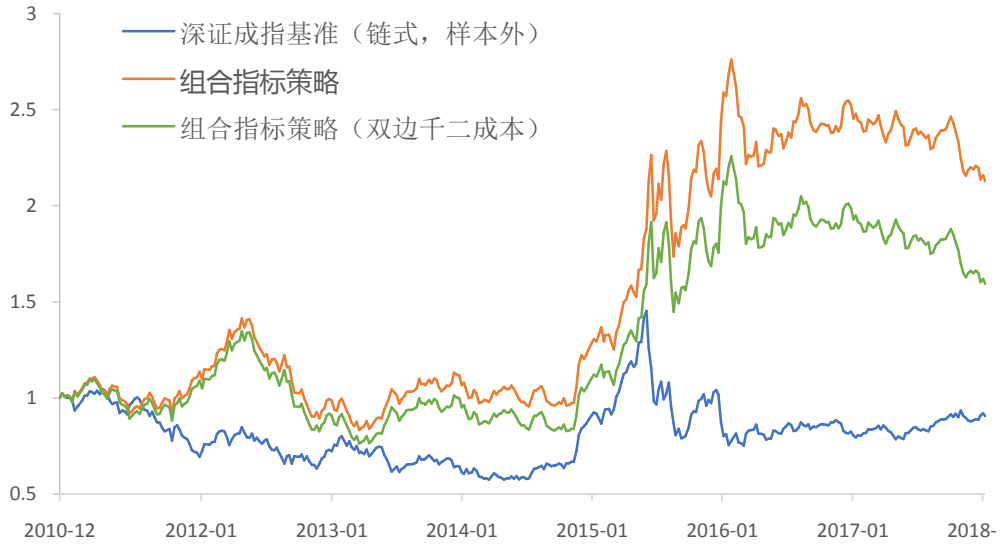
“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

表 5：链式结构在沪深 300 多空择时表现（样本外）

	组合指标策略	组合指标策略（双边千二成本）
择时次数	51	51
平均每年换仓次数	7.3	7.3
累积收益率（复利）	149.33%	125.75%
年化收益率	14.03%	12.41%
单次平均收益率	2.34%	2.15%
胜率	50.98%	49.02%
平均盈利率	8.52%	8.67%
平均亏损率	-4.08%	-4.12%
盈亏比	2.1	2.1
单次最大盈利	54.40%	54.20%
单次最大亏损	-12.42%	-12.62%
最大回撤率	-32.72%	-33.40%
收益回撤比	4.6	3.8

数据来源：广发证券发展研究中心，wind资讯

图10：链式结构在深证成指多空择时净值曲线（样本外）



数据来源：广发证券发展研究中心，wind资讯

表 6：链式结构在深证成指多空择时表现（样本外）

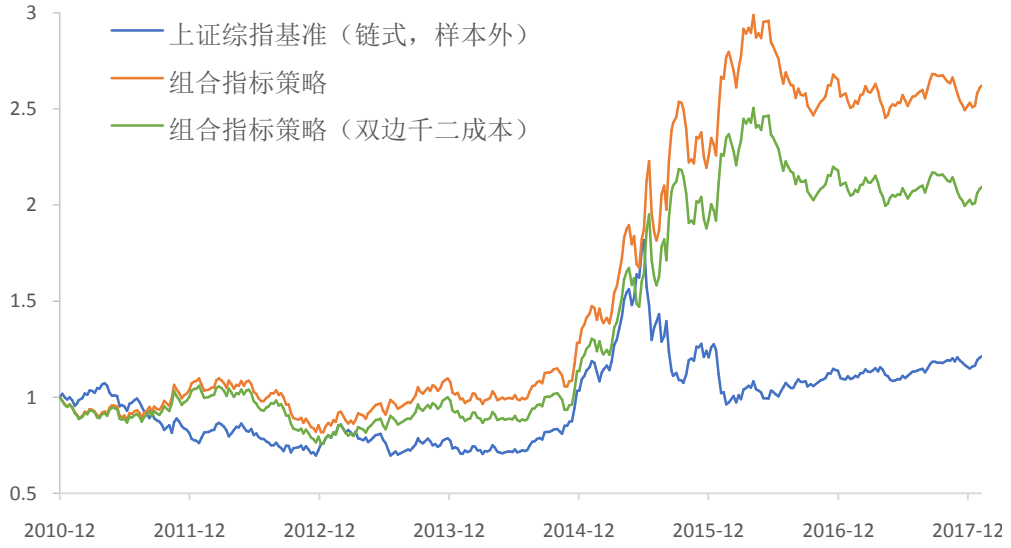
	组合指标策略	组合指标策略（双边千二成本）
择时次数	145	145
平均每年换仓次数	19.1	19.1
累积收益率（复利）	112.98%	59.47%
年化收益率	10.45%	6.33%
单次平均收益率	0.73%	0.53%
胜率	41.38%	41.38%
平均盈利率	6.02%	5.82%

“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

平均亏损率	-3.01%	-3.21%
盈亏比	2.0	1.8
单次最大盈利	27.19%	26.99%
单次最大亏损	-19.68%	-19.88%
最大回撤率	-41.02%	-43.38%
收益回撤比	2.8	1.4

数据来源：广发证券发展研究中心，wind资讯

图11：链式结构在上证综指多空择时净值曲线（样本外）



数据来源：广发证券发展研究中心，wind资讯

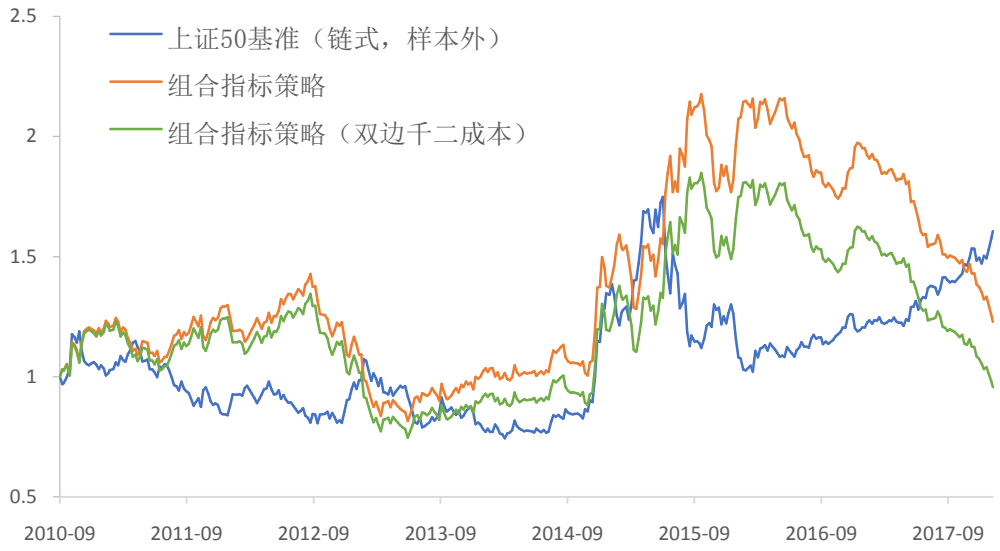
表 7：链式结构在上证综指多空择时表现（样本外）

	组合指标策略	组合指标策略（双边千二成本）
择时次数	114	114
平均每年换仓次数	15.0	15.0
累积收益率（复利）	162.19%	109.41%
年化收益率	13.51%	10.21%
单次平均收益率	1.04%	0.84%
胜率	47.37%	43.86%
平均盈利率	5.14%	5.34%
平均亏损率	-2.64%	-2.67%
盈亏比	1.9	2.0
单次最大盈利	32.70%	32.50%
单次最大亏损	-12.07%	-12.27%
最大回撤率	-25.58%	-28.38%
收益回撤比	6.3	3.9

数据来源：广发证券发展研究中心，wind资讯

“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

图12：链式结构在上证50多空择时净值曲线（样本外）



数据来源：广发证券发展研究中心，wind资讯

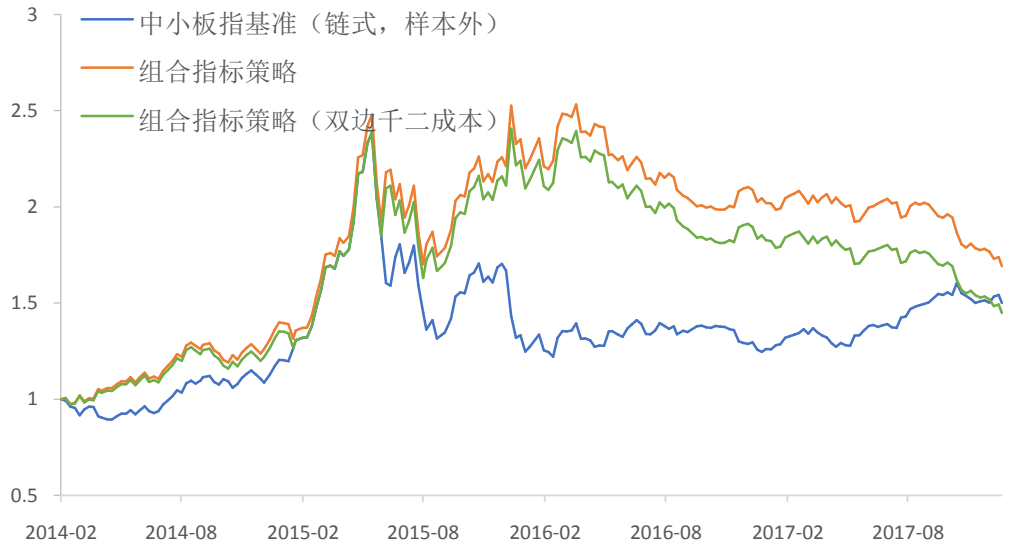
表 8：链式结构在上证 50 多空择时表现（样本外）

	组合指标策略	组合指标策略（双边千二成本）
择时次数	125	125
平均每年换仓次数	15.9	15.9
累积收益率（复利）	22.91%	-4.30%
年化收益率	2.65%	-0.56%
单次平均收益率	0.32%	0.12%
胜率	41.60%	38.40%
平均盈利率	4.91%	5.12%
平均亏损率	-2.95%	-2.99%
盈亏比	1.7	1.7
单次最大盈利	28.32%	28.12%
单次最大亏损	-13.39%	-13.59%
最大回撤率	-43.53%	-48.25%
收益回撤比	0.5	-0.1

数据来源：广发证券发展研究中心，wind资讯

“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入http://www.hibor.com.cn

图13：链式结构在中小板指多空择时净值曲线（样本外）



数据来源：广发证券发展研究中心，wind资讯

表 9：链式结构在中小板指多空择时表现（样本外）

	组合指标策略	组合指标策略（双边千二成本）
择时次数	78	78
平均每年换仓次数	18.6	18.6
累积收益率（复利）	69.27%	44.90%
年化收益率	13.39%	9.26%
单次平均收益率	0.91%	0.71%
胜率	38.46%	37.18%
平均盈利率	6.02%	6.02%
平均亏损率	-2.28%	-2.43%
盈亏比	2.6	2.5
单次最大盈利	46.34%	46.14%
单次最大亏损	-16.57%	-16.77%
最大回撤率	-33.19%	-39.80%
收益回撤比	2.1	1.1

数据来源：广发证券发展研究中心，wind资讯

总的来说，基于组合指标涨跌幅、涨跌幅波动率和收盘价连涨连跌序列的链式结构条件随机场模型在多个指数择时中都有较好的表现。在不考虑交易费用时，其在沪深300、深证成指、上证综指、上证50和中小板指上的年化收益率分别为14.03%、10.45%、13.51%、2.65%和13.39%；考虑双边千二交易成本后，其在沪深300、深证成指、上证综指、上证50和中小板指上的年化收益率分别为12.41%、6.33%、10.21%、-0.56%和9.26%。

进一步来看，最佳组合指标涨跌幅、涨跌幅波动率和收盘价连涨连跌序列事实上都是对价格某个侧面的反映，因此，基于这组预测指标的条件随机场策略本质上

“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

是一种市场走势模式识别策略。事实上，任意资产如果其过往价格与现在（未来）价格具有一定的相关性，使用上述策略进行择时一般都能比基准表现更好。但与传统的趋势追踪策略，如MA、EMA等相比，基于条件随机场策略优势在于1）条件随机场可以引入更多价格相关的指标以避免过度依赖于某一个特定指标，从而增强预测稳健性。例如基于MA、EMA的择时就仅依赖于前一段时间的价格；相比之下，条件随机场可以引入涨跌幅波动率而一定程度反映投资者的买卖行为变化程度所导致的市场供求关系变化的程度，可以引入收盘价连涨连跌序列而一定程度反映价格趋势的强度。这些指标的加入给预测结果添加了更多的参考信息。2）条件随机场对涨跌两个状态与预测指标进行建模，从而直接建立起市场走势与观测指标间的函数关系。因此，对于给定观测值，输入训练好的模型后，我们可以直接得到一个涨或跌的信号；3）条件随机场的灵活度和扩展性非常强。虽然在本文中，我们选定的最佳组合指标都是与价格有一定联系的，但条件随机场模型本身是可以引入更加丰富的预测指标的。

五、总结

本报告主要提供了基于条件随机场进行股市择时的思路和一个较稳健的预测指标组合。首先，我们介绍了条件随机场模型框架及其涉及的三个主要算法。考虑到该模型应用的关键点在于有效预测指标的输入，根据以往经验，接着我们对两个可能对中短期择时有预测作用的指标——涨跌幅和换手率进行了特征衍生。经过测算、比较和筛选，我们选出了一组比较优秀的预测指标，其中包括涨跌幅、涨跌幅波动率和收盘价连涨连跌序列。最后，我们利用上述指标组构建了三结点线性链式条件随机场模型，并在一系列指数中按周频调仓测算其收益风险情况，其中包括沪深300、深证成指、上证综指、上证50和中小板指，样本外测算时间大致落在2010年年末至2018年1月之间。测算结果显示，择时策略一般都有较好的表现。在不考虑交易费用时，其在沪深300、深证成指、上证综指、上证50和中小板指上的年化收益率分别为14.03%、10.45%、13.51%、2.65%和13.39%；考虑双边千二交易成本后，其在沪深300、深证成指、上证综指、上证50和中小板指上的年化收益率分别为12.41%、6.33%、10.21%、-0.56%和9.26%。可见，该模型的泛化能力和适用性都是较强的。

当然，本报告只是对条件随机场模型在股市择时研究中的一个初步尝试。事实上，寻找更加有效的预测指标和控制模型的过拟合可能是模型改进的突破口和着力点，可以据此进行进一步的探索。

风险提示

本篇报告仅作为基于条件随机场择时的研究，进行投资方法与建模的相关讨论，不提供任何投资建议。

“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

广发证券—行业投资评级说明

买入: 预期未来 12 个月内，股价表现强于大盘 10%以上。
持有: 预期未来 12 个月内，股价相对大盘的变动幅度介于-10%～+10%。
卖出: 预期未来 12 个月内，股价表现弱于大盘 10%以上。

广发证券—公司投资评级说明

买入: 预期未来 12 个月内，股价表现强于大盘 15%以上。
谨慎增持: 预期未来 12 个月内，股价表现强于大盘 5%-15%。
持有: 预期未来 12 个月内，股价相对大盘的变动幅度介于-5%～+5%。
卖出: 预期未来 12 个月内，股价表现弱于大盘 5%以上。

联系我们

	广州市	深圳市	北京市	上海市
地址	广州市天河区林和西路 9 号耀中广场 A 座 1401	深圳福田区益田路 6001 号太平金融大厦 31 层	北京市西城区月坛北街 2 号月坛大厦 18 层	上海浦东新区世纪大道 8 号国金中心一期 16 层
邮政编码	510620	518000	100045	200120
客服邮箱	gfyf@gf.com.cn			
服务热线				

免责声明

广发证券股份有限公司（以下简称“广发证券”）具备证券投资咨询业务资格。本报告只发送给广发证券重点客户，不对外公开发布，只有接收客户才可以使用，且对于接收客户而言具有相关保密义务。广发证券并不因相关人员通过其他途径收到或阅读本报告而视其为广发证券的客户。本报告的内容、观点或建议并未考虑个别客户的特定状况，不应被视为对特定客户关于特定证券或金融工具的投资建议。本报告发送给某客户是基于该客户被认为有能力独立评估投资风险、独立行使投资决策并独立承担相应风险。

本报告所载资料的来源及观点的出处皆被广发证券股份有限公司认为可靠，但广发证券不对其准确性或完整性做出任何保证。报告内容仅供参考，报告中的信息或所表达观点不构成所涉证券买卖的出价或询价。广发证券不对因使用本报告的内容而引致的损失承担任何责任，除非法律法规有明确规定。客户不应以本报告取代其独立判断或仅根据本报告做出决策。

广发证券可发出其它与本报告所载信息不一致及有不同结论的报告。本报告反映研究人员的不同观点、见解及分析方法，并不代表广发证券或其附属机构的立场。报告所载资料、意见及推测仅反映研究人员于发出本报告当日的判断，可随时更改且不予通告。

本报告旨在发送给广发证券的特定客户及其它专业人士。未经广发证券事先书面许可，任何机构或个人不得以任何形式翻版、复制、刊登、转载和引用，否则由此造成的一切不良后果及法律责任由私自翻版、复制、刊登、转载和引用者承担。

“慧博资讯”是中国领先的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn