2020 年 12 月 14 日

基于隐马尔科夫模型的动态配置策略

FOF 策略专题

联系信息

陶勤英 分析师

SAC 证书编号：S0160517100002

taoqy@ctsec.com

021-68592393

郭小川 研究助理

guoxc@ctsec.com

18565679657

021-68592337

相关报告

1、财通金工深度报告《风险优化下的SmartBeta-基于一个统一的优化框架》（2020-09-03）

投资要点：

- **基于 HMM 模型的资产配置策略**

基于隐马尔科夫模型（HMM）进行大类资产配置是一种基于市场状态（Market Regime State）转换的动态配置策略。该策略利用机器学习算法识别各类资产所潜在的市场状态，根据识别的结果构建资产配置策略并进行动态调整，达到资产配置的择时效果。

- **大类资产回测表现**

从净值走势来看，基于 HMM 模型策略的大类资产配置总体优于传统等权、股债四六组合的各项回测指标来看，HMM 模型策略组合在区间收益、年化收益、最大回撤、胜率、盈亏比领先于其他组合模型，分别录得 50.10%、5.81%、12.28%、36.30%（日）、1.871（月），相比于第二名分别领先了 3.29%（EQ）、0.32%（EQ）、1.83%（60/40）、0.55%（Markowitz）、0.038（EQ）。HMM 组合净值的波动较大，仅低于 Markowitz 组合。

- **行业配置回测表现**

从各项回测指标来看，其区间收益率 79.31%、年化收益率 5.95%、年化波动率 18.89%、最大回撤 64.23%、夏普比率 0.302，仅在波动性指标上优于 Markowitz 模型组合。基于行业轮动现象，行业指数的正向动量效应不明显，市场状态在通常条件下不具备连续性，因此 HMM 模型策略用于行业配置表现不如大类资产配置表现强劲。

- **总结**

本文将 HMM 模型创新性的运用到大类资产间的识别和配置上，以此来构建出大类资产上的组合配置策略，而且不同于以往的是，在识别方法上本文不同于前期的研究仅仅拘泥于单只股票或者期货的价格，我们在此同时选取了各类资产的区间收益和收益风险比作为观测值，这一方法的创新之处在于根据金融理论，收益风险比是衡量金融资产背后潜在机制最为通用且不直接可观测的指标，将收益风险比这一本身不能直接观测的变量引入到 HMM 模型中作为一个间接观测变量来充当观测变量使得模型在识别市场状态时更为精准有效。

- **研究展望**

在本文的研究过程中，激发了我们进一步的思考，HMM 这一模型在大类资产配置的识别上，只要选出合适的观测值序列，能够非常精确的识别出背后市场的潜在状态，这一发现给了我们重要启示，在 FOF 策略中标的基金的选择，常常需要参考其在择时能力上的表现，现有的一些方法都无法精准的识别其择时时点并量化其择时时点的选择能力，而 HMM 模型正好可以应用到这一点上，通过识别出单只基金潜在的调仓时点，并序列化之后，得到相应的基金择时量化指标，从而为基金筛选提供一个重要的参考指标。

- **风险提示：本报告统计数据基于历史数据，过去数据不代表未来，市场风格变化可能导致模型失效。**

“慧博资讯”专业的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

内容目录

1、 前言 3
2、 隐马尔科夫模型（HMM） 4
2.1 基本概念 4
2.2 隐马尔科夫的基本问题 4
2.2.1 概率计算问题 4
2.2.2 参数估计问题 6
2.2.3 预测问题 8
3、 利用隐马尔科夫模型（HMM）模型建立资产配置策略 9
4、 基于隐马尔科夫模型（HMM）策略构建组合回测 11
4.1 单一资产回测表现 11
4.2 全球大类资产配置 12
5、 行业配置 14
6、 总结 16
7、 后续研究展望 17

图表目录

图 1：沪深 300ETF 走势与对应识别市场状态 10
图 2：全球大类资产月收益率相关性热力图 13
图 3：全球大类资产月收益风险比相关性热力图 13
图 4：全球大类资产配置各策略下组合净值走势 13
图 5：MOM 策略下全球大类资产配置情况 14
图 6：HMM 策略下全球大类资产配置情况 14
图 7：申万一级行业月收益率相关性热力图 15
图 8：申万一级行业月收益风险比相关性热力图 15
图 9：行业配置各策略下组合净值走势 16

表 1：变量定义 5
表 2：利用 HMM 模型配置策略权重 9
表 3：利用 HMM 模型识别各状态情况 11
表 4：单资产 HMM 策略下回测表现 12
表 5：全球大类资产配置各策略下回测表现 14
表 6：行业配置各策略下回测表现 16

“慧博资讯”专业的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

1、 前言

市场涨跌不由我，但市场涨跌背后却潜在着真实的数据驱动过程，如果我们把涨跌看成一种市场发生结构性变化的数据驱动过程的话，那么市场指数的背后潜在着一个真实的却不为我们所观测的驱动市场涨跌的状态，决定这一状态发生的原因可能是多方面的或许是基本面，或许是流动性亦或是市场参与者的情绪发生了变化。在统计或者计量模型中，我们常常用一种基于可观测变量去推演不可观测变量的变化的隐马尔科夫模型。

基于隐马尔科夫模型（HMM）进行大类资产配置是一种基于市场状态（Market Regime State）转换的新颖的动态配置策略。该策略利用机器学习算法识别各类资产价格发生结构性变化背后所潜在的市场状态，根据这一特定状态预期下一个可能的市场状态，从而对资产组合配置进行动态调整，实现投资组合盈利的目标，这一方法，换句话说对于资产组合的调整我们依赖于对不可观测的状态的估计值，其本质是跟随市场而动，捕捉市场切换的机会。这一模型进行资产配置的好处在于，首先，它能够迅速捕捉市场状态转换并通过调整资产权重对其做出相应策略上的调整，降低因为市场整体状态切换而带来的潜在踏空或者踏错风险。市场状态往往与各资产类别的前期的表现高度相关，换句话说状态的切换不会是没有征兆的突然的切换，而是有很多端倪蕴藏在前期的资产类别表现中。投资者对市场状态的预期通常反应在资产的的前期表现，因此市场状态能在一定情况下反应未来走势。然而前文所述的潜在状态的变化通常不易被传统的传统的量化模型所捕捉，例如以市值等权模型（EQ）为代表的传统被动配置模型以及均值方差模型（Mean-Variance）仅能在各种确定市场状态下分散由资产类别差异造成的非系统性风险，而无法对冲市场状态转换的“系统性”风险。而 HMM 模型则采用定量的方法探索市场潜在的状态切换时点及其切换的概率，在上升的状态中获得趋势性盈利，而在下跌状态时采取空仓或者买入固定收益类类资产规避市场下行风险。其次，传统的投资组合理论常常基于对单个标的资产均衡收益率，波动率等多个变量的假设和预测而 HMM 模型无需关于均衡收益及波动率相关性等假设，模型假设越少其适用性越广，同时对假设参数的敏感性亦低很多。

本报告将利用 HMM 模型的估计市场潜在的状态来实现大类资产配置初期的配置和后期的调整切换，并对比目前传统的的资产配置策略，探索基于潜在市场状态的 HMM 模型的优劣势。其中，第 2 部分将介绍 HMM 模型的基本概念及参数估计中的两大问题，第 3 部分将介绍利用 HMM 模型的参数估计值如何构建一个可行的大类资产配置策略，第 4 部分则将第 3 部分的内容进行了回测和付现，第 5 部分对比讨论总结出模型和策略构建中的优劣势。

“慧博资讯”专业的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

2、 隐马尔科夫模型（HMM）

2.1 基本概念

隐马尔科夫模型是关于时间序列的混合概率模型，描述由一个马尔科夫链随机生成不可观测的状态随机序列，再由各个状态生成一系列可观测的测随机序列的过程，其本质上是一个随机参数的随机过程，即随机过程的某些参数本身也服从某一个随机过程，但这一参数对应的随机过程本质上是不可被观测的。

隐马尔科夫模型由其潜在状态的转移概率矩阵、观测值的概率矩阵、初始状态概率所决定。其中状态转移矩阵与初始状态概率向量确定了潜在的马尔科夫链，观测概率矩阵确定了如何从状态生成观测。

隐马尔科夫模型满足三个基本假设：

1、当前观测仅由当前隐藏状态确定，隐藏状态假设，即独立性假设，独立于其他隐藏状态或观测。

2、当前隐藏状态由其前相邻的隐藏状态决定，即一阶马尔可夫假设。

3、隐藏状态之间传递函数的概率不随时间变化，即传递函数的稳定性。

回归本报告研究的情形，观测序列即为各类资产的市场公开信息，可以为收盘价、净值、收益率、波动率、成交量等等，而状态序列即为市场信息背后潜在的市场整体状态，可分为上行、下行或者更多可能的状态。市场状态的过程的分布服从潜在不可观测的马尔科夫链，即当前市场状态的形成仅与上一个已实现的状态有关；而资产的市场公开信息如价格等可观测信息的分布函数仅与当前的市场所处的潜在状态有关，与市场之前所处的潜在状态并无关系。

2.2 隐马尔科夫的基本问题

基于隐马尔科夫模型可引申出三个基本问题：概率计算问题、参数估计问题以及预测问题。概率计算的具体问题为：给定模型和观测序列，计算在该模型下该观测序列出现的概率。参数估计的具体问题为：已知观测序列，估计模型中的各项参数值，使得在该参数估计值下观测序列的概率密度（分布）最大（观测值连续）或者概率最大（观测值离散）。预测的具体问题为：给定模型和观测序列，求未来最有可能的对应的状态序列。解决这三类问题对于利用隐马尔科夫模型识别潜在市场状态有重要作用，其中概率计算问题为其他两个问题的基石，在已知概率计算方式后，可以根据资产价格信息估计潜在的模型参数，根据该参数及资产价格信息识别背后潜在的状态机制。

2.2.1 概率计算问题

对于概率计算问题最简单的思路是列出状态转移的条件概率以及由状态转移到该观测的条件改了二者相乘并将所有可能转移路径概率相加，但该方式计算复杂，

“慧博资讯”专业的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

步骤繁多，计算量大，当然不利于具体实现。一种较为简便的且计算机效率上可操作的方法是考虑递推，即前向算法或后向算法（Forward/Backward）。

首先，对变量做如下定义：

表1：变量定义

变量	含义	表达式
o_t	t时刻的观测值（可连续、可为向量）	/
i_t	t时刻的状态（离散）	/
a_{ij}	t时刻的状态为i，$t+1$时刻的状态为j的转移概率分布	$p(i_{t+1}=j\|i_t=i)$
$b_i(o_t)$	t时刻处于状态i生成观测o_t的概率分布	$p(o_t\|i_t=i)$
π_i	$t=1$时刻的处于状态i的概率分布	$p(i_1=i)$

数据来源：WIND，财通证券研究所

前向算法（Forward）：

给定隐马尔科夫模型λ，定义到时刻t部

分观测序列为$o_1,o_2,\ldots,o_t$且状态为q_i的概率密度，记作：

$$\alpha_t(i)=p(o_1,o_2,\ldots,o_t,i_t=q_i|\lambda)$$

由于$+1$的状态只依时刻t赖于时刻t的状态，因此对于$\alpha_{t+1}(i)$的计算，只需将到达时刻$t+1$的状态q_i的所有状态及其对应状态转移概率列出，利用全概率公式，再乘以相应的观测概率，即可以得到下列递推式：

$$\alpha_1(i)=\pi_i b_i(o_1),\ i=1,2,\ldots,N$$

$$\alpha_{t+1}(i)=[\sum_{j=1}^{N}\alpha_t(j)a_{ji}]b_i(o_{t+1}),\ i=1,2,\ldots,N$$

最终求得的概率密度为：

$$p(O|\lambda)=\sum_{i=1}^{N}\alpha_T(i)$$

后向算法（Backward）：

后向算法与前向算法类似，是前向算法的逆向过程。前向算法是对于时刻t下各个可能状态收于时刻$t+1$下的固定状态q_i的情况进行计算，而后向算法则是对于时刻$t+1$下各个可能状态反向收于时刻t下的固定状态q_i的情况进行计算，二者没有本质区别。

给定隐马尔科夫模型λ，定义到时刻t状态为q_i的条件下，从$t+1$到T的部分观测序列为$o_{t+1},o_{t+2},\ldots,o_T$的概率分布，记作：

$$\beta_t(i)=p(o_{t+1},o_{t+2},\ldots,o_T,i_t=q_i|\lambda)$$

“慧博资讯”专业的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

则：

$$\beta_T(i) = 1,\ i = 1,2,\ldots,N$$

$$\beta_t(i) = \sum_{j=1}^{N} a_{ij} b_j(o_{t+1}) \beta_{t+1}(j),\ i = 1,2,\ldots,N$$

$$p(O|\lambda) = \sum_{i=1}^{N} \pi_i b_i(o_1) \beta_1(i)$$

除此之外，我们可以获得在 t 时刻状态为 i 的条件概率：

$$\gamma_i(t) = p(i_t = q_i|O,\lambda) = \frac{p(O,i_t = q_i|\lambda)}{p(O|\lambda)} = \frac{p(O,i_t = q_i|\lambda)}{\sum_{j=1}^{N} p(O,i_t = q_j|\lambda)}$$
$$= \frac{p(o_1,o_2,\ldots,o_t,i_t = q_i|\lambda) p(o_{t+1},o_{t+2},\ldots,o_T,i_t = q_i|\lambda)}{\sum_{j=1}^{N} p(O,i_t = q_j|\lambda)}$$
$$= \frac{\alpha_t(i)\beta_t(i)}{\sum_{j=1}^{N} \alpha_t(j)\beta_t(j)}$$

以及在 t 时刻状态为 i、$t+1$ 时刻状态为 j 的条件概率：

$$\xi_{ij}(t) = p(i_t = q_i, i_{t+1} = q_j|O,\lambda) = \frac{p(O,i_t = q_i,i_{t+1} = q_j|\lambda)}{\sum_{i=1}^{N}\sum_{j=1}^{N} p(O,i_t = q_i,i_{t+1} = q_j|\lambda)}$$
$$= \frac{p(o_1,\ldots,o_t,i_t = q_i|\lambda) p(i_{t+1} = q_j|i_t = q_i) p(o_{t+1}|i_{t+1} = q_j) p(o_{t+2},\ldots,o_T,i_{t+1} = q_j|\lambda)}{\sum_{i=1}^{N}\sum_{j=1}^{N} p(O,i_t = q_i,i_{t+1} = q_j|\lambda)}$$
$$= \frac{\alpha_t(i) a_{ij} b_j(o_{t+1}) \beta_{t+1}(j)}{\sum_{i=1}^{N}\sum_{j=1}^{N} \alpha_t(i) a_{ij} b_j(o_{t+1}) \beta_{t+1}(j)}$$

2.2.2 参数估计问题

我们采用 EM 算法（Baum-Welch 算法）对隐马尔科夫的参数λ进行估计，即对在求得参数估计值使得在当前参数及观测下对数似然函数的期望最大化。本报告采单一高斯分布的隐马尔科夫模型，即认为在 t 时刻状态为 j 的条件下生成观测为 o_t的概率服从均值为μ，方差为Σ的（多元）正态分布：

$$b_j(o_t) \propto |\Sigma|^{-\frac{1}{2}} e^{-\frac{1}{2}(o_t-\mu)^T \Sigma^{-1}(o_t-\mu)}$$

估计参数$\lambda = (A,\mu,\Sigma,\pi)$

Baum-Welch 算法：

按照 EM 算法步骤，首先获得模型的 Q 函数：

$$Q(\lambda,\bar{\lambda}) = E_I[\log p(O,I|\lambda)|O,\bar{\lambda}]$$
$$= \sum_I \log p(O,I|\lambda)\, p(O,I|\bar{\lambda})$$

“慧博资讯”专业的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

$$= \sum_{I} \log \pi_{i_1} p(O,I|\bar{\lambda}) + \sum_{I} \left(\sum_{t=1}^{T-1} \log a_{i_t i_{t+1}} \right) p(O,I|\bar{\lambda}) + \sum_{I} \left(\sum_{t=1}^{T} \log b_{i_t}(o_t) \right) p(O,I|\bar{\lambda})$$

其中$\bar{\lambda}$是隐马尔科夫模型参数当前估计值，在随后的计算过程中，随着迭代数量增加估计值$\bar{\lambda}$将收敛至待估参数λ的真实值。其次最大化 Q 函数，并求解出模型参数。由于状态转移概率矩阵 A、观测概率矩阵 B、初始状态概率π三者是相互独立的，因此上述求得的 Q 函数中的三项取值互不影响，因此极大化 Q 函数只需分别对以上三项进行最大化，从而可分别求出π、A、B 的估计值。

π极大似然估计：

$$\begin{cases} \arg\max_{\pi_i} \sum_{I} \log \pi_{i_1} p(O,I|\bar{\lambda}) \\ \sum_{i=1}^{N} \pi_i = 1 \end{cases}$$

$$\sum_{I} \log \pi_{i_1} p(O,I|\bar{\lambda}) = \sum_{i=1}^{N} \log \pi_i \, p(O,i_1 = i|\bar{\lambda})$$

利用拉格朗日乘子法，

$$\frac{\partial}{\partial \pi_{i_1}} \left(\sum_{i=1}^{N} \log \pi_i \, p(O,i_1 = i|\bar{\lambda}) + \gamma \left(\sum_{i=1}^{N} \pi_i - 1 \right) \right) = 0$$

即得

$$\pi_i = \frac{p(O,i_1 = i|\bar{\lambda})}{p(O|\bar{\lambda})} = \gamma_i(1)$$

A 极大似然估计：

$$\begin{cases} \arg\max_{a_{ij}} \sum_{I} \left(\sum_{t=1}^{T-1} \log a_{i_t i_{t+1}} \right) p(O,I|\bar{\lambda}) \\ \sum_{i=1}^{N} a_{ij} = 1 \end{cases}$$

$$\sum_{I} \left(\sum_{t=1}^{T-1} \log a_{i_t i_{t+1}} \right) p(O,I|\bar{\lambda}) = \sum_{i=1}^{N} \sum_{j=1}^{N} \sum_{t=1}^{T-1} \log a_{ij} \, p(O,i_t = i, i_{t+1} = j|\bar{\lambda})$$

同利用拉格朗日乘子法，

$$\frac{\partial}{\partial a_{ij}} \left(\sum_{i=1}^{N} \sum_{j=1}^{N} \sum_{t=1}^{T-1} \log a_{ij} \, p(O,i_t = i, i_{t+1} = j|\bar{\lambda}) + \gamma \left(\sum_{i=1}^{N} a_{ij} - 1 \right) \right) = 0$$

即得：

“慧博资讯”专业的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

$$a_{ij}=\frac{\sum_{t=1}^{T-1}p(O,i_t=i,i_{t+1}=j|\bar{\lambda})}{\sum_{t=1}^{T-1}p(O,i_t=i|\bar{\lambda})}=\frac{\sum_{t=1}^{T-1}\xi_{ij}(t)}{\sum_{t=1}^{T-1}\gamma_i(t)}$$

μ,Σ极大似然估计：

$\arg\max_{\pi_i}\sum_I(\sum_{t=1}^{T}\log b_{i_t}(o_t))p(O,I|\bar{\lambda})$同理得：

$$\sum_I(\sum_{t=1}^{T}\log b_{i_t}(o_t))p(O,I|\bar{\lambda})=\sum_{j=1}^{N}\sum_{t=1}^{T}\log b_j(o_t)\,p(O,i_t=j|\bar{\lambda})$$
$$=\sum_{j=1}^{N}\sum_{t=1}^{T}\log p(o_t|\mu,\Sigma)\,p(O,i_t=j|\bar{\lambda})$$
$$=\sum_{j=1}^{N}\sum_{t=1}^{T}(-\frac{1}{2}\log|\Sigma|$$
$$-\frac{1}{2}(o_t-\mu)^T\Sigma^{-1}(o_t-\mu))p(O,i_t=j|\bar{\lambda})$$

分别对μ、Σ求导：

$$\frac{\partial}{\partial\mu}\sum_{j=1}^{N}\sum_{t=1}^{T}(-\frac{1}{2}\log|\Sigma|-\frac{1}{2}(o_t-\mu)^T\Sigma^{-1}(o_t-\mu))p(O,i_t=j|\bar{\lambda})=0$$
$$\frac{\partial}{\partial\Sigma}\sum_{j=1}^{N}\sum_{t=1}^{T}(-\frac{1}{2}\log|\Sigma|-\frac{1}{2}(o_t-\mu)^T\Sigma^{-1}(o_t-\mu))p(O,i_t=j|\bar{\lambda})=0$$

即得：

$$\mu=\frac{\sum_{j=1}^{N}\sum_{t=1}^{T}o_t p(O,i_t=j|\bar{\lambda})}{\sum_{j=1}^{N}\sum_{t=1}^{T}p(O,i_t=j|\bar{\lambda})}=\frac{\sum_{i=1}^{N}\sum_{t=1}^{T}o_t\gamma_i(t)}{\sum_{i=1}^{N}\sum_{t=1}^{T}\gamma_i(t)}$$
$$\Sigma=\frac{\sum_{j=1}^{N}\sum_{t=1}^{T}(o_t-\mu)(o_t-\mu)^T p(O,i_t=j|\bar{\lambda})}{\sum_{j=1}^{N}\sum_{t=1}^{T}p(O,i_t=j|\bar{\lambda})}$$
$$=\frac{\sum_{i=1}^{N}\sum_{t=1}^{T}(o_t-\mu)(o_t-\mu)^T\gamma_i(t)}{\sum_{i=1}^{N}\sum_{t=1}^{T}\gamma_i(t)}$$

在实际实现中，初始模型$\bar{\lambda}$可任意选取，通过上一期估计得到的模型参数计算下一期的模型参数，经过反复迭代之后，$\bar{\lambda}$将收敛至真实模型λ。

2.2.3 预测问题

有了前向算法和后向算法的递推基础后，解决这一类问题可以采用动态规划方法（DP），这种方法能够保证求得的状态序列是实际可能发生的，不存在状态转移概率为 0 的情况。

维特比算法（Viterbi）：

定义在时刻 t 状态为 i 的所有单个路径$(i_1,i_2,\ldots,i_t)$中概率最大值为：

$$\delta_t(i)=\max_{i_1,i_2,\ldots,i_{t-1}}P(i_t=i,i_{t-1},\ldots,i_1,o_t,\ldots,o_1|\bar{\lambda}),\ i=1,2,\ldots,N$$

“慧博资讯”专业的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

定义在时刻 t 状态为 i 的所有单个路径$(i_1,i_2,...,i_{t-1},i)$中概率最大的路径的第 $t-1$ 个结点为：

$$\psi_t(i) = \arg\max_{1\le j\le N}[\delta_{t-1}(j)]a_{ji}$$

根据动态规划的原理，最优路径的所有子路径也必定是最优的，否则一定存在一条更优的子路径，连接其他固定最优路径后比原来整体最优路径更优的路径，产生矛盾。基于这一特性，可以考虑以下递推关系：最初时刻到时刻 $t+1$ 的最优路径即为最初时刻到时刻 t 的最优路径加上时刻 t 至时刻 $t+1$ 的最优路径。而时刻 t 至时刻 $t+1$ 的概率计算问题已通过前文前向算法和后向算法给出，最优路径只需将前向或后向算法中的递推式对各个可能状态求极值即可，同时也可求出相应的路径结点。具体表达形式如下：

$$\delta_{t+1}(i) = \max_{1\le j\le N}[\delta_t(j)a_{ji}]b_i(o_{t+1})$$

3、 利用隐马尔科夫模型（HMM）模型建立资产配置策略

本文基于上述隐马尔科夫模型构建了以高斯马尔科夫为依据的资产配置策略，假设共有 S 类资产$\{A_1,A_2,...,A_s\}$，潜在市场状类别主要划分为上行、小幅震荡、下行（据此划分的原因在于一是便于识别，二是避免过多的状态划分带来极大的计算量从而损耗参数的估计效率和准确性），因此对应着 3 个相应的状态值，，潜在状态值设置为上行（$State=1$）、小幅震荡（$State=0$）、下行（$State=-1$），

根据上述潜在状态的描述，我们构建了一个简单易行的配置策略，思路如下：

若该资产 t 时刻潜在状态为 1，则 t 时刻调仓时则将资产平均分配在 t 时刻状态为 1 的资产上，其他资产均为 0，此时只要有一类资产 t 时刻状态为 1，则其他类资产投资均为零，当 t 时刻没有资产的状态为 1（即上涨）时，我们选择降低仓位一半，并选择那些 t 时刻状态为 0 的资产作为标的资产并平均分配，当 t 时刻所有资产的状态均为-1（即下跌）时，我们认为此时没有一类资产是可投资的选择，选择空仓全投资于现金资产。这样构建的原因，一是我们认为当市场状态识别的频率较高（本文以一个月）的情况下潜在状态为 1 的资产容易保持有短期的动量效应，二是当资产的识别状态为 0 的时候，此时市场潜在状态为振荡市，这个时候大部分投资者的想法皆为情况不明朗时减仓持币观望态势，当所有资产当前潜在状态均为-1 即下跌态势时，我们认为此时市场已无机会可言，市场寒冬情况下则只能持币过冬，全部持有现金资产。表 2 清晰的定义了上述策略，并进行了严格的数学表达。

表2：利用HMM模型配置策略权重

资产状态	非现金类资产	现金资产
$\exists j, State_{A_j,T}=1$	$W_{A_j,T+1}=\begin{cases}\dfrac{Nav_T}{\sum_{i=1}^{S} I(State_{A_i,T}=1)}, & State_{A_j,T}=1\\ 0, & State_{A_j,T}\neq 1\end{cases}$	0

“慧博资讯”专业的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

$\forall j, State_{A_j,T} \neq 1;$ $\exists k, State_{A_k,T} = 0$	$W_{A_j,T+1} = \begin{cases} \frac{\frac{1}{2}Nav_T}{\sum_{i=1}^{S} I(State_{A_i,T}=0)}, & State_{A_j,T}=0 \\ 0, & State_{A_j,T}=-1 \end{cases}$	$\frac{1}{2}Nav_T$
$\forall j, State_{A_j,T} = -1$	0	Nav_T

数据来源：WIND，财通证券研究所

策略具体做法如下，先利用 HMM 模型根据当前观测进行参数估计然后依据状态的识别结合策略函数，分配资产进行组合构造：

观测序列：本文在构建回测组合时，与已有研究不同的是，我们采用了双观测变量，同时选取了各类资产的收益和波动率信息作为观测信息计算对应的 Sharpe 比率，综合考虑二者目的是更为精准的识别市场潜在的状态，当市场潜在状态发生转移的时候，其市场结构显然会发生变化，所以不应当仅仅只依靠单个资产的收益率来识别，而收益风险比（Sharpe 比率）则是市场结构最为典型的表征指标；因此在具体实施时我们将各类资产的月收益率及月收益风险比（Sharpe 比率）作为观测序列，这一方法创新之处在于，这一方法的创新之处在于将收益风险比这一本身不能直接观测的变量引入到 HMM 模型中作为一个观测变量后使得模型在识别市场状态时更为精准。。

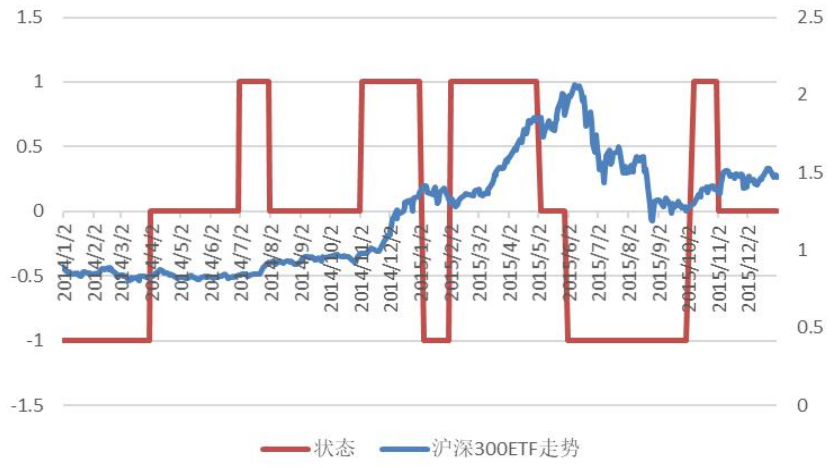
训练集及状态预测：以 T-23 月至 T 月的观测序列作为模型的训练集，利用 HMM 模型对市场状态进行月频识别。由于我们在识别的频率上采用了月度频率，我们认为市场状态具有一定正向“粘性效应”，认定未来一个月（T+1 月）的市场潜在状态与当前识别的市场潜在状态一致，即$\widehat{State_{A_j,T+1}} = State_{A_j,T}$。

状态识别：基于 HMM 模型的 FOF 资产配置为动态过程，关于状态的识别因收益率和收益风险比区间变动而变化，因此还需根据特定信息将状态识别结果与状态集合中的元素一一对应。我们对 24 个月识别的三种状态分别计算平均月收益风险比。平均收益风险比最高的状态列为“上行”，平均收益风险比最低的状态列为“下行”，平均收益风险比处于中间的列为“小幅震荡”。

以单资产沪深 300ETF 为例，选取 2014 年 1 月 1 日至 2015 年 12 月 31 日单位复权净值进行市场状态识别。沪深 300ETF 在状态-1 对应的区间均有明显下跌，例如在 2015 年 6 月至 2015 年 10 月收益率跌至-28.97%；状态 1 对应的区间均显著上涨，例如在 2014 年 11 月至 2014 年末，收益率高达 39.93%；状态 0 对应的区间亦有小幅上涨或下跌，但相较其他状态有明显的波动。从各个状态平均月收益率及平均月收益风险比来看，状态 1 具有最高的平均收益及平均月收益风险比，分别录得 12.51%与 0.443，因此将其认定为市场处于上行状态；状态-1 平均收益率-6.49%，平均收益风险比-0.131，在三种状态中处于最低位，因此认为市场处于下行状态；状态 0 平均收益率及收益风险比接近 0，认为该市场伴有小幅震荡。

图1：沪深300ETF走势与对应识别市场状态

“慧博资讯”专业的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn



数据来源：WIND，财通证券研究所

表3：利用HMM模型识别各状态情况

状态	平均收益率	平均收益风险比	市场机制
1	12.51%	0.443	上行
0	1.60%	0.075	小幅震荡
-1	-6.49%	-0.131	下行

数据来源：WIND，财通证券研究所

4、 基于隐马尔科夫模型（HMM）策略构建组合回测

在全球大类资产配置中，我们选用A股权益类、债券类、QDII权益、商品类资产进行回测，并选用在国内市场交易较活跃的指数型ETF作为回测的标的资产。具体地讲，权益选用沪深300ETF、中证500ETF、标普500ETF、纳指ETF、H股ETF；债券类选用国债ETF；商品资产则选用黄金ETF。这些资产基本覆盖了国内FOF市场上主流的可投资标的，且在资产类别上进行了较高的分散，使得组合内各资产间的相关性较低，达到分散风险的效果。

行业配置与全球大类资产配置方法类似，将HMM模型运用于行业指数基金构建组合。由于目前国内市场上行业指数ETF较少，因此为了方便统一采用对应的申万一级行业指数进行替代。同时，构建传统等权组合（EQ）、股债四六组合（60/40）、均值-方差模型组合（Markowitz）以及动量策略组合（MOM）与HMM策略组合进行比较。为在频率上保持一致，其中Markowitz组合的权重采用过去一个月的收益均值与协方差进行估计，MOM采用过去12个月的资产收益决定是否持仓。

4.1 单一资产回测表现

在多资产构建组合前，我们首先考察单一资产在HMM模型下的表现。我们对沪深300ETF、中证500ETF、标普500ETF、纳指ETF、H股ETF、国债ETF、黄金ETF

“慧博资讯”专业的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

交易日复权单位净值进行回测，由于部分 ETF 在国内成立时间较晚，因此数据范围从上述 ETF 上市时间中最晚年份后一年年初开始至今，即 2014 年 1 月 1 日至 2020 年 11 月 30 日。由于 HMM 模型需要 24 个月的交易数据进行模型训练和参数估计，因此回测区间为 2016 年 1 月 1 日至 2020 年 11 月 30 日。

单一资产的走势于 HMM 模型策略下总体在风险上得到较强控制，其年化波动率与最大回撤较被动投资下情形有明显减小，以标普 500ETF 为例，其净值最大回撤高达 32.95%，但在 HMM 模型下最大回撤仅 10.89%；但 HMM 模型策略为资产贡献的收益不容乐观，例如黄金 ETF 净值年化收益高达 8.61%，而 HMM 模型策略下仅获得 3.52%的收益。获得低风险低收益的原因在于该策略只允许资产在市场机制稳定上行的情况下在等权分配下被赋予全部权重，而部分情况下，资产的上涨往往伴有很大程度的波动，或者中途伴有小幅下跌，这些均可能被 HMM 模型识别为小幅震荡状态，而遇震荡市场则减仓的策略无法捕捉到震荡期上涨的全部收益。尽管收益与被动策略有差距，但从盈亏比上看，差距并没有这么明显，甚至实现反超，说明 HMM 模型策略在市场稳定上行的状态下能够为资产贡献稳定的涨幅以及在市场衰退或震荡的状态下避免过多的损失。

表4：单资产HMM策略下回测表现

标的	策略/净值	区间收益	年化收益率	年化波动率	最大回撤	夏普比率	日胜率	月胜率	日盈亏比	月盈亏比
沪深300ETF	HMM	14.05%	1.85%	10.63%	25.37%	0.055	24.16%	42.37%	1.059	1.240
	NAV	43.62%	5.17%	16.17%	31.19%	0.281	35.30%	62.71%	1.086	1.427
中证500ETF	HMM	-2.40%	-0.34%	11.16%	28.39%	-0.136	24.55%	38.98%	0.990	0.960
	NAV	-11.11%	-1.63%	19.75%	45.49%	-0.075	35.30%	45.76%	0.977	0.893
标普500ETF	HMM	62.33%	6.97%	7.06%	10.89%	0.735	24.94%	55.93%	1.301	3.079
	NAV	83.90%	8.85%	15.97%	32.95%	0.499	35.36%	72.88%	1.148	1.852
纳指 ETF	HMM	62.83%	7.02%	8.43%	13.08%	0.633	25.00%	50.85%	1.253	2.506
	NAV	162.81%	14.39%	18.29%	27.86%	0.729	36.53%	71.19%	1.201	2.308
H 股 ETF	HMM	-7.69%	-1.11%	10.11%	32.08%	-0.238	23.72%	42.37%	0.974	0.883
	NAV	23.02%	2.92%	16.39%	26.97%	0.148	33.91%	55.93%	1.036	1.190
国债 ETF	HMM	8.49%	1.14%	0.93%	1.93%	-0.718	26.61%	52.54%	1.433	2.387
	NAV	9.76%	1.30%	1.36%	4.50%	-0.369	36.25%	64.41%	1.233	1.794
黄金 ETF	HMM	27.70%	3.46%	6.77%	9.26%	0.270	23.33%	38.98%	1.165	2.220
	NAV	62.95%	7.03%	10.35%	17.09%	0.534	34.58%	50.85%	1.151	1.896

数据来源：WIND，财通证券研究所

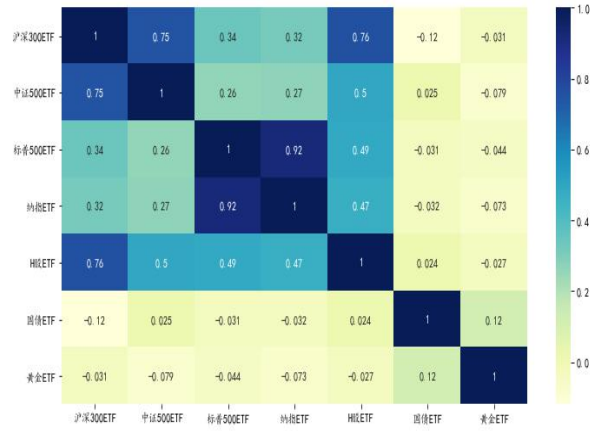
4.2 全球大类资产配置

全球大类资产配置回测标的与回测区间与单资产回测部分的选取相同，组合于每月最后一个交易日进行再平衡，回测区间为 2016 年 1 月 1 日-2020 年 11 月 30 日。

从月收益率及月收益风险比来看，国内权益资产及海外权益资产内部相关性较高，股债黄金间相关性较低，组合涨跌风险得到一定分散。

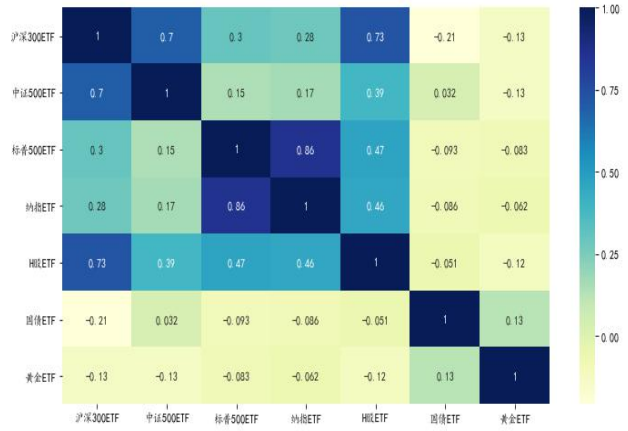
“慧博资讯”专业的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

图2：全球大类资产月收益率相关性热力图



数据来源：WIND，财通证券研究所

图3：全球大类资产月收益风险比相关性热力图



数据来源：WIND，财通证券研究所

从净值走势来看，基于 HMM 模型策略的大类资产配置总体优于传统等权组合、股债四六组合、动量策略组合、均值方差模型组合。在 2016 年初，基于 HMM 模型策略的组合看空所有权益资产，仅持国债 ETF，避开了股灾带来的负面影响。2018 年国内股市迎来大熊市，在此期间，HMM 模型策略组合持有大量国债及海外权益资产 ETF，因此相比等权、股债四六、MOM 组合净值走势一路下行，HMM 模型策略组合经历了很长一段时间的上涨。2020 年疫情爆发后的 HMM 模型策略组合走势呈逊，在 3 月疫情缓解的经济复苏期没有捕捉到上涨机会，且在 7 月股市大涨后持续出现强烈波动。出现该情况可能是受疫情突发事件影响，资产震荡较大，市场状态延续性较差。

图4：全球大类资产配置各策略下组合净值走势



数据来源：WIND，财通证券研究所

从回测组合的各项指标来看，HMM 模型策略组合在区间收益、年化收益、最大回撤、胜率、盈亏比领先于其他组合模型，分别录得 50.10%、5.81%、12.28%、36.30%（日）、1.871（月），相比于第二名分别领先了 3.29%（EQ）、0.32%（EQ）、1.83%（60/40）、0.55%（Markowitz）、0.038（EQ）。HMM 组合净值的波动较大，仅低于 Markowitz 组合。

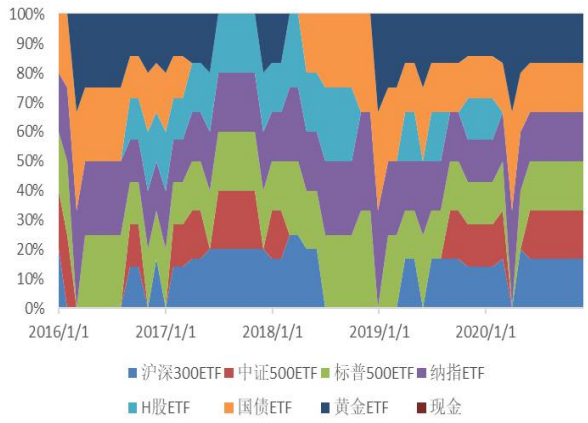
“慧博资讯”专业的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

表5：全球大类资产配置各策略下回测表现

策略	区间收益	年化收益率	年化波动率	最大回撤	夏普比率	日胜率	月胜率	日盈亏比	月盈亏比
HMM	50.10%	5.81%	9.88%	12.28%	0.439	36.30%	74.58%	1.154	1.871
EQ	46.81%	5.49%	8.86%	17.31%	0.444	35.52%	71.19%	1.158	1.833
MOM	35.38%	4.30%	9.19%	18.84%	0.308	35.47%	74.58%	1.123	1.634
60/40	31.38%	3.87%	7.37%	14.11%	0.307	35.02%	71.19%	1.134	1.687
Markowitz	37.58%	4.54%	15.32%	27.23%	0.249	35.75%	69.49%	1.088	1.423

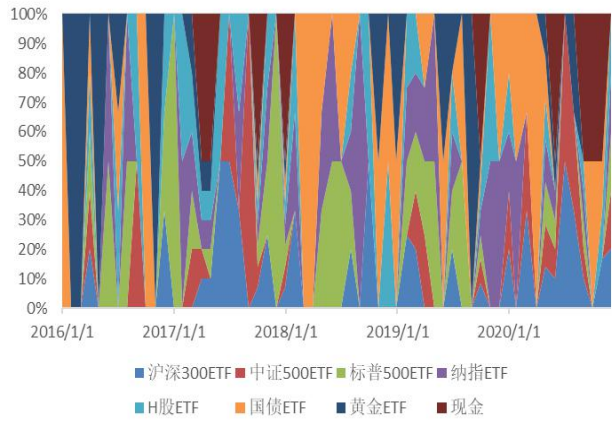
数据来源：WIND，财通证券研究所

图5：MOM策略下全球大类资产配置情况



数据来源：WIND，财通证券研究所

图6：HMM策略下全球大类资产配置情况



数据来源：WIND，财通证券研究所

不同于等权及四六组合资产配置情况，MOM与HMM模型下的资产配置模式均为对各类资产进行动态调整其持仓权重变化范围较大，因此组合对资产持仓比例调配的变动灵活性较高。相比于MOM策略，HMM模型下的资产配置对市场反应更灵敏，在市场下行期间增持债、黄金、现金等避险资产，而在市场回暖后迅速增配股票等权益资产，反应了一定的大类资产的“择时”能力，而MOM策略下资产配置对于市场变化反应具有一定延迟性，例如在2020年疫情后国内经济回升期至九月底，MOM模型下组合持有沪深300ETF、标普500ETF、中证500ETF、纳指ETF、国债ETF、黄金ETF比例较为平均，均接近16.6%，而此时正值国外疫情爆发期，HMM模型下的组合持有跨境资产比例为0%，7月迎来A股大牛市，组合持有100%的沪深300ETF和中证500ETF，但随着股市回落后减配权益资产并增配现金。

对市场变化反应差异这是由于MOM策略下单一资产持仓情况取决于过去12个月的收益是否为正，如果在过去一个月内资产下跌幅度小于去年该月的上涨幅度，则下月依然持有该资产；而HMM模型下单一资产持仓情况只取决于当前潜在的市场状态，对市场机制转变反应更快，因此HMM模型下的资产配置能够在市场状态好时获得更高收益，而在市场下行状态时规避时能够更早的识别这一状态，从而最大程度的规避掉这一风险。

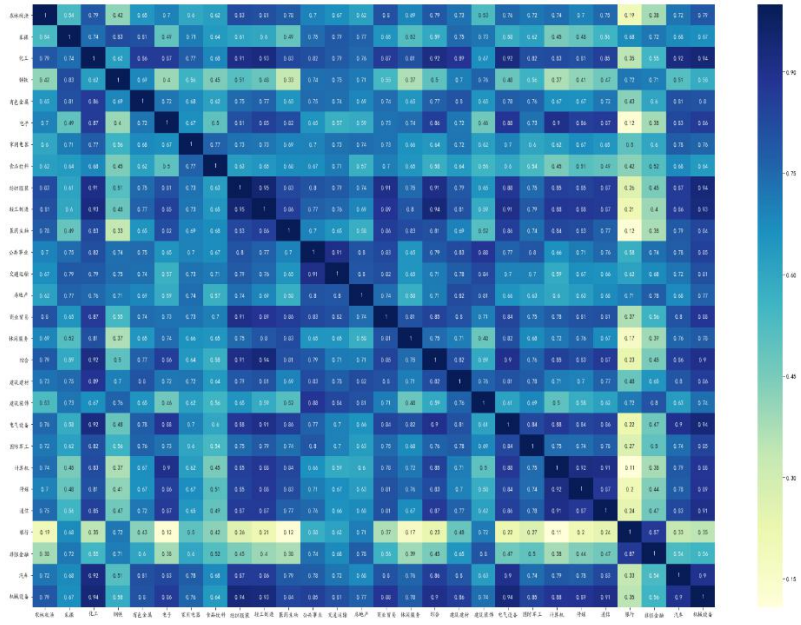
5、 行业配置

从月收益率和月收益风险比的相关性热力图来看，各行业间的相关性较大，分散

“慧博资讯”专业的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

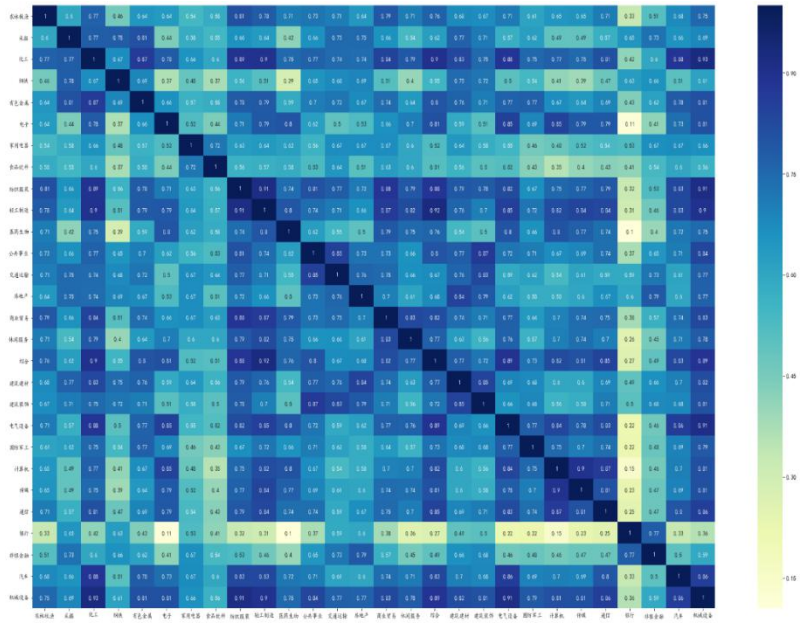
性不明显。

图7：申万一级行业月收益率相关性热力图



数据来源：WIND，财通证券研究所

图8：申万一级行业月收益风险比相关性热力图



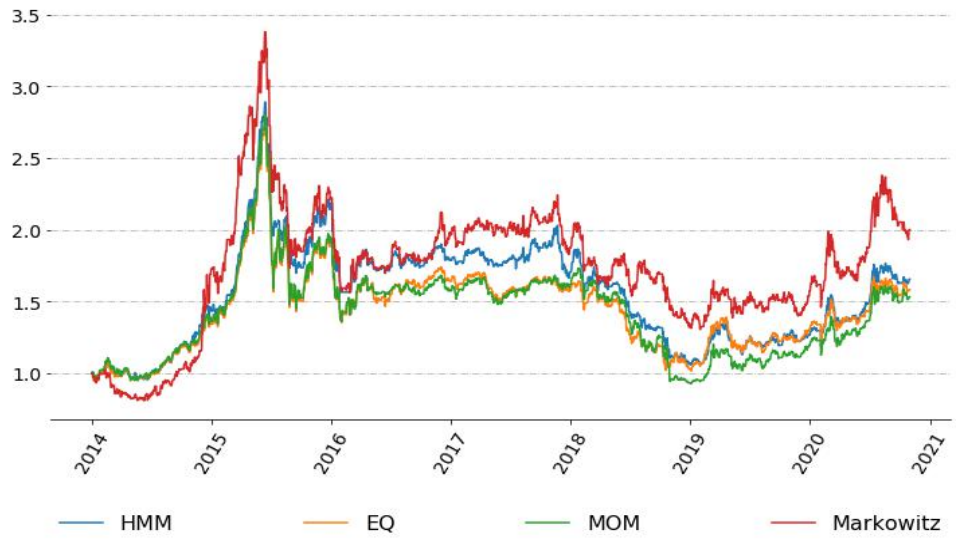
数据来源：WIND，财通证券研究所

以申万一级行业指数为模拟的开放式基金作为标的资产，回测区间为 2010 年 1 月 1 日至 2020 年 11 月 30 日，于每月最后一个公共交易日重新计算权重进行调仓。由于部分行业利用 24 个月的交易数据进行训练时，存在市场状态转移概率为 0 的情况，即某些状态的转移没有观测数据覆盖，训练数据较少，因此在此回测中我们将 HMM 模型需训练集拉长至 48 个月，因此回测区间为 2014 年 1 月 1 日

“慧博资讯”专业的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

至 2020 年 11 月 30 日。

图9：行业配置各策略下组合净值走势



数据来源：WIND，财通证券研究所

从净值走势来看，基于 HMM 模型策略的行业资产配置效果并无优势，在 2015 年初期涨幅与其他组合并无差别，且在行情回转后也没有守住跌势。2018 年和 2020 年中旬，基于 HMM 模型的行业配置不如 Markowitz 组合捕获到一段上涨期。从各项回测指标来看，其区间收益率 79.31%、年化收益率 5.95%、年化波动率 18.89%、最大回撤 64.23%、夏普比率 0.302，仅在波动性指标上优于 Markowitz 模型组合。基于行业轮动现象，行业指数的正向动量效应不明显，市场状态在通常条件下不具备连续性，因此 HMM 模型策略用于行业配置表现不如大类资产配置表现强劲。

表6：行业配置各策略下回测表现

	区间收益	年化收益率	年化波动率	最大回撤	夏普比率	日胜率	月胜率	日盈亏比	月盈亏比
HMM	79.31%	5.95%	18.89%	64.23%	0.302	34.96%	56.63%	1.062	1.266
EQ	66.34%	5.16%	20.12%	63.20%	0.259	35.55%	57.83%	1.052	1.229
MOM	59.86%	4.75%	20.59%	66.91%	0.239	34.76%	62.65%	1.046	1.199
Markowitz	117.75%	8.00%	24.57%	61.35%	0.361	35.19%	54.22%	1.061	1.278

数据来源：WIND，财通证券研究所

6、 总结

近年来，基于市场状态转换的动态资产配置深受投资者青睐。本报告利用了 HMM 模型识别各类资产走势背后潜在的市场状态，并基于该识别状态构建 FOF 组合回测其相关表现。

本文将 HMM 模型创新性的运用到大类资产间的识别和配置上，以此来构建出大类资产上的组合配置策略，而且不同于以往的是，在识别方法上本文不同于前期的研究仅仅拘泥于单只股票或者期货的价格，我们在此同时选取了各类资产的区间收益和收益风险比作为观测值，这一方法的创新之处在于根据金融理论，收益风

“慧博资讯”专业的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

险比是衡量金融资产背后潜在机制最为通用且不直接可观测的指标，将收益风险比这一本身不能直接观测的变量引入到 HMM 模型中作为一个间接观测变量来充当观测变量使得模型在识别市场状态时更为精准有效。

基于高斯分布的 HMM 模型在很大程度上能够精确识别各类资产背后潜在的涨跌状态。只要部分资产的市场状态存在，该策略组合能够捕捉上涨机会，同时降低踩错行情（做多或者空仓）的风险。该组合在各类资产间可以灵活的改变权重。使得组合在资产间的择时能力大幅增强。

从策略回测表现看，HMM 模型策略在全球大类资产配置中表现较好。尽管在单一资产上，HMM 择时模型带来的收益不如直接持有策略下的收益，但在 FOF 投资中，为了达到分散化目的，标的资产走势间走势往往呈负相关或者弱正相关，其实标的资产间的负相关或者弱正相关意味着背后潜在市场状态是相背离的，市场状态向上的资产获得的收益能部分弥补市场状态向下的资产可能带来的潜在损失，从而降低组合整体净值的波动风险，因此在全球大类资产配置和行业配置的回测中，组合的整体收较传统的常见组合较好，且整体风险也得到良好的控制。而 HMM 模型策略在行业配置中表现强差人意，由于 A 股存在着过于显著的行业轮动现象，单纯将最后一个月的市场状态作为下个月市场预测状态将与真实情况存在一定偏差，导致整体表现不如均值-方差模型组合。

7、 后续研究展望

在本文的研究过程中，激发了我们进一步的思考，HMM 这一模型在大类资产配置的识别上，只要选出合适的观测值序列，能够非常精确的识别出背后市场的潜在状态，这一发现给了我们重要启示，在 FOF 策略中标的基金的选择，常常需要参考其在择时能力上的表现，现有的一些方法都无法精准的识别其择时时点并量化其择时时点的选择能力，而 HMM 模型正好可以应用到这一点上，通过识别出单只基金潜在的调仓时点，并序列化之后，得到相应的基金择时量化指标，从而为基金筛选提供一个重要的参考指标。

信息披露

分析师承诺

作者具有中国证券业协会授予的证券投资咨询执业资格，并注册为证券分析师，具备专业胜任能力，保证报告所采用的数据均来自合规渠道，分析逻辑基于作者的职业理解。本报告清晰地反映了作者的研究观点，力求独立、客观和公正，结论不受任何第三方的授意或影响，作者也不会因本报告中的具体推荐意见或观点而直接或间接收到任何形式的补偿。

资质声明

“慧博资讯”专业的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn

财通证券股份有限公司具备中国证券监督管理委员会许可的证券投资咨询业务资格。

公司评级

买入：我们预计未来 6 个月内，个股相对大盘涨幅在 15%以上；
增持：我们预计未来 6 个月内，个股相对大盘涨幅介于 5%与 15%之间；
中性：我们预计未来 6 个月内，个股相对大盘涨幅介于-5%与 5%之间；
减持：我们预计未来 6 个月内，个股相对大盘涨幅介于-5%与-15%之间；
卖出：我们预计未来 6 个月内，个股相对大盘涨幅低于-15%。

行业评级

增持：我们预计未来 6 个月内，行业整体回报高于市场整体水平 5%以上；
中性：我们预计未来 6 个月内，行业整体回报介于市场整体水平-5%与 5%之间；
减持：我们预计未来 6 个月内，行业整体回报低于市场整体水平-5%以下。

免责声明

本报告仅供财通证券股份有限公司的客户使用。本公司不会因接收人收到本报告而视其为本公司的当然客户。

本报告的信息来源于已公开的资料，本公司不保证该等信息的准确性、完整性。本报告所载的资料、工具、意见及推测只提供给客户作参考之用，并非作为或被视为出售或购买证券或其他投资标的邀请或向他人作出邀请。

本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的价格、价值及投资收入可能会波动。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。

本公司通过信息隔离墙对可能存在利益冲突的业务部门或关联机构之间的信息流动进行控制。因此，客户应注意，在法律许可的情况下，本公司及其所属关联机构可能会持有报告中提到的公司所发行的证券或期权并进行证券或期权交易，也可能为这些公司提供或者争取提供投资银行、财务顾问或者金融产品等相关服务。在法律许可的情况下，本公司的员工可能担任本报告所提到的公司的董事。

本报告中所指的投资及服务可能不适合个别客户，不构成客户私人咨询建议。在任何情况下，本报告中的信息或所表述的意见均不构成对任何人的投资建议。在任何情况下，本公司不对任何人使用本报告中的任何内容所引致的任何损失负任何责任。

本报告仅作为客户作出投资决策和公司投资顾问为客户提供投资建议的参考。客户应当独立作出投资决策，而基于本报告作出任何投资决定或就本报告要求任何解释前应咨询所在证券机构投资顾问和服务人员的意见；

本报告的版权归本公司所有，未经书面许可，任何机构和个人不得以任何形式翻版、复制、发表或引用，或再次分发给任何其他人，或以任何侵犯本公司版权的其他方式使用。

“慧博资讯”专业的投资研究大数据分享平台
点击进入 http://www.hibor.com.cn