基于日内量价结构的神经网络因子挖掘框架

华泰研究

2026 年 10 月 15 日 | 中国内地 深度研究

浦彦恒* 研究员
SAC No. S0570526070005 puyanheng@htsc.com
+(86) 21 2897 2228

沈洋* 研究员
SAC No. S0570525070013 shenyang023029@htsc.com
+(86) 21 2897 2228

王晨宇 研究员
SAC No. S0570522010001 wangchenyu@htsc.com
SFC No. BTM049 +(86) 21 3847 6179

人工智能 106：基于日内量价结构的神经网络因子挖掘框架

日内量价路径蕴含了价格变化、成交活动及其时序关系的信息，固定的统计规则可能难以充分提取其中的有效信号。本文构建 Value–Weight 神经网络因子挖掘框架，将分钟信息表达与时序权重生成分离，通过多头联合学习获得一组可独立评价和组合的日频因子。2017-01-04 至 2026-09-30 的回测显示，挖掘因子与人工高频特征构建的模型等权合成后，后者的 RankIC 由 10.8%提升至 12.2%，多头组年化超额收益由 18.1%提升至 22.5%。进一步将其纳入全频段量价因子，中证 1000 指增组合年化超额收益由 17.7%提升至 19.3%，信息比率由 3.18 提升至 3.33。

实验方法：分钟信息表达与时序权重分离，多头联合挖掘日频因子

本文以个股单日 240 根分钟 K 线为输入，将因子生成划分为三个环节：（1）分钟信息表达：Value 模块采用固定公式或可学习网络，描述每一分钟的价格形态与成交信息。（2）时序权重生成：Weight 模块采用 GRU 或 Transformer，根据当日量价路径学习各分钟的相对重要性。（3）日频聚合：各输出头分别对分钟信息加权求和，形成 50 个日频因子。模型在损失函数中结合合成监督、逐头监督和去相关约束，同时优化整体预测能力、单因子有效性与头间冗余，并采用季度滚动方式开展三组对比实验。

实验结果：价格类表达效果较优，可学习因子合成后提供增量

实验结果显示：（1）固定 Value 组中，分钟收益、收盘位置、实体比例等价格类表达表现较优，Transformer Weight 在这类因子上的表现整体强于 GRU。（2）可学习 Value 组 50 个因子的 RankIC 主要集中在 5%至 7%，头间相关性较低，等权合成后的预测能力和多头表现均有提升。（3）在 2017-01-04 至 2026-09-30 的回测区间内，将可学习 50 头等权因子与人工高频特征构建的高频量价分支等权合成，RankIC 由后者的 10.8%提升至 12.2%，多头组年化超额收益由 18.1%提升至 22.5%，体现出两类信息提取方式的互补性。

指增组合测试：高频增强提升超额收益，动量与多路径改善回撤

将挖掘因子加入全频段量价因子的高频分支，构建中证 1000 指数增强组合。在 2017-01-04 至 2026-09-30 的历史回测中，高频增强组的年化超额收益由原全频段组合的 17.7%提升至 19.3%，信息比率由 3.18 提升至 3.33，超额收益最大回撤由 16.1%下降至 14.2%。考虑到量价因子在强动量行情中的回撤风险，进一步加入由行业成交集中度及上涨趋势共同控制的抱团动量因子，并采用五路径周频调仓。两项调整后，组合年化超额收益达到 20.2%，信息比率 4.25，超额收益最大回撤降至 7.1%。

风险提示：人工智能挖掘市场规律是对历史的总结，市场规律在未来可能失效。深度学习模型受随机数影响较大。本文回测假定以 VWAP 价格成交，未考虑其他影响交易因素。

正文目录

基于日内量价结构的神经网络因子挖掘 4

实验方法 5

Value 模块：分钟信息表达 5

Weight 模块：时序权重生成 7

日频因子聚合 7

损失函数设计 8

实验设置 8

实验结果 9

因子挖掘效果 9

固定 Value 组 9

可学习 Value 组 12

因子合成 15

组合实证 17

总结 20

参考文献 20

风险提示 20

图表目录

图表 1： 基于日内量价结构的神经网络因子挖掘 4

图表 2： 中证 1000 指数增强组合超额收益净值及回撤 4

图表 3： 模型结构示意图 5

图表 4： 分钟量价信息表达示例 6

图表 5： 可学习 Value 模块的输入特征 6

图表 6： 可学习 Value 模块网络结构 6

图表 7： Weight 模块网络结构 7

图表 8： 日频因子聚合示意图 7

图表 9： 模型训练细节 8

图表 10： 固定 Value + GRU Weight 挖掘因子表现 9

图表 11： 固定 Value + Transformer Weight 挖掘因子表现 9

图表 12： 固定 Value 组因子回测指标汇总 9

图表 13： GRU 组累计 RankIC 净值 10

图表 14： Transformer 组累计 RankIC 净值 10

图表 15： GRU 组多头超额收益净值 10

图表 16： Transformer 组多头超额收益净值 10

图表 17： 固定 Value + Transformer Weight 挖掘因子相关性 11

图表 18： 分钟收益因子：GRU 与 Transformer Weight 间相关性 12

图表 19： 可学习 Value＋GRU Weight 挖掘因子表现 12

图表 20： 可学习 Value 组因子回测指标汇总 13
图表 21： 可学习组部分因子累计 RankIC 净值 13
图表 22： 可学习组 50 因子等权累计 RankIC 净值 13
图表 23： 可学习组部分因子多头超额收益净值 13
图表 24： 可学习组 50 因子等权多头超额收益净值 13
图表 25： 可学习 Value + GRU Weight 挖掘因子相关性 14
图表 26： 全频段量价因子构造方式 15
图表 27： AI 高频量价因子回测指标汇总 15
图表 28： AI 高频量价因子累计 RankIC 净值 15
图表 29： AI 高频量价因子多头超额收益净值 15
图表 30： 高频量价分支与可学习 50 头等权因子相关性 16
图表 31： 高频增强全频段量价因子示意图 16
图表 32： 高频增强全频段量价因子回测指标汇总 17
图表 33： AI 高频量价因子累计 RankIC 净值 17
图表 34： AI 高频量价因子多头超额收益净值 17
图表 35： 组合优化及回测细节 17
图表 36： 高频增强组中证 1000 指数增强组合业绩对比 18
图表 37： 高频增强组中证 1000 指数增强组合超额收益净值及回撤对比 18
图表 38： 动量优化组中证 1000 指数增强组合业绩对比 19
图表 39： 动量优化组中证 1000 指数增强组合超额收益净值及回撤对比 19
图表 40： 动量优化组中证 1000 指数增强组合各区间超额收益 19

基于日内量价结构的神经网络因子挖掘

日内量价信息的预测价值不仅取决于价格变化和成交活动的强弱，也与其发生时点及演化过程有关。相近的日收益率和成交量，可能对应不同的日内路径，蕴含不同的交易信息。人工高频因子通常通过预设时段和统计公式刻画这些差异，具有较强的可解释性，但固定的信息提取方式对不同股票和交易状态的适应性存在局限。

本文构建基于日内量价结构的神经网络因子挖掘框架，将因子生成拆分为分钟信息表达（Value）与时序权重生成（Weight）两个模块。Value 通过固定公式或可学习网络描述分钟量价信息，Weight 根据当日路径分配不同分钟的权重，两者加权聚合得到多个日频因子。模型结合逐头收益监督与去相关约束，兼顾单因子的预测能力和因子间的互补性。

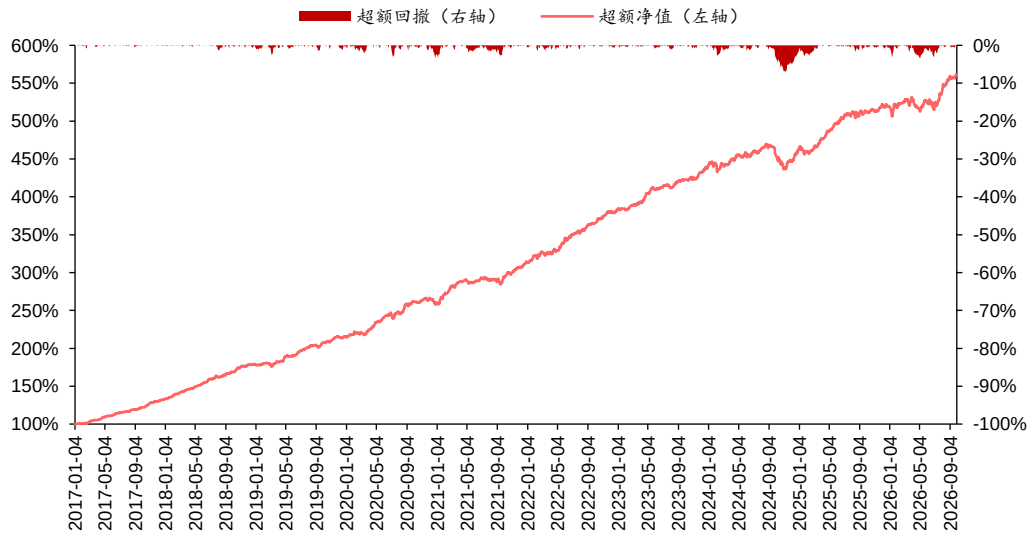
图表1：基于日内量价结构的神经网络因子挖掘



资料来源：华泰研究

本文围绕 Value 表达方式及 GRU、Transformer 两类时序网络设置三组实验，实证结果表明，固定 Value 中的价格类表达具有较好的选股效果；可学习 Value 生成的因子具有一定互补性，等权合成后预测能力进一步提升，并能为人工高频特征构建的模型提供增量信息。自 2017-01-04 至 2026-09-30，高频增强后的全频段因子对应中证 1000 指增组合年化超额收益由 17.7%提升至 19.3%；进一步加入抱团动量因子并采用多路径调仓后，年化超额收益达到 20.2%，信息比率 4.25，超额收益最大回撤为 7.1%。

图表2：中证 1000 指数增强组合超额收益净值及回撤



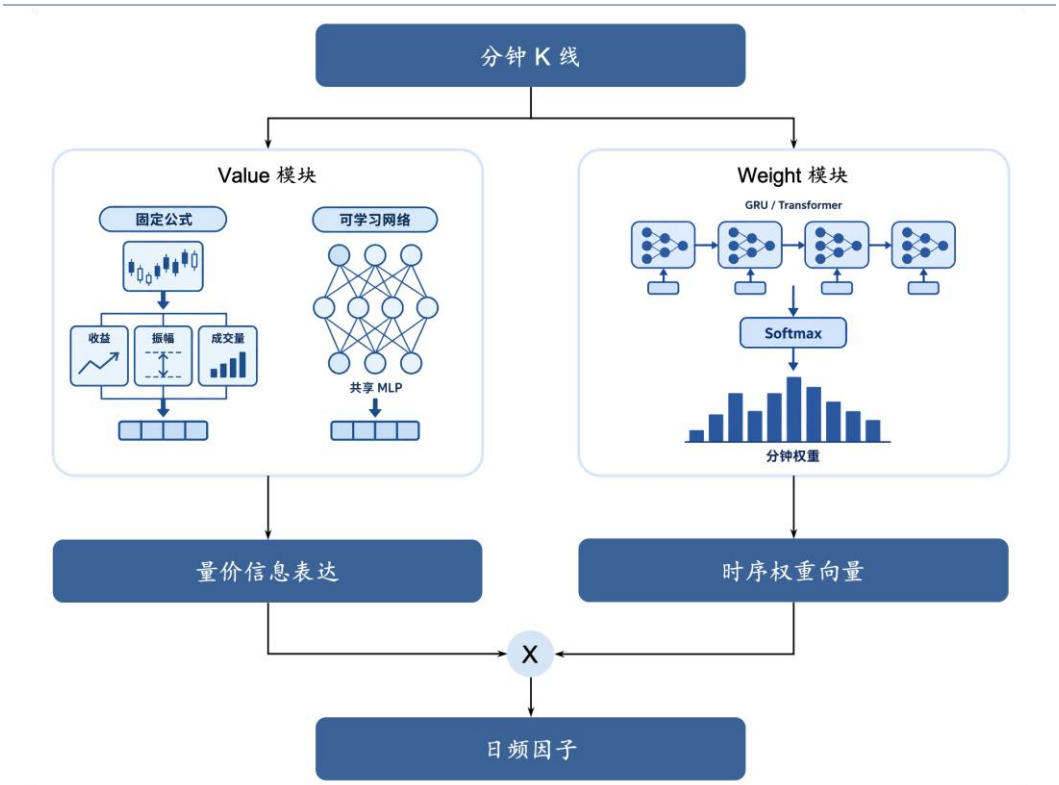
注：回测区间 2017-01-04 至 2026-09-30。
资料来源：Wind，华泰研究

实验方法

日内量价信息的预测作用可能随发生时点变化，固定的统计区间与聚合规则未必能充分反映这种差异。借鉴 Beckmeyer 和 Wiedemann（2025）在 CMM 模型中学习历史日收益权重的思路，本文根据个股当日量价路径，利用神经网络学习不同分钟的聚合权重，构建一套日内时序量价因子挖掘模型。

模型包括**分钟信息表达**、**时序权重生成**和**日频聚合**三个环节。个股单日的分钟 K 线分别输入 Value 与 Weight 模块：Value 模块生成各分钟的量价表达，Weight 模块生成各头对应的分钟打分；打分经 Softmax 转化为权重后，对 Value 加权求和，得到多个日频输出头，作为模型优化对象。模型整体结构如下。

图表3：模型结构示意图



资料来源：华泰研究

Value 模块：分钟信息表达

Value 模块描述每一分钟包含的价格形态与成交信息，本文通过**固定公式**或**可学习网络**两种方式生成日内量价信息表达。用于生成量价信息表达的输入特征为分钟 K 线，包含高开低收、成交均价、成交量、成交额和成交笔数共 8 个字段，股票 i 在交易日 t、分钟 m 的分钟 K 线特征表示为 $x_{i,t,m}$。

固定 Value 通过预设函数提取分钟特征。设 $k(h)$ 为输出头 h 对应的公式编号，则：

$$v_{i,t,m,h} = \phi_{k(h)}(x_{i,t,m})$$

同一公式可以配置多个输出头：这些头共享相同的分钟 Value，但使用 Weight 模块生成的不同权重，因而可以形成不同时间加权模式的因子。本文构造 10 类简单表达公式作为示例，具体计算方式如下。

图表4：分钟量价信息表达示例

价格类	计算方式	成交类	计算方式
分钟收益	$100\ln(C/O)$	成交量	V
成交均价偏离	$100\ln(C/\mathrm{VWAP})$	成交额	A
分钟振幅	$100\ln(H/L)$	成交笔数	N
收盘位置	$(C-L)/(H-L)$	每笔成交金额	A/N
实体占比	$(C-O)/(H-L)$	每笔成交量	V/N

资料来源：华泰研究

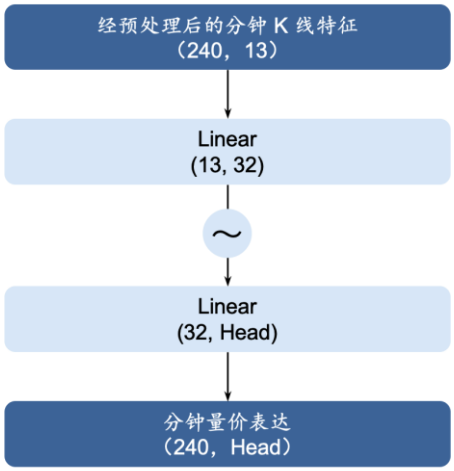
可学习 Value 则由神经网络直接学习分钟特征，每一分钟直接输出 H 维量价表达。其中输入分钟特征中包含经预处理的量价字段及时间编码等，具体处理方式如下。神经网络则由两层线性层构成，网络参数在股票和分钟之间共享，各输出维度联合学习，不再与某一固定公式一一对应。

图表5：可学习 Value 模块的输入特征

类别	维数	具体输入与处理
价格路径	5	Open、High、Low、Close、VWAP，分别计算 100 × ln(价格 / 当日首分钟开盘价)，并截断至[-20, 20]
相对成交活跃度	3	成交量、成交额、成交笔数，分别计算 ln(1 + 当前分钟数值 / 当日分钟均值)
绝对成交规模	3	成交量、成交额、成交笔数，分别计算 ln(1 + 数值) / 20
分钟位置	2	将 240 分钟的位置映射为 q ∈ [-1, 1]，使用 q 和 cos(πq)

资料来源：华泰研究

图表6：可学习 Value 模块网络结构

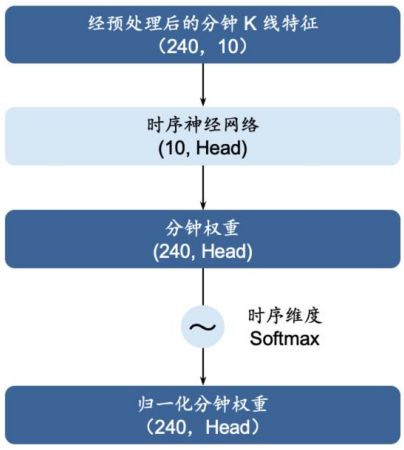


资料来源：华泰研究

Weight 模块：时序权重生成

Weight 模块根据当日量价路径生成分钟打分，并通过 Softmax 归一化，为各输出头生成日内 240 分钟的逐分钟权重。结构如下。

图表7：Weight 模块网络结构



资料来源：华泰研究

其中 Weight 模块输入特征与上节可学习 Value 模块基本一致，但考虑到 Weight 负责分钟间相对权重分配，因此将 3 个绝对成交规模特征去除，主要根据日内价格路径、成交活动的相对强弱和时间位置分配权重。

本文采用 GRU、Transformer 两种时序神经网络作为 Weight 模块的权重生成模型。记经预处理的当日序列为 $X_{i,t}$，$f_{\theta,h}$ 为第 h 个头的打分函数，则：

$$s_{i,t,m,h} = f_{\theta,h}(X_{i,t}, m)$$

各头分别沿分钟维度进行 Softmax 归一化：

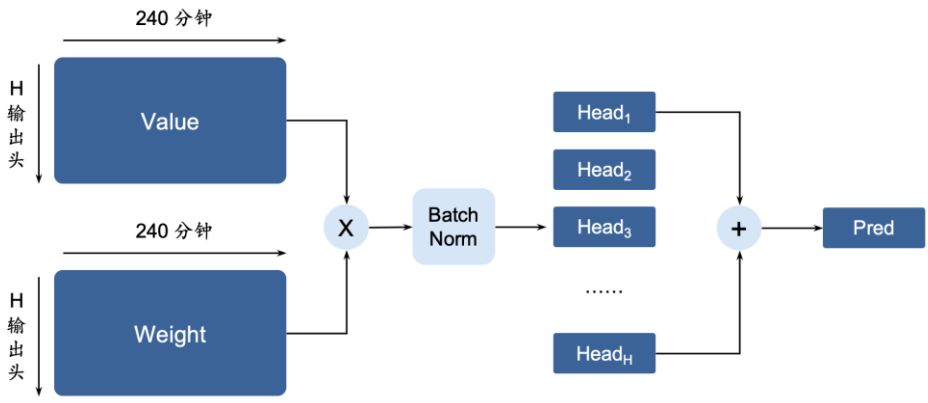
$$\alpha_{i,t,m,h} = \frac{\exp(s_{i,t,m,h}/\tau)}{\sum_{u\in\mathcal{M}_{i,t,h}} \exp(s_{i,t,u,h}/\tau)}$$

其中，$\mathcal{M}_{i,t,h}$ 为该头的有效分钟集合，τ 为温度参数。无效分钟权重直接置零，有效分钟权重之和为 1。

日频因子聚合

得到逐分钟的量价表达和分配权重后，每个输出头将两者在时序上加总，形成原始日频因子，结构如下。

图表8：日频因子聚合示意图



资料来源：华泰研究

为统一不同输出头的数值尺度，在时序加权求和后利用 BatchNorm 对每个截面内各输出头因子进行标准化，其中 BatchNorm 参与梯度计算，但训练与预测均使用当日统计量，不累计跨日均值和方差，也不额外学习平移或缩放参数。模型保留全部 H 个标准化因子，同时也计算其等权平均，作为用于联合监督的合成预测项。

损失函数设计

训练目标同时约束合成预测能力、单头有效性与头间冗余。记 $F_{i,t}$ 为各输出头等权平均的合成预测项，$Z_{i,t,h}$ 为第 h 个输出头经过标准化后的输出因子，$y_{i,t}$ 为未来收益标签，则损失函数定义为：

$$\mathcal{L}_t = L_{\text{agg},t} + \lambda_{\text{head}} L_{\text{head},t} + \lambda_{\text{decorr}} L_{\text{decorr},t}$$

$$L_{\text{agg},t} = -\text{Corr}_i(F_{i,t}, y_{i,t})$$

$$L_{\text{head},t} = -\frac{1}{H}\sum_{h=1}^{H} \text{Corr}_i(Z_{i,t,h}, y_{i,t})$$

$$L_{\text{decorr},t} = \frac{2}{H(H-1)}\sum_{h<k} \text{Corr}_i(Z_{i,t,h}, Z_{i,t,k})^2$$

其中，相关性均为当日股票截面上的 Pearson 相关系数。损失函数定义为三项之和：（1）合成监督项优化整体预测，（2）逐头监督项使每个因子直接接受收益约束，（3）去相关项降低多个头重复表达相似信息的倾向。

实验设置

本文围绕分钟信息表达方式与时序权重生成方式，设置三组因子挖掘实验：

1、 **固定 Value＋GRU Weight**：使用前文定义的 10 类分钟量价公式，每类公式配置 5 个输出头，共生成 50 个日频因子，Weight 模块采用单层 GRU。

2、 **固定 Value＋Transformer Weight**：Value 模块同上，Weight 模块采用单层 Transformer Encoder 生成分钟权重。

3、 **可学习 Value＋GRU Weight**。以前文定义线性层替代固定公式，输出 50 维信息表达。Weight 模块与第一组相同。两部分联合训练，共生成 50 个日频因子，各头的分钟表达与聚合权重均由模型学习。

其余模型训练参数设置及细节如下。

图表9： 模型训练细节

超参数	设置方式
股票池	中证全指
预测标签	未来 5 日收益，按 T+1 至 T+6 的复权收盘价计算
标签预处理	去极值、行业与市值中性化、截面标准化
数据集划分	训练/验证/测试集分别 3/1/1 季度，每季度滚动训练
样本外区间	2010-01-04 至 2026-09-30
优化器	AdamW
学习率	0.001
权重衰减	0.0001
Softmax 温度参数	1
最大训练轮数	40
早停轮数	5

资料来源：华泰研究

实验结果

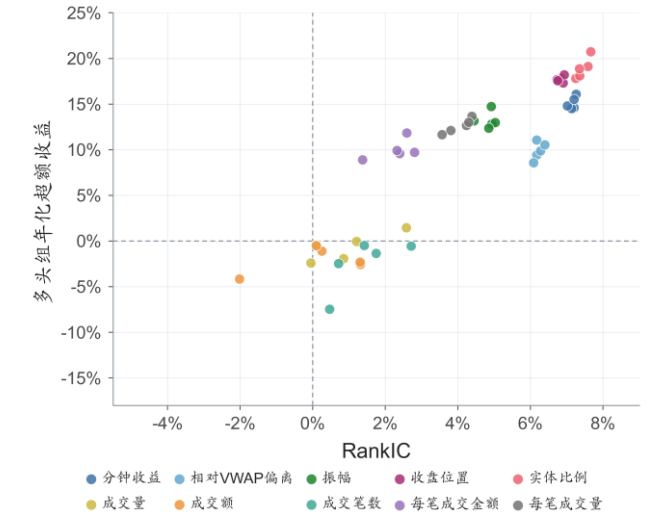
因子挖掘效果

基于上节介绍实验设置，共进行(1)固定 Value＋GRU Weight、(2)固定 Value＋Transformer Weight、(3) 可学习 Value＋GRU Weight 三组实验，以对比量价信息描述方式与时序权重学习模块性能表现。结果汇总如下。

固定 Value 组

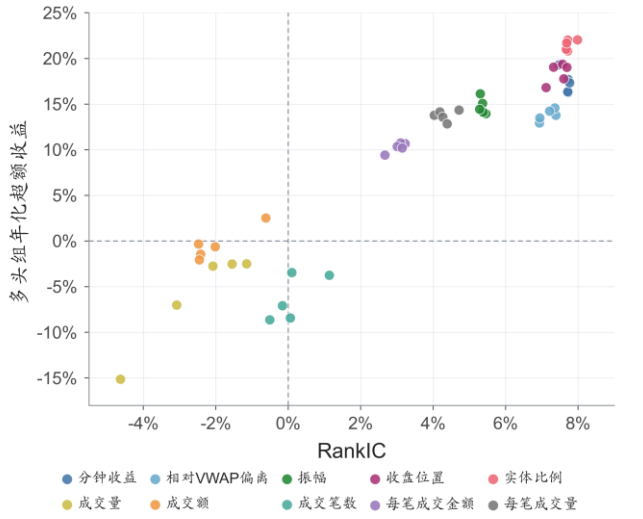
实验（1）、（2）使用 10 种固定量价信息表达作为 Value 网络，各挖掘得到 50 个因子，表现如下。考虑到因子数量较多，本节将同类的 5 个因子等权平均后展示其详细回测指标。

图表10： 固定 Value + GRU Weight 挖掘因子表现



注：回测区间 2010-01-04 至 2026-09-30。
资料来源：Wind，华泰研究

图表11： 固定 Value + Transformer Weight 挖掘因子表现



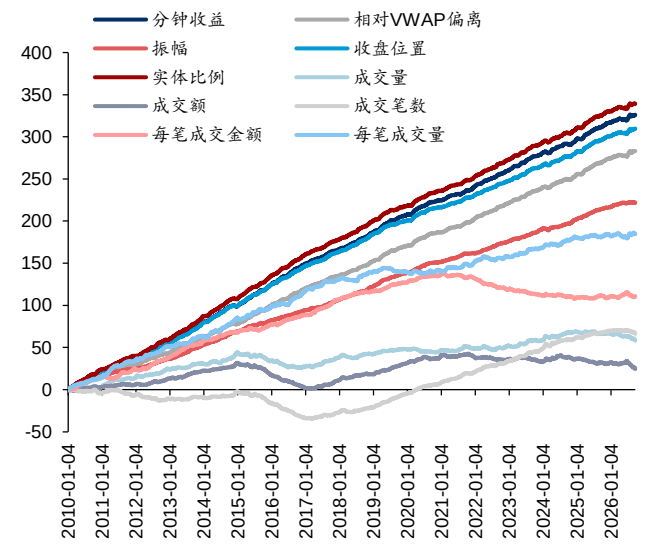
注：回测区间 2010-01-04 至 2026-09-30。
资料来源：Wind，华泰研究

图表12： 固定 Value 组因子回测指标汇总

Weight	Value	IC 均值	RankIC 均值	ICIR	RankICIR	多头组收益	多头组超额	多头组信息比率	空头组超额	|t|均值
GRU	分钟收益	6.5%	8.0%	0.69	0.81	27.7%	17.9%	3.26	-39.7%	5.20
	相对 VWAP 偏离	5.8%	7.0%	0.65	0.75	22.4%	12.9%	2.33	-37.5%	4.81
	振幅	4.8%	5.5%	0.76	0.76	25.3%	16.4%	2.82	-25.9%	3.60
	收盘位置	5.9%	7.6%	0.68	0.87	29.2%	19.4%	3.51	-38.3%	4.72
	实体比例	6.6%	8.4%	0.69	0.87	30.6%	20.7%	3.59	-39.9%	5.24
	成交量	0.1%	1.4%	0.01	0.12	7.9%	-0.7%	-0.09	-10.1%	2.98
	成交额	0.1%	0.6%	0.02	0.06	7.6%	-0.9%	-0.09	-11.1%	3.13
	成交笔数	0.0%	1.6%	0.00	0.15	5.6%	-2.7%	-0.31	-15.1%	3.44
	每笔成交金额	1.6%	2.7%	0.19	0.25	19.6%	10.3%	1.27	-11.5%	3.62
	每笔成交量	2.2%	4.6%	0.22	0.31	23.2%	13.2%	1.61	-15.6%	4.42
Transformer	分钟收益	7.3%	8.7%	0.76	0.86	29.3%	19.4%	3.33	-40.3%	5.45
	相对 VWAP 偏离	6.6%	8.3%	0.69	0.83	25.9%	16.3%	2.94	-38.6%	5.23
	振幅	5.3%	6.4%	0.70	0.78	28.1%	18.6%	3.09	-28.9%	4.02
	收盘位置	7.2%	8.5%	0.77	0.86	31.4%	21.5%	3.42	-39.9%	5.31
	实体比例	7.6%	8.9%	0.82	0.92	35.1%	25.1%	4.16	-41.0%	5.40
	成交量	-0.6%	-1.3%	-0.09	-0.11	5.9%	-2.5%	-0.29	1.6%	2.68
	成交额	0.1%	-0.3%	0.02	-0.03	11.5%	2.8%	0.31	2.6%	2.84
	成交笔数	-0.3%	0.8%	-0.03	0.07	2.6%	-5.5%	-0.63	-8.6%	3.44
	每笔成交金额	2.3%	3.7%	0.28	0.37	21.2%	11.9%	1.54	-15.8%	3.51
	每笔成交量	2.8%	5.1%	0.28	0.37	24.9%	14.9%	1.88	-17.9%	4.48

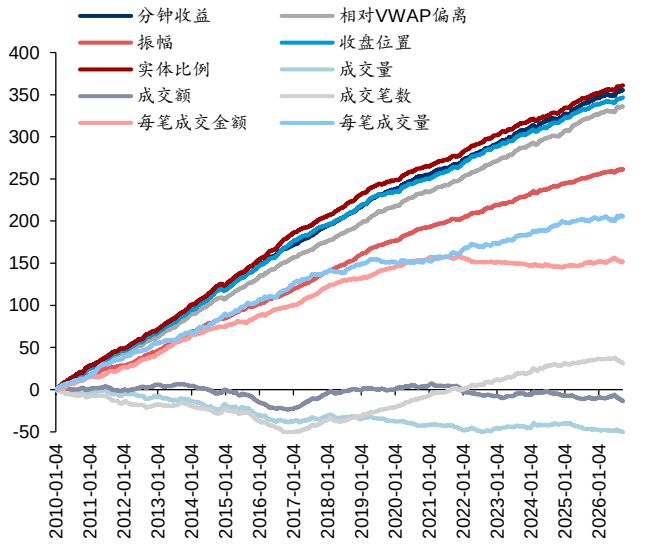
注：回测区间 2010-01-04 至 2026-09-30，IC、回归等指标以 5 日收益为标签，因子十分层回测，周频调仓，不计费率。
资料来源：Wind，华泰研究

图表13： GRU 组累计 RankIC 净值



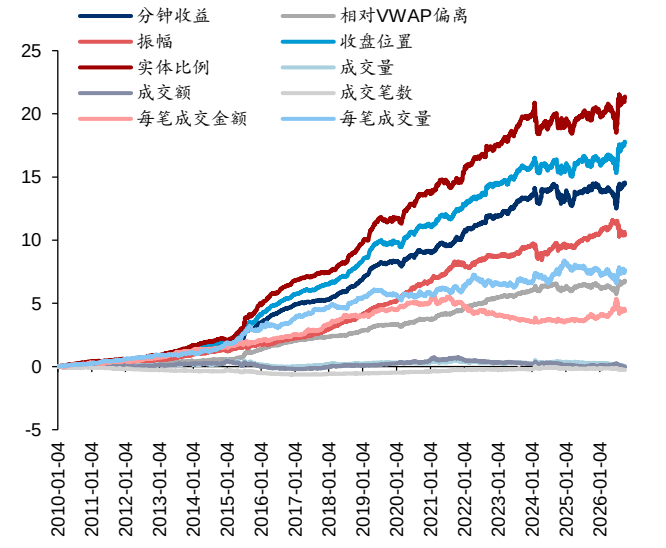
注：回测区间 2010-01-04 至 2026-09-30。
资料来源：Wind，华泰研究

图表14： Transformer 组累计 RankIC 净值



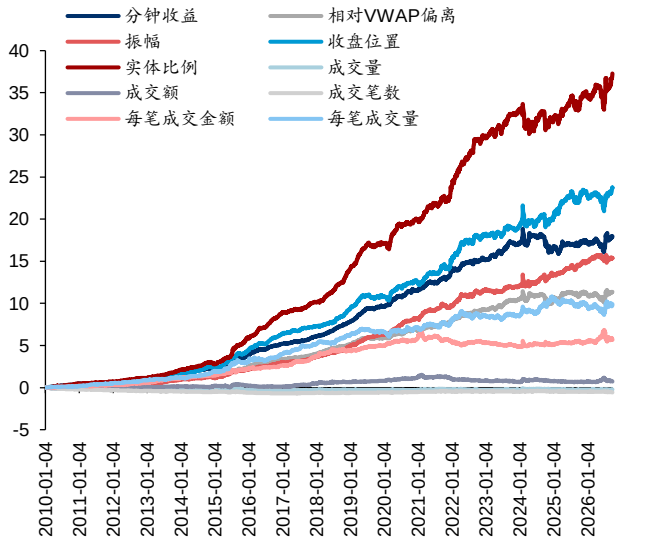
注：回测区间 2010-01-04 至 2026-09-30。
资料来源：Wind，华泰研究

图表15： GRU 组多头超额收益净值



注：回测区间 2010-01-04 至 2026-09-30。
资料来源：Wind，华泰研究

图表16： Transformer 组多头超额收益净值



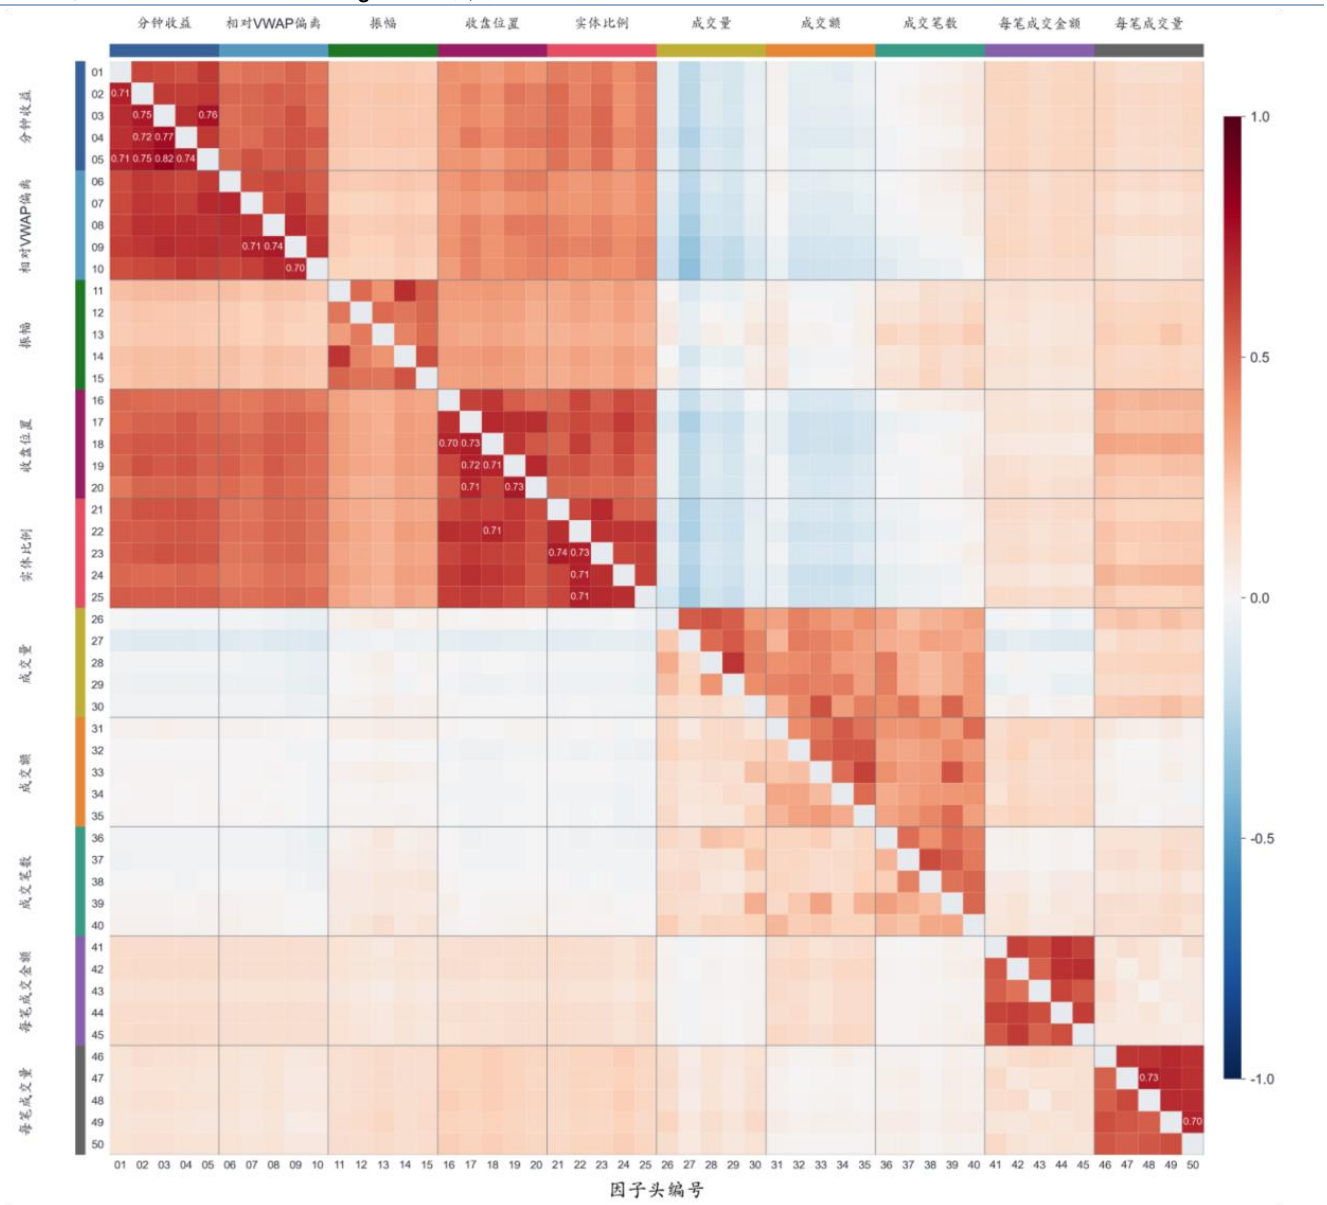
注：回测区间 2010-01-04 至 2026-09-30。
资料来源：Wind，华泰研究

结果表明：

1、 **价格类因子表现强，且时序上较为稳定**，均取得正向 RankIC 和多头组超额；
2、 成交类因子中成交量、成交额和成交笔数基本无效，每笔成交量和每笔成交额有一定效果，但后者在时序上不稳定；
3、 对比 Weight 模型，从挖掘因子的 RankIC 和多头组超额看，**Transformer 各组因子表现均强于 GRU**。

进一步统计因子间相关性，首先对比相同模型挖掘因子间相关性。以固定 Value + Transformer Weight 组为例，结果如下。可以发现，得益于因子挖掘模型在多头输出优化时添加的相关性控制项，50 组因子间相关性均在较低水平，其中**相同类型的 5 个因子间相关性相对较高，但也基本控制在 0.8 以下**。

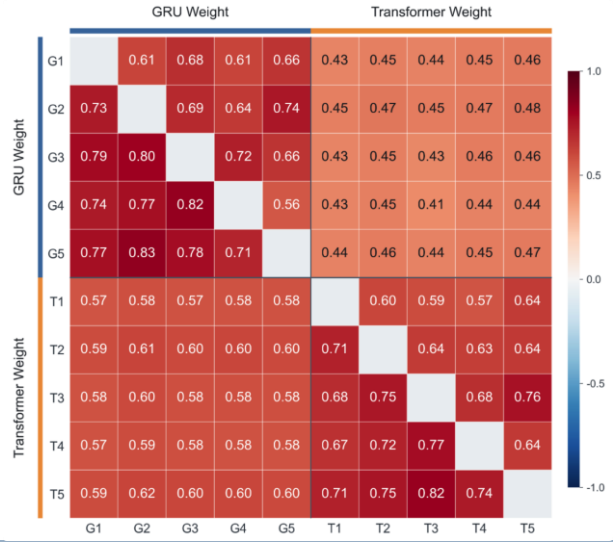
图表17： 固定 Value + Transformer Weight 挖掘因子相关性



注：统计区间 2010-01-04 至 2026-09-30，矩阵左下角为 Pearson 相关系数，右上角为 Spearman 相关系数，相关系数高于 0.7 标注数值。
资料来源：Wind，华泰研究

接着观察不同 Weight 模型挖掘相同 Value 表达因子间相关性，以“分钟收益”为例。可以发现，**不同模型挖掘因子间相关性低于相同模型挖掘的同类因子间相关性**，GRU 与 Transformer 挖掘同类因子的 Spearman 相关性均在 0.5 以下。

图表18：分钟收益因子：GRU 与 Transformer Weight 间相关性

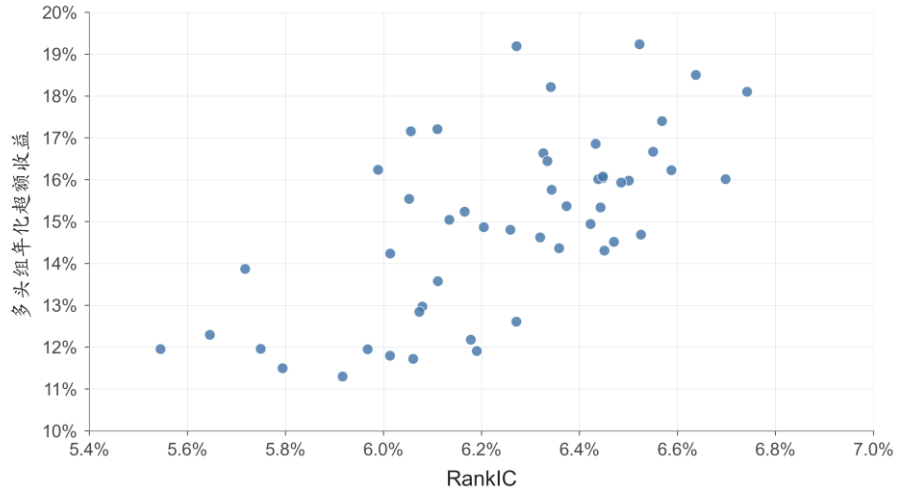


注：统计区间 2010-01-04 至 2026-09-30，矩阵左下角为 Pearson 相关系数，右上角为 Spearman 相关系数。
资料来源：Wind，华泰研究

可学习 Value 组

实验（3）用神经网络作为 Value 模块自适应提取量价表达，同样输出 50 个因子，并控制其相关性，结果汇总如下。

图表19：可学习 Value＋GRU Weight 挖掘因子表现



注：回测区间 2010-01-04 至 2026-09-30。
资料来源：Wind，华泰研究

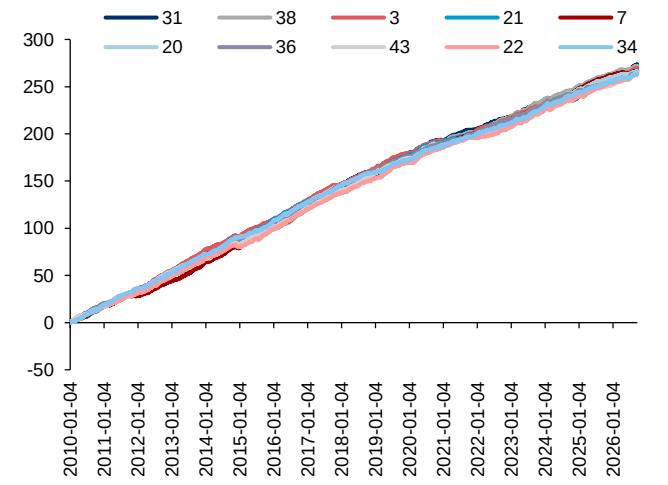
可以发现，由于无明确 Value 表达限制，该组 50 个因子间表现均接近，RankIC 集中在 5%至 7%间。因此本节按照 RankIC 均值从高到低排序，选取表现前十因子，以及全部 50 因子等权平均因子展示其详细回测指标。

图表20： 可学习 Value 组因子回测指标汇总

因子编号	IC 均值	RankIC 均值	ICIR	RankICIR	多头组收益	多头组超额	多头组信息比率	空头组超额	|t|均值
31	5.6%	6.7%	0.73	0.82	27.4%	18.1%	3.63	-33.3%	4.19
38	5.7%	6.7%	0.74	0.83	25.2%	16.0%	3.04	-34.3%	4.27
3	5.6%	6.6%	0.74	0.83	28.0%	18.5%	3.33	-33.1%	4.18
21	5.3%	6.6%	0.63	0.74	25.6%	16.2%	3.02	-30.2%	4.37
7	5.3%	6.6%	0.70	0.82	26.7%	17.4%	3.25	-32.0%	4.12
20	5.3%	6.6%	0.64	0.73	26.3%	16.7%	2.75	-32.2%	4.31
36	5.3%	6.5%	0.66	0.74	24.4%	14.7%	2.52	-33.4%	4.25
43	5.3%	6.5%	0.69	0.78	29.0%	19.2%	3.41	-31.2%	4.10
22	5.4%	6.5%	0.69	0.76	25.1%	16.0%	2.90	-29.3%	4.21
34	5.4%	6.5%	0.71	0.78	25.3%	15.9%	2.81	-31.2%	4.10
50 等权	8.8%	10.7%	0.87	1.00	38.9%	28.3%	4.51	-45.0%	6.17

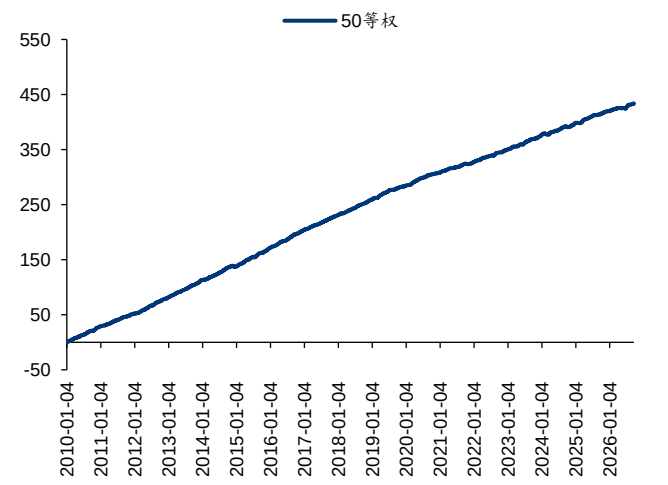
注：回测区间 2010-01-04 至 2026-09-30，IC、回归等指标以 5 日收益为标签，因子十分层回测，周频调仓，不计费率。
资料来源：Wind，华泰研究

图表21： 可学习组部分因子累计 RankIC 净值



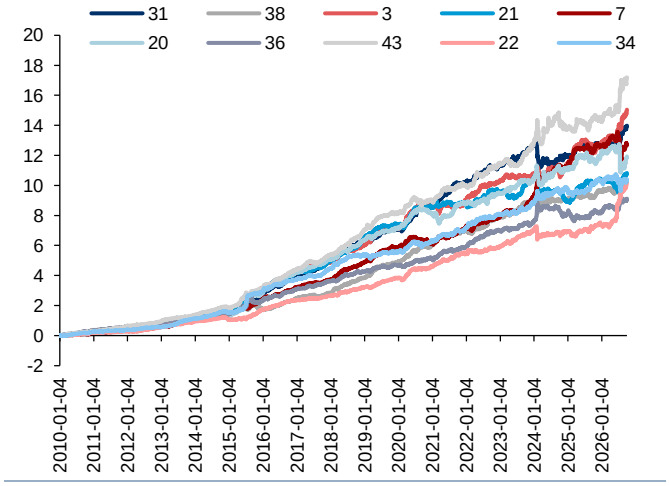
注：回测区间 2010-01-04 至 2026-09-30，图例为因子编号。
资料来源：Wind，华泰研究

图表22： 可学习组 50 因子等权累计 RankIC 净值



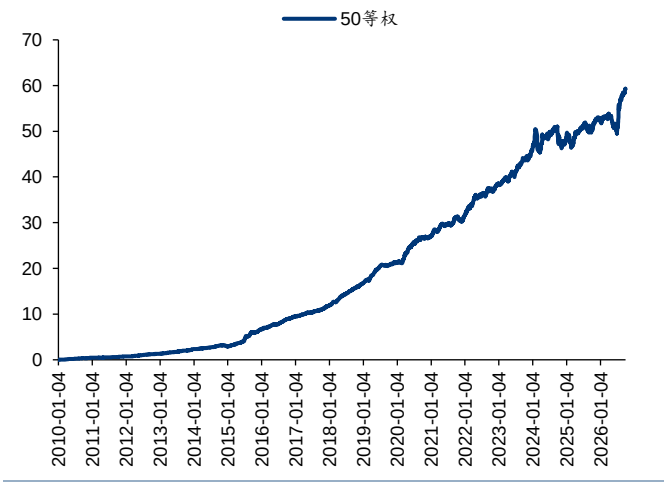
注：回测区间 2010-01-04 至 2026-09-30。
资料来源：Wind，华泰研究

图表23： 可学习组部分因子多头超额收益净值



注：回测区间 2010-01-04 至 2026-09-30，图例为因子编号。
资料来源：Wind，华泰研究

图表24： 可学习组 50 因子等权多头超额收益净值

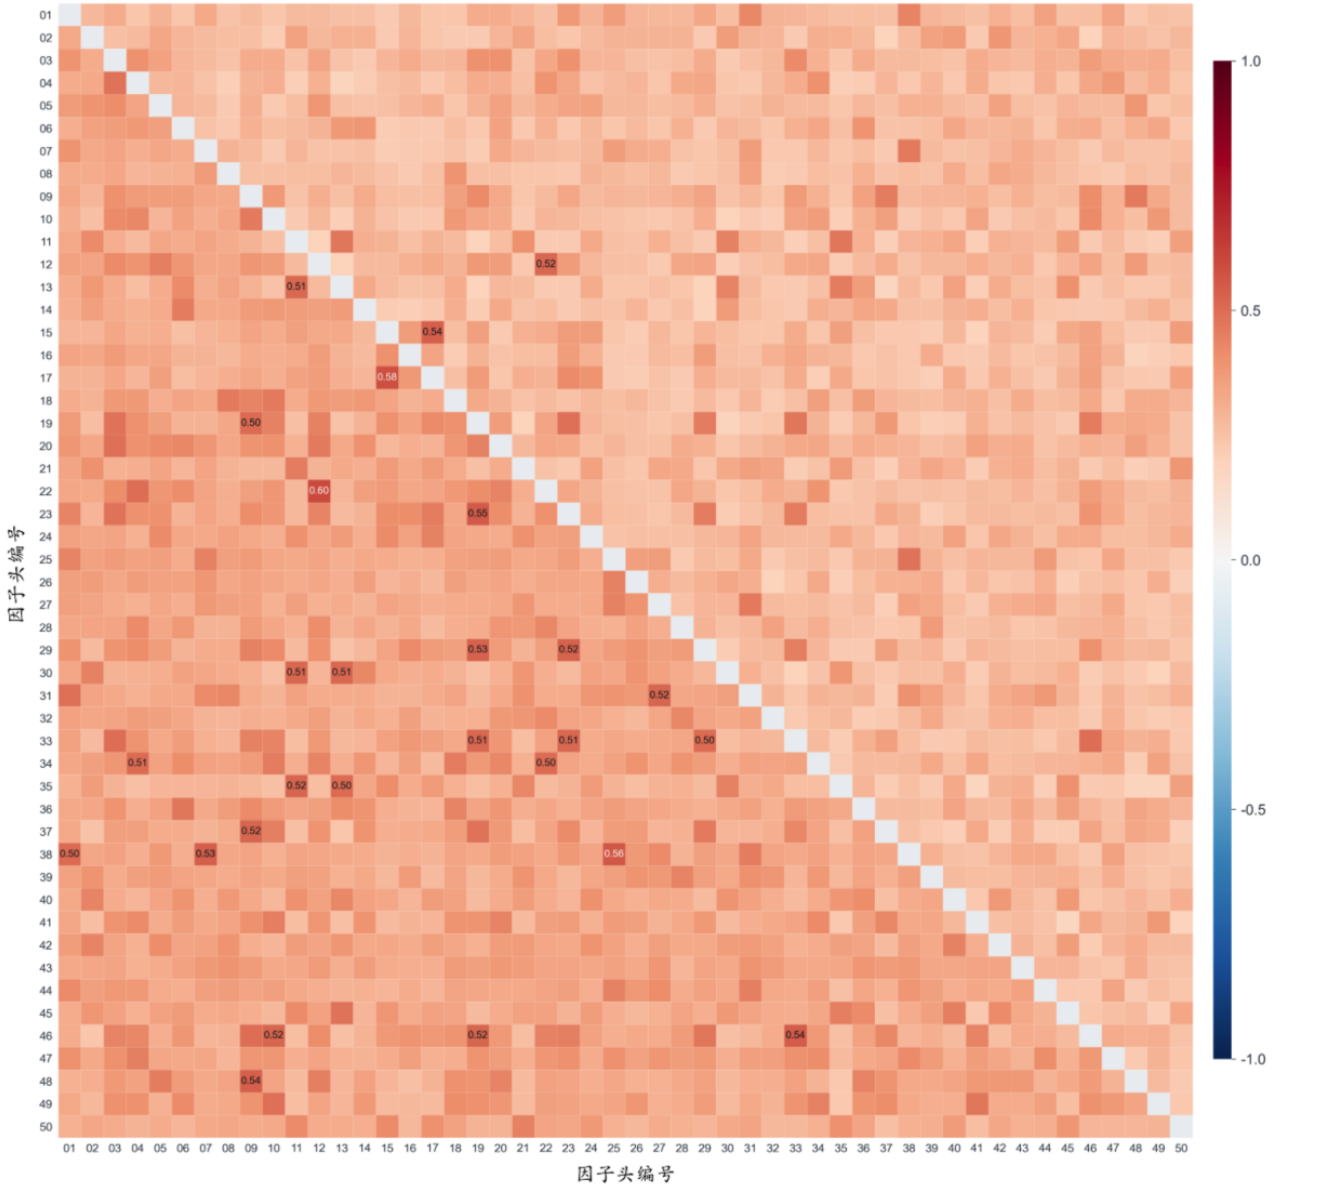


注：回测区间 2010-01-04 至 2026-09-30。
资料来源：Wind，华泰研究

结果表明，该组因子普遍有效，RankIC 和多头组超额收益在时序上均较为稳定，且等权合成因子表现突出，相较于单因子提升显著。

进一步统计因子间相关性，结果如下。可以发现，**该组 50 个因子间相关性较低，仅少数因子间相关性高于 0.5**。

图表25： 可学习 Value + GRU Weight 挖掘因子相关性

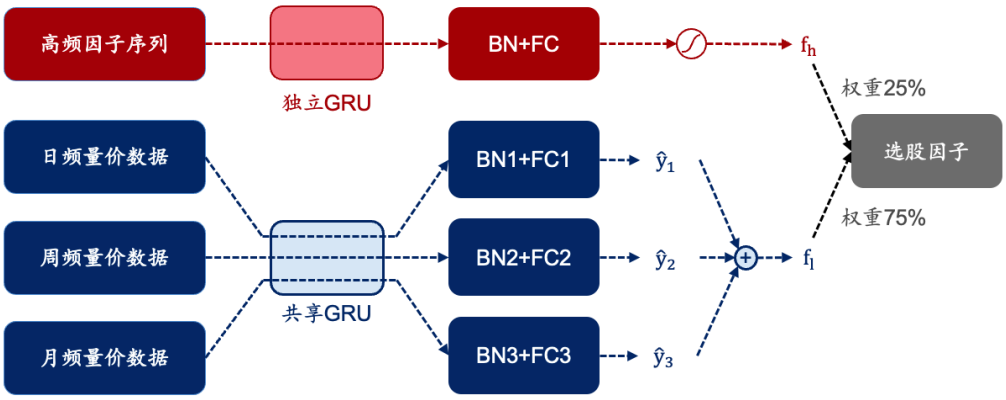


注：统计区间 2010-01-04 至 2026-09-30，矩阵左下角为 Pearson 相关系数，右上角为 Spearman 相关系数，相关系数高于 0.5 标注数值。
资料来源：Wind，华泰研究

因子合成

本节尝试将上文构造的神经网络高频因子加入选股因子体系。华泰金工前期研究《基于全频段量价特征的选股模型》（2023.12.8）中以人工构造的高频特征作为输入构建了高频量价分支，并进一步与低频量价分支合成得到全频段量价因子。

图表26：全频段量价因子构造方式



资料来源：华泰研究

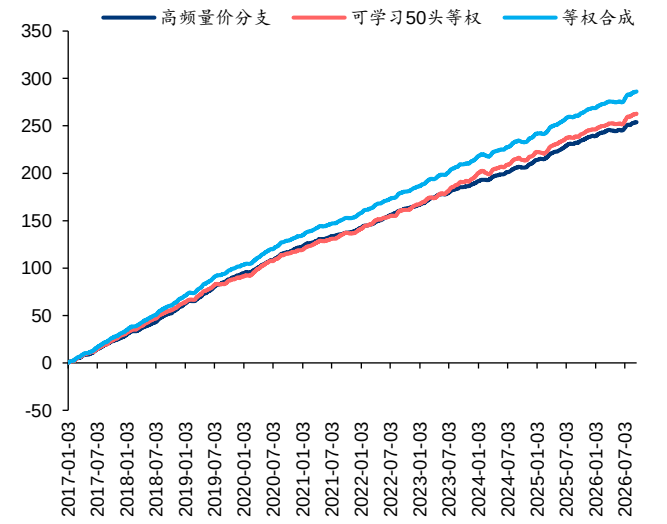
本节首先以高频量价分支作为基准，探究神经网络挖掘高频因子相比人工构造因子是否具有增量信息。将上节实验（3）中可学习 Value 加 GRU Weight 模型挖掘得到的 50 头等权因子与全频段量价因子中的高频量价分支按照 1:1 等权合成，结果如下。

图表27：AI 高频量价因子回测指标汇总

因子	IC 均值	RankIC 均值	ICIR	RankICIR	多头组收益	多头组超额	多头组信息比率	空头组超额	|t|均值
高频量价分支	9.4%	10.8%	1.17	1.41	23.8%	18.1%	4.28	-45.2%	6.60
可学习 50 头等权	9.4%	11.2%	0.89	0.97	26.3%	19.7%	3.12	-45.7%	7.43
两者等权合成	10.6%	12.2%	1.07	1.19	28.9%	22.5%	3.93	-49.1%	7.68

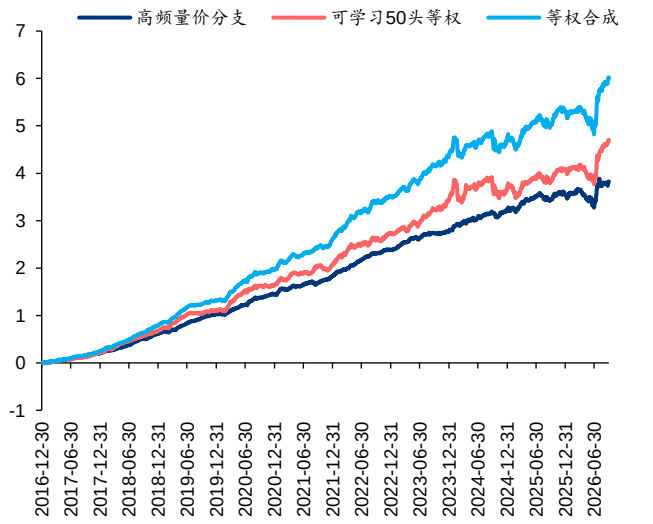
注：回测区间 2017-01-04 至 2026-09-30，IC、回归等指标以 10 日收益为标签，因子十分层回测，周频调仓，不计费率。
资料来源：Wind，华泰研究

图表28：AI 高频量价因子累计 RankIC 净值



注：回测区间 2017-01-04 至 2026-09-30。
资料来源：Wind，华泰研究

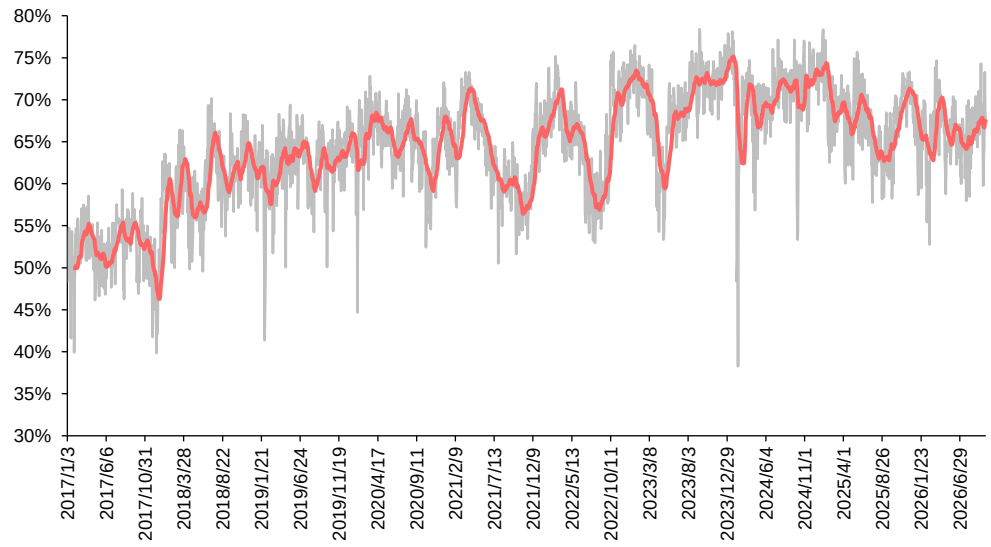
图表29：AI 高频量价因子多头超额收益净值



注：回测区间 2017-01-04 至 2026-09-30。
资料来源：Wind，华泰研究

进一步统计两者间的截面相关性，结果如下。

图表30：高频量价分支与可学习 50 头等权因子相关性



注：相关性以 Pearson 相关系数计算，红色实线为 20 日滚动平均值。
资料来源：Wind，华泰研究

结果表明：

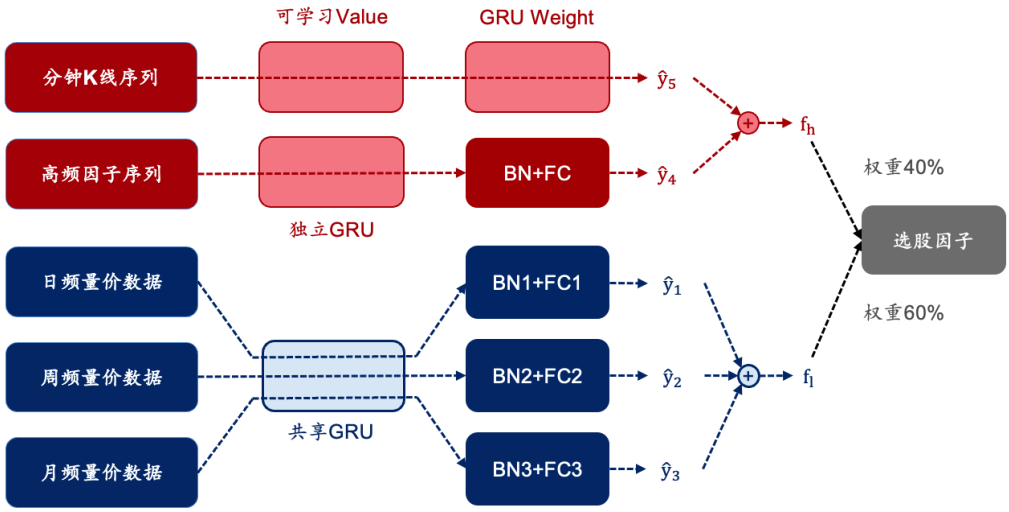
1、 神经网络挖掘高频因子相比人工构造高频因子在 **RankIC、多头组超额指标绝对值有优势，但稳定性有所下降**；

2、 两者相关性在时序维度维持在 50%至 70%的水平，**虽信息源同为高频特征，但因子间信息重合度较低**；

3、 两者合成因子在 RankIC、多头组超额等指标上均有较显著改进。

基于以上结论，本节将可学习 50 头等权因子加入全频段量价因子的高频分支，构建高频增强版全频段量价因子。构造方式与因子回测结果如下。

图表31：高频增强全频段量价因子示意图



资料来源：华泰研究

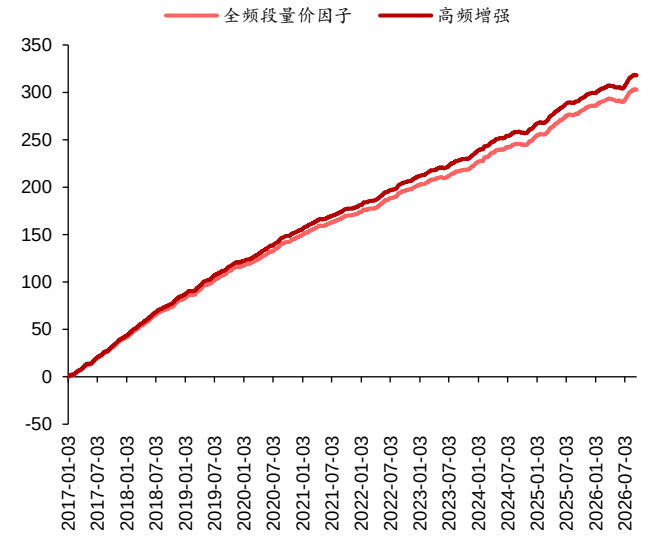
图表32：高频增强全频段量价因子回测指标汇总

因子	IC 均值	RankIC 均值	ICIR	RankICIR	多头组收益	多头组超额	多头组信息比率	空头组超额	|t|均值
全频段量价因子	11.1%	12.9%	1.03	1.16	41.8%	34.0%	4.52	-47.4%	7.91
高频增强	11.6%	13.5%	1.05	1.20	43.3%	35.3%	4.79	-49.1%	8.24

注：回测区间 2017-01-04 至 2026-09-30，IC、回归等指标以 10 日收益为标签，因子十分层回测，周频调仓，不计费率。

资料来源：Wind，华泰研究

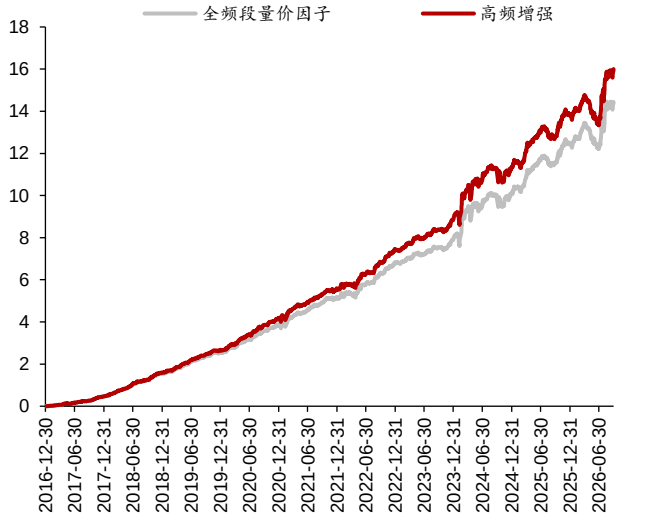
图表33：AI 高频量价因子累计 RankIC 净值



注：回测区间 2017-01-04 至 2026-09-30。

资料来源：Wind，华泰研究

图表34：AI 高频量价因子多头超额收益净值



注：回测区间 2017-01-04 至 2026-09-30。

资料来源：Wind，华泰研究

组合实证

本小节尝试基于以上选股因子构建组合进行实证。组合优化及回测细节如下。

图表35：组合优化及回测细节

组合优化	基准指数	中证 1000
	测试区间	2016-12-30 至 2026-09-30
	选股域	中证全指成分股
	成分股权重约束	不低于 80%
	控制风格	Barra-CNE5 全部风格因子
	风格暴露约束	0.2
	行业暴露约束	2%
	个股绝对权重上限	15%
	个股权重偏离上限	0.5%
	单边换手率上限	15%
组合回测	调仓频率	周度
	成交价格	VWAP
	调仓费率	双边千分之三
	可交易性	停牌不可交易、涨停不可买入、跌停不可卖出

资料来源：华泰研究

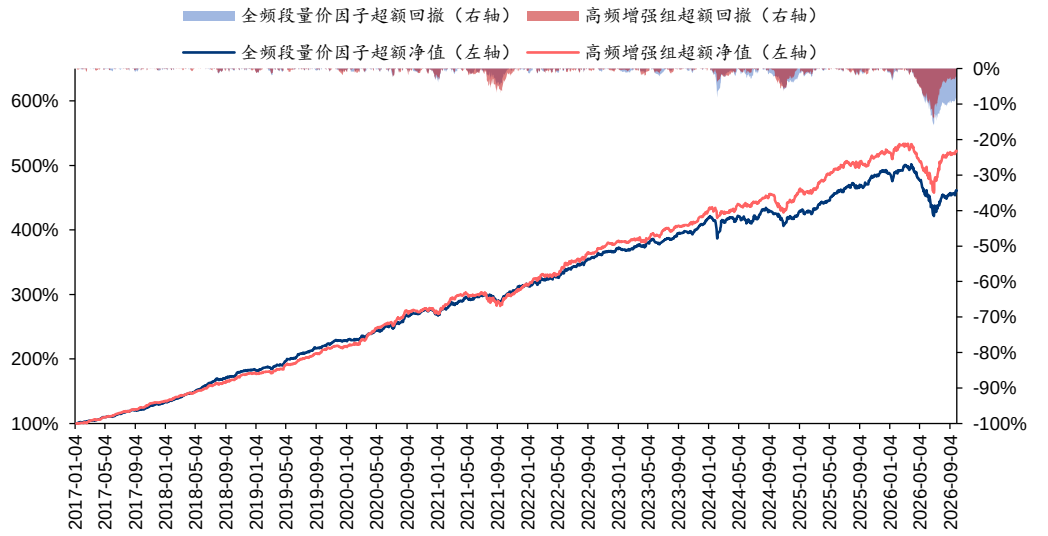
两组因子组合业绩指标汇总如下。

图表36：高频增强组中证 1000 指数增强组合业绩对比

因子	年化收益率	年化波动率	夏普比率	最大回撤	年化超额收益率	年化跟踪误差	信息比率	超额收益最大回撤	超额收益卡玛比率	超额收益月度胜率	年化换手率
全频段量价因子	15.8%	24.3%	0.65	34.8%	17.7%	5.6%	3.18	16.1%	1.10	84.6%	16.40
高频增强组	17.5%	23.6%	0.74	31.6%	19.3%	5.8%	3.33	14.2%	1.36	86.3%	16.25

注：回测区间 2017-01-04 至 2026-09-30，换手率单位为倍。
资料来源：Wind，华泰研究

图表37：高频增强组中证 1000 指数增强组合超额收益净值及回撤对比



注：回测区间 2017-01-04 至 2026-09-30。
资料来源：Wind，华泰研究

可以发现，经高频增强后的全频段因子可稳定提升组合超额收益，不过由于全频段因子较强的反转暴露，其在今年二季度强动量行情中仍面临持续深度回撤。因此本节将抱团动量因子加入高频增强后的全频段量价因子，尝试应对类似的抱团强动量行情。抱团动量因子构造方式如下。

$$M = D \cdot \mathbf{min}(1, \mathbf{max}(0, \frac{q - 0.8}{0.2})) \cdot mom_{20}$$

其中 D 为上涨行情确认系数，q 为行业成交额占比的 HHI 集中度系数的时序分位数。当行情上涨且行业成交集中度分位超过 80%后，标准化动量因子 mom_{20} 的配置强度随分位提高而线性增加。加入该因子并将组合优化改为多路径后组合业绩指标汇总如下。

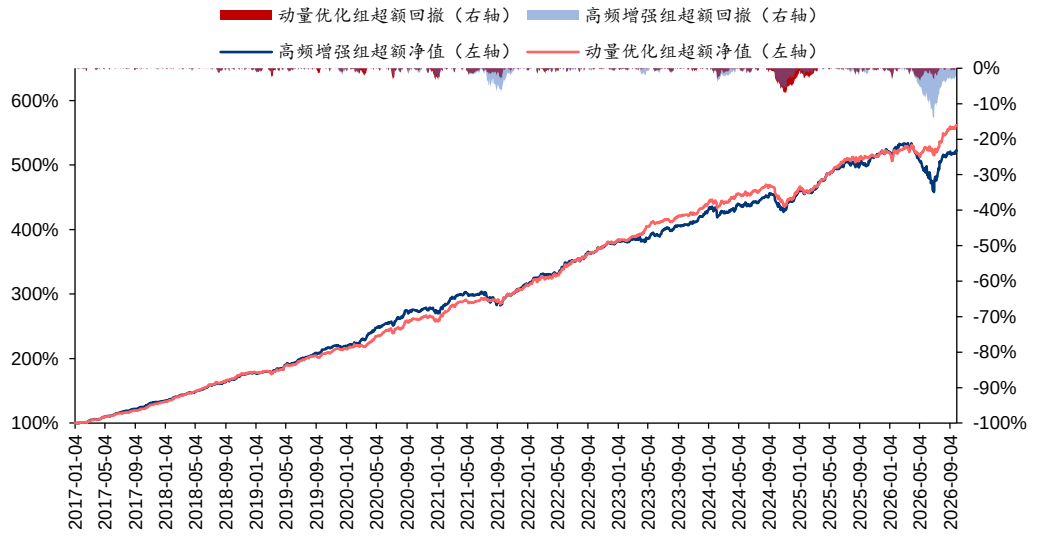
图表38：动量优化组中证 1000 指数增强组合业绩对比

因子	年化收益率	年化波动率	夏普比率	最大回撤	年化超额收益率	年化跟踪误差	信息比率	超额收益最大回撤	超额收益卡玛比率	超额收益月度胜率	年化换手率
全频段量价因子	15.8%	24.3%	0.65	34.8%	17.7%	5.6%	3.18	16.1%	1.10	84.6%	16.40
高频增强组	17.5%	23.6%	0.74	31.6%	19.3%	5.8%	3.33	14.2%	1.36	86.3%	16.25
动量优化组	18.3%	23.8%	0.77	31.6%	20.2%	4.8%	4.25	7.1%	2.83	88.0%	16.39

注：回测区间 2017-01-04 至 2026-09-30，换手率单位为倍。

资料来源：Wind，华泰研究

图表39：动量优化组中证 1000 指数增强组合超额收益净值及回撤对比



注：回测区间 2017-01-04 至 2026-09-30。

资料来源：Wind，华泰研究

图表40：动量优化组中证 1000 指数增强组合各区间超额收益

年度	1	2	3	4	5	6	7	8	9	10	11	12	Q1	Q2	Q3	Q4	全年
2017	1.1%	1.7%	2.3%	3.5%	1.8%	3.4%	1.3%	2.1%	2.6%	4.3%	2.0%	2.4%	5.3%	9.0%	6.1%	9.2%	33.1%
2018	2.9%	2.6%	2.6%	1.5%	3.2%	4.0%	2.2%	0.8%	2.9%	3.5%	2.0%	0.8%	9.3%	9.3%	6.0%	6.7%	35.1%
2019	0.4%	0.0%	1.8%	3.4%	0.3%	3.0%	2.6%	1.4%	1.5%	0.8%	2.9%	-0.1%	2.5%	7.3%	5.7%	3.7%	20.8%
2020	1.2%	1.3%	0.7%	4.6%	2.5%	2.7%	0.6%	4.9%	1.4%	0.9%	0.4%	-1.4%	3.4%	10.3%	6.3%	-0.1%	21.0%
2021	4.2%	4.0%	2.1%	0.9%	-0.7%	1.7%	-1.5%	-0.7%	1.1%	1.0%	2.4%	2.0%	10.7%	1.7%	-0.2%	6.0%	20.8%
2022	2.9%	0.9%	-0.3%	0.7%	3.5%	1.9%	0.5%	2.6%	0.9%	1.2%	1.9%	0.9%	4.3%	6.9%	4.3%	4.5%	22.3%
2023	0.3%	1.7%	1.2%	3.1%	1.0%	0.9%	0.0%	1.6%	0.6%	0.0%	1.9%	1.5%	2.7%	5.5%	2.5%	3.5%	14.4%
2024	0.8%	-0.2%	0.7%	1.9%	0.8%	0.2%	0.3%	0.6%	-2.6%	-2.9%	2.1%	3.6%	1.0%	2.4%	-1.1%	2.9%	5.0%
2025	-0.6%	0.4%	2.3%	2.2%	2.2%	1.2%	0.7%	-0.6%	1.2%	0.6%	0.9%	0.0%	2.7%	5.6%	1.6%	1.7%	12.4%
2026	0.3%	1.3%	0.8%	-2.7%	2.9%	-2.0%	4.1%	2.9%	0.7%				2.3%	-2.8%	9.0%		8.5%

注：回测区间 2017-01-04 至 2026-09-30。

资料来源：Wind，华泰研究

可以发现，经动量优化后组合在抱团上涨行情中有效规避了深度回撤，跟踪误差、超额回撤指标均得到了有效改善。

总结

本文为人工智能系列第 106 篇：基于日内量价结构的神经网络因子挖掘框架。日内量价路径蕴含了价格变化、成交活动及其时序关系的信息，固定的统计规则可能难以充分提取其中的有效信号。本文构建 Value－Weight 神经网络因子挖掘框架，将分钟信息表达与时序权重生成分离，通过多头联合学习获得一组可独立评价和组合的日频因子。2017-01-04 至 2026-09-30 的回测显示，挖掘因子与人工高频特征构建的模型等权合成后，后者的 RankIC 由 10.8%提升至 12.2%，多头组年化超额收益由 18.1%提升至 22.5%。进一步将其纳入全频段量价因子，中证 1000 指增组合年化超额收益由 17.7%提升至 19.3%，信息比率由 3.18 提升至 3.33。

实验方法：分钟信息表达与时序权重分离，多头联合挖掘日频因子。本文以个股单日 240 根分钟 K 线为输入，将因子生成划分为三个环节：（1）分钟信息表达：Value 模块采用固定公式或可学习网络，描述每一分钟的价格形态与成交信息。（2）时序权重生成：Weight 模块采用 GRU 或 Transformer，根据当日量价路径学习各分钟的相对重要性。（3）日频聚合：各输出头分别对分钟信息加权求和，形成 50 个日频因子。模型在损失函数中结合合成监督、逐头监督和去相关约束，同时优化整体预测能力、单因子有效性与头间冗余，并采用季度滚动方式开展三组对比实验。

实验结果：价格类表达效果较优，可学习因子合成后提供增量。实验结果显示：（1）固定 Value 组中，分钟收益、收盘位置、实体比例等价格类表达表现较优，Transformer Weight 在这类因子上的表现整体强于 GRU。（2）可学习 Value 组 50 个因子的 RankIC 主要集中在 5%至 7%，头间相关性较低，等权合成后的预测能力和多头表现均有提升。（3）在 2017-01-04 至 2026-09-30 的回测区间内，将可学习 50 头等权因子与人工高频特征构建的高频量价分支等权合成，RankIC 由后者的 10.8%提升至 12.2%，多头组年化超额收益由 18.1%提升至 22.5%，体现出两类信息提取方式的互补性。

指增组合测试：高频增强提升超额收益，动量与多路径改善回撤。将挖掘因子加入全频段量价因子的高频分支，构建中证 1000 指数增强组合。在 2017-01-04 至 2026-09-30 的历史回测中，高频增强组的年化超额收益由原全频段组合的 17.7%提升至 19.3%，信息比率由 3.18 提升至 3.33，超额收益最大回撤由 16.1%下降至 14.2%。考虑到量价因子在强动量行情中的回撤风险，进一步加入由行业成交集中度及上涨趋势共同控制的抱团动量因子，并采用五路径周频调仓。两项调整后，组合年化超额收益达到 20.2%，信息比率 4.25，超额收益最大回撤降至 7.1%。

本研究还有以下未尽之处：

1、 固定 Value 模块仅尝试了 10 个基础字段，且未将量价指标相结合构建量价描述指标，后续可尝试扩展量价表达字段并提升输出数量、提升实验数量；
2、 模型结构方面，可学习 Value 模块仅使用 GRU Weight 模块进行搭配，且 Value 模块仅用简单线性层，未来均可尝试替换和扩展。

参考文献

Beckmeyer, H., & Wiedemann, T. (2025). All Days Are Not Created Equal: Understanding Momentum by Learning to Weight Past Returns. Journal of Banking & Finance, 181, 107565. https://doi.org/10.1016/j.jbankfin.2025.107565

风险提示

人工智能挖掘市场规律是对历史的总结，市场规律在未来可能失效。深度学习模型受随机数影响较大。本文回测假定以 VWAP 价格成交，未考虑其他影响交易因素。

免责声明

分析师声明

本人，浦彦恒、沈洋、王晨宇，兹证明本报告所表达的观点准确地反映了分析师对标的证券或发行人的个人意见；彼以往、现在或未来并无就其研究报告所提供的具体建议或所表达的意见直接或间接收取任何报酬。请注意，标*的人员并非香港证券及期货事务监察委员会的注册持牌人，不可在香港从事受监管活动。

一般声明及披露

本报告由华泰证券股份有限公司或其关联机构制作，华泰证券股份有限公司和其关联机构统称为“华泰证券”(华泰证券股份有限公司已具备中国证监会批准的证券投资咨询业务资格) 。本报告所载资料是仅供接收人的严格保密资料。本报告仅供华泰证券及其客户和其关联机构使用。华泰证券不因接收人收到本报告而视其为客户。

本报告基于华泰证券认为可靠的、已公开的信息编制，但华泰证券对该等信息的准确性及完整性不作任何保证。

本报告所载的意见、评估及预测仅反映报告发布当日的观点和判断。在不同时期，华泰证券可能会发出与本报告所载意见、评估及预测不一致的研究报告。同时，本报告所指的证券或投资标的的价格、价值及投资收入可能会波动。以往表现并不能指引未来，未来回报并不能得到保证，并存在损失本金的可能。华泰证券不保证本报告所含信息保持在最新状态。华泰证券对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

华泰证券（华泰证券（美国）有限公司除外）不是 FINRA 的注册会员，其研究分析师亦没有注册为 FINRA 的研究分析师/不具有 FINRA 分析师的注册资格。

华泰证券力求报告内容客观、公正，但本报告所载的观点、结论和建议仅供参考，不构成购买或出售所述证券的要约或招揽。该等观点、建议并未考虑到个别投资者的具体投资目的、财务状况以及特定需求，在任何时候均不构成对客户私人投资建议。投资者应当充分考虑自身特定状况，并完整理解和使用本报告内容，不应视本报告为做出投资决策的唯一因素。对依据或者使用本报告所造成的一切后果，华泰证券及作者均不承担任何法律责任。任何形式的分享证券投资收益或者分担证券投资损失的书面或口头承诺均为无效。

除非另行说明，本报告中所引用的关于业绩的数据代表过往表现，过往的业绩表现不应作为日后回报的预示。华泰证券不承诺也不保证任何预示的回报会得以实现，分析中所做的预测可能是基于相应的假设，任何假设的变化可能会显著影响所预测的回报。

华泰证券及作者在自身所知情的范围内，与本报告所指的证券或投资标的不存在法律禁止的利害关系。在法律许可的情况下，华泰证券可能会持有报告中提到的公司所发行的证券头寸并进行交易，为该公司提供投资银行、财务顾问或者金融产品等相关服务或向该公司招揽业务。

华泰证券的销售人员、交易人员或其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。华泰证券没有将此意见及建议向报告所有接收者进行更新的义务。华泰证券的资产管理部门、自营部门以及其他投资业务部门可能独立做出与本报告中的意见或建议不一致的投资决策。投资者应当考虑到华泰证券及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突。投资者请勿将本报告视为投资或其他决定的唯一信赖依据。有关该方面的具体披露请参照本报告尾部。

本报告并非意图发送、发布给在当地法律或监管规则下不允许向其发送、发布的机构或人员，也并非意图发送、发布给因可得到、使用本报告的行为而使华泰证券违反或受制于当地法律或监管规则的机构或人员。

本报告版权仅为华泰证券所有。未经华泰证券书面许可，任何机构或个人不得以翻版、复制、发表、引用或再次分发他人(无论整份或部分)等任何形式侵犯华泰证券版权。如征得华泰证券同意进行引用、刊发的，需在允许的范围内使用，并需在使用前获取独立的法律意见，以确定该引用、刊发符合当地适用法规的要求，同时注明出处为“华泰证券研究所”，且不得对本报告进行任何有悖原意的引用、删节和修改。华泰证券保留追究相关责任的权利。所有本报告中使用的商标、服务标记及标记均为华泰证券的商标、服务标记及标记。

中国香港

本报告由华泰证券股份有限公司或其关联机构制作,在香港由华泰金融控股（香港）有限公司向符合《证券及期货条例》及其附属法律规定的机构投资者和专业投资者的客户进行分发。华泰金融控股（香港）有限公司受香港证券及期货事务监察委员会监管，是华泰国际金融控股有限公司的全资子公司，后者为华泰证券股份有限公司的全资子公司。在香港获得本报告的人员若有任何有关本报告的问题,请与华泰金融控股（香港）有限公司联系。

香港-重要监管披露

- 华泰金融控股（香港）有限公司的雇员或其关联人士没有担任本报告中提及的公司或发行人的高级人员。
- 有关重要的披露信息，请参华泰金融控股（香港）有限公司的网页 https://www.htsc.com.hk/stock_disclosure

其他信息请参见下方 **“美国-重要监管披露”**。

美国

在美国本报告由华泰证券（美国）有限公司向符合美国监管规定的机构投资者进行发表与分发。华泰证券（美国）有限公司是美国注册经纪商和美国金融业监管局（FINRA）的注册会员。对于其在美国分发的研究报告，华泰证券（美国）有限公司根据《1934 年证券交易法》（修订版）第 15a-6 条规定以及美国证券交易委员会人员解释，对本研究报告内容负责。华泰证券（美国）有限公司联营公司的分析师不具有美国金融监管（FINRA）分析师的注册资格，可能不属于华泰证券（美国）有限公司的关联人员，因此可能不受 FINRA 关于分析师与标的公司沟通、公开露面和所持交易证券的限制。华泰证券（美国）有限公司是华泰国际金融控股有限公司的全资子公司，后者为华泰证券股份有限公司的全资子公司。任何直接从华泰证券（美国）有限公司收到此报告并希望就本报告所述任何证券进行交易的人士，应通过华泰证券（美国）有限公司进行交易。

美国-重要监管披露

- 分析师浦彦恒、沈洋、王晨宇本人及相关人士并不担任本报告所提及的标的证券或发行人的高级人员、董事或顾问。分析师及相关人士与本报告所提及的标的证券或发行人并无任何相关财务利益。本披露中所提及的“相关人士”包括 FINRA 定义下分析师的家庭成员。分析师根据华泰证券的整体收入和盈利能力获得薪酬，包括源自公司投资银行业务的收入。
- 华泰证券股份有限公司、其子公司和/或其联营公司，及/或不时会以自身或代理形式向客户出售及购买华泰证券研究所覆盖公司的证券/衍生工具，包括股票及债券（包括衍生品）华泰证券研究所覆盖公司的证券/衍生工具，包括股票及债券（包括衍生品）。
- 华泰证券股份有限公司、其子公司和/或其联营公司，及/或其高级管理层、董事和雇员可能会持有本报告中所提到的任何证券（或任何相关投资）头寸，并可能不时进行增持或减持该证券（或投资）。因此，投资者应该意识到可能存在利益冲突。

新加坡

华泰证券（新加坡）有限公司持有新加坡金融管理局颁发的资本市场服务许可证，可从事资本市场产品交易，包括证券、集体投资计划中的单位、交易所交易的衍生品合约和场外衍生品合约，并且是《财务顾问法》规定的豁免财务顾问，就投资产品向他人提供建议，包括发布或公布研究分析或研究报告。华泰证券（新加坡）有限公司可能会根据《财务顾问条例》第 32C 条的规定分发其在华泰证券内的外国附属公司各自制作的信息/研究。本报告仅供认可投资者、专家投资者或机构投资者使用，华泰证券（新加坡）有限公司不对本报告内容承担法律责任。如果您是非预期接收者，请您立即通知并直接将本报告返回给华泰证券（新加坡）有限公司。本报告的新加坡接收者应联系您的华泰证券（新加坡）有限公司关系经理或客户主管，了解来自或与所分发的信息相关的事宜。

评级说明

投资评级基于分析师对报告发布日后 6 至 12 个月内行业或公司回报潜力（含此期间的股息回报）相对基准表现的预期（A 股市场基准为沪深 300 指数，香港市场基准为恒生指数，美国市场基准为标普 500 指数，台湾市场基准为台湾加权指数，日本市场基准为日经 225 指数，新加坡市场基准为海峡时报指数，韩国市场基准为韩国有价证券指数，英国市场基准为富时 100 指数，德国市场基准为 DAX 指数），具体如下：

行业评级

增持：预计行业股票指数超越基准
中性：预计行业股票指数基本与基准持平
减持：预计行业股票指数明显弱于基准

公司评级

买入：预计股价超越基准 15%以上
增持：预计股价超越基准 5%~15%
持有：预计股价相对基准波动在-15%~5%之间
卖出：预计股价弱于基准 15%以上
暂停评级：已暂停评级、目标价及预测，以遵守适用法规及/或公司政策
无评级：股票不在常规研究覆盖范围内。投资者不应期待华泰提供该等证券及/或公司相关的持续或补充信息

法律实体披露

中国：华泰证券股份有限公司具有中国证监会核准的“证券投资咨询”业务资格，经营许可证编号为：91320000704041011J

香港：华泰金融控股（香港）有限公司具有香港证监会核准的“就证券提供意见”业务资格，经营许可证编号为：AOK809

美国：华泰证券（美国）有限公司为美国金融业监管局（FINRA）成员，具有在美国开展经纪交易商业务的资格，经营业务许可编号为：CRD#:298809/SEC#:8-70231

新加坡：华泰证券（新加坡）有限公司具有新加坡金融管理局颁发的资本市场服务许可证，并且是豁免财务顾问，经营许可证编号为：202233398E

华泰证券股份有限公司

南京
南京市建邺区江东中路 228 号华泰证券广场 1 号楼/邮政编码：210019

电话：86 25 83389999/传真：86 25 83387521
电子邮件：ht-rd@htsc.com

北京
北京市西城区太平桥大街丰盛胡同 28 号太平洋保险大厦 A 座 18 层/邮政编码：100032
电话：86 10 63211166/传真：86 10 63211275
电子邮件：ht-rd@htsc.com

深圳
深圳市福田区益田路 5999 号基金大厦 10 楼/邮政编码：518017
电话：86 755 82493932/传真：86 755 82492062
电子邮件：ht-rd@htsc.com

上海
上海市浦东新区东方路 18 号保利广场 E 栋 23 楼/邮政编码：200120
电话：86 21 28972098/传真：86 21 28972068
电子邮件：ht-rd@htsc.com

华泰金融控股（香港）有限公司
香港中环皇后大道中 99 号中环中心 53 楼
电话：+852-3658-6000/传真：+852-2567-6123
电子邮件：research@htsc.com
http://www.htsc.com.hk

华泰证券（美国）有限公司
美国纽约公园大道 280 号 21 楼东（纽约 10017）
电话：+212-763-8160/传真：+917-725-9702
电子邮件: Huatai@htsc-us.com
http://www.htsc-us.com

华泰证券（新加坡）有限公司
滨海湾金融中心 1 号大厦, #08-02, 新加坡 018981
电话：+65 68603600
传真：+65 65091183
https://www.htsc.com.sg

©版权所有2026年华泰证券股份有限公司