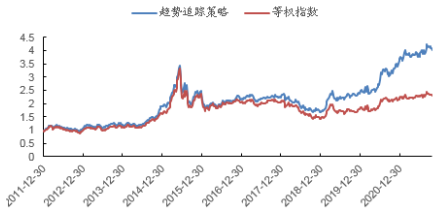
行业聚类方法探讨

——重构行业轮动框架之十

报告摘要:

- **基于行业聚类的理念，捕获行业之间的联动性关系。**一个完整的行业轮动框架通常涵盖了对行业划分、重构的探讨。随着近几年来，行业之间的联动，产业链之间的传导特征加快以及随着研究的更加细化，对行业、板块的细分提出了更高的要求。本篇专题报告主要对行业的重新划分、重构进行了详细的探讨，并基于行业重新划分后的结果，考察相关的结果在行业轮动中的应用。
- **采用多种模型进行行业聚类。**为了探讨行业的重新划分、重构，本篇专题报告主要考虑了使用 K-Means、Kernel K-Means 和凝聚层次聚类三种聚类方法的应用。实证聚类分析结果表明，三种聚类的方法对行业充分划分都有一定的适用性。
- **实证分析结果。**在回测期内，考虑周频换仓条件下，运用层次聚类模型对聚类后的行业划分结果，进行行业轮动应用。基于之前的行业轮动研究结果，考虑在聚类后的行业中进行动量轮动，即认为行业的上涨趋势是具有惯性的。在实证回测期内，从 2012 年 1 月 1 日截止至今年 10 月 31 日，趋势跟踪策略年化收益率 14.76%，年化波动率 22.81%，信息比率 0.65。
- **核心假设风险。**本文所做的数据测算完全基于过去数据的推演，市场未来环境可能发生变化。投资者制定投资策略时，必须结合市场环境和自身投资理念。

图：考虑行业聚类结果下的轮动策略



数据来源：Wind，广发证券发展研究中心

分析师： 陈原文

SAC 执证号：S0260517080003

0755-82797057

chenyuanwen@gf.com.cn

分析师： 安宁宁

SAC 执证号：S0260512020003

SFC CE No. BNW179

0755-23948352

anningning@gf.com.cn

请注意，陈原文并非香港证券及期货事务监察委员会的注册持牌人，不可在香港从事受监管活动。

相关研究：

海量技术指标掘金 Alpha 因子:多因子 Alpha 系列报告之（四十二）	2021-07-30
成长配置显著回升，行业抱团趋于集中:主动型权益基金二季报点评	2021-07-25
考虑拥挤度的细分行业动量策略:——重构量化行业轮动框架：技术篇	2021-07-09

目录索引

一、背景介绍 5
二、行业划分已有成果 5
三、行业聚类方法介绍 6
（一）聚类方法介绍 6
（二）常用聚类方法介绍 7
（三）K-MEANS 算法改进 10
四、行业聚类方法应用 12
（一）聚类设置 12
（二）聚类敏感性分析 12
五、基于动态行业聚类的板块轮动策略 28
（一）策略思想 28
（二）样本数据 28
（三）实证分析 29
六、风险提示 31

图表索引

图 1：广发金工行业轮动框架 6
图 2：类与类之间方式对聚类结果的影响 9
图 3：聚类数 K=3，行业划分结果一览 13
图 4：聚类数 K=4，行业划分结果一览 13
图 5：聚类数 K=5，行业划分结果一览 13
图 6：聚类数 K=6，行业划分结果一览 13
图 7：聚类数 K=7，行业划分结果一览 14
图 8：聚类数 K=8，行业划分结果一览 14
图 9：时间跨度 3 个月，行业划分结果一览 15
图 10：时间跨度 6 个月，行业划分结果一览 15
图 11：时间跨度 1 年，行业划分结果一览 15
图 12：时间跨度 2 年，行业划分结果一览 15
图 13：时间跨度 3 年，行业划分结果一览 16
图 14：聚类数 K=3，行业划分结果一览 18
图 15：聚类数 K=4，行业划分结果一览 18
图 16：聚类数 K=5，行业划分结果一览 18
图 17：聚类数 K=6，行业划分结果一览 18
图 18：聚类数 K=7，行业划分结果一览 19
图 19：聚类数 K=8，行业划分结果一览 19
图 20：3 个月，行业划分结果一览 20
图 21：6 个月，行业划分结果一览 20
图 22：1 年，行业划分结果一览 20
图 23：2 年，行业划分结果一览 20
图 24：3 年，行业划分结果一览 21
图 25：euclidean 欧氏距离，行业划分结果一览 22
图 26：manhattan 曼哈顿距离，行业划分结果一览 22
图 27：cosine 余弦距离，行业划分结果一览 22
图 28：全链，行业划分结果一览 24
图 29：平均链，行业划分结果一览 24
图 30：单链，行业划分结果一览 24
图 31：聚类数 K=3，行业划分结果一览 25
图 32：聚类数为 4，行业划分结果一览 25
图 33：聚类数为 5，行业划分结果一览 25
图 34：聚类数为 6，行业划分结果一览 25
图 35：聚类数为 7，行业划分结果一览 26
图 36：聚类数为 8，行业划分结果一览 26
图 37：时间跨度 3 个月，行业划分结果一览 27
图 38：时间跨度 6 个月，行业划分结果一览 27
图 39：时间跨度 1 年，行业划分结果一览 27
图 40：时间跨度 2 年，行业划分结果一览 27
图 41：时间跨度 3 年，行业划分结果一览 28

图 42: 周度调仓趋势跟踪策略回测表现一览 29
图 43: 周度调仓反转类策略净值曲线 30

表 1: 传统行业划分方式一览 5
表 2: 常用距离度量方式 8
表 3: 类之间常用距离方式 8
表 4: 常用核函数 11
表 5: 聚类数 K 与每一类中包含行业数 14
表 6: 每一类中包含行业数与时间跨度的关系 16
表 7: 每一类中包含行业数与核函数的关系 17
表 8: 聚类数量与每一类中包含行业数量的关系 19
表 9: 时间跨度与每一类中包含行业数的关系 21
表 10: 距离度量方式与每一类中包含行业数量的关系 22
表 11: 聚类数量与每一类中包含行业数量的关系 23
表 12: 类之间距离计算方式对聚类结果的关系 24
表 13: 聚类数量与每一类中包含行业数的关系 26
表 14: 时间跨度与每一类中包含行业数的关系 28
表 15: 趋势跟踪策略相对行业等权指数历史分年度收益率表现 30
表 16: 反转类策略相对等权指数历史分年度收益率表现 31

一、背景介绍

一个完整的行业轮动的框架，通常涵盖了自上而下和自下而上的结合，自上而下层面通常涵盖了对宏观指标，如PMI、CPI、货币政策等指标相关的解读，对行业中观层面指标的分析等；而自下而上层面通常涵盖了对行业内个股、行业价量走势等相关特征的解析。

随着近几年来，行业之间的联动，产业链之间的传导特征加快以及随着研究的更加细化，对行业、板块的细分提出了更高的要求，如传统的行业划分依据行业名称、行业所处产业链阶段等特征进行主动地划分可能不大适合当前及未来的市场行情演化。因此作为研究行业轮动这一话题中重要的一个环节—行业重新划分，提出了研究需求，新的行业划分、分类从逻辑、理论上应该更加注重行业间的统计相关特征的显著性。

从行业划分的角度上看，一般上，研究主要基于中信或者是申万的行业划分，并基于产业周期、行业主营业务等特征“人为”地将行业分为几个大类。但是，这种传统的行业划分可能随着市场状态特征、产业周期的变化而产生调整，而这种“人为”的划分方式可能对行业的调整不及时，因此从行业相关的统计特征出发去重新刻画、划分行业可能能够更加及时地捕捉到相关的行业轮动投资机会。

表 1：传统行业划分方式一览

基于行业主营业务领域	划分为：能源、制造、消费、TMT及金融等
基于行业所处产业链阶段	划分为：上游、中游、下游等
基于行业状态特征	划分为：周期、成长等
基于行业对资源、资本等生产要素的依赖程度	划分为：劳动密集型、资源密集型、资本密集型、技术密集型等

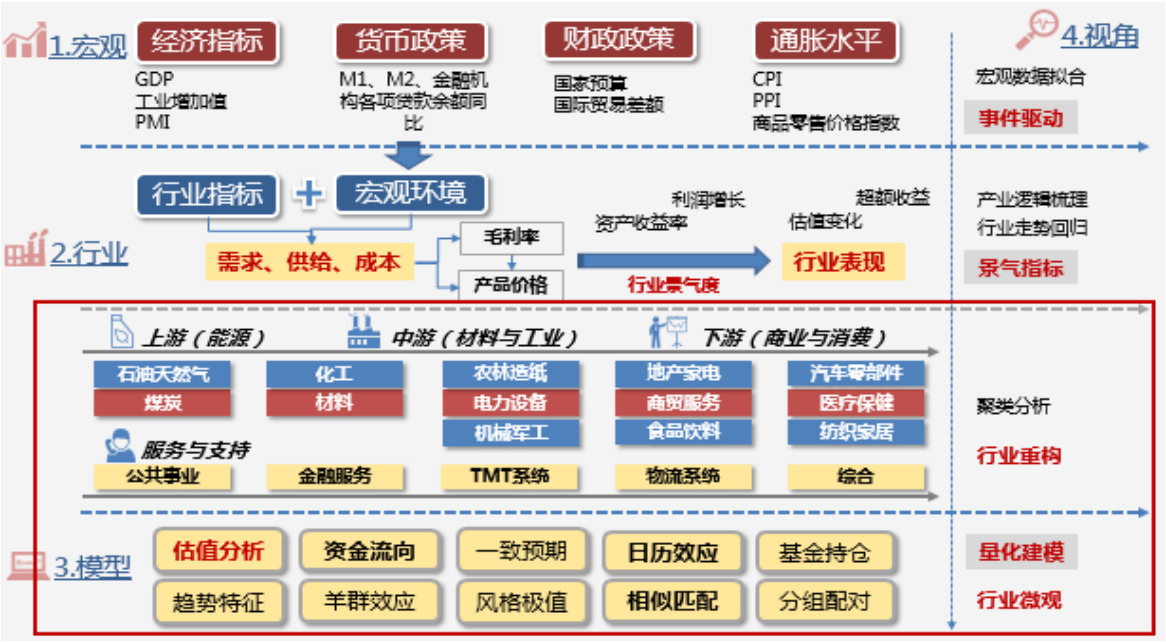
数据来源：广发证券发展研究中心

本篇专题报告将主要聚焦于行业的重新划分这一主要的研究话题，并基于此探探重新划分后的行业在行业轮动上的应用。

二、行业划分已有成果

广发金工团队在过去几年中一直深耕于行业轮动相关的研究问题。基于自上而下和自下而上的结合，搭建了个完善的行业轮动的框架体系。在这个框架体系中，关于行业划分的相关问题有一些相关的探讨，详细内容可以见《行业聚类与估值轮动策略——重构行业轮动框架之六》专题报告，其中基于行业划分的问题通过行业聚类模型及估值聚类等角度相关的思考。

图 1：广发金工行业轮动框架



数据来源：广发证券发展研究中心

三、行业聚类方法介绍

（一）聚类方法介绍

常言道“人以类聚，物以群分”，聚类就是对事物按照相似性特征进行分类。聚类分析不需要事先知道数据集有什么特征，而是按照算法判断数据集的相似性，把一个数据集分割成不同的类，使得同一类中的数据对象的相似性尽可能大，同时使不同类中的数据对象的相似性尽可能小。举个例子，如果有两种动物的数据集（比如鳄鱼和大象的食性、活动范围和体型），考虑用点与点之间的距离刻画相似度，那么在高维空间中，相同物种的距离近，相似度高；不同物种之间的距离远，相似度低，这样数据集按照相似度就可以分成两个集群。

聚类分析就是靠算法判断数据之间的相似性，再根据规则把相似的数据聚在一起，同时分割不相似的数据。主流的聚类算法有划分聚类、层次聚类、密度聚类等。

划分聚类首先给出一个初始的分组方法，再通过反复迭代的方式改变分组，使得每一次改进之后的分组方案都较前一次好，直到最后到达目标效果，代表算法为K-Means，改进算法Kernel K-Means;

层次聚类则对给定的样本集进行类似层次的分解，直到某种满足条件。其具体又可分为“自底向上”和“自顶向下”两种方案，代表算法为凝聚层次聚类和分裂层次聚类;

密度聚类并不基于样本距离，而是基于样本密度进行聚类，其指导思想是，只要一个区域中的点的密度大过某个阈值，就把它加到与之相近的聚类中去，以此克服基于距离的算法只能发现“类圆形”的聚类的缺点，代表算法为Density-Based

Spatial Clustering of Applications with Noise，简称为DBSCAN;

此外，其他聚类方法包括网格聚类、模型聚类等方法，这些算法不直接处理原数据，而是先对原数据进行特征提取，或者学习模型，然后再根据特征或模型进行聚类。

（二）常用聚类方法介绍

1.K-Means算法

K-Means算法是解决聚类问题的最简便的算法之一，该算法认为两个数据点的距离越近，相似度越高。

该算法一开始随机生成K个聚类中心，然后把每个数据点归入离聚类中心最近的中心，这样就得到了K个类。再计算K个类中所有数据点的中心，作为新的聚类中心，就这样重复划分数据点与计算聚类中心，直到所有聚类中心都不再变化，这样就把数据集聚为了K类。

K-Means算法的目标是最小化样本点到聚类中心的距离之和:

$$E(X)=\sum_{i=1}^{k}\sum_{x\in\pi_i}\|x-v_i\|^2$$

其中，x为数据集中的点，v_i为第i类的聚类中心，计算公式为$v_i=\frac{1}{|\pi_i|}\sum_{x\in\pi_i}x$

计算步骤如下:

随机选K个初始聚类中心;

逐个将所有样本按最小距离准则分配给K个聚类中心;

根据分类结果，利用分类后的数据点重新计算聚类中心;

重复步骤2、3直至聚类中心不再变化;

优点: 思想简洁，便于理解；运算复杂度低，高效率。

不足: 聚类结果对初始位置敏感，初始位置不同可能会导致聚类结果不同，对同一个数据集多次聚类时，得出的聚类结果很有可能不同；聚类结果很大程度上依赖人工设定的聚类个数K，而且无法确定数据集中最佳的K值，容易造成聚类结果的偏差；孤立点和噪声很容易干扰到算法；另外对于非凸面的数据集，该算法很难得到满意的结果。

2.凝聚层次聚类算法

在凝聚层次聚类中，刻画相似度的指标是距离，距离越近说明数据点之间的相似度越高；距离越远说明数据点之间相似度越低。在计算距离时，有多种距离度量方式，例如：欧式距离(Euclidean)、曼哈顿距离(Manhattan)和余弦距离(Cosine)，三种距离方式的计算公式如下。

表 2：常用距离度量方式

距离度量方式	公式
欧氏距离(Euclidean)	$D(x,y)=\sqrt{(x_1-y_1)^2+(x_2-y_2)^2}$
曼哈顿距离(Manhattan)	$D(x,y)=\lvert x_1-y_1\rvert+\lvert x_2-y_2\rvert$
余弦距离(Cosine)	$D(x,y)=1-\cos(\theta)=1-\frac{x\cdot y}{\lVert x\rVert\lVert y\rVert}$

数据来源：广发证券发展研究中心

凝聚层次聚类算法是一种自底向上的策略，该算法一开始把所有数据点当成单独的类，然后根据类之间的距离（即相似度），逐步合并距离最近的类，直到把所有数据点合并到K个类。

计算步骤如下：

把每个对象各自划分为单独的类；

根据类之间的距离，合并最近的两个类；

重新计算新产生的类和其他类之间的距离；

重复步骤2、3直至所有的对象都被归并到K个类中

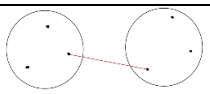
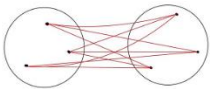
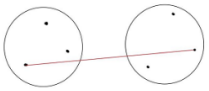
优点：层次聚类可以使用多种距离度量框架；对类的形状不敏感；可以发现类的层次关系。

缺点：聚类结果依赖提前设定的聚类数K；异常值对结果有较大影响；计算复杂度高；聚类结果具有不可逆性，一旦聚类结果形成，无法再重新合并来优化聚类的性能。

在第(2)步与第(3)步使用到了类之间的距离。对于包含单个数据点的类，类之间的距离就是点与点的距离；对于包含多个数据点的类，有多种方法计算类与类之间的距离，例如以下三种：单链(Single Linkage)、全链(Complete Linkage)和平均链(Average Linkage)。

单链使用两个类之间最近的点的距离作为类之间的距离，全链方法使用两个类之间最远的点的距离作为类之间的距离，平均链使用两个类之间数据点的平均距离作为类之间的距离。如下表所示：

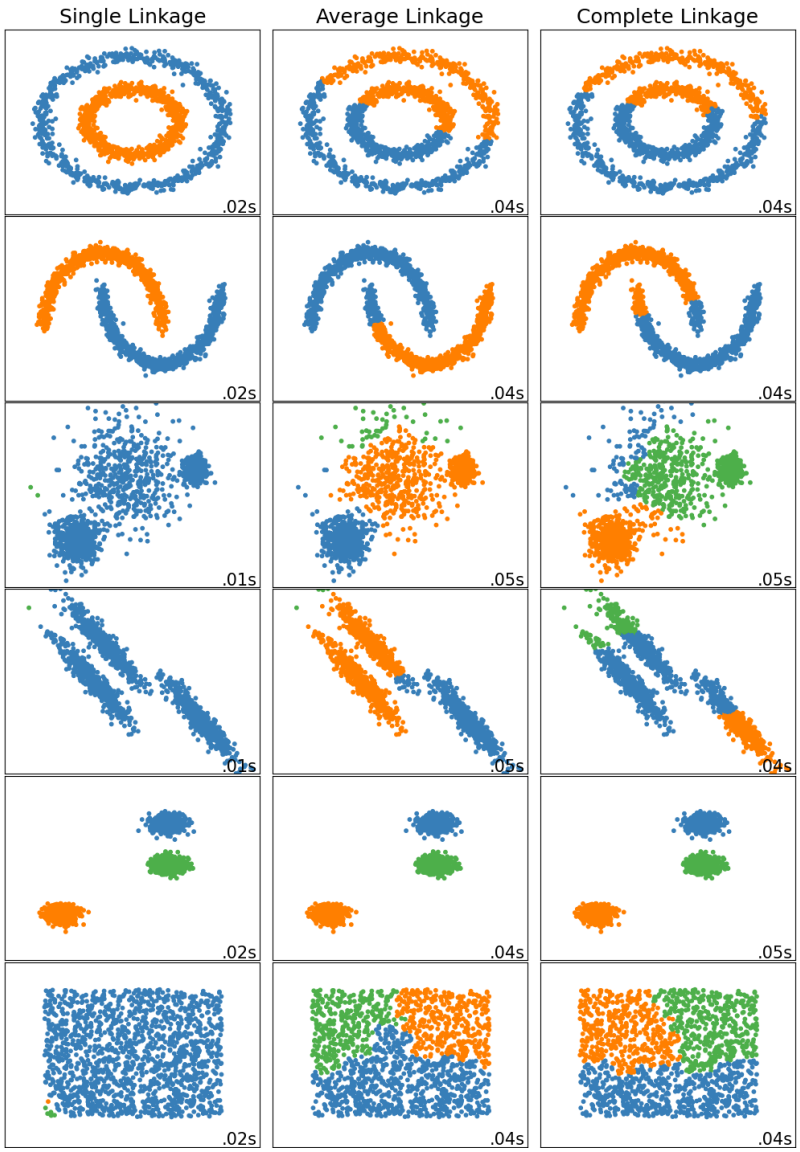
表 3：类之间常用距离方式

距离方式	公式	图示
单链	$D(C_1,C_2)=\mathrm{MinD}(X_1,X_2)$	
平均链	$D(C_1,C_2)=\frac{1}{\lvert C1\rvert\lvert C2\rvert}\sum_{x1}\sum_{x2}\mathrm{D}(X_1,X_2)$	
全链	$D(C_1,C_2)=\mathrm{MaxD}(X_1,X_2)$	

数据来源：广发证券发展研究中心

以上三种方法的计算方式各有优劣，对于不同类型的数据集，三种方法效果对比如下：

图 2：类与类之间方式对聚类结果的影响



数据来源：scikit-learn.org，广发证券发展研究中心

对于有明显边界的数据，单链的效果较好。但是当数据集的边界模糊时，单链的效果较差，平均链和全链的效果较好。

3.DB-Scan算法

DBSCAN是一种基于密度的聚类算法，根据样本分布的紧密程度分类，**算法计算步骤如下：**

从数据集中任意选取一个数据对象点 p;

如果所选取的数据对象点 p 为核心点，则找出所有从 p 密度可达的数据对象点，形成一个簇;

如果选取的数据对象点 p 是边缘点，选取另一个数据对象点;

重复步骤2、3，直到所有点被处理。

优点：可以对任意形状的数据进行聚类；可以在聚类的过程中发现异常点，且对异常点不敏感；起始点对结果没有影响。

缺点：算法复杂度高，代码运行缓慢；需要对距离阈值与邻域样本数阈值进行联合调参，且参数对聚类结果有较大影响。

（三）K-Means 算法改进

本文主要对划分聚类方法进行研究。在划分聚类的定义中，一个重要的聚类目标就是“类内的点都足够近，类间的点都足够远”，而其中涉及最重要的概念就是样本距离。换言之，对样本距离的定义很大程度上决定了划分聚类的效果。

1.样本距离的定义与核聚类方法

传统的样本距离定义一般基于欧式空间，即样本点之间的距离刻画为

$$d(x_i, x_j) = \| x_i - x_j \|^2 = \sum_{s=1}^{d} (x_{is} - x_{js})^2$$

其中，x_i, x_j为不同样本，s为样本特征维度的下标，这里每个样本具有d个维度的特征；欧式距离的优点是直观方便，与传统意义上对空间距离的主观理解比较契合。基于此类距离刻画的一种经典聚类方法为K-Means，其核心思想是通过迭代算法最小化所有样本点到对应聚类中心的距离之和：

$$\min_{U} \sum_{k=1}^{C} \sum_{i=1}^{n} U_{ki} \| c_k - x_i \|_2^2$$

其中c_k为聚类中心，U_{ki}为类别归属指标，当且仅当x_i属于k类别时取值为1，否则取值为0。

K-Means模型的核心思想是在特征空间中借助若干超平面对样本进行划分聚类，而这就要求所有样本在特征空间中是线性可分的。因此，尽管K-Means聚类在线性空间中具有优异的聚类效果，但在非线性聚类场景中，其局限性较大。

针对K-Means模型存在的上述缺陷，可以通过引入核函数，将特征空间向更高维的空间映射，从而使样本在高维空间中满足线性可分的条件。这便是kernel K-means模型的思想。

2.kernel K-Means算法的技术细节

由前文可知，kernel K-Means的本质是在传统K-Means方法的基础上替换了样本距离的衡量方式。设样本向高维空间的映射函数为$\Phi(\cdot)$，则样本点在高维空间的距离为：

$$d(x_i, x_j) = \left\| \Phi(x_i) - \Phi(x_j) \right\|^2 = \left(\Phi(x_i) - \Phi(x_j) \right)' \left(\Phi(x_i) - \Phi(x_j) \right)$$
$$= \Phi(x_i)'\Phi(x_i) + \Phi(x_j)'\Phi(x_j) - \Phi(x_i)'\Phi(x_j) - \Phi(x_j)'\Phi(x_i)$$

进一步，定义核函数为样本点在高维空间中的内积

$$K(x_i, x_j) = \Phi(x_i)'\Phi(x_j)$$

则样本点的距离定义变为

$$d(x_i, x_j) = K(x_i, x_i) + K(x_j, x_j) - 2K(x_i, x_j)$$

类似地，样本点与第k个聚类中心的距离为

$$d(x_i, c_k) = \| \Phi(x_i) - \Phi(c_k) \|^2 = \| \Phi(x_i) - \frac{1}{n^{(k)}} \sum_{h=1}^{n^{(k)}} \Phi(x_h) \|^2$$

$$= \Phi(x_i)'\Phi(x_i) - 2\frac{1}{n^{(k)}} \Phi(x_i)' \sum_{h=1}^{n^{(k)}} \Phi(x_h)$$

$$+ \frac{1}{n^{(k)^2}} \sum_{h_1=1}^{n^{(k)}} \sum_{h_2=1}^{n^{(k)}} \Phi(x_{h_1})' \Phi(x_{h_2})$$

$$= K(x_i, x_j) - 2\frac{1}{n^{(k)}} \sum_{h=1}^{n^{(k)}} K(x_i, x_h) + \frac{1}{n^{(k)^2}} \sum_{h_1=1}^{n^{(k)}} \sum_{h_2=1}^{n^{(k)}} K(x_{h_1}, x_{h_2})$$

其中，n_k为第k个聚类簇内的样本数量，x_h为第k个聚类簇内的任一样本。由此可知，想要计算高维空间内任意两个样本点或任意样本点与聚类中心的距离，我们只需利用核函数计算任意两个样本点在高维空间中的内积即可。

kernel K-Means算法常用核函数如下：

表 4：常用核函数

核函数	公式
Cosine 核函数	$K(x, y) = \frac{xy^T}{\|x\|\|y\|}$
Linear 核函数	$K(x, y) = x^T y$
Polynomial 核函数	$K(x, y) = (\gamma x^T y + c_0)^d$
RBF 核函数	$K(x, y) = \exp(-\gamma \|x - y\|^2)$

数据来源：广发证券发展研究中心

3.匹配算法合并多次聚类结果

由于K-Means聚类算法对于分类的初值选取较为敏感，可以尝试使用聚类匹配算法对多次聚类的结果进行合并，以增强聚类算法的稳定性。具体步骤如下：

步骤1：利用随机初值进行多次聚类，得到聚类结果；

步骤2：从n=1开始，循环利用前n个聚类的合并结果（记为x）与第n+1个聚类结果（记为y）合并，合并方案为：

首先对两组聚类结果x和y的聚类中心进行匹配，设计相似度指标：

$$similarity_{i,j} = \frac{c_i与c_j共有行业数量}{c_i内行业数量 + c_j内行业数量}$$

其中c_i, c_j分别为两组聚类结果x和y中的任意类别；

利用贪心算法，选取similarity矩阵中最大的数值进行聚类匹配，例如指定x中的类别c_i对应y中的类别c_j；

重复步骤2，对剩下的类别进行一一匹配。

步骤3：完成类别匹配后，逐一对所有行业进行归属统计，选择归属次数最多的类别作为最终分类结果。

四、行业聚类方法应用

这部分主要对上述提到的几类经典的聚类算法在行业划分上进行探讨应用。

（一）聚类设置

聚类方案：使用K-Means、kernel K-Means和凝聚层次聚类三种聚类方法，对样本进行划分。通过对距离计算使用的时间跨度长度，聚类数K，核函数种类与距离刻画方式等方式的差异，观察不同聚类划分结果对参数的敏感性。

聚类目的：通过研究不同模型、不同参数对聚类结果的影响，挖掘出较优的行业聚类模型。

（二）聚类敏感性分析

聚类方法会按照一定的相似性将行业指数进行分类，在使用收益率数据时，可能会受到参数值等因素的干扰，导致聚类结果与实际情况相违背。这种情况可能需要调整参数，观察聚类结果对参数值的敏感性，尽可能地排除干扰，找出合适的参数结果下对应的相对稳健的行业聚类效果。

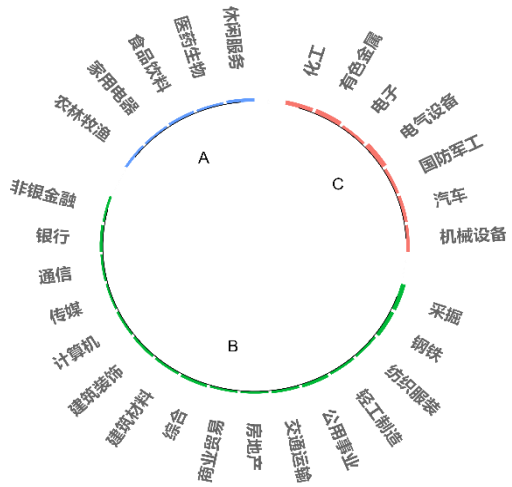
1.K-Means算法

聚类数量K对聚类结果的影响

使用时间跨度为1年的申万一级行业数据（2020.10.01到2021.10.31）进行聚类分析，设定不同的聚类数（K值），统计聚类结果与聚类数的关系。

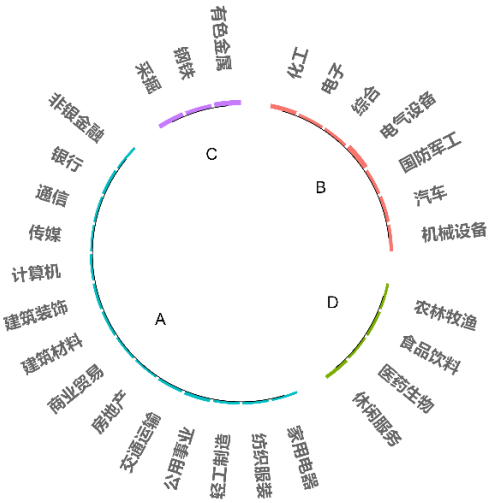
下图即为聚类结果，以聚类数K=3为例，申万一级行业指数被划分为3类（A类、B类和C类），聚到同一类别中的行业在图中的颜色相同。

图 3：聚类数K=3，行业划分结果一览



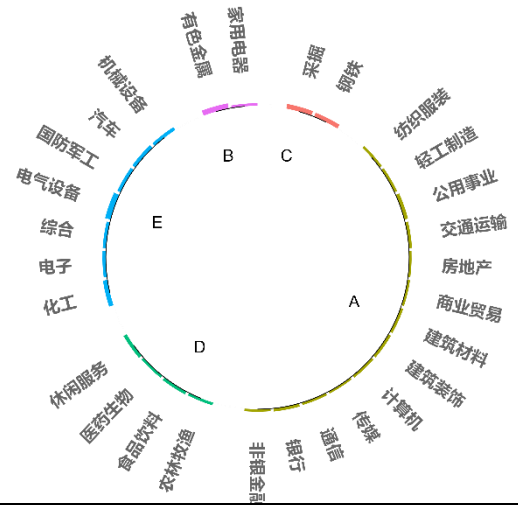
数据来源：Wind，广发证券发展研究中心

图 4：聚类数K=4，行业划分结果一览



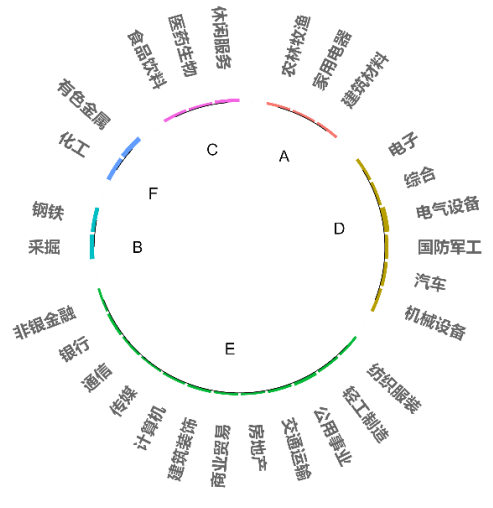
数据来源：Wind，广发证券发展研究中心

图 5：聚类数K=5，行业划分结果一览



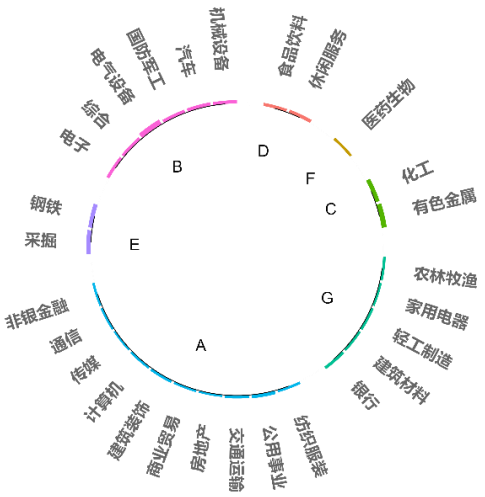
数据来源：Wind，广发证券发展研究中心

图 6：聚类数K=6，行业划分结果一览



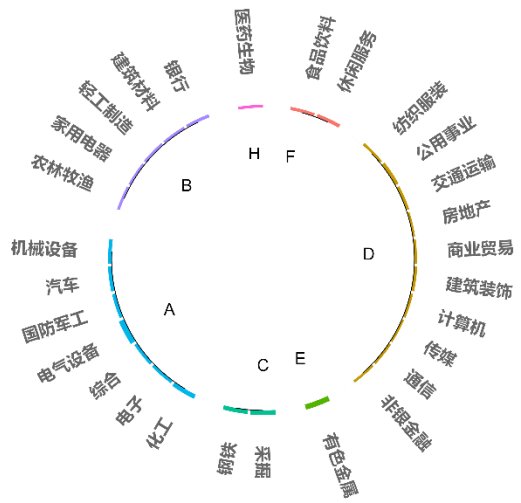
数据来源：Wind，广发证券发展研究中心

图 7：聚类数K=7，行业划分结果一览



数据来源：Wind，广发证券发展研究中心

图 8：聚类数K=8，行业划分结果一览



数据来源：Wind，广发证券发展研究中心

对上述聚类结果进行整理，统计聚类结果中每一类包含行业的个数：

表 5：聚类数K与每一类中包含行业数

聚类数K	类1	类2	类3	类4	类5	类6	类7	类8
3	7	16	5					
4	7	4	14	3				
5	2	13	4	7	2			
6	3	6	12	2	2	3		
7	2	1	2	5	10	2	6	
8	2	10	1	2	7	5	0	1

数据来源：Wind，广发证券发展研究中心

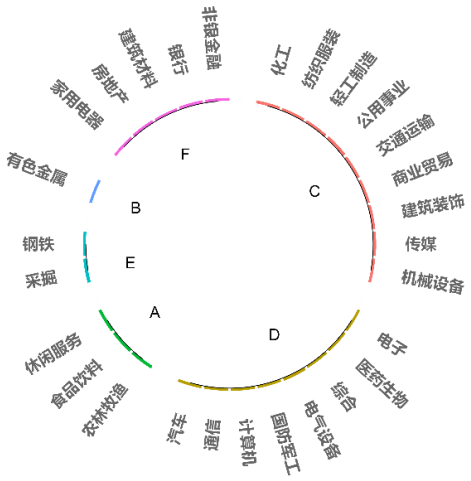
综合以上结果，可以看出聚类数越多，行业划分就越细致。行业划分结果显示，无论聚类数如何，总有行业被聚为同一类（如钢铁和采掘）。但是对于银行来说，当聚类数K不超过6时，银行会和非银金融行业被划分为同一类；当聚类数大于6时，银行和非银金融不再聚为同一类，聚类有效性降低。另外，当聚类数量为8时，使用K-Means算法只能将结果聚为7类，剩余一类为空集。

考虑聚类结果的分布情况，可以看到当K的数量越大时，聚类结果就越均匀，但聚类数量过大会干扰聚类的有效性。综合考虑聚类的有效性、实际的行业走势相关性等，选取聚类数K等于6，进行后续研究。

样本时间跨度对聚类结果的影响

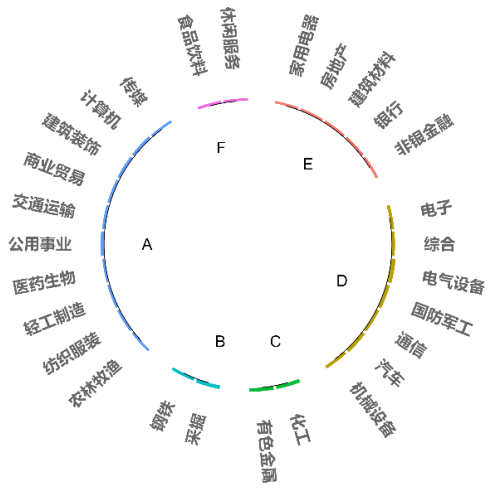
根据上述研究，将聚类数设置为6类，再考虑利用不同时间跨度的数据长度进行行业划分。以2021.10.31为截至日期，往前倒推时间，分别构建3个月、6个月、1年、2年和3年的数据集，研究时间跨度对聚类结果的影响。

图 9：时间跨度3个月，行业划分结果一览



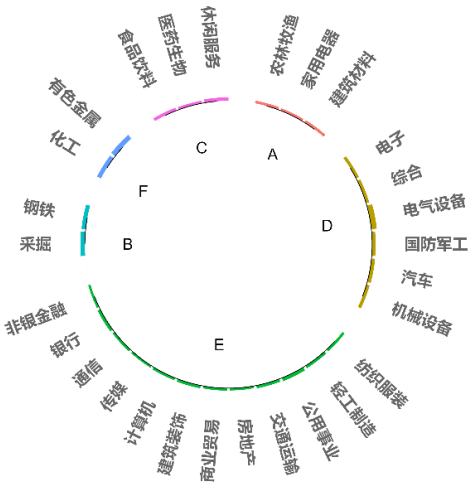
数据来源：Wind，广发证券发展研究中心

图 10：时间跨度6个月，行业划分结果一览



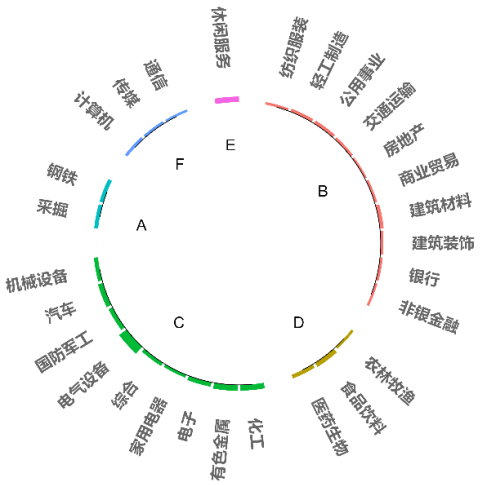
数据来源：Wind，广发证券发展研究中心

图 11：时间跨度1年，行业划分结果一览



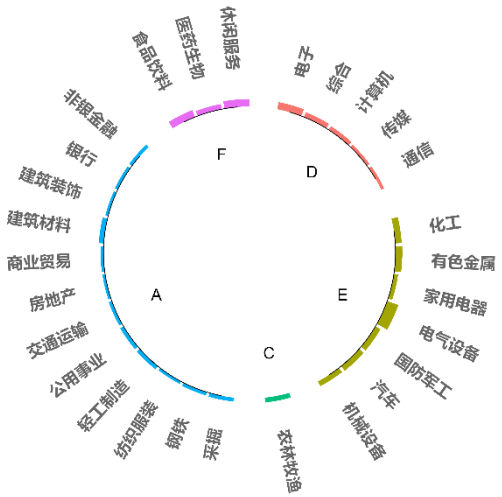
数据来源：Wind，广发证券发展研究中心

图 12：时间跨度2年，行业划分结果一览



数据来源：Wind，广发证券发展研究中心

图 13：时间跨度3年，行业划分结果一览



数据来源：Wind，广发证券发展研究中心

表 6：每一类中包含行业数与时间跨度的关系

时间跨度	类1	类2	类3	类4	类5	类6
3个月	9	8	3	2	1	5
6个月	5	7	2	2	10	2
1年	3	6	12	2	2	3
2年	10	3	9	2	3	1
3年	5	0	7	1	12	3

数据来源：Wind，广发证券发展研究中心

根据聚类结果，可以看出当聚类时间跨度为6个月时，分组结果较为均匀，采掘和钢铁、有色金属与化工等周期联动性较强的行业。

2.Kernel-K-Means算法

核函数与聚类数对聚类结果的影响

使用时间跨度为1年的数据进行聚类分析，初始设置不同的核函数与聚类数K值，结果如下。

表 7：每一类中包含行业数与核函数的关系

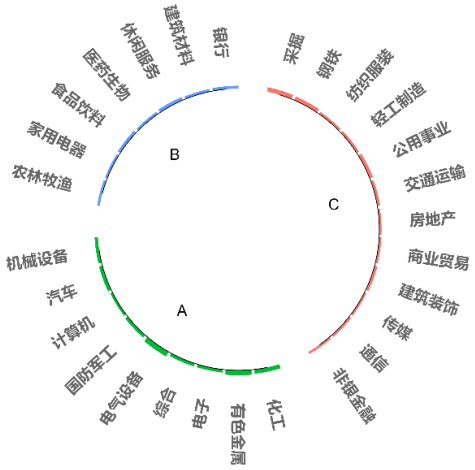
核函数与分组数	类1	类2	类3	类4	类5	类6	类7	类8
linear-3	9	5	14					
linear-4	13	6	5	4				
linear-5	7	13	0	5	3			
linear-6	4	2	8	0	2	12		
linear-7	3	11	3	6	0	1	4	
linear-8	2	2	7	2	8	2	1	4
polynomial-3	3	23	2					
polynomial-4	2	2	3	21				
polynomial-5	3	1	21	2	1			
polynomial-6	2	2	21	1	2			
polynomial-7	2	1	3	1	2	1	18	
polynomial-8	18	0	2	3	1	2	1	1
rbf-3	12	9	7					
rbf-4	6	9	8	5				
rbf-5	9	6	3	4	6			
rbf-6	6	6	7	4	4	1		
rbf-7	6	4	6	4	2	4	2	
rbf-8	4	3	3	5	7	3	3	0
cosine-3	12	9	7					
cosine-4	8	10	8	2				
cosine-5	8	5	3	7	5			
cosine-6	3	5	3	7	3	7		
cosine-7	6	5	2	4	3	7	1	
cosine-8	4	5	5	6	3	0	2	3

数据来源：Wind，广发证券发展研究中心

观察分组情况，当核函数为linear和polynomial时，分组结果较不均匀，考虑剔除以上两种核函数。剩余的Cosine核函数与rbf核函数结果相差不大，以Cosine核函数为例，研究聚类数对行业划分结果的影响。

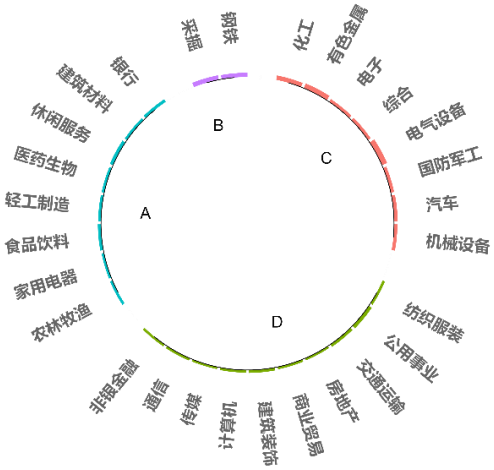
聚类数对行业划分结果的影响

图 14：聚类数K=3，行业划分结果一览



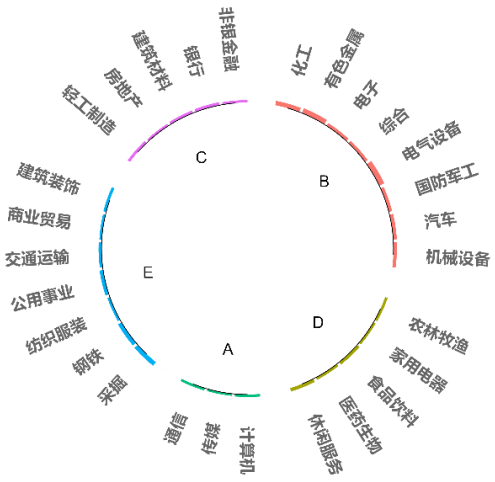
数据来源：Wind，广发证券发展研究中心

图 15：聚类数K=4，行业划分结果一览



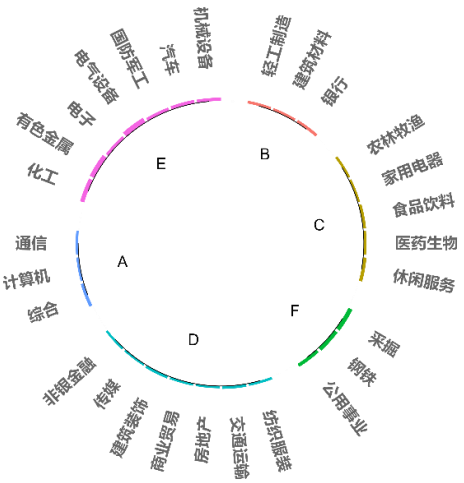
数据来源：Wind，广发证券发展研究中心

图 16：聚类数K=5，行业划分结果一览



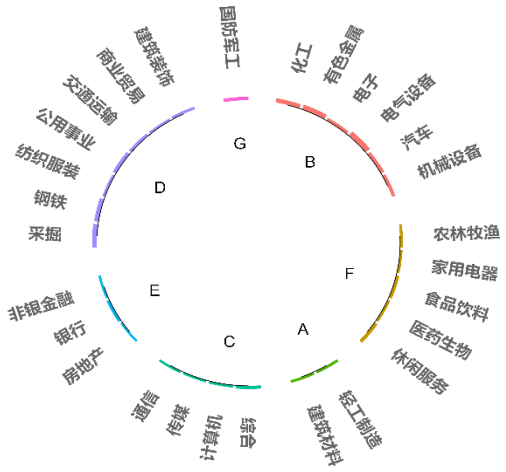
数据来源：Wind，广发证券发展研究中心

图 17：聚类数K=6，行业划分结果一览



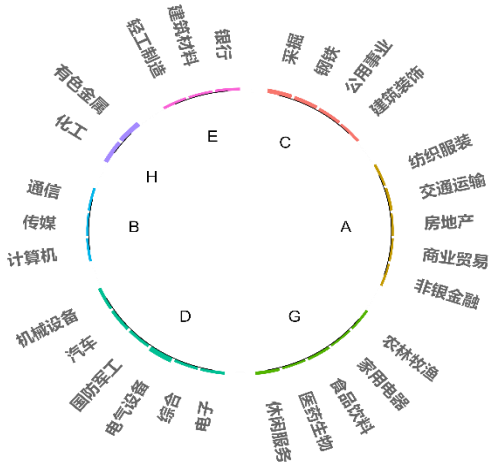
数据来源：Wind，广发证券发展研究中心

图 18：聚类数K=7，行业划分结果一览



数据来源：Wind，广发证券发展研究中心

图 19：聚类数K=8，行业划分结果一览



数据来源：Wind，广发证券发展研究中心

表 8：聚类数量与每一类中包含行业数量的关系

聚类数量	类1	类2	类3	类4	类5	类6	类7	类8
3	12	9	7					
4	8	10	8	2				
5	8	5	3	7	5			
6	3	5	3	7	3	7		
7	6	5	2	4	3	7	1	
8	4	5	5	6	3	0	2	3

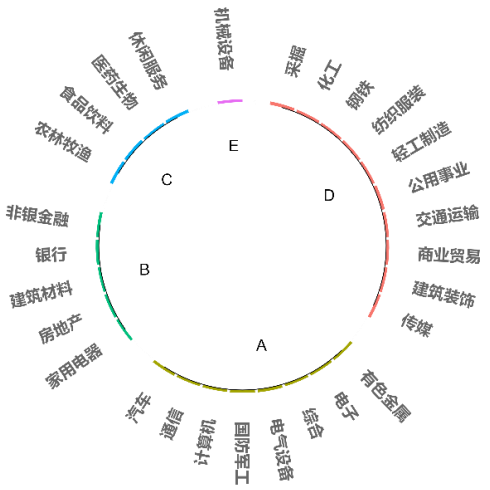
数据来源：Wind，广发证券发展研究中心

观察分组情况，可以发现当聚类数增加时，行业分类更加细致，但是当聚类数K等于6时，银行行业会和轻工制造与建筑材料分为一类；当聚类数K等于7时，国防军工会单独分为一类；当聚类数K等于8时，仅能聚类为7类，其中有一类为空类。综合考虑行业划分细致度、准确性等情况，选取聚类数K=5进行后续研究。

样本时间跨度对聚类结果的影响

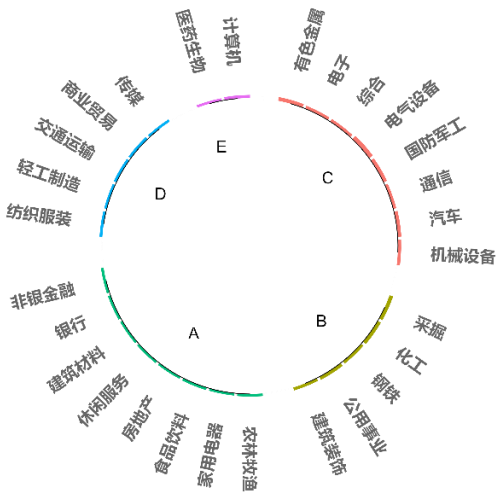
选取聚类数K=5，核函数为cosine，分析不同时间跨度对聚类结果的影响。

图 20：3个月，行业划分结果一览



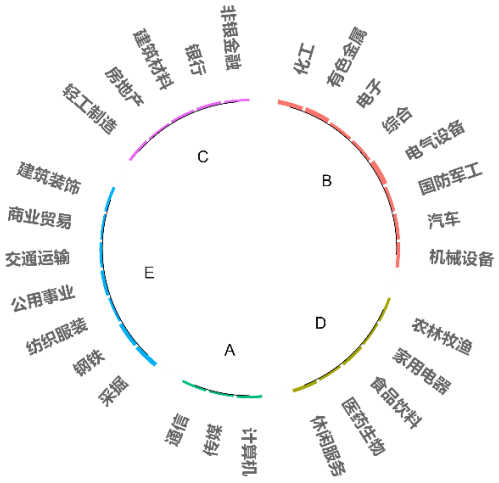
数据来源：Wind，广发证券发展研究中心

图 21：6个月，行业划分结果一览



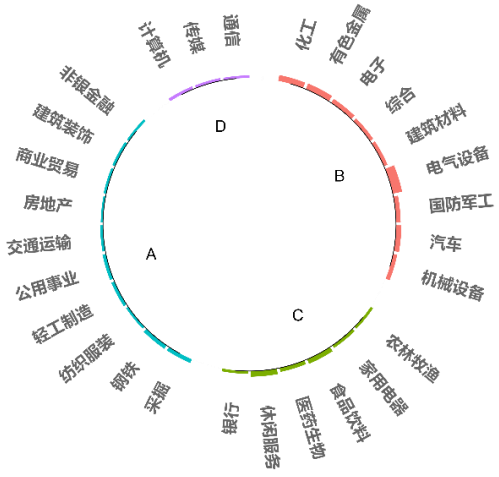
数据来源：Wind，广发证券发展研究中心

图 22：1年，行业划分结果一览



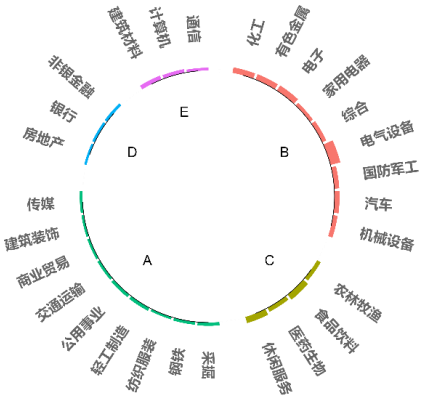
数据来源：Wind，广发证券发展研究中心

图 23：2年，行业划分结果一览



数据来源：Wind，广发证券发展研究中心

图 24：3年，行业划分结果一览



数据来源：Wind，广发证券发展研究中心

表 9：时间跨度与每一类中包含行业数的关系

时间跨度	类1	类2	类3	类4	类5
3个月	10	8	5	4	1
6个月	8	5	8	5	2
1年	8	5	3	7	5
2年	9	6	10	3	0
3年	9	4	9	3	3

数据来源：Wind，广发证券发展研究中心

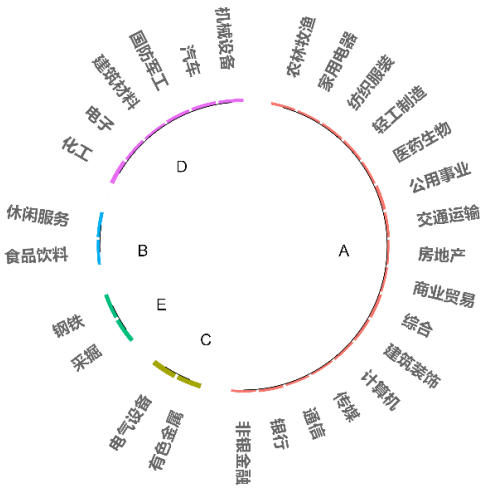
当时间跨度为两年时，聚类结果中出现了空类。当时间跨度为3年时，聚类结果中银行、地产和非银金融被分为同一类，识别出了大金融板块；食品饮料、医药生物、农林牧渔和休闲服务被分为同一类，识别出了消费板块的产业链。

3.凝聚层次聚类算法

距离度量方式对聚类结果的影响

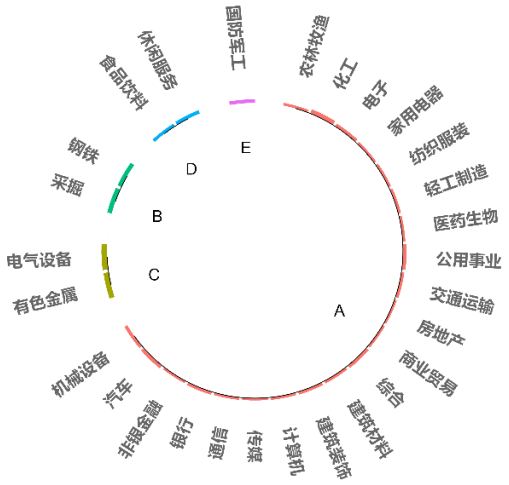
将时间跨度设定为1年，聚类数设定为5，类之间距离方式选定为全链(Complete Linkage)，研究不同距离度量方式对聚类结果的影响。

图 25：euclidean欧氏距离，行业划分结果一览



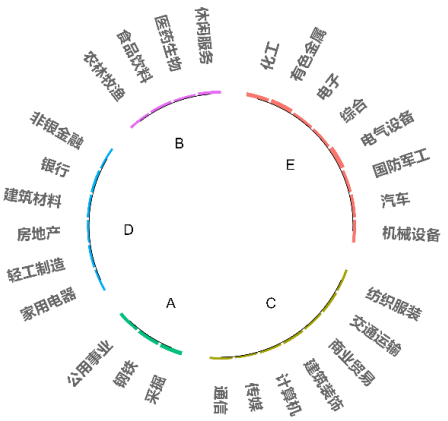
数据来源：Wind，广发证券发展研究中心

图 26：manhattan曼哈顿距离，行业划分结果一览



数据来源：Wind，广发证券发展研究中心

图 27：cosine余弦距离，行业划分结果一览



数据来源：Wind，广发证券发展研究中心

表 10：距离度量方式与每一类中包含行业数量的关系

距离度量方式	类1	类2	类3	类4	类5
欧氏距离	16	2	2	2	6
曼哈顿距离	21	2	2	2	1
余弦距离	8	7	3	6	4

数据来源：Wind，广发证券发展研究中心

当距离度量方式为欧式距离和曼哈顿距离时，聚类结果较不均匀，余弦距离的聚类结果较为理想。故选取余弦距离进行后续研究。

类之间距离计算方式对聚类结果的影响

选取1年的数据进行聚类，类与类之间的距离方式设定为complete，距离度量方式设定为cosine，聚类结果如下：

表 11：聚类数量与每一类中包含行业数量的关系

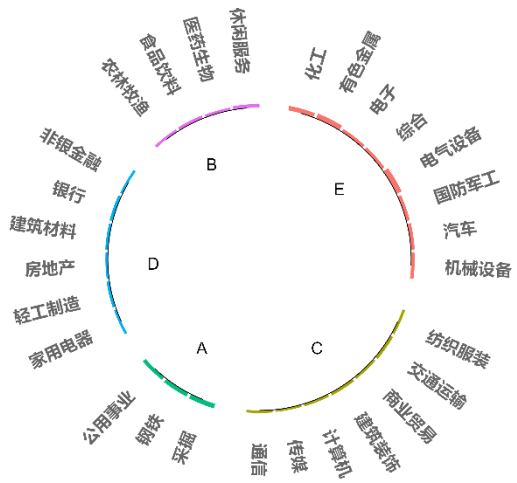
类之间距离方式与聚类数量	类1	类2	类3	类4	类5	类6	类7	类8
全链-3	13	12	3					
全链-4	12	7	3	6				
全链-5	8	7	3	6	4			
全链-6	3	7	6	6	4	2		
全链-7	7	6	6	2	4	2	1	
全链-8	6	4	6	4	3	2	1	2
平均链-3	16	4	8					
平均链- 4	13	3	8	4				
平均链-5	3	6	8	4	7			
平均链- 6	6	7	8	4	2	1		
平均链- 7	8	7	3	4	2	1	3	
平均链- 8	7	4	3	6	2	1	3	2
单链- 3	23	4	1					
单链- 4	22	4	1	1				
单链- 5	21	4	1	1	1			
单链- 6	19	4	2	1	1	1		
单链- 7	18	4	2	1	1	1	1	
单链- 8	17	4	2	1	1	1	1	1

数据来源：Wind，广发证券发展研究中心

由上表结果可以看出，当类之间距离为单链(Singe Linkage)时，聚类结果极不均匀，类1包含的行业数量高于其他类。全链(Complete Linage)和平均链(Average Linkage)的聚类结果都优于单链。当聚类数为5时，两者的聚类结果都比较均匀。

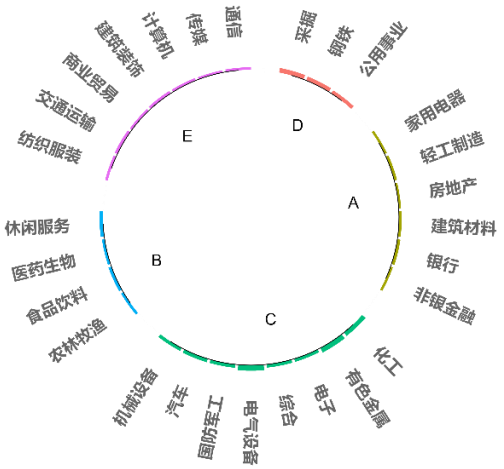
将时间跨度设定为1年，聚类数量设置为5，距离度量方式设定为cosine，分别研究全链、平均链和单链对聚类结果的影响。

图 28：全链，行业划分结果一览



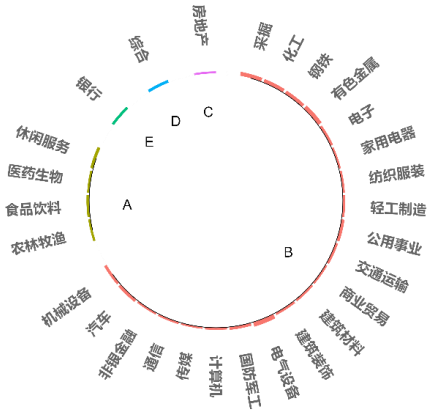
数据来源：Wind，广发证券发展研究中心

图 29：平均链，行业划分结果一览



数据来源：Wind，广发证券发展研究中心

图 30：单链，行业划分结果一览



数据来源：Wind，广发证券发展研究中心

表 12：类之间距离计算方式对聚类结果的关系

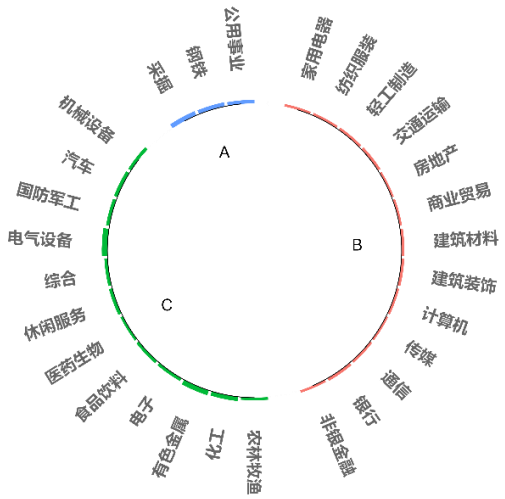
类之间距离方式	类1	类2	类3	类4	类5
全链	8	7	3	6	4
平均链	3	6	8	4	7
单链	21	4	1	1	1

数据来源：Wind，广发证券发展研究中心

对以上结果进行研究，可以发现单链(Single Linkage)的聚类结果较不均匀，同时全链(Complete Linkage)和平均链(Average Linkage)的聚类结果比较一致，因此选取全链进行下一步研究。

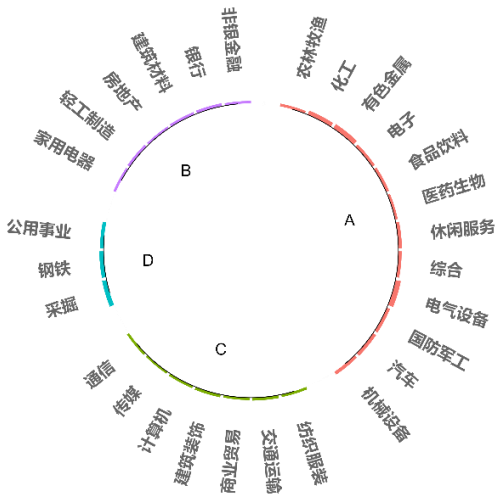
聚类数K对聚类结果的影响

图 31：聚类数K=3，行业划分结果一览



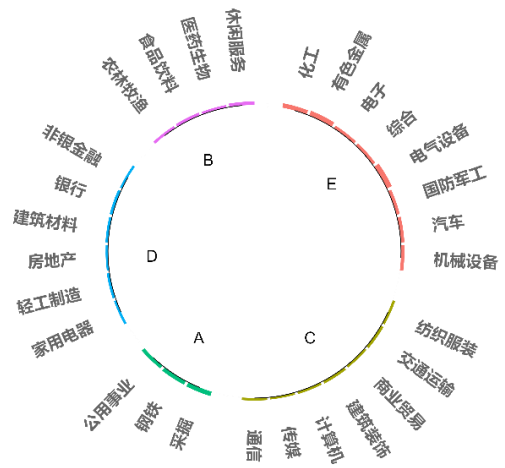
数据来源：Wind，广发证券发展研究中心

图 32：聚类数为4，行业划分结果一览



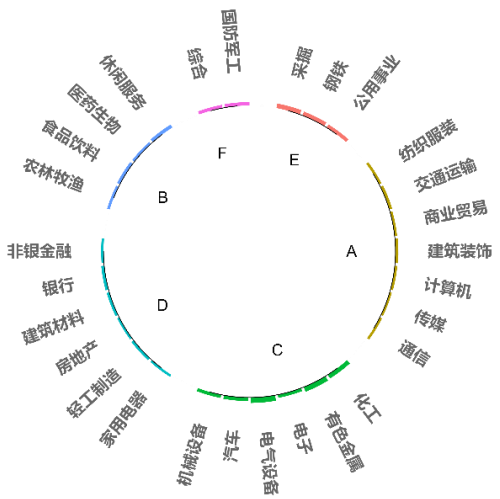
数据来源：Wind，广发证券发展研究中心

图 33：聚类数为5，行业划分结果一览



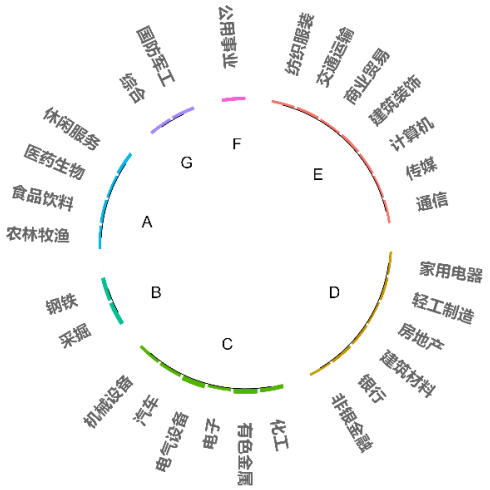
数据来源：Wind，广发证券发展研究中心

图 34：聚类数为6，行业划分结果一览



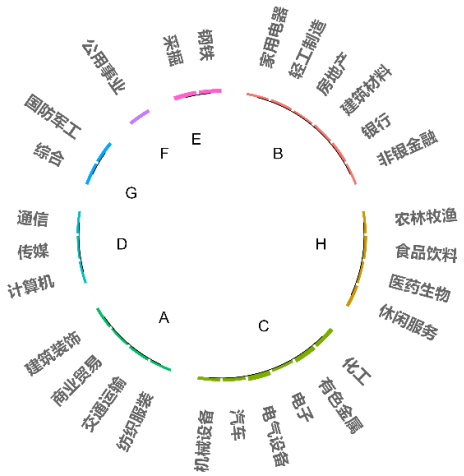
数据来源：Wind，广发证券发展研究中心

图 35：聚类数为7，行业划分结果一览



数据来源：Wind，广发证券发展研究中心

图 36：聚类数为8，行业划分结果一览



数据来源：Wind，广发证券发展研究中心

表 13：聚类数量与每一类中包含行业数的关系

聚类数量	类1	类2	类3	类4	类5	类6	类7	类8
3	13	12	3					
4	12	7	3	6				
5	8	7	3	6	4			
6	3	7	6	6	4	2		
7	7	6	6	2	4	2	1	
8	6	4	6	4	3	2	1	2

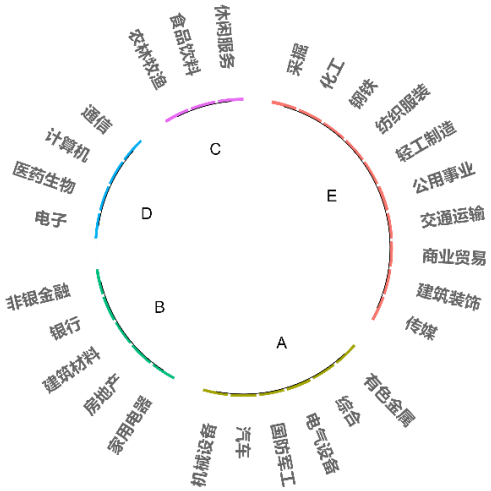
数据来源：Wind，广发证券发展研究中心

从聚类结果的均匀性来看，当聚类数量为3和4时，类1中包含的行业数过多；当聚类数量为7和8时，类7中包含的行业数过少；聚类数量为5和6时，分类结果较为均匀。

样本时间跨度对聚类结果的影响

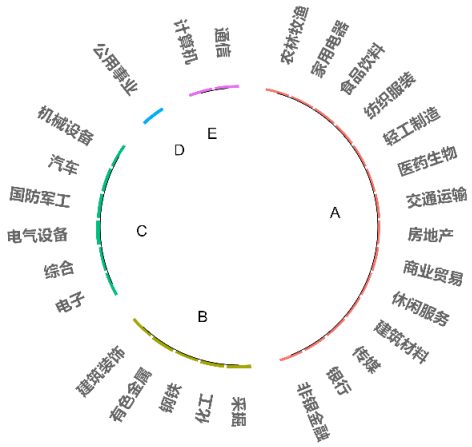
根据上述研究，类之间距离使用全链，将聚类数设置为5类，再构造不同时间跨度的数据集。以2021.10.31为截至日期，向前倒推时间，分别构建3个月、6个月、1年、2年和3年的数据集，研究时间跨度对聚类结果的影响。

图 37：时间跨度3个月，行业划分结果一览



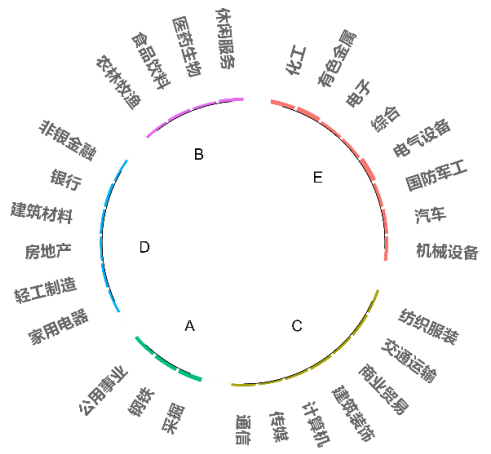
数据来源：Wind，广发证券发展研究中心

图 38：时间跨度6个月，行业划分结果一览



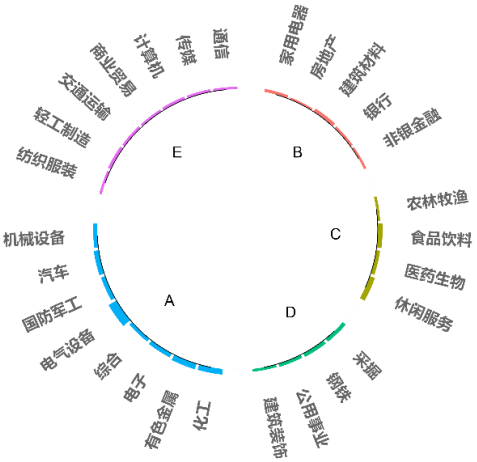
数据来源：Wind，广发证券发展研究中心

图 39：时间跨度1年，行业划分结果一览



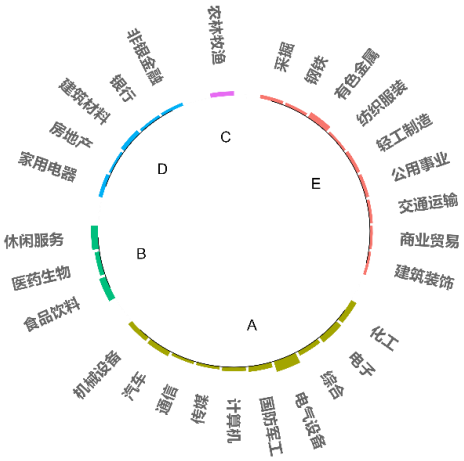
数据来源：Wind，广发证券发展研究中心

图 40：时间跨度2年，行业划分结果一览



数据来源：Wind，广发证券发展研究中心

图 41：时间跨度3年，行业划分结果一览



数据来源：Wind，广发证券发展研究中心

表 14：时间跨度与每一类中包含行业数的关系

时间跨度	类1	类2	类3	类4	类5
3个月	10	6	5	4	3
6个月	14	5	6	1	2
1年	8	7	3	6	4
2年	5	4	4	8	7
3年	9	10	3	5	1

数据来源：Wind，广发证券发展研究中心

结果显示，时间跨度为1年、2年的聚类结果分布较为均匀。从行业划分结果来看，在时间跨度为2年的聚类结果中，建筑装饰行业与钢铁行业被分为同一类，但两者周度收益率的走势差距较大，说明聚类结果不合理。相比较之下，时间跨度为1年的聚类结果更加合理。

五、基于动态行业聚类的板块轮动策略

本报告选取申万一级行业指数数据，回测区间为2012年1月1日至2021年10月31日。

（一）策略思想

上下游行业或相似行业之间可能存在短期的联动关系，可以构建一个基于动态行业聚类的板块轮动策略：利用每个调仓点前的时间窗口进行行业聚类，得到存在短期联动关系的板块，再利用板块与行业的关系进行行业轮动，从而寻找投资机会。

（二）样本数据

行业选择：申万一级行业，共28个行业指数。

动态聚类窗口：聚类窗口期指的是利用调仓日前一段时间的收益率序列进行行

业聚类，窗口期的大小与期望得到的联动关系周期长短有关。本策略将聚类窗口设置为一年，即希望模型观测到调仓前一年的行业联动情况。

聚类模型与参数选择：使用层次聚类模型，其中距离度量方式选取余弦距离(Cosine)，类之间距离方式选取全链(Complete Linkage)，聚类数K选取为5，时间跨度设定为1年。

聚类结果：选取申万一级行业2011年1月1日至2021年10月31日的日度收益率数据，进行滚动窗口期为1年的滚动聚类，得到2012年1月1日至2021年10月31日的聚类序列。

（三）实证分析

本篇专题报告探讨三种策略对历史数据进行回测，考虑周频换仓下结果。使用2012年1月1日至2021年10月31日的申万一级行业指数周度收益率数据进行策略回测，申万一级行业等权指数作为基准。

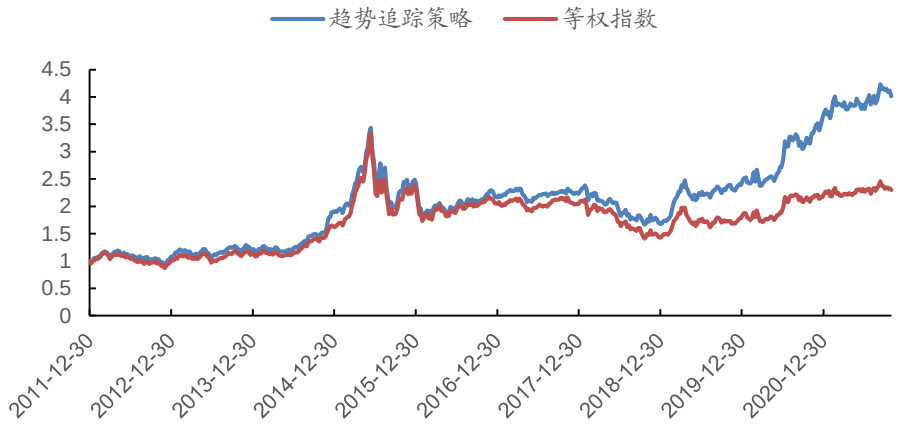
趋势跟踪策略：在每期调仓日节点，根据行业聚类结果，在每个板块内选择当期收益率最高的行业，等权持有。

反转类策略：每期调仓日节点，根据行业聚类结果，在每个板块内选择当期收益率最低的行业，等权持有。

1.趋势跟踪策略

历史回测期内，策略结果表现如下所示。

图 42：周度调仓趋势跟踪策略回测表现一览



数据来源：Wind，广发证券发展研究中心

表 15：趋势跟踪策略相对行业等权指数历史分年度收益率表现

分年度	组合收益	最大回撤	年化波动率	年化收益率	信息比率	等权指数收益	相对等权指数超额
2012	6.68%	21.64%	19.65%	6.68%	0.34	0.07%	6.61%
2013	13.76%	13.49%	20.01%	13.47%	0.67	12.65%	0.99%
2014	57.39%	8.18%	19.14%	53.40%	2.79	43.51%	9.67%
2015	27.14%	42.76%	39.08%	25.97%	0.66	44.40%	-11.95%
2016	-10.83%	25.01%	23.85%	-10.83%	-0.45	-12.40%	1.79%
2017	3.00%	10.55%	10.73%	2.94%	0.27	-0.24%	3.25%
2018	-24.71%	30.09%	22.41%	-24.29%	-1.08	-30.13%	7.76%
2019	42.36%	14.75%	20.04%	41.38%	2.07	25.24%	13.67%
2020	54.52%	11.00%	24.87%	51.96%	2.09	24.04%	24.57%
2021 至今	8.74%	6.00%	16.14%	10.24%	0.63	3.89%	4.67%
全样本	301.73%	51.52%	22.81%	14.76%	0.65	126.73%	77.18%

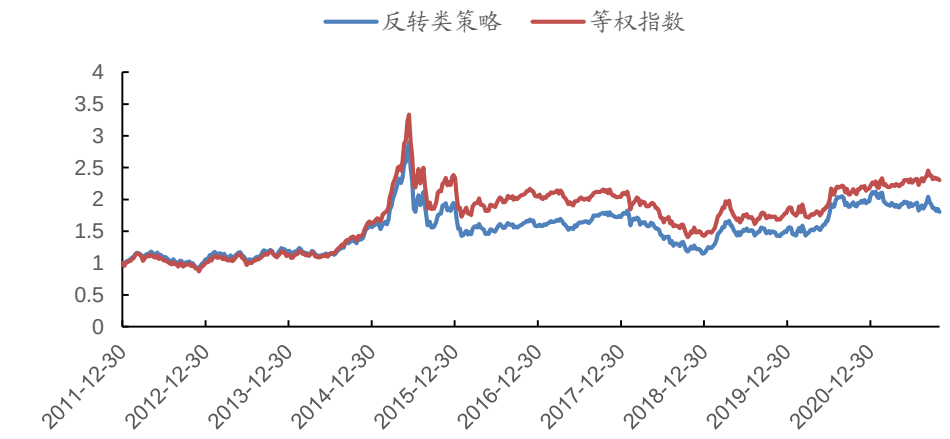
数据来源：Wind，广发证券发展研究中心

全样本累积收益率为301.73%，年化收益率14.76%，年化波动率22.81%，信息比率0.65，相对等权指数的超额收益率为77.18%。

2.反转类策略

历史回测期内，策略结果表现如下所示。

图 43：周度调仓反转类策略净值曲线



数据来源：Wind，广发证券发展研究中心

表 16：反转类策略相对等权指数历史分年度收益率表现

分年度	组合收益	最大回撤	年化波动率	年化收益率	信息比率	等权指数收益	相对等权指数超额
2012	5.23%	23.26%	21.30%	5.23%	0.25	0.07%	5.16%
2013	13.20%	14.17%	19.98%	12.92%	0.65	12.65%	0.49%
2014	31.35%	10.25%	17.44%	29.34%	1.68	43.51%	-8.47%
2015	21.34%	46.10%	41.84%	20.45%	0.49	44.40%	-15.97%
2016	-16.48%	24.89%	22.91%	-16.48%	-0.72	-12.40%	-4.66%
2017	8.83%	10.11%	11.44%	8.65%	0.76	-0.24%	9.09%
2018	-33.32%	36.91%	23.18%	-32.79%	-1.41	-30.13%	-4.57%
2019	29.15%	14.62%	19.82%	28.51%	1.44	25.24%	3.12%
2020	38.58%	9.78%	21.85%	36.85%	1.69	24.04%	11.72%
2021 至今	-12.48%	15.07%	18.12%	-14.36%	-0.79	3.89%	-15.76%
全样本	80.24%	60.25%	23.11%	6.01%	0.26	126.73%	-20.50%

数据来源：Wind，广发证券发展研究中心

全样本累积收益率为80.24%，年化收益率6.01%，年化波动率23.11%，信息比率0.26，相对等权指数的超额收益为-20.50%。

六、风险提示

本文所做的数据测算完全基于过去数据的推演，市场未来环境可能发生变化。投资者制定投资策略时，必须结合市场环境和自身投资理念。

广发金融工程研究小组

罗　　军：首席分析师，华南理工大学硕士，从业 14 年，2010 年进入广发证券发展研究中心。
安 宁 宁：联席首席分析师，暨南大学硕士，从业 12 年，2011 年进入广发证券发展研究中心。
史 庆 盛：资深分析师，华南理工大学硕士，从业 8 年，2011 年进入广发证券发展研究中心。
张　　超：资深分析师，中山大学硕士，从业 7 年，2012 年进入广发证券发展研究中心。
文 巧 钧：资深分析师，浙江大学博士，从业 4 年，2015 年进入广发证券发展研究中心。
陈 原 文：资深分析师，中山大学硕士，从业 4 年，2015 年进入广发证券发展研究中心。
樊 瑞 铎：资深分析师，南开大学硕士，从业 4 年，2015 年进入广发证券发展研究中心。
李　　豪：资深分析师，上海交通大学硕士，从业 3 年，2016 年进入广发证券发展研究中心。
季 燕 妮：高级研究员，厦门大学硕士，2020 年进入广发证券发展研究中心。
张 钰 东：高级研究员，中山大学硕士，2020 年进入广发证券发展研究中心。

广发证券—行业投资评级说明

买入：预期未来 12 个月内，股价表现强于大盘 10%以上。
持有：预期未来 12 个月内，股价相对大盘的变动幅度介于-10%～+10%。
卖出：预期未来 12 个月内，股价表现弱于大盘 10%以上。

广发证券—公司投资评级说明

买入：预期未来 12 个月内，股价表现强于大盘 15%以上。
增持：预期未来 12 个月内，股价表现强于大盘 5%-15%。
持有：预期未来 12 个月内，股价相对大盘的变动幅度介于-5%～+5%。
卖出：预期未来 12 个月内，股价表现弱于大盘 5%以上。

联系我们

	广州市	深圳市	北京市	上海市	香港
地址	广州市天河区马场路 26 号广发证券大厦 35 楼	深圳市福田区益田路 6001 号太平金融大厦 31 层	北京市西城区月坛北街 2 号月坛大厦 18 层	上海市浦东新区南泉北路 429 号泰康保险大厦 37 楼	香港德辅道中 189 号李宝椿大厦 29 及 30 楼
邮政编码	510627	518026	100045	200120	-
客服邮箱	gfzqyf@gf.com.cn				

法律主体声明

本报告由广发证券股份有限公司或其关联机构制作，广发证券股份有限公司及其关联机构以下统称为“广发证券”。本报告的分销依据不同国家、地区的法律、法规和监管要求由广发证券于该国家或地区的具有相关合法合规经营资质的子公司/经营机构完成。

广发证券股份有限公司具备中国证监会批复的证券投资咨询业务资格，接受中国证监会监管，负责本报告于中国（港澳台地区除外）的分销。

广发证券（香港）经纪有限公司具备香港证监会批复的就证券提供意见（4 号牌照）的牌照，接受香港证监会监管，负责本报告于中国香港地区的分销。

本报告署名研究人员所持中国证券业协会注册分析师资质信息和香港证监会批复的牌照信息已于署名研究人员姓名处披露。

重要声明

广发证券股份有限公司及其关联机构可能与本报告中提及的公司寻求或正在建立业务关系，因此，投资者应当考虑广发证券股份有限公司及其关联机构因可能存在的潜在利益冲突而对本报告的独立性产生影响。投资者不应仅依据本报告内容作出任何投资决策。投资者应自主作出投资决策并自行承担投资风险，任何形式的分享证券投资收益或者分担证券投资损失的书面或者口头承诺均为无效。

本报告署名研究人员、联系人（以下均简称“研究人员”）针对本报告中相关公司或证券的研究分析内容，在此声明：（1）本报告的全部分析结论、研究观点均精确反映研究人员于本报告发出当日的关于相关公司或证券的所有个人观点，并不代表广发证券的立场；（2）研究人员的部分或全部的报酬无论在过去、现在还是将来均不会与本报告所述特定分析结论、研究观点具有直接或间接的联系。

研究人员制作本报告的报酬标准依据研究质量、客户评价、工作量等多种因素确定，其影响因素亦包括广发证券的整体经营收入，该等经营收入部分来源于广发证券的投资银行类业务。

本报告仅面向经广发证券授权使用的客户/特定合作机构发送，不对外公开发布，只有接收人才可以使用，且对于接收人而言具有保密义务。广发证券并不因相关人员通过其他途径收到或阅读本报告而视其为广发证券的客户。在特定国家或地区传播或者发布本报告可能违反当地法律，广发证券并未采取任何行动以允许于该等国家或地区传播或者分销本报告。

本报告所提及证券可能不被允许在某些国家或地区内出售。请注意，投资涉及风险，证券价格可能会波动，因此投资回报可能会有所变化，过去的业绩并不保证未来的表现。本报告的内容、观点或建议并未考虑任何个别客户的具体投资目标、财务状况和特殊需求，不应被视为对特定客户关于特定证券或金融工具的投资建议。本报告发送给某客户是基于该客户被认为有能力独立评估投资风险、独立行使投资决策并独立承担相应风险。

本报告所载资料的来源及观点的出处皆被广发证券认为可靠，但广发证券不对其准确性、完整性做出任何保证。报告内容仅供参考，报告中的信息或所表达观点不构成所涉证券买卖的出价或询价。广发证券不对因使用本报告的内容而引致的损失承担任何责任，除非法律法规有明确规定。客户不应以本报告取代其独立判断或仅根据本报告做出决策，如有需要，应先咨询专业意见。

广发证券可发出其它与本报告所载信息不一致及有不同结论的报告。本报告反映研究人员的不同观点、见解及分析方法，并不代表广发证券的立场。广发证券的销售人员、交易员或其他专业人士可能以书面或口头形式，向其客户或自营交易部门提供与本报告观点相反的市场评论或交易策略，广发证券的自营交易部门亦可能会有与本报告观点不一致，甚至相反的投资策略。报告所载资料、意见及推测仅反映研究人员于发出本报告当日的判断，可随时更改且无需另行通告。广发证券或其证券研究报告业务的相关董事、高级职员、分析师和员工可能拥有本报告所提及证券的权益。在阅读本报告时，收件人应了解相关的权益披露（若有）。

本研究报告可能包括和/或描述/呈列期货合约价格的事实历史信息（“信息”）。请注意此信息仅供用作组成我们的研究方法/分析中的部分论点/依据/证据，以支持我们对所述相关行业/公司的观点的结论。在任何情况下，它并不（明示或暗示）与香港证监会第 5 类受规管活动（就期货合约提供意见）有关联或构成此活动。

权益披露

(1)广发证券（香港）跟本研究报告所述公司在过去 12 个月内并没有任何投资银行业务的关系。

版权声明

未经广发证券事先书面许可，任何机构或个人不得以任何形式翻版、复制、刊登、转载和引用，否则由此造成的一切不良后果及法律责任由私自翻版、复制、刊登、转载和引用者承担。