专 题 报 告

再探可微 RankIC 的损失函数改造：基于分域加权与时序平滑正则的实证研究——机器学习选股系列研究之三

方 正 证 券 研 究 所 证 券 研 究 报 告

分析师

曹春晓 登记编号：S1220522030005

联系人 郭樾

相 关 研 究

《指增超额遭遇极致风格挑战，非货 ETF 整体规模回落——金融工程 2026 年中期策略》2026.06.01

《净值上升带动宽基 ETF 规模继续高增，申购资金主要流入 A 股港股行业主题及债券 ETF 方向——2025H2ETF 基金持有人结构变化跟踪》2026.05.21

《2026 年 6 月沪深 300、中证 500 等指数成分调整预测》2026.05.14

《主动权益 QDII 整体减持美股增持亚太 AI 产业链标的，重仓持有海外资产 FOF 基金数量占比跌破五成——海外基金跟踪报告（2026Q1）》2026.05.02

《通信行业持仓占比上涨续创 2020 年以来新高，主动量化基金规模增长超 440 亿元领跑各类基金———主动权益基金季报分析 2026Q1》2026.04.30

《自进化 AI 智能体 Hermes Agent：核心机制解析与金融投研深度应用——AI Agent 赋能金融投研应用系列之五》2026.04.23

在前序报告《基于可微 RankIC 损失函数的深度学习选股策略——机器学习选股系列研究之一》中，我们采用 sigmoid 与 Neural Sort 两种可微排序方法实现了 RankIC 的可微分改造，并直接将其作为损失函数用于模型优化，此外，为优化既有模型，我们构建了一个双分支残差学习网络架构，使模型在优化可微 RankIC 的过程中，始终能以已知有效的线性组合为基座进行增量学习，初步验证了直接优化排序质量在量化选股中的可行性。

本期报告作为该篇研究的延续，我们对可微 RankIC 损失函数做了两个方向的改进：

第一，引入分域加权机制。前序研究中，模型优化目标基于全市场样本等权计算可微 RankIC，由于小微盘股票在数量上占优，模型倾向于学习多数类特征，导致 alpha 呈现小盘偏好。为此，我们将损失函数改造为分域加权形式，按中证 800 内、中证 1000 内及其他小微盘三域分别计算可微 RankIC 并加权求和，权重设计显式对齐指数增强产品的组合优化约束，使得因子在训练阶段即内嵌了组合层面的约束偏好，进而提高了指数增强产品表现。

第二，引入时序平滑正则。常规的损失函数往往以截面拟合精度为直接优化对象，未将交易成本纳入考量。当高换手 alpha 带来的边际提升更大时，模型将倾向于拟合这类信号，然而实际落地中换手成本会显著侵蚀其净收益。为此，我们将换手率惩罚作为正则项引入损失函数，在降低组合换手率的同时引导模型注意力从反转型 alpha 转向动量型 alpha，提升了指数增强产品表现以及因子在基准指数内的解释度。

此外，在模型结构层面，我们借鉴 HipreNets 的渐进式训练范式，对前序研究的残差网络进行了重构：摒弃一次性用大型网络拟合全部目标的训练策略，改为逐阶段训练小型子网络，每个子网络仅拟合前一阶段输出的残差，最终通过各阶段输出的累加得到预测结果。

综合来看，训练实证表明，分域加权与时序平滑正则两项改造均切实提升了模型在指数成份内的表现，但实现路径各不相同：前者通过域内权重约束将模型注意力从小微盘拉回指数内部，后者通过压低换手并引导模型聚焦动量型 alpha。两项改造相互独立，均可单独作用于损失函数并带来策略净表现的改善，为可微 RankIC 损失函数的落地应用提供了多元化的改进方向。

风险提示：

本报告基于历史数据分析，历史规律未来可能存在失效的风险；市场可能发生超预期变化；各驱动因子受环境影响可能存在阶段性失效的风险。

正文目录

1 渐进式训练框架与对照组模型的构建 4
1.1 前序网络结构的回顾 4
1.2 HipreNets：逐阶段残差拟合的渐进式训练范式 5
1.3 渐进式训练模型：基于残差级联的渐进式训练改造 6
1.4 对照组参数设定 9
1.5 对照组因子聚合效果 9
2 加权分域 RankIC 损失函数的改造 11
2.1 分域 RankIC 的加权改造：基于指增产品组合优化约束的损失函数重构 11
2.2 加权分域 RankIC 损失函数的因子聚合效果 12
3 时序平滑正则 RankIC 损失函数的改造 14
3.1 理论依据与损失函数的构造 14
3.2 时序平滑正则 RankIC 损失函数的因子聚合效果 16
4 总结与展望 20
5 风险提示 21

图表目录

图表 1：双分支残差网络结构示意图 4
图表 2：HiPreNets 训练流程示意图 6
图表 3：渐进式训练模型网络结构示意图 7
图表 4：训练数据集划分示意图 9
图表 5：训练结果 RankIC 与 IR 概览 10
图表 6：5 日普通收益率测度下累计 RankIC 10
图表 7：5 日残差收益率测度下累计 RankIC 10
图表 8：多空组合净值走势对比 10
图表 9：分域等权 RankIC 损失函数 11
图表 10：分域加权 RankIC 损失函数 12
图表 11：分域加权 RankIC 损失函数权重关系 12
图表 12：加权分域 RankIC 训练结果概览 12
图表 13：普通 RankIC 训练结果概览 13
图表 14：分域加权 RankIC 中证 1000 指数增强表现对比 13
图表 15：分域加权 RankIC 中证 1000 指数增强净值对比 13
图表 16：分域加权 RankIC 中证 1000 指数增强分年度表现对比 14
图表 17：信息系数与信息比率之间的解析关系 14
图表 18：信息系数与组合年化超额之间的解析关系 14
图表 19：组合单边换手率与 alpha 自相关系数之间的解析关系 15
图表 20：时序平滑正则 RankIC 损失函数 15
图表 21：时序平滑正则 RankIC 损失函数的线性替代 15
图表 22：原惩罚项函数与替代方案曲线对比 16
图表 23：时序平滑正则 RankIC 损失函数的线性替代 16
图表 24：时序平滑正则 RankIC 损失函数训练结果概览 17
图表 25：时序平滑正则在普通收益率测度下累计 RankIC 17
图表 26：时序平滑正则在残差收益率测度下累计 RankIC 17
图表 27：时序平滑正则多空组合净值走势对比 17
图表 28：时序平滑正则 RankIC 中证 1000 指数增强表现对比（无税费） 18
图表 29：时序平滑正则 RankIC 中证 1000 指数增强净值对比（无税费） 18
图表 30：时序平滑正则 RankIC 中证 1000 指数增强表现对比（单边千 1 税费） 18
图表 31：时序平滑正则 RankIC 中证 1000 指数增强净值对比（单边千 1 税费） 19
图表 32：时序平滑正则 RankIC 训练结果分选股域统计 19

1 渐进式训练框架与对照组模型的构建

1.1 前序网络结构的回顾

在前序报告《基于可微 RankIC 损失函数的深度学习选股策略——机器学习选股系列研究之一》中，为优化既有线性模型，我们构建了一个双分支的残差网络架构（如图表 1 所示），其核心设计如下：

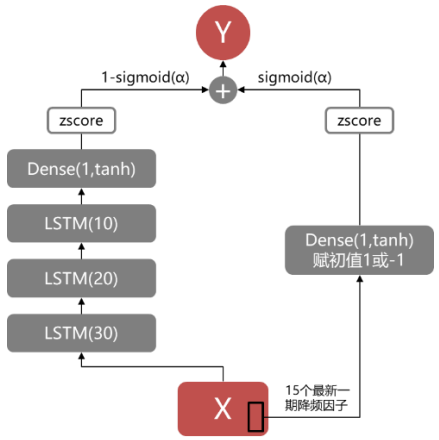
（1） 线性侧：以核心策略因子作为输入，通过赋初值方式保留其线性等权表征；

（2） 非线性侧：采用三层堆叠 LSTM 网络挖掘因子间的深层时序交互，聚焦学习线性侧无法表征的增量特征，形成对基底的有效补充。

（3） 融合机制：两侧输出经 zscore 标准化后，由可训练参数 α 通过 sigmoid 概率门控进行加权融合：

$$\text{output} = \big(1 - \text{sigmoid}(\alpha)\big) * \text{zscore}\big(\text{非线性侧}\big) + \text{sigmoid}(\alpha) * \text{zscore}\big(\text{线性侧}\big)$$

图表1:双分支残差网络结构示意图



资料来源：方正证券研究所

概率门控机制使得模型可以在既有线性模型与增量非线性模型之间进行自适应权衡。我们将参数α赋初值 2.2，使得线性侧的概率门控在初始状态下接近于 0.9，即在训练初期，模型仍以既有线性模型为主导，随着训练推进，非线性侧逐步进行增量信息的学习，α的取值由数据驱动调整，最终收敛至损失最优的融合比例。

然而，上述双分支架构虽然在结构上实现了线性侧与非线性侧的分离，但在训练方式上仍处于耦合优化的框架之下，即两侧网络与融合参数α共享同一条损失函数，在同一优化器下同步更新。这种结构分离但训练耦合的设计可能会对梯度计算带来一定的干扰，具体表现为三个层面：

（1） 梯度尺度不匹配导致的“掩盖效应”。非线性侧的参数量远大于线性侧，反向传播时产生的梯度范数通常高出若干数量级。在联合优化中，主导梯度下降方向的实质上是非线性侧的梯度信号。即便线性侧已接近收敛到合理的线性基底，非线性侧的一次大梯度更新也可能将其推离当前位置，导致线性侧并非独立优化自身的损失地形，而是在被动跟随非线性侧的更新节奏。

（2） 更新节奏不同步导致的“震荡效应”。线性侧的任务相对简单，即捕捉因子与收益的一阶线性关系，其收敛路径理应平稳而迅速；而非线性侧需要在高维时序空间中搜索复杂的交互模式，收敛路径本身具有较大的波动

性。当两侧在同一优化器下同步更新时，非线性侧的震荡会通过顶层融合节点传导至线性侧，使后者在已接近最优解的邻域内反复摇摆，难以稳定收敛。

（3） 概率门控参数α的动态博弈。权重α的更新方向取决于当前两侧输出的相对优劣。若某一训练步中非线性侧偶发表现更好，α便被推向更倚重非线性侧的方向，这反过来又改变了两侧的梯度流向和输出分布。线性侧、非线性侧与融合参数α三者之间的动态博弈，使得整个优化过程的收敛路径更加曲折，弱信号因子中的有效信息可能会在这一过程中被湮没。

上述问题的根源在于：联合训练迫使不同复杂度、不同收敛特性的子模块在同一损失函数中相互适应，而非各自在最合适的时机完成最擅长的任务。线性基底应当先行收敛，为整体模型提供一个稳定的锚点；非线性模块应当在锚点稳固之后，再对剩余误差进行增量学习。然而，传统的一体化训练范式无法提供这种时序上的分工，所有分支网络均被置于同一起跑线，在相互干扰中摸索前进，效率低下且收敛路径不稳定。

这一观察促使我们重新审视训练范式的选择：是否可以将“耦合优化”改造为“序贯优化”？沿着这个方向，我们关注到了 HiPreNets 提出的残差级联训练框架，其核心逻辑恰与我们的需求高度契合。

1.2 HipreNets：逐阶段残差拟合的渐进式训练范式

HiPreNets（High-Precision Neural Networks through Progressive Training）针对的核心问题是：当目标映射高度复杂时，传统深度网络的一次性端到端训练策略面临严重的优化瓶颈。神经网络的损失函数地形通常并非凸函数，而是布满局部最优和鞍点的崎岖景观。当模型试图一次性拟合所有数据模式时，优化器极易陷入某个局部最优而无法逃离，导致模型精度停滞——即便增加网络深度、宽度或训练数据，边际收益也迅速递减。

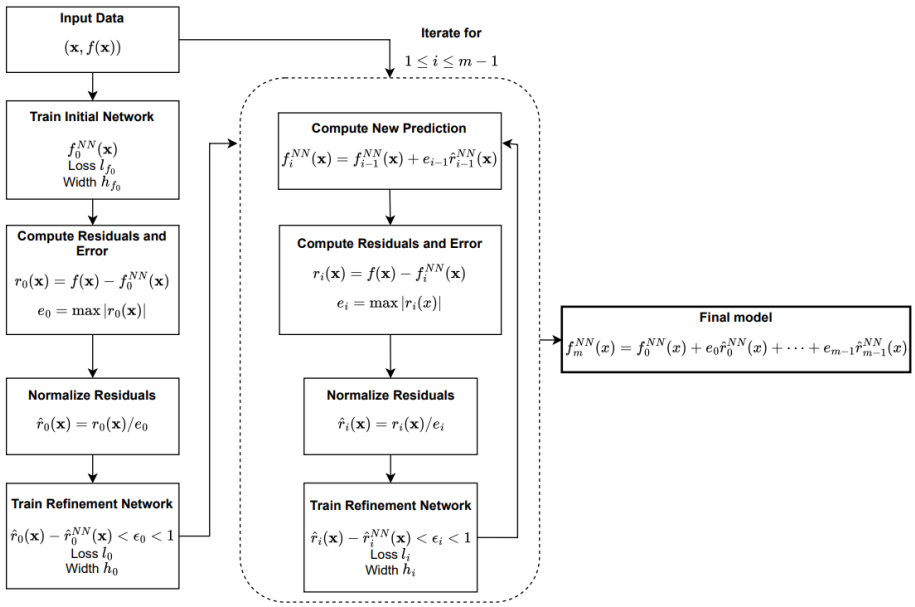
HiPreNets 的解法是彻底改变优化策略：不追求“一步到位”，而是将复杂的全局优化问题拆解为一连串目标明确、难度递减的子任务，逐级逼近真实函数。其核心流程可概括为“预测-评估-修正”的循环迭代：首先训练一个初始网络对目标函数进行初步拟合；然后计算该网络的预测残差，将其作为下一阶段的学习目标；接着引入一个全新的子网络，专门学习上一阶段遗留的残差，并将其输出叠加到已有预测之上；最后重复上述过程，每一阶段的新网络仅聚焦于前序模型未能解释的剩余误差，直至残差中不再包含可被学习的有意义信息。

从优化理论的视角审视，这一设计解决的核心问题是优化地形的重塑。传统训练中，优化器需要在一片复杂的全局地形中寻找最优解；HiPreNets 的做法等价于每完成一个阶段，就将原始目标中已被学会的成分剥离，使剩余待学习的残差构成一片更平滑、更简单的局部地形。换言之，HiPreNets 并未发明新的优化器，而是通过“任务拆解”改变了优化问题的结构本身——将一个困难的全局优化，转化为一连串更容易的局部优化。

在基本框架之上，HiPreNets 还提出了若干增强技术以进一步提升精度：在后续阶段逐渐增加网络宽度，以匹配残差随层级加深而递增的复杂度；采用加权均方误差替代标准 MSE，使模型对误差较大的区域施加更高权重，针对性降低最大绝对误差；以及自适应采样与局部修补技术，在验证集上定位 L∞误差最大的点进行局部校正。

从思想渊源来看，HiPreNets 的残差级联逻辑可追溯至 ResNet 的残差学习范式——ResNet 通过跳层连接使网络层学习残差映射而非直接映射，解决了深层网络的梯度消失问题；HiPreNets 则将残差学习从“网络内部层级”扩展至“模型间的级联集成”，以同样的哲学解决整体训练中的优化困难。两者共同的理论直觉是：学习残差映射通常比学习原始映射更容易，因为残差的分布更接近零均值、更平滑，优化地形更友好。

图表2:HiPreNets 训练流程示意图



资料来源：《HiPreNets: High-Precision Neural Networks through Progressive Training》

1.3 渐进式训练模型：基于残差级联的渐进式训练改造

本文借鉴 HiPreNets 的残差级联思想，将其应用于因子聚合任务。我们对原双分支架构的训练范式进行了重构，将“耦合优化”改造为“序贯优化”，构建了多层残差级联的渐进式训练框架：以线性层作为第一阶段基底模型，以 GRU 网络作为后续残差修正模型。训练策略与 HiPreNets 保持一致的阶段性逻辑：让线性基底先独立收敛，再让后续网络在稳固的基底之上逐级学习残差，最后进行全局协同微调。

本文在初始设计时构建了三个子网络：

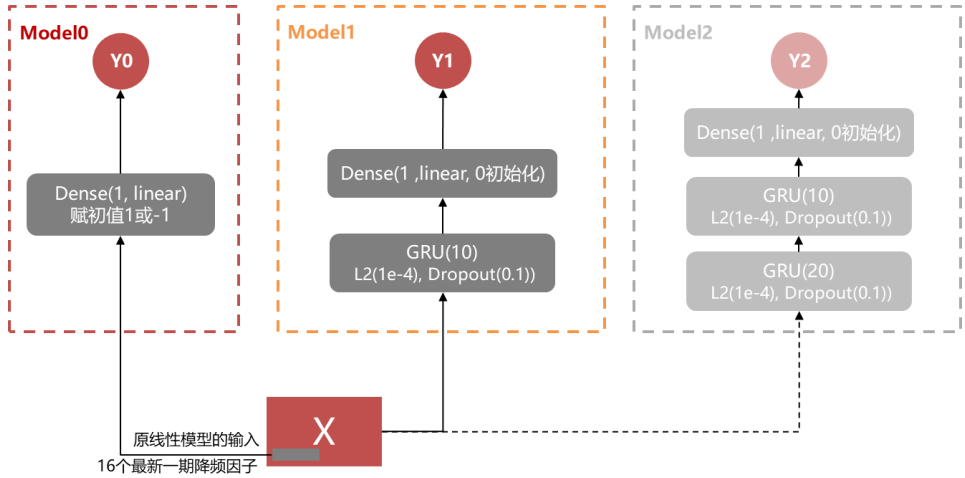
（1） Model0 为单层 Dense 线性基底，仅接收最新一期核心策略因子，根据因子方向赋初值 1 或-1，模拟初始状态下的等权组合的效果。

（2） Model1 的结构为单层 GRU 后接全连接输出层，隐藏层由 10 个 GRU 单元组成，输入为全部因子在历史若干交易日的面板数据。末端 Dense 层均采用零初始化策略，即权重与偏置均置为零，使得 Model1 初次接入时输出恒为零，模型总输出退化为 Model0 的基底预测，训练从不增不减的中性起点平稳起步，避免随机初始化对已收敛结构的扰动。

（3） Model2 的结构为双层 GRU 后接全连接输出层，隐藏层分别由 20 个/10 个 GRU 单元组成，输入同上，末端 Dense 层亦采用了采用零初始化策略。

三者以残差级联方式串联：M0 拟合原始目标，M1 在 M0 的基础上学习其未能捕捉的剩余排序信息，M2 进一步学习 M0+M1 联合预测后仍遗留的排序信息增量，最终预测为 $Y_0+Y_1+Y_2$。这一多层架构的意图在于逐级提取不同复杂度的信息增量：从一阶线性关系，到简单非线性时序交互，再到更深层的非线性模式。

图表3:渐进式训练模型网络结构示意图



资料来源：方正证券研究所

具体而言，训练分为以下阶段：

（1） 第一阶段：线性基底预训练。 以等权组合为起点，对 Model0 进行独立训练至收敛。该阶段的目标是让模型充分学习因子与收益之间最直接、最稳定的一阶线性关系。训练完成后，将 Model0 权重冻结。

（2） 第二阶段：一级残差修正训练。 引入单层 GRU 网络 Model1，此时模型的前向传播为 output = Model0(x) + Model1(x)。本阶段的核心操作是：Model0 权重全程冻结，仅 Model1 的权重参与梯度更新。训练完成后，将 Model1 权重冻结。此处的设计需特别说明：在传统的残差学习框架中，标准做法是先显式计算 M0 的预测残差，再将残差作为 Model1 的监督目标进行训练。然而，本文采用的损失函数为 RankIC，其衡量的并非预测值与真实值之间的数值偏差，而是两者排序的一致性。在这一设定下，显式计算残差缺乏明确的物理含义，且额外增加了存储开销。本文的解法更为直接：不显式计算残差，而是将 Model1 直接叠加于 Model0 之上，在 Model0 权重冻结的条件下，以原始 RankIC 损失对 Model1 进行训练。由于 Model0 的输出固定不变，RankIC 损失的梯度信号会自然引导 Model1 学习那些 Model0 尚未充分解释的剩余排序信息，这等价于让 Model1 隐式地学习排序残差，但无需在工程层面显式构造和存储残差变量，保持了训练流程的一致性，工程实现上更为简洁高效。

（3） 第三阶段：二级残差修正训练。 在 Model0+Model1 之上继续叠加双层 GRU 网络 Model2，训练方式与第二阶段一致：Model0 与 Model1 权重冻结，M2 以隐式残差学习的方式接入模型——前向传播为 output = Model0(x) + Model1(x) + Model2(x)。

（4） 第四阶段：全局联合微调。 这是本文对 HiPreNets 原框架的一个重要补充。在原论文的算法描述中，各子网络顺序训练完成后即直接加和用于预测，并不存在一个将所有权重解冻后联合微调的最终阶段。然而，这种“训练一个、冻结一个”的策略本质上属于贪婪算法——每一步追求当前阶段的局部最优，但无法保证所有阶段拼合后达到全局最优。具体而言，

Model0 的输出中可能存在对最终目标并非最优、却因后续冻结而无法调整的成分；Model1 也只能被动接受 Model0 的输出，无法通过反向反馈促使 Model0 做出让步。为解决这一问题，本文在贪婪初始化完成后引入了一个全局微调阶段：解冻 Model0 与 Model1 的所有权重，以远小于前序阶段的学习率对整个模型进行端到端训练。该阶段的意图并非推翻前序阶段学到的结构，而是在已有高质量初始化的基础上，允许各模块在小范围内协同调整、互相让步，以逼近真正的全局最优解。这一改进将 HiPreNets 的原框架推向了更加灵活的协同式微调，在保持序贯训练稳定性的同时，赋予了模型跨层级协调的能力。

本文在初始设计中构建了三层残差级联，但因 Model2 未能带来样本外泛化性提升而最终回退至 Model0+Model1 的双层架构。但需指出，这并不意味着残差级联的潜力在二阶即已耗尽。当前双层架构的上限，更多反映的是现有因子集合的信息容量边界，而非框架本身的能力上限。若因子集更加丰富、覆盖的信息维度更加宽广，或对每一级的输入机制进行差异化改造，该框架的上限具备继续推高的空间。本文提出三个可尝试的扩展方向：

（1） 时间尺度的差异化。 随着模型层级加深，各层输入的历史数据切片长度可逐级递增。例如，Model0 使用较短的历史窗口（如 1 日）捕捉短周期信号，Model2 将窗口扩展至 10 日以学习中期趋势，Model3 进一步拉长至 20 日以捕捉长期均值回复特征。这一设计使得各层不再在同一时间尺度的数据上反复榨取信息，而是各自负责一个时间维度的特征提取，层级之间形成明确的分工，有助于逐级提取不同周期的定价信号。

（2） 因子类型的差异化。 各层输入的因子集合可进行类型划分。例如，Model0 专注于策略核心因子，Model1 引入基本面因子，Model2 引入价量因子，Model3 进一步引入波动率或情绪类因子。不同类型的因子所包含的信息具有互补性——前一层学完某一类因子所承载的信息后，剩余排序信息中可能仍残留着另一类因子方能解释的规律，为后一层提供了明确的学习空间。

（3） 基于残差的动态特征筛选。 这一思路的核心是：每个阶段训练完成后，对当前模型的排序残差进行一次因子 RankIC 检验，筛选出对残差具有显著解释力的特征，作为下一阶段模型的输入。与传统做法中“锁定全量因子、逐级榨取”的策略不同，动态特征筛选使得每一层面对的并非固定因子集合，而是“当前残差最需要的特征”，有效规避了无关因子引入的噪声干扰。

在残差级联框架下，因子筛选的标准需从“对收益率的解释力”转向“对当前残差的解释力”，这一视角转换具有重要的方法论含义。传统因子筛选以因子对收益率的 RankIC 为核心准则——RankIC 显著的因子被纳入模型，不显著的则被舍弃。然而，这一标准在序贯训练的语境下面临重新检视的必要。一个对收益率解释度有限的因子，完全可能对某一阶段的排序残差具有显著的解释力，因为它所捕捉的并非收益本身的方向性规律，而是前序模型在该阶段系统性预测偏差的来源。反之，一个对收益率 RankIC 较高的因子，若其信息已被前序模型充分吸收，则对残差的边际解释力可能接近于零，继续作为后续阶段的输入不仅无益于增量学习，反而可能引入冗余噪声。因此，在逐级训练的过程中，每一层的筛选目标不应是“对收益率显著的因子”，而应是“对当前残差显著的因子”。这两个集合存在交集但并不等同，准确识别二者的差异，是残差级联框架实现信息分层利用的关键前提。

1.4 对照组参数设定

为构建可比的对照组，本节以未经改造的原始 RankIC 作为损失函数进行模型训练。除损失函数形式外，对照组在数据预处理、模型架构、训练策略等方面与后续各章保持一致。以下从数据层面与训练层面分别阐述关键参数设定。

（1） 预测目标：预测目标为股票 5 日残差收益率。具体处理流程为：取股票 5 日收益率，剔除异常值、上市时间不足一年的样本以及 ST、PT、*ST 股票后，进行截面去尾化处理、截面 zscore 标准化与市值行业中性化。采用残差收益率而非原始收益率的考量在于：剥离市值与行业层面的系统性收益后，残差部分更能反映因子选股能力的纯粹贡献。

（2） 输入特征：待聚合的因子池由三部分构成：方正金工团队前期研究所构建的特色量价因子 16 个，及其原始因子与构成因子 36 个；部分基本面因子；部分 Barra 风格因子。对每个因子进行剔除异常值、剔除上市不足一年的样本及风险警示股票，随后进行截面 zscore 标准化。滚动选取最近 20 个交易日的历史值，构造形状为（样本数，20，因子数）的三维输入张量。

（3） 损失函数：损失函数采用前序报告的基于 sigmoid 软排序法构建的 Spearman 秩相关系数（RankIC），温度参数 τ 设定为 0.01。

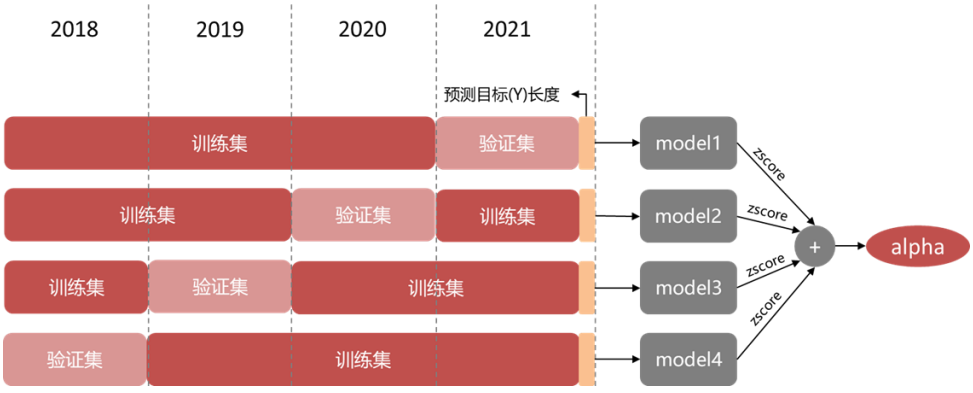
（4） 数据洗牌（reshuffle）：每个训练轮次开始前，以缓冲区大小为 100 的随机洗牌机制对训练集进行重排。洗牌的目的在于打破样本的时间序列依赖，降低模型对特定时间路径的过拟合风险。

（5） 训练轮次与早停： 设定最大训练轮次为 500，并引入早停机制：若验证集损失在连续 10 轮内未创新低，则判定模型泛化能力已趋于饱和，提前终止训练。模型的最终权重取自验证集损失的最低点。

（6） 优化器与学习率：优化器统一选用 Adam，三阶段训练的学习率设定呈逐级递减：Stage 1（线性基底预训练）为 0.001，Stage 2（残差修正训练）为 0.0001，Stage 3（全局联合微调）为 0.00001。

（7） 训练-验证集划分：样本内范围 2018 年至 2021 年，基于 KFold 交叉验证划分训练集与验证集（如图表 4 所示），将各子模型的结果进行截面 zscore 处理后等权合成最终的 alpha。

图表4:训练数据集划分示意图



资料来源：方正证券研究所

1.5 对照组因子聚合效果

由于数据洗牌、模型权重初始化等模块具有随机性，将上述训练重复进行多次后，将各个训练的预测输出值进行截面 zscore 后等权组合，得出最终的训练结果（下称 RankIC 组），并统计其与原等权模型在样本外区间的表现（2022 年至 2026 年 3 月），并根据因子值打分作 1-10 档多空组合回测，间隔 5 交易日换仓。

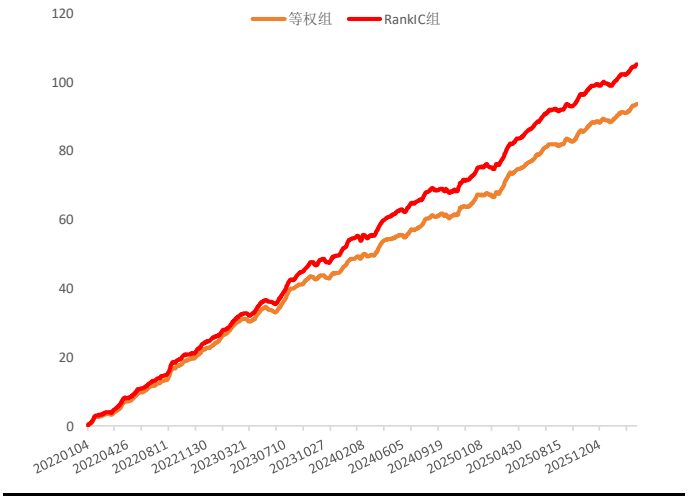
在训练目标——5 日残差收益率的测度下，RankIC 组的 RankIC 为 10.02%，RankICIR 为 2.32，相对于等权组的 Rank IC 8.81%以及 Rank ICIR 2.09 均有所提升。在多空组合的表现上，RankIC 组的多空年化收益率为 54.20%，信息比率为 2.95，月度胜率为 78.43%，相对于等权组合均得到了提升。

图表5:训练结果 RankIC 与 IR 概览

因子名称	Rank IC(普通)	Rank ICIR(普通)	Rank IC(残差)	Rank ICIR(残差)	多空年化收益率	多空年化波动率	多空信息比率	多空月度胜率	多空最大回撤
等权组	9.20%	1.57	8.81%	2.09	50.14%	18.31%	2.74	74.51%	-14.32%
RankIC组	10.33%	1.67	10.02%	2.32	54.20%	18.40%	2.95	78.43%	-16.24%

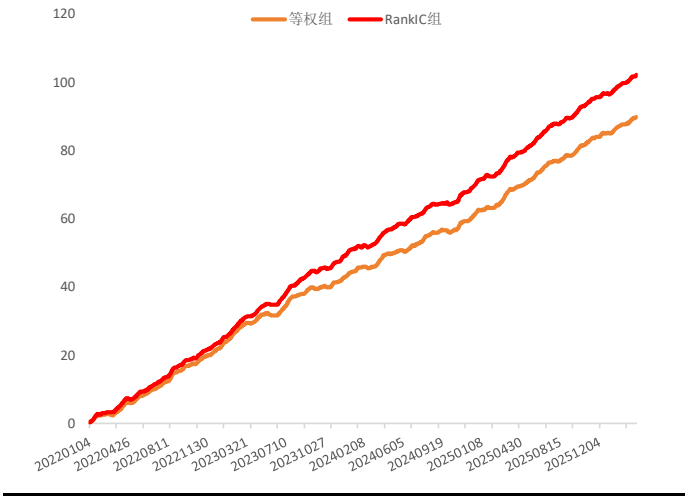
资料来源：Wind，方正证券研究所

图表6:5 日普通收益率测度下累计 RankIC



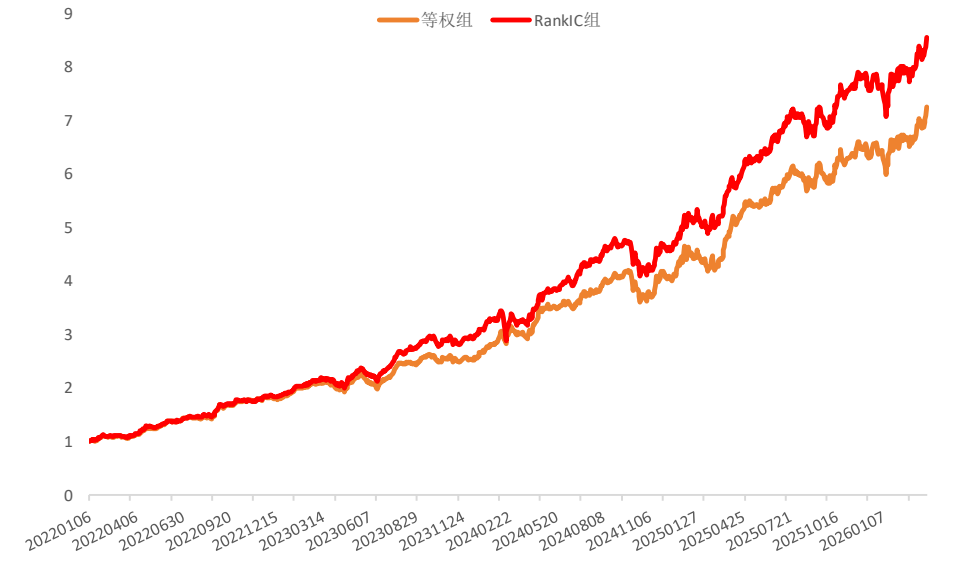
资料来源：Wind，方正证券研究所

图表7:5 日残差收益率测度下累计 RankIC



资料来源：Wind，方正证券研究所

图表8:多空组合净值走势对比



资料来源：Wind，方正证券研究所

从分层测试结果来看，相较于等权组合，RankIC 组在头部区间的选股区分能力获得了更为显著的提升。从年度表现来看，RankIC 组在各年份上均系统性优于等权组合，呈现出跨年度的一致性优势。分选股域来看，边际增量最为突出的仍集中于小微盘。这一现象的成因可追溯至损失函数的优化逻辑：训练目标为等权 RankIC，而小微盘样本在全市场中的数量占比过半，模型在最小化全局损失的过程中，将更多的优化容量分配至多数类样本，从而在小微盘域上呈现出更强的绩效提升。然而，指数增强策略的实际关切并不在于全市场普适的选股能力，而在于指数成份内的排序精度，尤其是对中大盘股票的解释度。这一目标偏移构成了本章后续引入分域加权 RankIC 的出发点。

2 加权分域 RankIC 损失函数的改造

从分层测试与分域评估的结果来看，等权 RankIC 损失函数存在一个结构性的偏差：模型在全市场范围内优化排序精度时，小微盘样本凭借其数量优势主导了损失函数的梯度方向，导致模型将过多的优化容量分配至小微盘域，而指数成份内的选股能力未能获得与之重要性匹配的提升幅度，尤其是指数增强策略最为倚重的中大盘股票解释度。这一目标偏移的根源在于损失函数对每个样本施加了均等的权重，忽视了不同样本在投资实务中的差异化重要性。

为解决这一问题，本章提出第一项损失函数改造方案——加权分域 RankIC。核心思想则是先按指数成份将全市场样本划分为若干选股域，对每个域分别计算带权重的 RankIC，再将各域结果按预设权重加总，使得损失函数的优化方向与组合优化的部分约束逻辑上对齐。

2.1 分域 RankIC 的加权改造：基于指增产品组合优化约束的损失函数重构

为解决等权 RankIC 下小微盘样本“以量取胜”的结构性偏差，本文首先考虑一种最直接的分域加权方案。将全市场样本按指数归属划分为四个互斥子域——沪深 300 指数成份内、中证 500 指数成份内、中证 1000 指数成份内，以及上述三者之外的其余小微盘样本——并对每个子域分别计算 RankIC 后等权加总：

图表9:分域等权 RankIC 损失函数

$$Loss = -(RankIC_{300\text{ 内}} + RankIC_{500\text{ 内}} + RankIC_{1000\text{ 内}} + RankIC_{others})$$

资料来源：方正证券研究所

其中，各域的 RankIC 的计算方式为：对于任意标的，若其在当前选股域内，则样本权重设为 1；若在域外，则权重设为 0，即该样本不参与当前域的 RankIC 计算。各域 RankIC 以等权相加进入总损失，意味着大、中、小、微四个板块在优化目标中拥有完全对等的话语权。这一机制从结构上消除了小微盘凭借样本数量主导全局 RankIC 的可能性——无论某域包含多少只股票，其对总损失的边际贡献均被规范化至同等水平。

相较于全市场等权 RankIC，该形式至少实现了域间公平性这一基本诉求。然而， 考虑到中证 1000 指数增强策略在实际运作中面临两项核心约束：其一，合同通常要求成份股最低仓位不低于 80%，这意味着策略的大部分超额收益取决于指数内的选股能力；其二，市值敞口需严格对齐基准指数，意味着组合在指数左侧（中证 800 指数成份股）与右侧（小微盘）需保持适度但有限的风险暴

露，以对冲市值风格偏离风险。这两项约束可被自然地转换为损失函数中各域的优化权重。设中证 800 指数成份内、中证 1000 指数成份内与其余样本三个选股域的损失权重分别为 w1、w2、w3，构造加权复合损失函数：

图表10:分域加权 RankIC 损失函数

$$Loss = -(w_1 * RankIC_{800\ 内} + w_2 * RankIC_{1000\ 内} + w_3 * RankIC_{others})$$

资料来源：方正证券研究所

其中 w2=0.8，直接对应指数增强策略中 80%的成份内最低仓位约束。w1 与 w3 的比例则由对应选股域的市值配比关系推导：

图表11:分域加权 RankIC 损失函数权重关系

$$\frac{w1}{w1+w3} * mkv(800\ 平均) + \frac{w3}{w1+w3} * mkv(others平均) \approx mkv(1000\ 加权)$$

资料来源：方正证券研究所

其中 mkv(800 平均)与 mkv(others 平均)分别为中证 800 指数成份股与域外样本的平均市值，mkv(1000 加权) 为中证 1000 指数成份股的加权平均市值，依据实际市值数据，w1 取 0.025，w3 取 0.175，可以让两侧的平均加权市值趋近于中证 1000 指数成份股的加权平均市值。

这一设计将组合优化层面的两项核心约束——成份内最低仓位与市值中性——以权重参数的形式直接嵌入损失函数，使得模型在因子训练阶段即感知到不同选股域的差异化重要性，从源头削弱小微盘样本对优化方向的过度牵引。相较于等权 RankIC 在全市场范围内“以量取胜”的粗放优化，分域加权 RankIC 实现了优化容量向指数成份内的定向倾斜，为后续的指数增强组合构建提供了更具实战适配性的 Alpha 来源。

2.2 加权分域 RankIC 损失函数的因子聚合效果

以加权分域 RankIC 作为损失函数进行因子聚合训练，除损失函数形式外，其余参数设定与普通 RankIC 对照组保持严格一致，以确保对比的公平性。训练结果表明，相较于普通 RankIC 基线，分域加权 RankIC 在指数成份内的选股能力获得了系统性提升。更为重要的是，提升的结构发生了实质性转变：在普通 RankIC 损失函数下的增量主要集中于小微盘域，而分域加权 RankIC 将优化容量重新分配至指数成份内，小微盘域的提升幅度则相应收敛。这一变化恰与分域加权的设计目标一致，损失函数从“全市场等权优化”转向“成份内优先优化”，模型的注意力分布随之调整。

图表12:加权分域 RankIC 训练结果概览

选股域	Rank IC(普通)	Rank ICIR(普通)	Rank IC(残差)	Rank ICIR(残差)
沪深300成分股	5.81%	0.69	4.37%	1.05
中证500成分股	5.78%	0.78	5.46%	1.35
中证1000成分股	7.22%	1.13	7.20%	1.92
其他	11.89%	2.01	10.76%	2.51

资料来源：Wind，方正证券研究所

图表13:普通 RankIC 训练结果概览

选股域	Rank IC(普通)	Rank ICIR(普通)	Rank IC(残差)	Rank ICIR(残差)
沪深300成分股	5.69%	0.67	4.18%	1.01
中证500成分股	5.67%	0.73	5.39%	1.31
中证1000成分股	7.12%	1.08	7.06%	1.89
其他	12.55%	2.00	11.12%	2.56

资料来源：Wind，方正证券研究所

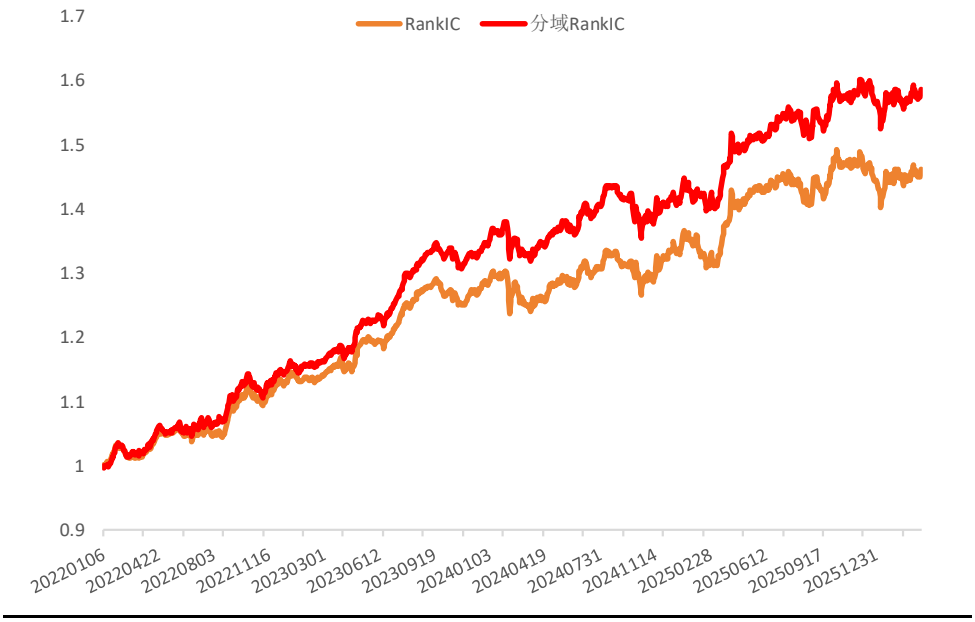
基于分域加权 RankIC 损失函数所训练的 Alpha，本文进一步构建了中证 1000 指数增强组合。组合优化端施加了严格的实战约束：二级行业权重与基准指数对齐，市值暴露与基准指数对齐，指数成份内权重不低于 80%。在此约束框架下，基于分域加权 RankIC 损失函数所训练的 Alpha 在年化收益率、最大回撤、信息比率与跟踪误差等核心绩效指标上，相较于原始等权 RankIC 损失函数均获得了可观测的改善。拆解至各年度来看，上述指标的提升呈现出跨年度的一致性，表明分域加权的效果并非由特定年份的极端行情驱动，而是具有统计意义上的稳健性。这一结果验证了损失函数层面的域权重设计能够有效传导至组合层面的业绩表现：当因子训练阶段内嵌了指增策略的仓位约束与市值约束，模型所产出的 Alpha 天然具备更强的实战适配性。

图表14:分域加权 RankIC 中证 1000 指数增强表现对比

alpha	年化收益率	年化波动率	信息比率	最大回撤	年化双边换手	月胜率	跟踪误差
RankIC	9.50%	6.57%	1.45	-6.14%	48.19	66.67%	6.57%
分域RankIC	11.48%	6.42%	1.79	-5.76%	46.48	76.47%	6.42%

资料来源：Wind，方正证券研究所

图表15:分域加权 RankIC 中证 1000 指数增强净值对比



资料来源：Wind，方正证券研究所

图表16:分域加权 RankIC 中证 1000 指数增强分年度表现对比

alpha	年度	年化收益率	年化波动率	信息比率	最大回撤	年化双边换手	月胜率	跟踪误差
RankIC	2022	14.25%	5.81%	2.45	-2.83%	49.38	66.67%	5.81%
	2023	11.78%	4.55%	2.59	-3.17%	50.30	83.33%	4.55%
	2024	5.43%	7.05%	0.77	-5.26%	47.63	58.33%	7.05%
	2025	7.52%	7.66%	0.98	-4.28%	46.97	58.33%	7.66%
	2026	5.38%	9.30%	0.58	-2.62%	41.75	66.67%	9.30%
分域RankIC	2022	15.28%	5.82%	2.62	-3.29%	48.16	75.00%	5.82%
	2023	15.61%	4.35%	3.59	-3.01%	48.17	91.67%	4.35%
	2024	6.50%	6.82%	0.95	-5.76%	45.13	66.67%	6.82%
	2025	9.94%	7.61%	1.31	-3.59%	45.72	75.00%	7.61%
	2026	5.49%	8.69%	0.63	-2.71%	41.08	66.67%	8.69%

资料来源：Wind，方正证券研究所

3 时序平滑正则 RankIC 损失函数的改造

3.1 理论依据与损失函数的构造

前章通过分域加权机制将损失函数的优化重心从全市场等权分配调整至以指数成份内为核心的结构，解决了模型注意力分布与投资实务约束之间的错配。然而，上述改造仅涉及损失函数中样本权重的空间维度，未触及 RankIC 损失本身的维度局限：RankIC 度量的是预测排序与真实收益排序之间的一致性，即仅反映预测的准确性，未将实现该预测所伴随的交易成本纳入优化目标。当模型为追逐边际 RankIC 提升而频繁切换预测方向时，由此引致的高换手率及其交易磨损可能部分甚至完全抵消 RankIC 提升所带来的理论收益增量。因此，一个完整的损失函数应当同时反映预测的准确性与稳定性两个维度，于是我们在 RankIC 损失函数中引入换手率惩罚项，使得模型在训练阶段即感知到频繁调仓的成本代价，内生地学习在收益与换手之间取得平衡。这一设计的理论依据来自两条经典量化金融研究。

Grinold 与 Kahn（1999）提出的主动管理基本定律建立了信息系数（IC）与信息比率（IR）之间的解析关系：

图表17:信息系数与信息比率之间的解析关系

$$IR \approx IC * \sqrt{BR}$$

资料来源：方正证券研究所，Richard Grinold & Ronald Kahn《Active Portfolio Management》，McGraw-Hill，1999

其中 BR 为策略广度，即年化独立预测次数。实践中通常以 Spearman 秩相关系数（RankIC）度量 IC。

在给定目标跟踪误差ω的条件下，可推得组合年化超额收益：

图表18:信息系数与组合年化超额之间的解析关系

$$\alpha = IR \cdot \omega \approx IC \cdot BR \cdot \omega$$

资料来源：方正证券研究所

该关系表明，在跟踪误差与策略广度给定的前提下，组合超额收益与 RankIC 近似成正比，最大化 RankIC 等价于最大化组合收益的理论上限。

Qian，Sorensen 与 Hua（2007）在均值-方差优化框架下推导出最优多空组合单边换手率的解析表达式，其核心结论为：

图表19:组合单边换手率与 alpha 自相关系数之间的解析关系

$$TO \propto \sqrt{1-\rho_{\alpha}}$$

资料来源：方正证券研究所，Edward E. Qian, Ronald H. Hua & Eric H. Sorensen《Quantitative Equity Portfolio Management》, Chapman & Hall/CRC, 2007

其中$\rho_{\alpha}=corr(\alpha_t,\alpha_{t-1})$ 为 Alpha 预测值的一阶自相关系数。该公式揭示，换手率的决定性因素在于 Alpha 信号本身的时序结构——信号自相关性越高，相邻期持仓调整幅度越小，换手率越低。

上述两条理论线索分别指向两个优化方向：最大化 RankIC 以提升预期收益，最大化ρ_{α}以降低预期换手，二者之间的权衡正是损失函数设计中需要解决的核心问题。基于此，本文构造如下复合损失函数：

图表20:时序平滑正则 RankIC 损失函数

$$Loss=-(RankIC(y_{true},y_{pred})-lambda*\sqrt{1-RankIC(y_{pred},y_{lastpred})}\ )$$

资料来源：方正证券研究所

其中，第一项为当期预测与真实收益的秩相关系数，对应收益最大化目标；第二项为时序平滑正则项，$y_{lastpred}$为上一换仓周期的 Alpha 预测值，$lambda$为惩罚系数，调节准确性与稳定性之间的相对权重。

然而，在梯度下降训练中，上述时序平滑正则项存在数值缺陷：记$r=RankIC(y_{pred},y_{lastpred})$，惩罚项变为$\sqrt{1-r}$，其对 r 的梯度为$-1/2\sqrt{1-r}$。当$r\to 1$时，惩罚项梯度$-1/2\sqrt{1-r}\to\infty$，引发梯度爆炸，导致训练后期参数震荡，反而破坏了信号的时序稳定性。

针对上述缺陷，本文考察了两种梯度有界的替代方案。其一为线性形式$1-r$，梯度恒为-1，训练全程稳定；其二为对数形式$ln(2-r)$，梯度为$-1/(2-r)$，在函数形状上更接近平方根形式的非线性特征。两者在$r\in[-1,1]$范围内梯度始终有界，同时规避了边界发散问题。

综合权衡数值稳定性与工程实现的简洁性，本文以线性形式作为平方根项的平滑替代，最终损失函数为：

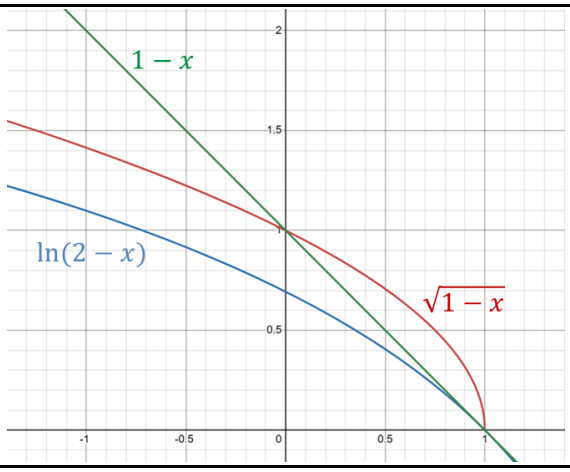
图表21:时序平滑正则 RankIC 损失函数的线性替代

$$Loss=-(RankIC(y_{true},y_{pred})-lambda*RankIC(y_{pred},y_{lastpred})\ )$$

资料来源：方正证券研究所

该形式保持了惩罚力度与预测自相关之间的单调递减方向，同时恒定的梯度信号规避了训练后期的梯度发散问题，确保了优化路径的平稳收敛。

图表22:原惩罚项函数与替代方案曲线对比



资料来源：Wind，方正证券研究所

此外，我们对训练机制做了相应的配套调整。换手惩罚项涉及相邻两期预测值的比较，y_{pred}与$y_{lastpred}$需在同一组模型参数下生成，其自相关计算方具有明确的物理含义。然而，本文的训练数据按交易日切割为 Mini-Batch，若沿用常规的逐 Batch 独立更新机制，每个 Batch 完成后模型参数即发生改变，则相邻两个交易日的预测值由不同版本的参数生成，自相关度量被参数更新所污染，惩罚项的梯度信号将产生系统性偏差。

为此，本文对训练循环的梯度更新逻辑进行了针对性调整。原机制为每个 Mini-Batch 独立计算损失并立即更新参数；新机制改为：各 Mini-Batch 分别计算损失与梯度，梯度在一个 Epoch 内跨 Batch 累积加总，取平均后执行一次统一的参数更新。其数学形式为：

图表23:时序平滑正则 RankIC 损失函数的线性替代

$$gradient = \frac{1}{B}\sum_{b=1}^{B}\nabla_{\theta}(Loss_b)$$

$$\theta - \eta \cdot gradient \rightarrow \theta$$

资料来源：方正证券研究所

其中 B 为一个 Epoch 内的 Mini-Batch 数量，$Loss_b$为第 b 个 Batch 的损失，η为学习率。这一调整使得一个 Epoch 内所有样本共享同一组参数进行前向传播，相邻交易日的预测值在参数层面保持一致，换手惩罚项的时序连续性得以保证；同时，每个 Epoch 内所有样本对参数更新的贡献均等，消除了 Batch 顺序对梯度估计的影响。

此外，两项配套设置需同步调整。其一，关闭训练数据的随机洗牌机制，以保持交易日之间的自然时间顺序。若数据被随机打乱，相邻 Batch 不再对应真实的相邻交易日，自相关计算将失去实际意义。其二，适当放大学习率以补偿参数更新频率的降低。梯度更新机制由每个 Batch 更新一次改为每个 Epoch 更新一次后，单步更新所对应的数据量上升，学习率需相应提高以保持收敛速度。

3.2 时序平滑正则 RankIC 损失函数的因子聚合效果

为验证时序平滑正则项的实证效果，我们以线性形式的换手惩罚 RankIC 作为损失函数，对惩罚系数分别取 0.1、0.2、0.3 进行遍历，除上述提及的调整之外，其余参数设定与对照组保持一致。

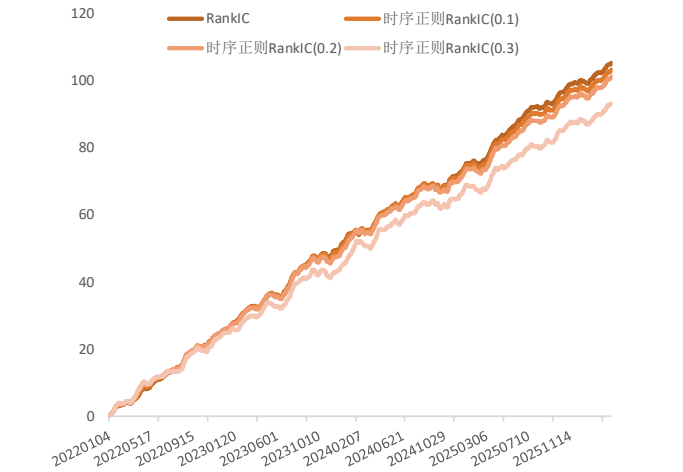
在全市场多空组合框架下，随着惩罚系数的增大，多空双边换手率呈逐步下降趋势，表明惩罚项确实起到了约束换手的作用。我们的预测目标，即残差收益率测度下 RankIC，基本保持稳定，说明模型的原始选股能力未因换手约束而出现显著退化。

图表24:时序平滑正则 RankIC 损失函数训练结果概览

损失函数	Rank IC(普通)	Rank ICIR(普通)	Rank IC(残差)	Rank ICIR(残差)	多空年化收益率	多空年化波动率	多空信息比率	多空最大回撤	双边换手率	多空月度胜率
RankIC	10.33%	1.67	10.02%	2.32	54.20%	18.40%	2.95	-16.24%	73.77	78.43%
时序正则RankIC(0.1)	10.12%	1.52	10.06%	2.22	48.48%	19.50%	2.49	-17.17%	69.73	72.55%
时序正则RankIC(0.2)	9.91%	1.39	10.14%	2.17	46.30%	20.70%	2.24	-18.27%	67.77	70.59%
时序正则RankIC(0.3)	9.14%	1.17	10.01%	2.10	42.88%	22.48%	1.91	-19.24%	64.48	64.71%

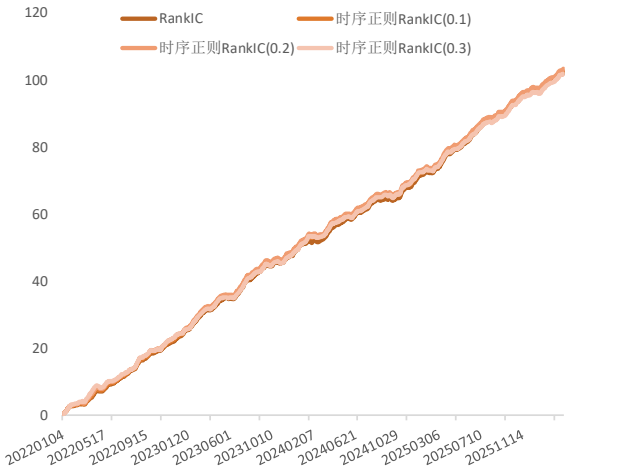
资料来源：Wind，方正证券研究所

图表25:时序平滑正则在普通收益率测度下累计 RankIC



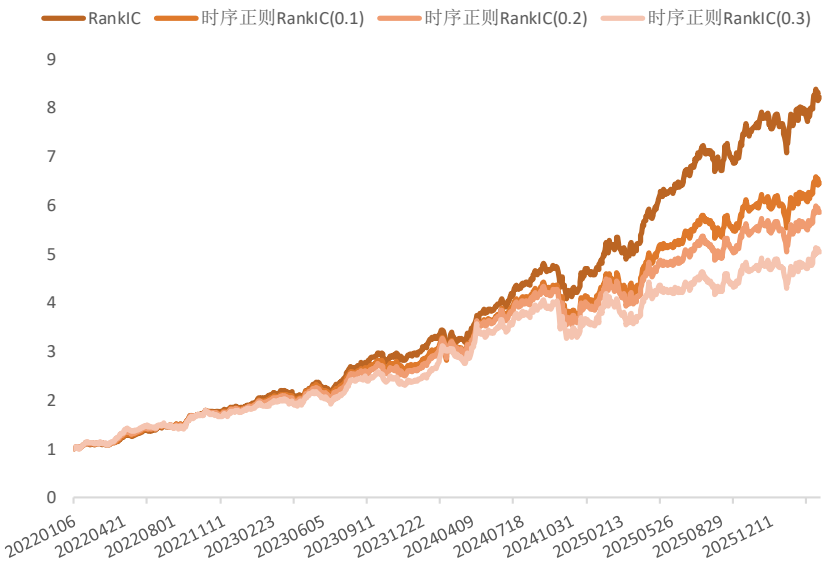
资料来源：Wind，方正证券研究所

图表26:时序平滑正则在残差收益率测度下累计 RankIC



资料来源：Wind，方正证券研究所

图表27:时序平滑正则多空组合净值走势对比



资料来源：Wind，方正证券研究所

然而，多空年化收益率与信息比率均随惩罚系数的增大而同步下降，这一现象可由换手惩罚项对反转型 Alpha 的系统性压制来解释。全市场多空组合的多头与空头两端均以小微盘股票为主，而在小微盘选股域内，短期反转因子占据主导地位。换手惩罚项在数理结构上奖励预测信号的时序正自相关，与反转策略所依赖的时序负自相关背道而驰。增大惩罚系数意味着对反转信号的压制力度加大，而小微盘域内反转因子是收益的核心来源，因此惩罚力度提升直接导致组合收益受损。

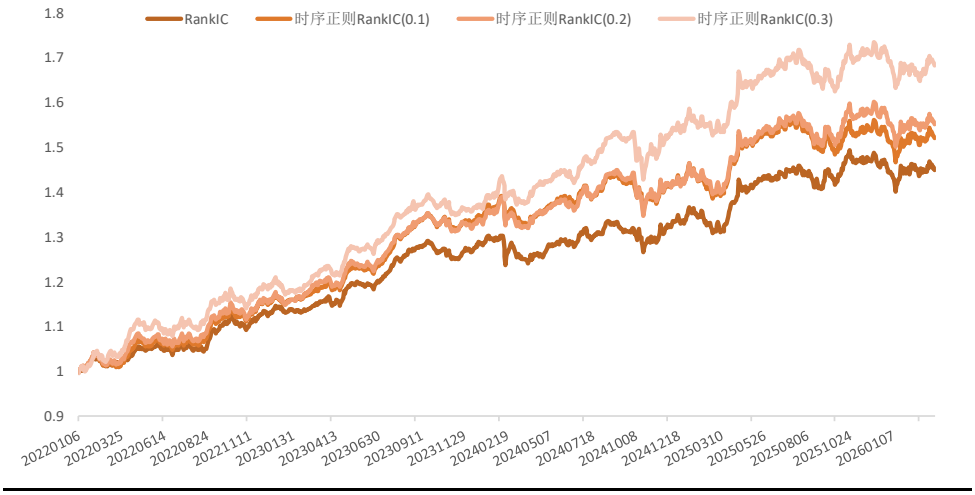
但是将同样的 Alpha 应用于中证 1000 指数增强组合（约束二级行业与市值严格对齐指数，指数成份内权重不低于 80%），在不考虑交易手续费的情况下，结果呈现出与全市场多空组合截然相反的特征。随着惩罚系数的增大，年化收益率与信息比率同步提升，同时换手率下降，各项指标实现了同向优化。在单边手续费千分之一的情境下，上述差异被进一步放大。

图表28:时序平滑正则 RankIC 中证 1000 指数增强表现对比（无税费）

损失函数	年化收益率	年化波动率	信息比率	最大回撤	年化双边换手	月胜率	跟踪误差
RankIC	9.50%	6.57%	1.45	-6.14%	48.19	66.67%	6.57%
时序正则RankIC(0.1)	10.79%	7.06%	1.53	-6.19%	44.88	70.59%	7.06%
时序正则RankIC(0.2)	11.27%	7.30%	1.54	-7.10%	43.52	68.63%	7.30%
时序正则RankIC(0.3)	13.24%	7.55%	1.75	-6.91%	42.05	70.59%	7.55%

资料来源：Wind，方正证券研究所

图表29:时序平滑正则 RankIC 中证 1000 指数增强净值对比（无税费）



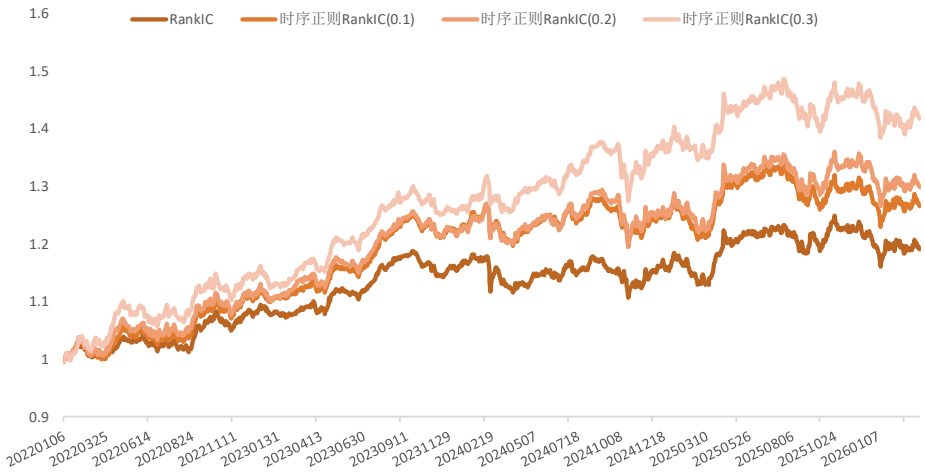
资料来源：Wind，方正证券研究所

图表30:时序平滑正则 RankIC 中证 1000 指数增强表现对比（单边千 1 税费）

损失函数	年化收益率	年化波动率	信息比率	最大回撤	年化双边换手	月胜率	跟踪误差
RankIC	4.68%	6.56%	0.71	-7.04%	48.19	62.75%	6.56%
时序正则RankIC(0.1)	6.30%	7.06%	0.89	-8.07%	44.88	58.82%	7.06%
时序正则RankIC(0.2)	6.92%	7.30%	0.95	-7.64%	43.52	62.75%	7.30%
时序正则RankIC(0.3)	9.04%	7.55%	1.20	-7.42%	42.05	64.71%	7.55%

资料来源：Wind，方正证券研究所

图表31:时序平滑正则 RankIC 中证 1000 指数增强净值对比（单边千 1 税费）



资料来源：Wind，方正证券研究所

随着惩罚系数的增大，中证 1000 指数增强策略绩效的提升，其根源不仅在于换手率下降所带来的交易成本节约，更在于换手惩罚项的另一潜在功能——削弱小盘反转，引导模型聚焦于更稳定的中长期 Alpha 来源。换手惩罚项在数理结构上奖励预测信号的时序正自相关，与反转策略所依赖的时序负自相关背道而驰，这一偏好在不同选股域上呈现出分化的效果。实证数据显示，反转效应的强度随市值下沉而递增。当惩罚系数增大时，反转效应最强的小微盘域首当其冲受到压制，RankIC 随之下降；而指数内的反转效应本就微弱，模型在正则项的引导下转向挖掘动量类或其他时序稳定的信号，进而使得指数内的 RankIC 反而逆势提升。在指数增强组合的受限选股域内，这一功能体现为信号提纯效应：抑制对短期反转噪声的过度学习，使模型转而挖掘时序更稳健的定价信号。成份内的选股能力不降反升，叠加交易磨损的下降，共同推高了净收益。

图表32:时序平滑正则 RankIC 训练结果分选股域统计

选股域	损失函数	Rank IC(普通)	Rank ICIR(普通)	Rank IC(残差)	Rank ICIR(残差)
800成分股	RankIC	5.63%	0.71	5.11%	1.26
	时序正则RankIC(0.1)	6.25%	0.73	5.60%	1.24
	时序正则RankIC(0.2)	6.41%	0.72	5.81%	1.24
	时序正则RankIC(0.3)	6.29%	0.71	5.87%	1.25
中证1000成分股	RankIC	7.12%	1.08	7.06%	1.89
	时序正则RankIC(0.1)	7.54%	1.02	7.49%	1.82
	时序正则RankIC(0.2)	7.68%	0.95	7.75%	1.76
	时序正则RankIC(0.3)	7.72%	0.86	8.00%	1.65
其他	RankIC	12.55%	2.00	11.12%	2.56
	时序正则RankIC(0.1)	12.07%	1.92	10.95%	2.45
	时序正则RankIC(0.2)	11.81%	1.81	10.88%	2.39
	时序正则RankIC(0.3)	10.96%	1.65	10.49%	2.31

资料来源：Wind，方正证券研究所

分域加权与换手惩罚作为两项独立的损失函数改造方向，均对指数增强策略的绩效产生了正向贡献，但二者的实现路径存在本质差异。分域加权通过调整各选股域的优化权重，将模型的注意力从全市场等权分配转向以指数成份内为核心的结构，直接回应了指数增强策略中成份内最低仓位与市值中性的实务约束。换手惩罚则通过奖励预测信号的时序正相关，在数理层面重塑了模型的因子偏好——抑制反转、奖励动量，引导模型聚焦于更稳定的中长期 Alpha 来源。前者解决的是“模型在哪选股”的问题，后者解决的是“模型选什么类型信号”的问题。两者路径独立、功能互补，可在同一损失函数中叠加使用。当

分域加权限定了优化边界、换手惩罚在此边界内完成信号提纯后，两者共同推动模型产出时序更稳健、更适配指数增强策略实战需求的 Alpha。

4 总结与展望

本文围绕可微 RankIC 损失函数的改造展开研究，从两个独立且可叠加的方向对损失函数进行了系统性的改进，并结合渐进式训练框架完成了从模型结构到训练范式的全面升级。

在损失函数层面，本文提出了两项核心改造。其一为分域加权 RankIC，通过按指数成份划分选股域并赋予差异化权重，将指数增强策略中成份内最低仓位与市值中性两项实务约束直接嵌入损失函数，解决了等权 RankIC 下小微盘样本“以量取胜”导致优化目标偏移的问题。其二为换手惩罚项的引入，依据主动管理基本定律与信号自相关结构决定换手率的理论框架，在损失函数中构造时序平滑正则项，使得模型在训练阶段即感知频繁调仓的成本代价，内生地学习在收益与换手之间取得平衡。两项改造的路径独立、功能互补：分域加权解决“模型在哪选股”的问题，换手惩罚重塑“模型选什么类型信号”的偏好，两者叠加可共同推动模型产出时序更稳健、更适配指数增强策略实战需求的 Alpha。

在模型层面，本文借鉴 HiPreNets 的残差级联思想，将原双分支架构的耦合训练范式改造为序贯优化的渐进式训练框架。线性基底先行收敛并冻结，非线性残差修正模块在稳固基底之上专注增量学习，最后通过全局联合微调修正贪婪算法的固有缺陷。该框架在优化稳定性、信息利用效率、工程实现简洁性与可解释性等维度均较原一体化训练范式有所提升，且保留了向更深层级扩展的架构弹性。

展望未来，本文的损失函数改造框架尚有若干可进一步探索的方向：

（1） 残差级联框架的层级扩展。如 1.3 节所述，当前双层架构的上限受限于现有因子集合的信息容量。若未来因子库进一步丰富，或引入时间尺度差异化、因子类型差异化、基于残差的动态特征筛选等输入机制，该框架具备向更深层级扩展的能力，以逐级提取不同层次的信息增量。

（2） 面向多头端选股的损失函数设计。本文的 RankIC 损失函数及其两项改造均以全市场或全域内的排序精度为优化目标，即同时关注多头端与空头端的选股能力。然而，对于指数增强策略而言，实际投资操作通常仅涉及多头端，无法通过做空来实现尾部的排序精度。这一实务特征对损失函数提出了差异化的需求：模型应将有限的优化容量集中于排名顶部的样本，而非在全序列上均匀分配注意力。在这一方向上，可探索的路径包括将 Top 分位损失引入 RankIC 框架，构造更契合纯多头策略的优化目标。这一方向的初步实验表明，仅关注多头选股的损失函数在指数增强组合上的绩效表现值得进一步深入研究。

（3） 换手惩罚项的自适应校准。本文中惩罚系数通过网格搜索确定，但最优惩罚系数可能与市场状态、选股域宽度及策略容量等因素有关。如何依据交易成本与预期收益的动态变化实现惩罚系数的自适应调节，是一个兼具理论价值与实践意义的研究问题。

5 风险提示

本报告基于历史数据分析，历史规律未来可能存在失效的风险；市场可能发生超预期变化；各驱动因子受环境影响可能存在阶段性失效的风险。

分析师声明

作者具有中国证券业协会授予的证券投资咨询执业资格，保证报告所采用的数据和信息均来自公开合规渠道，分析逻辑基于作者的职业理解，本报告清晰准确地反映了作者的研究观点，力求独立、客观和公正，结论不受任何第三方的授意或影响。研究报告对所涉及的证券或发行人的评价是分析师本人通过财务分析预测、数量化方法、或行业比较分析所得出的结论，但使用以上信息和分析方法存在局限性。特此声明。

免责声明

本研究报告由方正证券制作及在中国（香港和澳门特别行政区、台湾省除外）发布。根据《证券期货投资者适当性管理办法》，本报告内容仅供我公司适当性评级为 C3 及以上等级的投资者使用，本公司不会因接收人收到本报告而视其为本公司的当然客户。若您并非前述等级的投资者，为保证服务质量、控制风险，请勿订阅本报告中的信息，本资料难以设置访问权限，若给您造成不便，敬请谅解。
在任何情况下，本报告的内容不构成对任何人的投资建议，也没有考虑到个别客户特殊的投资目标、财务状况或需求，方正证券不对任何人因使用本报告所载任何内容所引致的任何损失负任何责任，投资者需自行承担风险。
本报告版权仅为方正证券所有，本公司对本报告保留一切法律权利。未经本公司事先书面授权，任何机构或个人不得以任何形式复制、转发或公开传播本报告的全部或部分内容，不得将报告内容作为诉讼、仲裁、传媒所引用之证明或依据，不得用于营利或用于未经允许的其它用途。如需引用、刊发或转载本报告，需注明出处且不得进行任何有悖原意的引用、删节和修改。

评级说明：

类别	评级	说明
公司评级	强烈推荐	分析师预测未来12个月内相对同期基准指数有20%以上的涨幅。
	推荐	分析师预测未来12个月内相对同期基准指数有10%以上的涨幅。
	中性	分析师预测未来12个月内相对同期基准指数在-10%和10%之间波动。
	减持	分析师预测未来12个月内相对同期基准指数有10%以上的跌幅。
行业评级	推荐	分析师预测未来12个月内行业表现强于同期基准指数。
	中性	分析师预测未来12个月内行业表现与同期基准指数持平。
	减持	分析师预测未来12个月内行业表现弱于同期基准指数。
基准指数说明		A股市场以沪深300 指数为基准；香港市场以恒生指数为基准，美股市场以标普500指数为基准。

方正证券研究所联系方式：

北京：朝阳区朝阳门南大街 10 号兆泰国际中心 A 座 17 层
上海：静安区延平路71号延平大厦2楼
深圳：福田区竹子林紫竹七道光大银行大厦31层
广州：天河区兴盛路12号楼隽峰苑2期3层方正证券
长沙：天心区湘江中路二段36号华远国际中心37层
网址：https://www.foundersc.com
E-mail：yjzx@foundersc.com